



Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias Físico Matemáticas

La regresión multivariada como marco estadístico para el
análisis conjunto de indicadores socioeconómicos: una
aplicación al Censo de Población y Vivienda 2020

Tesis presentada al

Colegio de Matemáticas

como requisito parcial para la obtención del grado de

Licenciado en Matemáticas Aplicadas

por

Israel Cervantes Juárez

Asesorado por

Dr. Bulmaro Juárez Hernández

Puebla Pue.
31 de mayo de 2026



Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias Físico Matemáticas

La regresión multivariada como marco estadístico para el
análisis conjunto de indicadores socioeconómicos: una
aplicación al Censo de Población y Vivienda 2020

Tesis presentada al

Colegio de Matemáticas

como requisito parcial para la obtención del grado de

Licenciado en Matemáticas Aplicadas

por

Israel Cervantes Juárez

Asesorado por

Dr. Bulmaro Juárez Hernández

Puebla Pue.
31 de mayo de 2026

Título: La regresión multivariada como marco estadístico para el análisis conjunto de indicadores socioeconómicos: una aplicación al Censo de Población y Vivienda 2020

Estudiante: ISRAEL CERVANTES JUÁREZ

COMITÉ

Dr. José Juan Castro Alva
Presidente

Dr. Fernando Velasco Luna
Secretario

Dr. Carlos Camilo Garay
Vocal

Dra. Hortensia Josefina Reyes Cervantes
Vocal

Dr. Bulmaro Juárez Hernández
Asesor

Agradecimientos

Resumen

Esta investigación implementa y aplica un modelo de regresión lineal multivariada para el análisis conjunto de indicadores de vulnerabilidad social a nivel municipal en México, empleando información del Censo de Población y Vivienda 2020 del INEGI; el objetivo central modela simultáneamente un sistema de variables respuesta interrelacionadas —incorporando explícitamente su estructura de dependencia— y supera las limitaciones de enfoques univariados independientes. El estudio se ancla en la formulación matricial $Y = XB + U$, con desarrollo de MCO, descomposición SSCP y pruebas multivariadas. La implementación se realizó en Python mediante álgebra lineal explícita —ante la ausencia de una librería multivariada adecuada— para garantizar correspondencia directa entre la formulación teórica y su ejecución numérica; la aplicación empírica se construye sobre una base municipal de $n = 2469$ unidades, integrando indicadores de rezago social como variables dependientes y un bloque de covariables demográficas, educativas y habitacionales. El coeficiente de determinación multivariado basado en la traza alcanza $R_{tr}^2 \approx 0.77$, con evidencia robusta del efecto global de las covariables mediante la traza de Pillai ($V_{Pillai} \approx 1.745$, $F_{Pillai} \approx 422.89$, $p < 0.0001$); el análisis espectral de la matriz $E^{-1}H$ revela una dimensión dominante en la estructura de dependencia, con eigenvalor principal cercano a 22.5 y correlación canónica asociada de aproximadamente 0.98. Una sola combinación lineal absorbe gran parte de la varianza conjunta. El sistema admite lectura sintética. El análisis identifica diferencias sustantivas en la capacidad explicativa entre componentes —ajustes elevados en dimensiones educativas y habitacionales, niveles menores de explicación en variables laborales, y persistencia de dependencia residual entre respuestas— que perfilan la asimetría interna del fenómeno; los hallazgos confirman la naturaleza intrínsecamente multidimensional del rezago social y respaldan el uso de la regresión lineal multivariada como herramienta adecuada para su análisis integrado, articulando teoría estadística, implementación computacional y evidencia empírica.

Índice general

Agradecimientos	v
1. Introducción	1
1.1. Planteamiento del problema	1
1.2. Justificación	2
1.3. Objetivos	2
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
1.4. Alcance del estudio	3
1.5. Estructura del documento	3
2. Marco Teórico	5
2.1. Fundamentos matemáticos del análisis multivariado	5
2.1.1. Vectores, matrices y producto interno	5
2.1.2. Rango, independencia lineal e invertibilidad	6
2.1.3. Traza, determinante y matrices simétricas	6
2.1.4. Matrices definidas positivas y formas cuadráticas	7
2.1.5. Descomposición espectral	7
2.1.6. Espacios columna y proyecciones ortogonales	7
2.1.7. Norma de Frobenius y aproximación matricial	9
2.1.8. Operador vec y producto de Kronecker	9
2.2. Vectores aleatorios multivariados y estructura de covarianza	9
2.2.1. Vector de medias y matriz de covarianza	10
2.2.2. Transformaciones lineales	10
2.2.3. Estructura de muestras multivariadas	11
2.2.4. Media muestral	12
2.2.5. Matriz de dispersión muestral	13
2.2.6. Estructura de dependencia	13
2.3. Distribución normal multivariada	14
2.3.1. Definición y propiedades básicas	14
2.3.2. Caracterización mediante transformaciones lineales	14
2.3.3. Forma cuadrática y distribución χ^2	15
2.3.4. Combinaciones lineales	16
2.3.5. Marginales y distribución condicional	16
2.3.6. Independencia y covarianza	17
2.3.7. Distribución normal matricial	17
2.3.8. Muestras normales	18
2.4. Distribución Wishart y matrices de dispersión	18
2.4.1. Definición de la Wishart	18
2.4.2. Relación con la chi-cuadrada	19

2.4.3.	Propiedades fundamentales	19
2.4.4.	Matriz de covarianza muestral	20
2.4.5.	Estructura espectral	22
2.4.6.	Distribución de submatrices	22
2.4.7.	La Wishart en el modelo lineal multivariado	22
2.4.8.	Matrices de suma de cuadrados y productos cruzados	23
2.5.	Modelo lineal multivariado	24
2.5.1.	Interpretaciones equivalentes del modelo	24
2.5.2.	Supuestos del modelo	25
2.5.3.	Formulación vectorizada	25
2.5.4.	Estimación por mínimos cuadrados	26
2.5.5.	Propiedades del estimador	27
2.5.6.	Interpretación geométrica	28
2.5.7.	Relación con la estimación por máxima verosimilitud	28
2.5.8.	Matriz de residuos y estimación de Σ	29
2.5.9.	Descomposición de la variabilidad	29
2.5.10.	Optimalidad del estimador	30
2.6.	Inferencia en el modelo lineal multivariado	31
2.6.1.	Hipótesis lineales generales	31
2.6.2.	Contraste global del modelo: el caso $D = 0$	31
2.6.3.	Construcción de las matrices de hipótesis y error	31
2.6.4.	Distribución de H y E	32
2.6.5.	Estructura espectral del problema inferencial	33
2.6.6.	Estadísticos de prueba clásicos	33
2.6.7.	Región de rechazo	34
2.6.8.	Regiones de confianza simultáneas	34
2.6.9.	Invarianza	35
2.7.	Diagnóstico del modelo lineal multivariado	35
2.7.1.	Matriz de residuos	35
2.7.2.	Normalidad multivariada	36
2.7.3.	Homocedasticidad e independencia	36
2.7.4.	Observaciones influyentes	36
2.7.5.	Residuos estandarizados	37
3.	Implementación computacional del modelo	39
3.1.	Arquitectura del sistema	39
3.1.1.	Funciones auxiliares	41
3.2.	Preparación de la base analítica	41
3.2.1.	Lectura, validación y depuración inicial	41
3.2.2.	Construcción de variables analíticas	42
3.2.3.	Transformación y estandarización	42
3.2.4.	Controles numéricos	42
3.3.	Estimación y descomposición SSCP	43
3.3.1.	Descomposición centrada de la variabilidad	43
3.4.	Inferencia multivariada	44
3.4.1.	Contraste global del modelo	44
3.4.2.	Pruebas individuales por variable explicativa	44
3.5.	Análisis de residuales y detección de observaciones atípicas	45
3.5.1.	Distancias de Mahalanobis y coeficientes de Mardia	46
3.5.2.	Apalancamiento y distancia de Cook	46
3.5.3.	Prueba de homocedasticidad	47
3.6.	Análisis canónico	47

3.6.1. Resolución del problema de valores propios generalizado	47
3.6.2. Cargas canónicas relativas	47
3.7. Visualización de resultados	47
4. Aplicación del modelo al Censo de Población y Vivienda 2020	49
4.1. Fuente de información	49
4.2. Unidad de análisis y delimitación territorial	49
4.3. Construcción de la base analítica	50
4.4. Universos de referencia y denominadores	50
4.5. Especificación empírica del sistema de variables	51
4.5.1. Variables respuesta	51
4.5.2. Variables explicativas	52
4.6. Criterios de selección de variables	52
4.7. Transformaciones previas al análisis	54
5. Resultados	57
5.1. Ajuste global del modelo	57
5.1.1. Descomposición matricial de la variabilidad	57
5.1.2. Magnitud del ajuste conjunto	58
5.1.3. Pruebas globales de significancia multivariada	59
5.1.4. Matriz de covarianza residual y dependencia remanente	60
5.2. Análisis de los coeficientes y contribución de las covariables	60
5.2.1. Jerarquía explicativa por pruebas parciales multivariadas	61
5.2.2. Distribución de efectos por respuesta y patrones de signo	63
5.2.3. Colinealidad sustantiva y lectura de efectos parciales	65
5.3. Estructura canónica del modelo	66
5.3.1. Problema espectral del modelo	66
5.3.2. Correlaciones canónicas y fuerza de asociación	66
5.3.3. Normalización canónica y matriz de coeficientes	67
5.3.4. Primera dirección canónica: eje educativo	68
5.3.5. Segunda dirección canónica: contraste educación-vivienda	68
5.3.6. Tercera dirección canónica: eje cognitivo	68
5.3.7. Cuarta dirección canónica: contraste laboral-cognitivo	69
5.3.8. Representación geométrica del espacio canónico	69
5.4. Diagnóstico del modelo y evaluación de supuestos	71
5.4.1. Normalidad multivariada de los residuos	71
5.4.2. Estructura residual y diagnóstico de heterocedasticidad	72
5.4.3. Correlación residual remanente	74
5.4.4. Observaciones influyentes y geometría del espacio explicativo	74
5.4.5. Evaluación integrada del diagnóstico	76
6. Conclusiones	79
6.1. Síntesis de hallazgos	79
6.2. Aportaciones del estudio	79
6.3. Limitaciones y consideraciones diagnósticas	80
6.4. Recomendaciones para investigaciones futuras	80
A. Acceso al código fuente	81
Bibliografía	83

Índice de tablas

2.1. Aproximaciones a la distribución F para los estadísticos multivariados clásicos. . .	34
3.1. Correspondencia entre celdas de código y matrices del modelo.	41
4.1. Universos de referencia utilizados en la construcción de indicadores.	51
4.2. Variables dependientes del modelo.	52
4.3. Variables independientes del modelo.	52
5.1. Descomposición de la diagonal principal $T = H + E$ y varianza explicada por dimensión.	58
5.2. Estadísticos escalares de ajuste del modelo multivariado basados en la traza. . . .	59
5.3. Estadísticos de prueba para la significancia global del modelo multivariado.	59
5.4. Pruebas parciales tipo III por covariable, ordenadas por traza de Pillai.	62
5.5. Valores propios de la matriz $E^{-1}H$ y varianza relativa explicada.	66
5.6. Correlaciones canónicas asociadas a cada dirección.	67
5.7. Pruebas de normalidad multivariada de Mardia sobre los residuos.	72
5.8. Diagnóstico auxiliar de heterocedasticidad multivariada.	73

Índice de figuras

3.1. Esquema del procedimiento algorítmico de estimación multivariada.	40
4.1. Mapa de calor de correlaciones entre covariables explicativas.	53
4.2. Distribución empírica de las variables transformadas (parte 1).	55
4.3. Distribución empírica de las variables transformadas (parte 2).	56
5.1. Contribución marginal de cada covariable (traza de Pillai).	62
5.2. Valor absoluto de los coeficientes canónicos para cada dirección.	67
5.3. Municipios en el subespacio canónico tridimensional.	70
5.4. Proyecciones bidimensionales sobre los planos canónicos.	70
5.5. Gráfico Q-Q de la distancia de Mahalanobis residual.	72
5.6. Residuos estandarizados frente a valores ajustados, por variable respuesta.	73
5.7. Leverage frente a la distancia de Mahalanobis sobre la matriz de covariables X	75
5.8. Distancia de Cook multivariada frente al leverage.	75
5.9. Distancia de Mahalanobis residual frente al leverage.	76

Capítulo 1

Introducción

Analizar la marginación social con información territorial agregada exige distinguir entre el comportamiento individual de cada indicador y su comportamiento conjunto cuando todos se observan sobre la misma unidad de análisis. Las variables no son piezas independientes, están correlacionadas entre sí porque miden facetas del mismo fenómeno y por eso conviene tratarlas conjuntamente, no por separado. Analfabetismo en mayores de 15 años, desocupación laboral, limitaciones funcionales, ausencia de servicios básicos en la vivienda, cada una cuenta una parte distinta del rezago. El hecho de que todas se agreguen al mismo municipio hace estadísticamente esperable que aparezcan interdependencias no triviales entre ellas, así que ignorar esa estructura de correlación, como ocurre al ajustar modelos univariados independientes, descarta información relevante del fenómeno [1].

La información utilizada proviene del Censo de Población y Vivienda 2020, levantado por el Instituto Nacional de Estadística y Geografía [2]. A partir de los registros agregados a nivel municipal se construyeron indicadores proporcionales, es decir tasas, razones y porcentajes, con el fin de hacer comparables municipios con poblaciones y dinámicas radicalmente distintas no tiene sentido sin alguna normalización previa. Esa base, ya procesada, es la que alimenta las matrices de variables respuesta y de covariables que el modelo multivariado necesita.

La elección de un modelo multivariado responde a la naturaleza del problema. Cada municipio reporta al mismo tiempo un conjunto de indicadores de rezago social que ya se sabe de antemano que están correlacionados entre sí, así que las variables respuesta se organizan en una matriz Y que se vincula con un mismo bloque de covariables sociodemográficas a través de una matriz de coeficientes B . Lo que se gana con esta especificación es la preservación íntegra de la estructura de dependencia entre respuestas, ya que estimar el sistema de manera conjunta obliga a modelar de forma explícita la varianza no explicada mediante una matriz de covarianzas residuales. De ahí que se analice la vulnerabilidad como lo que es, un objeto multidimensional, y se evadan de paso los defectos estadísticos que aparecen al correr regresiones lineales ordinarias por separado, una por respuesta [3–5].

1.1. Planteamiento del problema

El núcleo estadístico de esta tesis se reduce en el fondo a una pregunta de representación, ¿cómo conviene modelar las distintas dimensiones del rezago social a nivel municipal? Resumir todo en un único índice escalar produce una cifra fácil de comunicar, pero se pierde información sobre la magnitud y dirección particular de cada carencia, y esa pérdida no se recupera después. La salida opuesta, que sería ajustar una regresión univariada por cada respuesta, conserva la interpretación marginal de los efectos, pero arrastra un costo silencioso: la correlación entre los residuales de las distintas ecuaciones se asume inexistente cuando casi nunca lo es. Esta tesis se mueve por un camino

intermedio, conserva la dimensionalidad original del vector de respuestas y estima sus parámetros de forma simultánea en un único sistema matricial.

Cuando se trabaja con agregados censales territoriales, este enfoque tiene su justificación observacional más clara. Los indicadores de capital humano, mercado laboral, vivienda y demografía se distribuyen a nivel nacional de manera muy desigual, las condiciones de rezago tienden a acumularse sobre los mismos municipios y eso configura una dependencia que sólo el tratamiento conjunto puede capturar bien. El propósito analítico va más allá de elegir covariables pertinentes para cada indicador, también busca evaluar si la formulación multivariada proporciona una caracterización más informativa del rezago social al incorporar explícitamente la dependencia entre respuestas.

De ahí surge la pregunta central de la investigación:

¿Qué información estadística adicional se obtiene al estimar conjuntamente los indicadores de rezago social municipal mediante un modelo de regresión lineal multivariada, en comparación con el ajuste aislado de modelos univariados independientes?

1.2. Justificación

Concebir cada municipio como un vector de observaciones sobre múltiples atributos sociales lleva casi de forma natural a una formulación matricial que ligue ese vector de respuestas con un bloque común de covariables. La ganancia es directa, se obtiene un andamiaje analítico riguroso que rebasa los límites del análisis univariado y habilita la inferencia simultánea anclada en matrices de sumas de cuadrados y productos cruzados, tanto de hipótesis como de error [3–5].

En el terreno aplicado, este trabajo entrega una lectura cuantitativa de la marginación regional, aunque hay una cautela que conviene marcar de entrada. La inferencia estadística y las conclusiones que de ella se desprendan son válidas únicamente a nivel municipal, así que toda extrapolación que pretenda inferir conductas de individuos u hogares particulares, incurriendo en la conocida falacia ecológica, queda fuera del alcance metodológico legítimo del trabajo. La razón es simple, los datos censales miden lo que pasa entre municipios, no lo que pasa dentro de cada hogar. El modelo sirve para estimar esas relaciones territoriales, no para hablar de causas a nivel persona.

Hay una dimensión adicional que conviene subrayar: la implementación computacional. La estimación de parámetros se programó a partir de operaciones algebraicas básicas, sin delegar el ajuste a rutinas multivariadas de alto nivel. Aunque Python dispone de herramientas parciales para modelos con varias respuestas, no se identificó una librería estándar que implementara de forma integrada y transparente el flujo requerido en esta tesis: estimación de $\hat{B}$, matrices SSCP, estadísticos multivariados, pruebas parciales, diagnóstico residual y análisis canónico. Por ello, cada etapa se tradujo directamente desde su formulación matricial al código, conservando una correspondencia verificable entre teoría matemática, implementación computacional y datos empíricos.

1.3. Objetivos

1.3.1. Objetivo general

Especificar, desarrollar la implementación computacional y estimar un modelo de regresión lineal multivariada para analizar, a nivel de municipio, la relación conjunta entre múltiples variables de rezago social y un conjunto de variables explicativas derivadas del Censo de Población y Vivienda 2020 [2].

1.3.2. Objetivos específicos

1. Formalizar la teoría matemática del modelo de regresión lineal multivariada y establecer explícitamente sus supuestos estadísticos.

2. Construir las matrices de datos Y y X , generando indicadores censales en forma de tasas o proporciones que permitan su comparabilidad espacial.
3. Programar el código para calcular el estimador de mínimos cuadrados de la matriz de coeficientes $\hat{B}$ empleando operaciones directas de álgebra lineal en el lenguaje Python.
4. Calcular computacionalmente las matrices de sumas de cuadrados y productos cruzados de la regresión, del error y totales, indispensables para las pruebas de hipótesis conjuntas.
5. Evaluar la bondad de ajuste del modelo analizando la matriz de covarianzas residuales, detectando observaciones atípicas o influyentes y llevando a cabo la verificación de supuestos.
6. Interpretar los coeficientes estimados y su significancia estadística para caracterizar la asociación empírica entre las covariables demográficas y las dimensiones de vulnerabilidad en los municipios.

1.4. Alcance del estudio

El análisis utiliza exclusiva de información de corte transversal sacada del Censo de Población y Vivienda 2020 [2], con el municipio como unidad espacial de observación. Esa elección implicó un filtrado severo, así que quedaron fuera de manera sistemática los registros correspondientes a totales nacionales, resúmenes estatales, localidades sub-municipales y clasificaciones no especificadas, es decir cualquier cosa que rompiera la comparabilidad horizontal de la base.

El marco metodológico se restringe al modelo de regresión lineal multivariada clásico. No se incorpora modelación explícita de autocorrelación espacial, ni estimación bayesiana, ni relaciones estocásticas no lineales, ni modelos de variables latentes. La delimitación responde a un propósito concreto, ver empíricamente si la formulación matricial lineal tradicional rinde un ajuste suficiente para describir el comportamiento conjunto del rezago frente a las covariables explicativas. Los resultados entonces cuantifican covariación estadística entre variables observadas, no avalan determinismos y tampoco aspiran a establecer relaciones causales sobre la población individual.

La implementación computacional se mueve bajo dos imperativos, reproducibilidad y congruencia estricta con la teoría estadística. Cada transformación requerida se formula matricialmente y se traduce de forma explícita al código fuente, así que se preserva la trazabilidad de extremo a extremo del proceso numérico, desde la depuración de las bases y la normalización de los indicadores, pasando por la estimación algebraica de los residuales, hasta la verificación de supuestos y el cómputo de la significancia conjunta.

1.5. Estructura del documento

El documento se reparte en seis capítulos consecutivos. El Capítulo 2 sienta los cimientos matemáticos de la regresión multivariada, introduce la notación matricial, los supuestos del modelo, la derivación del estimador de mínimos cuadrados y la teoría de pruebas de hipótesis simultáneas. El Capítulo 3 aborda la implementación computacional, documentando la programación en Python de las operaciones de álgebra lineal requeridas. El Capítulo 4 desmenuza la estructuración de la matriz de datos censal, justificando la selección de covariables explicativas y el cómputo de los indicadores municipales. El Capítulo 5 despliega los resultados empíricos, es decir los coeficientes estimados, los valores propios asociados a los estadísticos de prueba y una evaluación exhaustiva de la varianza residual con miras a la verificación de supuestos. El Capítulo 6 cierra el trabajo con las conclusiones, expone las limitaciones analíticas identificadas y delinea posibles extensiones del estudio para investigación futura.

Capítulo 2

Marco Teórico

2.1. Fundamentos matemáticos del análisis multivariado

Formular un modelo de regresión lineal con múltiples respuestas obliga, casi por necesidad, a representar datos, parámetros, métricas de variabilidad y transformaciones lineales en notación matricial. La razón es operativa, no estética. Esa representación abre la puerta a leer el modelo en clave geométrica —proyecciones ortogonales, subespacios vectoriales, formas cuadráticas—, que es el lenguaje natural de la teoría estadística multivariada [4].

Definición 2.1 (Modelo lineal multivariado). Se define el modelo lineal multivariado mediante la relación

$$Y = XB + U,$$

en la cual $Y \in \mathbb{R}^{n \times p}$ contiene las variables respuesta observadas, $X \in \mathbb{R}^{n \times q}$ representa la matriz de covariables explicativas, $B \in \mathbb{R}^{q \times p}$ es la matriz de parámetros a estimar, y $U \in \mathbb{R}^{n \times p}$ denota los errores aleatorios del modelo.

Tratar este sistema con rigor exige herramientas de tres frentes: álgebra lineal, geometría en espacios euclidianos y probabilidad multidimensional [5]. Antes de meterse con inferencia y estimación, conviene asentar los cimientos.

2.1.1. Vectores, matrices y producto interno

Sea $\mathbb{R}^p$ el espacio euclidiano real de dimensión p . Para todo par $x, y \in \mathbb{R}^p$, el producto interno canónico se define como

$$\langle x, y \rangle = x' y,$$

el cual induce la norma euclidiana

$$\|x\| = (x' x)^{1/2}.$$

Dos vectores son ortogonales cuando su producto interno se anula —es decir, $x' y = 0$. Cada observación con p variables se representa matricialmente como un vector columna

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p,$$

mientras que el conjunto empírico de n observaciones se organiza disponiendo cada vector transpuesto como una fila dentro de una matriz

$$\mathcal{X} = \begin{pmatrix} x'_1 \\ x'_2 \\ \vdots \\ x'_n \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

Esta representación admite dos lecturas geométricas. Son equivalentes pero conceptualmente distintas —o bien n puntos viviendo en $\mathbb{R}^p$, o bien p vectores tendidos sobre $\mathbb{R}^n$; la equivalencia no es un detalle decorativo, sostiene todo el análisis posterior sobre dependencia lineal y proyecciones ortogonales en la estimación [6]. Dos miradas, un mismo objeto.

2.1.2. Rango, independencia lineal e invertibilidad

Proposición 2.2. Sea $X \in \mathbb{R}^{n \times q}$. Si

$$\text{rang}(X) = q,$$

entonces sus columnas son linealmente independientes y la matriz $X'X$ es simétrica, definida positiva e invertible.

Demostración. La condición $\text{rang}(X) = q$ indica que las q columnas de la matriz son linealmente independientes. La simetría de $X'X$ se comprueba directamente mediante la propiedad de la transpuesta:

$$(X'X)' = X'X.$$

Para demostrar que $X'X$ es definida positiva, sea un vector $z \in \mathbb{R}^q$ tal que $z \neq 0$. Se obtiene que:

$$z'(X'X)z = (Xz)'(Xz) = \|Xz\|^2.$$

Dado que las columnas de X son linealmente independientes, el sistema homogéneo $Xz = 0$ solo admite la solución trivial $z = 0$. Se sigue entonces que para $z \neq 0$, se tiene $Xz \neq 0$, lo que implica que

$$\|Xz\|^2 > 0.$$

En consecuencia, la forma cuadrática $z'(X'X)z$ es estrictamente mayor que cero para todo vector no nulo, demostrando que la matriz es definida positiva. La invertibilidad es consecuencia directa de esta propiedad. Si $X'X$ fuera singular, existiría un vector $z \neq 0$ tal que $(X'X)z = 0$. Al premultiplicar por z' , se obtendría $z'(X'X)z = 0$, lo cual contradice el hecho de que la matriz es estrictamente definida positiva. Por consiguiente, la matriz inversa $(X'X)^{-1}$ existe. $\square$

El supuesto de rango completo no es una condición necesaria del modelo; sin él, la regresión lineal pierde sentido —los parámetros dejan de ser estimables y el estimador de mínimos cuadrados carece de solución única [7].

2.1.3. Traza, determinante y matrices simétricas

Una matriz cuadrada $A \in \mathbb{R}^{p \times p}$ es simétrica si coincide con su transpuesta,

$$A' = A.$$

Esta estructura aparece con frecuencia en estadística multivariada: matrices de covarianzas, matrices de sumas de cuadrados y productos cruzados [4]. El operador traza recoge la suma de la diagonal principal,

$$\text{tr}(A) = \sum_{i=1}^p a_{ii},$$

y el determinante se anota como $|A|$. Una propiedad útil de la traza es su invarianza bajo permutaciones cíclicas,

$$\text{tr}(AB) = \text{tr}(BA).$$

El determinante, por su parte, admite una lectura geométrica nítida —representa el factor de cambio de volumen que induce la transformación lineal asociada a A [8].

2.1.4. Matrices definidas positivas y formas cuadráticas

Definición 2.3. Una matriz simétrica $A \in \mathbb{R}^{p \times p}$ es definida positiva si

$$x'Ax > 0 \quad \text{para todo } x \neq 0.$$

Si se cumple la condición $x'Ax \geq 0$, la matriz se clasifica como semidefinida positiva.

Estas matrices son piezas centrales para modelar la varianza residual multivariada. Toda matriz de covarianzas, por construcción, es simétrica y al menos semidefinida positiva; cuando las explicativas no exhiben colinealidad exacta, la condición se endurece a definida positiva [5]. La función escalar

$$Q(x) = x'Ax$$

recibe el nombre de forma cuadrática. Aparece —y este es el punto— tanto en la función a minimizar del estimador MCO como en el exponente de la densidad normal multivariada. Si A es definida positiva, el conjunto

$$\{x \in \mathbb{R}^p : x'Ax \leq c\}$$

describe un elipsoide centrado en el origen. La orientación y la longitud de sus ejes principales quedan fijadas por los valores y vectores propios de A [8].

2.1.5. Descomposición espectral

Teorema 2.4 (Descomposición espectral). *Toda matriz simétrica $A \in \mathbb{R}^{p \times p}$ puede factorizarse como*

$$A = P\Lambda P',$$

donde P es una matriz ortogonal y $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ es una matriz diagonal que contiene los valores propios de A .

Esta factorización permite expresar traza y determinante usando únicamente los valores propios:

$$\text{tr}(A) = \sum_{i=1}^p \lambda_i, \quad |A| = \prod_{i=1}^p \lambda_i.$$

Una matriz simétrica resulta ser definida positiva si y solo si todos sus valores propios son estrictamente positivos. En el análisis de matrices de covarianzas, los vectores propios marcan las direcciones de máxima variabilidad en los datos; los valores propios miden la varianza a lo largo de esas direcciones [4].

2.1.6. Espacios columna y proyecciones ortogonales

Para una matriz de diseño $X \in \mathbb{R}^{n \times q}$ de rango completo, el espacio columna generado por sus vectores se define como

$$\mathcal{C}(X) = \{Xb : b \in \mathbb{R}^q\}.$$

Proposición 2.5. *La matriz*

$$P_X = X(X'X)^{-1}X'$$

es un proyector ortogonal, lo cual implica que es idempotente y simétrica:

$$P_X^2 = P_X, \quad P_X' = P_X.$$

Demostración. Para verificar que P_X es una matriz de proyección ortogonal, se comprueba su idempotencia y simetría. Para la idempotencia, se calcula P_X^2 :

$$P_X^2 = (X(X'X)^{-1}X')(X(X'X)^{-1}X').$$

Aplicando la propiedad asociativa del producto matricial:

$$P_X^2 = X(X'X)^{-1}(X'X)(X'X)^{-1}X'.$$

Como $(X'X)^{-1}(X'X) = I_k$, se obtiene

$$P_X^2 = X(X'X)^{-1}X' = P_X.$$

Para la simetría, se aplica la transpuesta al operador:

$$P_X' = (X(X'X)^{-1}X')'.$$

Utilizando la propiedad distributiva de la transpuesta $(ABC)' = C'B'A'$:

$$P_X' = (X')'((X'X)^{-1})'X'.$$

Sabiendo que $(X')' = X$ y que la inversa de una matriz simétrica es simétrica, es decir, $((X'X)^{-1})' = (X'X)^{-1}$, se tiene que:

$$P_X' = X(X'X)^{-1}X' = P_X.$$

Al verificarse las propiedades de simetría ($P_X' = P_X$) e idempotencia ($P_X^2 = P_X$), se concluye que la matriz es un proyector ortogonal. $\square$

La matriz complementaria

$$M_X = I_n - P_X$$

es el proyector ortogonal sobre el complemento ortogonal de $\mathcal{C}(X)$.

Corolario 2.6. *Toda matriz $Y \in \mathbb{R}^{n \times p}$ puede descomponerse de la forma*

$$Y = P_X Y + M_X Y,$$

donde $P_X Y \in \mathcal{C}(X)$ y $M_X Y$ pertenece a su complemento ortogonal.

Demostración. A partir de la definición de la matriz de proyección residual

$$M_X = I_n - P_X,$$

se establece la identidad matricial

$$P_X + M_X = I_n.$$

Postmultiplicando esta ecuación por la matriz Y , se obtiene

$$(P_X + M_X)Y = P_X Y + M_X Y = Y,$$

lo que establece la descomposición ortogonal del sistema. $\square$

La partición geométrica fundamenta la descomposición. Esta lectura es la base matemática para repartir las sumas de cuadrados al ajustar el modelo lineal [6]. Cada bloque tiene su rol.

2.1.7. Norma de Frobenius y aproximación matricial

Para una matriz $A \in \mathbb{R}^{m \times n}$, la norma de Frobenius se define como

$$\|A\|_F^2 = \text{tr}(A'A).$$

Definición 2.7. En el modelo lineal multivariado, el estimador de mínimos cuadrados se obtiene encontrando la matriz $\hat{B}$ que minimiza la norma de Frobenius de los residuales:

$$\hat{B} = \arg \min_{B \in \mathbb{R}^{q \times p}} \|Y - XB\|_F^2.$$

La norma de Frobenius extiende el criterio. Generaliza los mínimos cuadrados ordinarios al terreno multivariado —busca la mejor aproximación lineal de Y sobre el subespacio que generan las columnas de X [3]. Esa búsqueda define el estimador.

2.1.8. Operador vec y producto de Kronecker

Definición 2.8. El operador vec transforma una matriz en un vector columna apilando secuencialmente cada una de sus columnas. El producto de Kronecker entre dos matrices A y B se denota como $A \otimes B$.

Proposición 2.9. Si las dimensiones de las matrices son compatibles, se cumple la identidad

$$\text{vec}(ABC) = (C' \otimes A) \text{vec}(B).$$

Aplicando la vectorización a la ecuación poblacional del modelo lineal multivariado

$$Y = XB + U,$$

se obtiene el sistema equivalente

$$\text{vec}(Y) = (I_p \otimes X) \text{vec}(B) + \text{vec}(U).$$

La vectorización abre un cambio de representación. Esta reescritura convierte un problema matricial en uno vectorial de dimensión np ; el cambio facilita formular tanto la matriz de covarianzas residuales como las propiedades asintóticas de los estimadores [5]. Dos formulaciones del mismo modelo.

2.2. Vectores aleatorios multivariados y estructura de covarianza

El análisis multivariado descansa sobre la noción de vector aleatorio. La regresión lineal multivariada se aparta del caso univariado en un punto medular: asume que cada observación es un vector cuyas componentes —las distintas variables respuesta— exhiben una correlación estadística con estructura propia [5].

Definición 2.10 (Vector aleatorio multivariado). Dado un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, un vector aleatorio multivariado es una función medible

$$X : \Omega \rightarrow \mathbb{R}^p, \quad X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix},$$

cuyas componentes $X_1, \dots, X_p$ son variables aleatorias continuas reales.

Caracterizar la distribución conjunta de esas componentes pasa por dos objetos: el vector de esperanzas y la matriz de covarianzas cruzadas.

2.2.1. Vector de medias y matriz de covarianza

Definición 2.11 (Vector de medias y matriz de covarianza). Sea un vector aleatorio multivariado $X \in \mathbb{R}^p$. El vector de medias esperado es

$$\mu = \mathbb{E}(X) = \begin{pmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \\ \vdots \\ \mathbb{E}(X_p) \end{pmatrix} \in \mathbb{R}^p.$$

La matriz de covarianzas poblacional de X se define como

$$\Sigma = \text{Cov}(X) = \mathbb{E}[(X - \mu)(X - \mu)'] \in \mathbb{R}^{p \times p},$$

donde cada componente corresponde a la covarianza estadística

$$\sigma_{ij} = \text{Cov}(X_i, X_j) = \mathbb{E}[(X_i - \mu_i)(X_j - \mu_j)].$$

La matriz Σ es simétrica y semidefinida positiva. Se vuelve estrictamente definida positiva cuando ninguna combinación lineal de las variables aleatorias tiene varianza exactamente nula:

$$\text{Var}(a'X) > 0 \quad \text{para todo } a \neq 0.$$

Σ cumple un papel directo. Modela la dependencia estocástica conjunta entre las variables de respuesta [4]. No hay regresión multivariada sin ella.

2.2.2. Transformaciones lineales

Proposición 2.12. Sea $X \in \mathbb{R}^p$ un vector aleatorio poblacional con media μ y matriz de covarianzas Σ , y sea una matriz constante $A \in \mathbb{R}^{q \times p}$. La transformación lineal

$$Y = AX$$

presenta los siguientes momentos estadísticos:

$$\mathbb{E}(Y) = A\mu, \quad \text{Cov}(Y) = A\Sigma A'.$$

Para una transformación afín $Y = AX + b$, con $b \in \mathbb{R}^q$, la covarianza se mantiene invariante y el vector de medias cambia:

$$\mathbb{E}(Y) = A\mu + b, \quad \text{Cov}(Y) = A\Sigma A'.$$

Demostración. Aplicando las propiedades lineales de la esperanza matemática para $Y = AX$:

$$\mathbb{E}(Y) = \mathbb{E}(AX) = A\mathbb{E}(X) = A\mu.$$

Para obtener la matriz de covarianzas, se analiza la diferencia respecto a la media:

$$Y - \mathbb{E}(Y) = AX - A\mu = A(X - \mu).$$

Aplicando la definición de covarianza, se obtiene:

$$\text{Cov}(Y) = \mathbb{E}[(Y - \mathbb{E}(Y))(Y - \mathbb{E}(Y))'] = \mathbb{E}[A(X - \mu)(X - \mu)'A'].$$

Como A es una matriz constante determinística, se factoriza fuera del operador esperanza:

$$\text{Cov}(Y) = A \mathbb{E}[(X - \mu)(X - \mu)'] A' = A\Sigma A'.$$

Para el caso de la transformación con constante $Y = AX + b$, el valor esperado es

$$\mathbb{E}(Y) = \mathbb{E}(AX + b) = A\mu + b.$$

Dado que los vectores constantes se anulan al calcular la desviación respecto a la media:

$$Y - \mathbb{E}(Y) = (AX + b) - (A\mu + b) = A(X - \mu),$$

la matriz de covarianzas no se altera y resulta en:

$$\text{Cov}(Y) = A\Sigma A'.$$

□

Medias y covarianzas se comportan de manera predecible bajo transformaciones afines. Ese comportamiento es la base que habilita —más adelante en el desarrollo— evaluar proyecciones de residuales en la inferencia multivariada [5]. La estructura algebraica se preserva.

Corolario 2.13. *Para cualquier vector constante $a \in \mathbb{R}^p$, la varianza poblacional de la combinación lineal $a'X$ es*

$$\text{Var}(a'X) = a'\Sigma a.$$

Demostración. Definiendo la matriz $A = a'$ (un vector fila) y aplicando la proposición anterior, la covarianza se define como

$$\text{Cov}(a'X) = a'\Sigma(a')'.$$

Dado que $(a')' = a$, y que para un escalar la covarianza es equivalente a la varianza, se obtiene que

$$\text{Var}(a'X) = a'\Sigma a.$$

□

2.2.3. Estructura de muestras multivariadas

Considérese una muestra aleatoria de vectores

$$X_1, \dots, X_n \in \mathbb{R}^p,$$

constituida por observaciones independientes e idénticamente distribuidas, con parámetros poblacionales

$$\mathbb{E}(X_i) = \mu, \quad \text{Cov}(X_i) = \Sigma.$$

Los datos empíricos se organizan en la matriz observacional

$$\mathcal{X} = \begin{pmatrix} X_1' \\ X_2' \\ \vdots \\ X_n' \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

La independencia entre municipios convive con dependencia interna. La covarianza cero entre filas (unidades censales distintas) refleja muestreo independiente, mientras que las columnas —las distintas variables de rezago— conservan la dependencia que codifica Σ . Filas independientes, columnas no.

Proposición 2.14. *Si las observaciones censales son estadísticamente independientes, la matriz de covarianzas de la matriz vectorizada es*

$$\text{Cov}(\text{vec}(\mathcal{X})) = \Sigma \otimes I_n.$$

Demostración. El operador vec apila las columnas de la matriz observacional. Denotando por $X^{(j)} \in \mathbb{R}^n$ la j -ésima columna de $\mathcal{X}$ —el vector que recoge la j -ésima componente observada en cada uno de los n municipios—, la vectorización se escribe

$$\text{vec}(\mathcal{X}) = \begin{pmatrix} X^{(1)} \\ X^{(2)} \\ \vdots \\ X^{(p)} \end{pmatrix} \in \mathbb{R}^{np}.$$

La matriz $\text{Cov}(\text{vec}(\mathcal{X}))$ es de dimensión $np \times np$ y se descompone en $p \times p$ bloques de tamaño $n \times n$. El bloque (j, k) corresponde a $\text{Cov}(X^{(j)}, X^{(k)})$, cuya entrada (i, ℓ) es

$$\text{Cov}(X_{ij}, X_{\ell k}) = \begin{cases} 0, & i \neq \ell \quad (\text{independencia entre municipios}), \\ \Sigma_{jk}, & i = \ell \quad (\text{covarianza intramunicipal}). \end{cases}$$

En consecuencia, $\text{Cov}(X^{(j)}, X^{(k)}) = \Sigma_{jk} I_n$, y la matriz completa adopta la estructura por bloques

$$\text{Cov}(\text{vec}(\mathcal{X})) = \begin{pmatrix} \Sigma_{11}I_n & \Sigma_{12}I_n & \cdots & \Sigma_{1p}I_n \\ \Sigma_{21}I_n & \Sigma_{22}I_n & \cdots & \Sigma_{2p}I_n \\ \vdots & \vdots & \ddots & \vdots \\ \Sigma_{p1}I_n & \Sigma_{p2}I_n & \cdots & \Sigma_{pp}I_n \end{pmatrix},$$

expresión matricial que coincide exactamente con el producto de Kronecker $\Sigma \otimes I_n$. $\square$

El supuesto poblacional del modelo censal queda así sintetizado. La estructura describe independencia entre municipios y dependencia fija entre indicadores dentro de un mismo municipio [3]. Dos planos, una sola matriz.

2.2.4. Media muestral

Definición 2.15 (Media muestral). Dada una muestra aleatoria multivariada $X_1, \dots, X_n$, el estimador de la media muestral es el vector

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Los momentos asociados son:

$$\mathbb{E}(\bar{X}) = \mu, \quad \text{Cov}(\bar{X}) = \frac{1}{n} \Sigma.$$

Proposición 2.16. La media muestral $\bar{X}$ es un estimador insesgado de μ y su matriz de covarianzas poblacional es $\frac{1}{n} \Sigma$.

Demostración. La propiedad de estimador insesgado se verifica utilizando la linealidad del operador esperanza matemática:

$$\mathbb{E}(\bar{X}) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = \frac{1}{n} \sum_{i=1}^n \mu = \mu.$$

Para analizar la matriz de covarianzas, se calcula la desviación respecto a la media:

$$\bar{X} - \mu = \frac{1}{n} \sum_{i=1}^n (X_i - \mu),$$

y se determina la covarianza:

$$\text{Cov}(\bar{X}) = \mathbb{E}[(\bar{X} - \mu)(\bar{X} - \mu)'] = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n \mathbb{E}[(X_i - \mu)(X_j - \mu)'].$$

Por el supuesto de independencia estadística poblacional, la covarianza cruzada para índices distintos es nula,

$$\mathbb{E}[(X_i - \mu)(X_j - \mu)'] = 0 \quad \text{si } i \neq j.$$

Para los índices iguales, la covarianza corresponde al parámetro poblacional,

$$\mathbb{E}[(X_i - \mu)(X_i - \mu)'] = \Sigma.$$

La suma se reduce únicamente a los n términos donde $i = j$:

$$\text{Cov}(\bar{X}) = \frac{1}{n^2} \sum_{i=1}^n \Sigma = \frac{n\Sigma}{n^2} = \frac{1}{n} \Sigma.$$

□

El estimador muestral es insesgado. Su dispersión disminuye en proporción inversa al tamaño de la muestra [5]. Más datos, menor varianza.

2.2.5. Matriz de dispersión muestral

Para estimar la matriz de covarianzas poblacional se recurre a la matriz de sumas de cuadrados y productos cruzados centrada en la media:

$$S = \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})'.$$

Matricialmente, este estimador se reescribe como

$$S = (\mathcal{X} - \mathbf{1}\bar{X}')'(\mathcal{X} - \mathbf{1}\bar{X}'),$$

donde $\mathbf{1} \in \mathbb{R}^n$ es un vector columna de unos. Por construcción, la matriz S es simétrica y semidefinida positiva.

Definición 2.17 (Estimador muestral de la covarianza). El estimador insesgado de la matriz de covarianzas Σ se calcula como

$$\hat{\Sigma} = \frac{1}{n-1} S.$$

2.2.6. Estructura de dependencia

La matriz Σ condensa la dependencia estadística conjunta entre las variables respuesta. Hay cuatro lecturas que conviene tener presentes:

- Los elementos de la diagonal principal miden la varianza marginal intrínseca de cada indicador.
- Las covarianzas fuera de la diagonal cuantifican la asociación lineal cruzada entre distintos indicadores.
- Los vectores propios obtenidos de la descomposición de Σ establecen las direcciones de mayor dispersión empírica.

- La varianza de cualquier combinación lineal estimada depende directamente de la matriz cuadrática Σ .

Σ diagonal sería postular independencia total. En datos sociodemográficos y censales eso casi nunca se cumple —el modelo lineal multivariado estima Σ de forma explícita y esa matriz reaparece luego en el diagnóstico del ajuste y en la inferencia poblacional [4]. La dependencia es regla. La diagonal pura es ficción.

2.3. Distribución normal multivariada

Normalidad multivariada habilita el aparato inferencial completo. El supuesto permite derivar estadísticos exactos en los modelos de regresión, calcular pruebas de significancia para los coeficientes y caracterizar analíticamente las distribuciones de los residuales y sus varianzas [5]. Es el cimiento del régimen exacto.

2.3.1. Definición y propiedades básicas

Definición 2.18 (Distribución normal multivariada). Un vector aleatorio poblacional $X \in \mathbb{R}^p$ sigue una distribución normal multivariada paramétrica definida por su vector de medias $\mu \in \mathbb{R}^p$ y matriz de covarianzas $\Sigma \in \mathbb{R}^{p \times p}$ (simétrica y definida positiva), si su función de densidad es:

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)' \Sigma^{-1} (x - \mu) \right\}, \quad x \in \mathbb{R}^p.$$

La notación estándar para esta distribución es

$$X \sim N_p(\mu, \Sigma).$$

La densidad depende de la forma cuadrática

$$(x - \mu)' \Sigma^{-1} (x - \mu),$$

cuyas curvas de nivel son hiper-elipsoides centrados en μ y cuya forma queda determinada por Σ [4].

2.3.2. Caracterización mediante transformaciones lineales

Teorema 2.19. Considerando un vector normal estándar $Z \sim N_p(0, I_p)$. Para una matriz paramétrica definida positiva Σ existe una matriz no singular $\Sigma^{1/2}$ tal que

$$\Sigma = \Sigma^{1/2} (\Sigma^{1/2})'.$$

La transformación afín

$$X = \mu + \Sigma^{1/2} Z$$

sigue exactamente una distribución

$$X \sim N_p(\mu, \Sigma).$$

Inversamente, si $X \sim N_p(\mu, \Sigma)$, la estandarización lineal

$$Z = \Sigma^{-1/2} (X - \mu)$$

transforma los datos en un vector normal estándar $Z \sim N_p(0, I_p)$.

Demostración. Dado que Σ es simétrica y definida positiva, su descomposición espectral arroja P ortogonal y Λ diagonal con $\lambda_i > 0$, tal que

$$\Sigma = P\Lambda P'.$$

Al definir la matriz

$$\Sigma^{1/2} = P\Lambda^{1/2}P',$$

se verifica directamente que

$$\Sigma^{1/2}(\Sigma^{1/2})' = P\Lambda^{1/2}P'P\Lambda^{1/2}P' = P\Lambda P' = \Sigma.$$

Dado que todos los valores propios son estrictamente positivos, $\Sigma^{1/2}$ no es una matriz singular. Definiendo la variable aleatoria $X = \mu + \Sigma^{1/2}Z$. A partir de la transformación matemática,

$$X - \mu = \Sigma^{1/2}Z, \quad Z = \Sigma^{-1/2}(X - \mu).$$

El determinante del jacobiano de la transformación matemática es

$$\left| \det \left(\frac{\partial z}{\partial x} \right) \right| = |\Sigma^{-1/2}| = |\Sigma|^{-1/2}.$$

Considerando la densidad paramétrica de $Z \sim N_p(0, I_p)$,

$$f_Z(z) = \frac{1}{(2\pi)^{p/2}} \exp \left(-\frac{1}{2} z' z \right),$$

y sustituyendo la equivalencia $z = \Sigma^{-1/2}(x - \mu)$, se obtiene:

$$f_X(x) = f_Z(\Sigma^{-1/2}(x - \mu)) |\Sigma|^{-1/2} = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)' \Sigma^{-1} (x - \mu) \right\},$$

lo cual corresponde exactamente a la definición paramétrica de la distribución normal poblacional $N_p(\mu, \Sigma)$. Para la segunda implicación de la prueba, partiendo de $X \sim N_p(\mu, \Sigma)$ y aplicando el mapeo inverso

$$Z = \Sigma^{-1/2}(X - \mu)$$

se obtiene de forma analítica que el resultado distribuye estadísticamente como $Z \sim N_p(0, I_p)$. $\square$

La estandarización abre una vía operativa. Permite modelar variables censales interrelacionadas como composiciones lineales de proyecciones independientes [5]. El cambio de coordenadas separa la dependencia.

2.3.3. Forma cuadrática y distribución χ^2

Teorema 2.20. Si el vector poblacional sigue la distribución $X \sim N_p(\mu, \Sigma)$, entonces su proyección paramétrica cuadrática es

$$(X - \mu)' \Sigma^{-1} (X - \mu) \sim \chi_p^2.$$

Demostración. Sustituyendo la estandarización comprobada $Z = \Sigma^{-1/2}(X - \mu)$, que sigue una distribución $N_p(0, I_p)$, se tiene:

$$(X - \mu)' \Sigma^{-1} (X - \mu) = (X - \mu)' (\Sigma^{-1/2})' \Sigma^{-1/2} (X - \mu) = Z' Z.$$

Dado que los componentes del vector Z son variables estocásticas normales independientes, el resultado paramétrico equivale a una chi-cuadrada con grados de libertad proporcionales a p :

$$Z' Z = \sum_{i=1}^p Z_i^2 \sim \chi_p^2.$$

$\square$

La distancia de Mahalanobis ocupa un lugar natural. Esta relación la instala como la herramienta canónica para detectar observaciones atípicas multivariadas en la inferencia conjunta [3]. Es el detector estándar.

2.3.4. Combinaciones lineales

Proposición 2.21. *Para todo vector escalar paramétrico $a \in \mathbb{R}^p$, si $X \sim N_p(\mu, \Sigma)$, la distribución de la proyección lineal escalar es*

$$a'X \sim N(a'\mu, a'\Sigma a).$$

Demostración. Empleando el teorema de estandarización paramétrica poblacional $X = \mu + \Sigma^{1/2}Z$ con $Z \sim N_p(0, I_p)$, se establece la relación

$$a'X = a'\mu + a'\Sigma^{1/2}Z.$$

El primer término es la media determinista del vector. El segundo, $a'\Sigma^{1/2}Z$, es una combinación lineal de las componentes independientes de $Z \sim N_p(0, I_p)$ y por tanto sigue una distribución normal univariada. La esperanza poblacional paramétrica y la varianza son:

$$\mathbb{E}(a'X) = a'\mathbb{E}(X) = a'\mu, \quad \text{Var}(a'X) = a'\Sigma a.$$

□

Corolario 2.22. *Un vector poblacional aleatorio $X \in \mathbb{R}^p$ presenta una distribución paramétrica normal multivariada si y sólo si cualquier proyección analítica $a'X$ se distribuye como normal univariada.*

La caracterización sirve para validar empíricamente. Resulta útil en la práctica para verificar si los residuales censales se ajustan a un comportamiento gaussiano conjunto [5]. El supuesto se prueba con datos.

2.3.5. Marginales y distribución condicional

Al particionar las matrices:

$$X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix},$$

donde $X_1 \in \mathbb{R}^{p_1}$ y $X_2 \in \mathbb{R}^{p_2}$.

Proposición 2.23. *Asumiendo que la distribución poblacional es*

$$X \sim N_p(\mu, \Sigma),$$

se comprueban analíticamente las siguientes características:

1. *Marginalización paramétrica: El bloque X_1 distribuye según*

$$X_1 \sim N_{p_1}(\mu_1, \Sigma_{11}).$$

2. *Distribución condicional poblacional: La variable X_1 condicionada a $X_2 = x_2$ se parametriza por:*

$$X_1 | X_2 = x_2 \sim N_{p_1}(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}).$$

Las dos propiedades blindan el ajuste. Garantizan que el carácter gaussiano del modelo multivariado se conserva al trabajar con un subconjunto cualquiera de variables [4]. La marginalización no rompe la familia.

2.3.6. Independencia y covarianza

Proposición 2.24. *Bajo el supuesto paramétrico asintótico de normalidad multivariada, la covarianza estadística nula implica independencia. Si*

$$X \sim N_p(\mu, \Sigma)$$

y el componente poblacional cruzado cumple $\Sigma_{12} = 0$, las subvariables X_1 y X_2 son independientes paramétricamente.

Demostración. Sustituyendo el valor analítico $\Sigma_{12} = 0$ en los momentos condicionales probados previamente:

$$X_1 | X_2 = x_2 \sim N_{p_1}(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}).$$

Las equivalencias analíticas matemáticas se simplifican a:

$$\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2) = \mu_1, \quad \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = \Sigma_{11}.$$

Por lo que la variable asume el comportamiento marginal:

$$X_1 | X_2 = x_2 \sim N_{p_1}(\mu_1, \Sigma_{11}).$$

Al observarse que el comportamiento paramétrico estadístico no es afectado por x_2 , se obtiene que la probabilidad condicional empírica es equivalente a la marginal:

$$\mathcal{L}(X_1 | X_2 = x_2) = \mathcal{L}(X_1) \quad \forall x_2,$$

lo que garantiza matemáticamente la independencia asintótica paramétrica entre los bloques observacionales. $\square$

Covarianza nula implica independencia, propiedad exclusiva de la normalidad multivariada. Esa equivalencia resulta operativamente clave al validar supuestos residuales en la estimación [5]. Fuera de la normal, esa puerta se cierra.

2.3.7. Distribución normal matricial

Definición 2.25 (Distribución normal matricial). Se dice que una matriz aleatoria $Y \in \mathbb{R}^{n \times p}$ sigue una distribución normal matricial con parámetros $M \in \mathbb{R}^{n \times p}$, $\Omega \in \mathbb{R}^{n \times n}$ y $\Sigma \in \mathbb{R}^{p \times p}$, denotado como

$$Y \sim MN_{n,p}(M, \Omega, \Sigma),$$

si su vectorización sigue la distribución:

$$\text{vec}(Y) \sim N_{np}(\text{vec}(M), \Sigma \otimes \Omega).$$

Corolario 2.26. *Considerando el caso*

$$Y \sim MN_{n,p}(M, I_n, \Sigma),$$

las filas de Y son independientes y se distribuyen:

$$Y_{i\cdot} \sim N_p(m_i, \Sigma), \quad i = 1, \dots, n.$$

Demostración. Aplicando la definición de la matriz normal,

$$\text{vec}(Y) \sim N_{np}(\text{vec}(M), \Sigma \otimes I_n).$$

La estructura del producto de Kronecker $\Sigma \otimes I_n$ implica que la covarianza entre filas distintas es nula. En consecuencia, cada fila $Y_{i\cdot}$ conserva su propia distribución:

$$Y_{i\cdot} \sim N_p(m_i, \Sigma), \quad i = 1, \dots, n.$$

$\square$

La especificación fija la estructura de errores. Describe formalmente la matriz aleatoria sobre la que opera la estimación MCO [3]. Sin esa estructura no hay inferencia.

2.3.8. Muestras normales

Proposición 2.27. *Dado un conjunto de observaciones independientes $X_1, \dots, X_n$ que siguen $N_p(\mu, \Sigma)$, el modelo arroja:*

1. *El estimador de media empírico sigue:*

$$\bar{X} \sim N_p\left(\mu, \frac{1}{n}\Sigma\right).$$

2. *La matriz central de productos sigue una Wishart:*

$$\sum_{i=1}^n (X_i - \mu)(X_i - \mu)' \sim W_p(n, \Sigma).$$

3. *La media muestral y la matriz central son estadísticamente independientes:*

$$\bar{X} \perp S, \quad S = \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})'.$$

La independencia entre estimadores cierra el andamiaje. Localización y dispersión se separan limpiamente, resultado que consolida la base necesaria para derivar la teoría inferencial sobre matrices Wishart [5]. Dos estimadores, dos planos disjuntos.

2.4. Distribución Wishart y matrices de dispersión

La Wishart extiende la chi-cuadrada al terreno matricial. En pocas palabras: es la generalización de χ^2 al espacio de matrices simétricas semidefinidas positivas, y gobierna —en el análisis conjunto de estimadores— el comportamiento de las sumas de cuadrados y productos cruzados que aparecen en las proyecciones empíricas [4, 5]. Una distribución para matrices completas.

2.4.1. Definición de la Wishart

Definición 2.28 (Distribución Wishart). Sea un conjunto de observaciones independientes $X_1, \dots, X_n$ provenientes de $\mathcal{N}_p(0, \Sigma)$, con Σ definida positiva. La matriz central de productos [4]

$$S = \sum_{i=1}^n X_i X_i'$$

sigue la distribución Wishart con n grados de libertad y matriz de escala Σ . Se denota como

$$S \sim \mathcal{W}_p(n, \Sigma).$$

Si las observaciones se organizan en $X \in \mathbb{R}^{n \times p}$,

$$S = X'X \sim \mathcal{W}_p(n, \Sigma).$$

La familia Wishart es la herramienta natural. Modela los residuos multivariados en el ajuste de regresión. Encaja por construcción.

2.4.2. Relación con la chi-cuadrada

Proposición 2.29. *Cuando la dimensión se reduce al caso escalar ($p = 1$), la Wishart construida a partir de $X_i \sim \mathcal{N}(0, \sigma^2)$ se simplifica a:*

$$S = \sum_{i=1}^n X_i^2 \sim \sigma^2 \chi_n^2.$$

Demostración. Al fijar $p = 1$, el parámetro Σ se reduce a σ^2 . Estandarizando las variables como

$$X_i = \sigma Z_i, \quad Z_i \sim \mathcal{N}(0, 1).$$

Sustituyendo en la suma de cuadrados:

$$S = \sum_{i=1}^n X_i^2 = \sum_{i=1}^n (\sigma Z_i)^2 = \sigma^2 \sum_{i=1}^n Z_i^2.$$

La suma de cuadrados de normales estándar independientes sigue, por definición:

$$S \sim \sigma^2 \chi_n^2.$$

□

Queda confirmado el paralelismo dimensional. La Wishart generaliza —en el sentido matricial estricto— las sumatorias cuadráticas univariadas conocidas [5]. Misma estructura, dimensión mayor.

2.4.3. Propiedades fundamentales

Proposición 2.30. *Para una matriz $S \sim \mathcal{W}_p(n, \Sigma)$ se cumple:*

1. **Esperanza:**

$$\mathbb{E}(S) = n\Sigma.$$

2. **Escalamiento:** para toda proyección $A \in \mathbb{R}^{q \times p}$,

$$ASA' \sim \mathcal{W}_k(n, A\Sigma A').$$

3. **Adición:** Para matrices $S_1 \sim \mathcal{W}_p(n_1, \Sigma)$ y $S_2 \sim \mathcal{W}_p(n_2, \Sigma)$ independientes,

$$S_1 + S_2 \sim \mathcal{W}_p(n_1 + n_2, \Sigma).$$

4. **Invarianza ortogonal:** si se emplea una matriz ortogonal Q ($Q'Q = I$),

$$Q'SQ \sim \mathcal{W}_p(n, Q'\Sigma Q).$$

Demostración. Sea $X \in \mathbb{R}^{n \times p}$ tal que cada fila proviene de $\mathcal{N}_p(0, \Sigma)$. La matriz central de productos es

$$S = X'X = \sum_{i=1}^n X_i X_i'.$$

1. **Esperanza.** Aplicando la linealidad del operador esperanza:

$$\mathbb{E}(S) = \sum_{i=1}^n \mathbb{E}(X_i X_i').$$

Con centroide nulo, se deduce que $\mathbb{E}(X_i X_i') = \Sigma$. Por tanto:

$$\mathbb{E}(S) = \sum_{i=1}^n \Sigma = n\Sigma.$$

2. Escalamiento. Sea $Y_i = AX_i$. Como las combinaciones lineales de normales conservan su carácter gaussiano,

$$Y_i \sim \mathcal{N}_k(0, A\Sigma A').$$

Para el agregado:

$$ASA' = AX'XA' = (XA')'(XA') = \sum_{i=1}^n Y_i Y_i'.$$

Esta suma sigue, por la misma definición Wishart:

$$ASA' \sim \mathcal{W}_k(n, A\Sigma A').$$

3. Adición. Considérense $S_1 = X'X$ y $S_2 = Y'Y$ provenientes de $X \in \mathbb{R}^{n_1 \times p}$ e $Y \in \mathbb{R}^{n_2 \times p}$ sin covarianza cruzada y con distribución común $\mathcal{N}_p(0, \Sigma)$. El apilamiento

$$Z = \begin{pmatrix} X \\ Y \end{pmatrix} \in \mathbb{R}^{(n_1+n_2) \times p},$$

contiene $n_1 + n_2$ filas independientes. Por ende:

$$Z'Z = X'X + Y'Y = S_1 + S_2,$$

y la suma distribuye:

$$S_1 + S_2 \sim \mathcal{W}_p(n_1 + n_2, \Sigma).$$

4. Invarianza ortogonal. Se obtiene tomando $A = Q'$ en la propiedad de escalamiento:

$$Q'SQ \sim \mathcal{W}_p(n, Q'\Sigma Q).$$

□

Las propiedades de la Wishart sostienen el armado inferencial. Respaldan, desde su núcleo, la metodología de pruebas multivariadas basadas en sumas de cuadrados [4]. El soporte teórico queda en pie.

2.4.4. Matriz de covarianza muestral

Para una muestra $X_1, \dots, X_n \sim \mathcal{N}_p(\mu, \Sigma)$, con la media muestral

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

y la suma de productos centrada

$$S = \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})'.$$

Teorema 2.31. *Se verifica que:*

1. *La matriz centrada sigue:*

$$S \sim \mathcal{W}_p(n-1, \Sigma).$$

2. El estimador insesgado de la covarianza es:

$$\widehat{\Sigma} = \frac{1}{n-1} S, \quad \mathbb{E}(\widehat{\Sigma}) = \Sigma.$$

3. La media muestral y la matriz S son independientes:

$$\bar{X} \perp S.$$

Demostración. Considérese la representación matricial:

$$X = \begin{pmatrix} X'_1 \\ \vdots \\ X'_n \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

Para una muestra con distribución común $\mathcal{N}_p(\mu, \Sigma)$, la matriz X sigue:

$$X \sim \mathcal{MN}_{n,p}(\mathbf{1}\mu', I_n, \Sigma),$$

donde $\mathbf{1} \in \mathbb{R}^n$. Sea el proyector centralizador

$$M = I_n - \frac{1}{n} \mathbf{1}\mathbf{1}',$$

idempotente, con rango $n-1$, que anula al vector constante:

$$M\mathbf{1} = 0.$$

La suma de productos centrada se reescribe como

$$S = X'MX,$$

dado que $MX = X - \mathbf{1}\bar{X}'$ produce:

$$X'MX = (X - \mathbf{1}\bar{X}')'(X - \mathbf{1}\bar{X}') = \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})'.$$

Como la proyección elimina la media ($M(\mathbf{1}\mu') = 0$), la matriz centrada distribuye:

$$MX \sim \mathcal{MN}_{n,p}(0, M, \Sigma).$$

Por ser simétrica de rango $n-1$, existe una transformación ortogonal $Q \in \mathbb{R}^{n \times n}$ que la diagonaliza; se elige su última fila como $(1/\sqrt{n})\mathbf{1}'$ para alinearla con el espacio nulo de M (la dirección anulada por la centrada):

$$M = Q' \begin{pmatrix} I_{n-1} & 0 \\ 0 & 0 \end{pmatrix} Q.$$

Definiendo $Z = QX$, las primeras $n-1$ filas $Z_1, \dots, Z_{n-1}$ son combinaciones lineales centradas de las filas de X (ortogonales a la dirección de la media) y, por ortogonalidad de Q y normalidad de X , resultan independientes con distribución $\mathcal{N}_p(0, \Sigma)$; la última fila $Z_n = \sqrt{n}\bar{X}$ absorbe la media muestral y no interviene en S . Sustituyendo:

$$S = X'MX = Z' \begin{pmatrix} I_{n-1} & 0 \\ 0 & 0 \end{pmatrix} Z = \sum_{i=1}^{n-1} Z_i Z_i'.$$

En consecuencia, la matriz S sigue:

$$S \sim \mathcal{W}_p(n-1, \Sigma).$$

El sesgo del estimador se evalúa con la esperanza:

$$\mathbb{E}(\widehat{\Sigma}) = \mathbb{E}\left(\frac{1}{n-1}S\right) = \frac{1}{n-1}(n-1)\Sigma = \Sigma.$$

Para la independencia entre $\bar{X}$ y S , nótese que

$$\bar{X} = \frac{1}{n}\mathbf{1}'X.$$

El vector $\mathbf{1}$ y el proyector M son ortogonales — $\mathbf{1}$ reside en el espacio nulo de M —; por ello, los estimadores asociados se separan en componentes normales independientes:

$$\bar{X} \perp S.$$

□

La separación entre localización y dispersión es estructural. Esta dicotomía sostiene buena parte del modelado multivariado posterior [5]. Dos ejes de análisis disjuntos.

2.4.5. Estructura espectral

Proposición 2.32. Si $S \sim \mathcal{W}_p(n, \Sigma)$ con $n \geq p$, la matriz S es definida positiva, con descomposición espectral:

$$S = Q\Lambda Q',$$

donde Q es ortogonal y $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$.

La factorización entrega las direcciones principales. Sobre esas direcciones descansa la interpretación geométrica del análisis multivariado [4]. Los ejes son los autovectores.

2.4.6. Distribución de submatrices

Al particionar

$$S = \begin{pmatrix} S_{11} & S_{12} \\ S_{21} & S_{22} \end{pmatrix} \sim \mathcal{W}_p(n, \Sigma),$$

los bloques no son independientes entre sí. Las operaciones de condicionamiento, en cambio, preservan la estructura Wishart sobre las submatrices correspondientes [4].

2.4.7. La Wishart en el modelo lineal multivariado

Dado el modelo

$$Y = XB + U,$$

junto con el supuesto

$$U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma).$$

Teorema 2.33. Para este ajuste, la matriz residual

$$E = \widehat{U}'\widehat{U} = Y'(I_n - P_X)Y$$

se distribuye como

$$E \sim \mathcal{W}_p(n-q, \Sigma),$$

y existe independencia:

$$\widehat{B} \perp E.$$

Demostración. Como $(I_n - P_X)X = 0$, el proyector residual filtra el término sistemático:

$$(I_n - P_X)Y = (I_n - P_X)XB + (I_n - P_X)U = (I_n - P_X)U.$$

De ahí surge la forma cuadrática:

$$E = Y'(I_n - P_X)Y = U'(I_n - P_X)U.$$

El operador $(I_n - P_X)$ es simétrico, idempotente y de rango $n - q$. Bajo el supuesto

$$U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma),$$

su forma cuadrática distribuye:

$$(I_n - P_X)U \sim \mathcal{MN}_{n,p}(0, I_n - P_X, \Sigma).$$

Tomando la descomposición ortogonal:

$$I_n - P_X = Q' \begin{pmatrix} I_{n-q} & 0 \\ 0 & 0 \end{pmatrix} Q,$$

y aplicando el cambio $Z = QU$, resulta:

$$E = U'(I_n - P_X)U = Z' \begin{pmatrix} I_{n-q} & 0 \\ 0 & 0 \end{pmatrix} Z = \sum_{i=1}^{n-q} Z_i Z_i',$$

con Z_i independientes siguiendo $\mathcal{N}_p(0, \Sigma)$. El estimador residual distribuye:

$$E \sim \mathcal{W}_p(n - q, \Sigma).$$

La independencia entre $\hat{B}$ y E descansa en la ortogonalidad de los proyectores. El estimador

$$\hat{B} = (X'X)^{-1}X'Y,$$

depende de $P_X Y$; el operador E depende, en cambio, del componente ortogonal $(I_n - P_X)Y$. Bajo normalidad, dos formas asociadas a subespacios perpendiculares resultan estadísticamente independientes:

$$\hat{B} \perp E.$$

□

El resultado habilita el análisis de varianza conjunto. Sostiene el núcleo del andamiaje inferencial [3]. ANOVA multivariado descansa aquí.

2.4.8. Matrices de suma de cuadrados y productos cruzados

En regresión lineal multivariada aparecen dos formas cuadráticas matriciales centrales:

Definición 2.34 (Matrices SSCP). La matriz explicada por el modelo es

$$H = Y'P_X Y,$$

y la matriz residual es

$$E = Y'(I_n - P_X)Y.$$

Proposición 2.35. La descomposición de la suma de cuadrados total se expresa como

$$Y'Y = H + E.$$

Demostración. Usando la identidad

$$P_X + (I_n - P_X) = I_n,$$

la suma total se reescribe:

$$Y'Y = Y'I_nY = Y'(P_X + (I_n - P_X))Y.$$

Al distribuir:

$$Y'Y = Y'P_XY + Y'(I_n - P_X)Y = H + E.$$

□

Teorema 2.36. *Bajo normalidad multivariada, la matriz residual distribuye como*

$$E \sim \mathcal{W}_p(n - q, \Sigma),$$

y es independiente de H . Cuando también se cumple la hipótesis nula sobre los coeficientes:

$$H \sim \mathcal{W}_p(q, \Sigma).$$

Demostración. Ya se probó que $\hat{B}$ y E son independientes. Como

$$H = Y'P_XY$$

se origina en el espacio columna a través de P_XY , mientras que E lo hace en el complemento ortogonal $(I_n - P_X)Y$, la estructura gaussiana garantiza la independencia entre ambas:

$$H \perp E.$$

Para la distribución de H , nótese que $P_XY = XB + P_XU$. Cuando la componente sistemática XB se anula —escenario que corresponde a la hipótesis nula—, H se comporta como una Wishart central $\mathcal{W}_p(q, \Sigma)$. □

La partición matricial de la varianza es el pilar inferencial. Sobre ella se erige el análisis de hipótesis conjuntas en este marco [3, 4]. Sin partición, no hay prueba.

2.5. Modelo lineal multivariado

El modelo extiende la regresión múltiple clásica al caso de varias respuestas analizadas en paralelo. La ventaja teórico-metodológica radica en un solo punto —incorpora de forma explícita la correlación estadística entre dichas respuestas, esquivando las patologías que aparecen al estimar regresiones univariadas independientes una por una [3]. El salto es de fondo. La covarianza queda dentro del modelo.

Definición 2.37 (Modelo lineal multivariado). Sean $Y \in \mathbb{R}^{n \times p}$ la matriz de variables respuesta, $X \in \mathbb{R}^{n \times q}$ la matriz de covariables explicativas con rango completo q , y $B \in \mathbb{R}^{q \times p}$ la matriz de coeficientes poblacionales. El modelo lineal multivariado se define formalmente como

$$Y = XB + U,$$

donde $U \in \mathbb{R}^{n \times p}$ es la matriz de errores aleatorios.

2.5.1. Interpretaciones equivalentes del modelo

El sistema matricial admite dos lecturas complementarias.

Representación por filas Al extraer la i -ésima fila de cada componente, denotadas por y'_i , u'_i y x'_i , se obtiene la ecuación

$$y'_i = x'_i B + u'_i.$$

Para el municipio i , el vector de variables respuesta de dimensión p depende linealmente del vector específico de covariables x_i .

Representación por columnas Si se denotan por $Y_{.j}$ y β_j a las j -ésimas columnas de las matrices Y y B respectivamente, el modelo se descompone en p ecuaciones de la forma:

$$Y_{.j} = X\beta_j + U_{.j}, \quad j = 1, \dots, p.$$

La forma sugiere, engañosamente, que cada β_j podría estimarse mediante p regresiones aisladas. Pero los vectores de error $U_{.j}$ están correlacionados entre sí, así que el tratamiento multivariado conjunto modela explícitamente esa matriz de covarianzas residuales —ahí está la diferencia esencial frente a un análisis por separado [1]. La trampa es sutil. Ignorar la covarianza tiene costo.

2.5.2. Supuestos del modelo

La teoría de estimación e inferencia se fundamenta sobre los siguientes supuestos matemáticos:

■ **Linealidad:** $Y = XB + U$.

■ **Rango completo:** $\text{rang}(X) = q$.

■ **Errores con media cero:**

$$\mathbb{E}(U) = 0.$$

■ **Estructura de la varianza residual:**

$$\text{Cov}(\text{vec}(U)) = \Sigma \otimes I_n,$$

donde $\Sigma \in \mathbb{R}^{p \times p}$ es una matriz simétrica y definida positiva.

■ **Normalidad multivariada (requerida para inferencia exacta):**

$$U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma).$$

El producto de Kronecker $\Sigma \otimes I_n$ codifica dos cosas al mismo tiempo. Captura, por un lado, independencia entre filas (observaciones) y, por otro, dependencia estructurada entre columnas (respuestas) dentro de una misma observación —gobernada esta última por Σ [5]. Dos planos en un solo operador.

2.5.3. Formulación vectorizada

Proposición 2.38. *Al aplicar el operador matricial vec , el modelo de regresión multivariada se expresa como*

$$\text{vec}(Y) = (I_p \otimes X) \text{vec}(B) + \text{vec}(U).$$

Demostración. A partir de la ecuación del modelo poblacional

$$Y = XB + U,$$

la aplicación lineal del operador vec resulta en

$$\text{vec}(Y) = \text{vec}(XB) + \text{vec}(U).$$

Empleando la propiedad del producto de Kronecker referida a la vectorización de productos matriciales,

$$\text{vec}(ABC) = (C' \otimes A) \text{vec}(B),$$

y parametrizando con $A = X$, $B = B$ y la matriz identidad $C = I_p$, se deduce que

$$\text{vec}(XB) = \text{vec}(XB I_p) = (I_p' \otimes X) \text{vec}(B) = (I_p \otimes X) \text{vec}(B).$$

Al sustituir este resultado, el sistema se transforma en

$$\text{vec}(Y) = (I_p \otimes X) \text{vec}(B) + \text{vec}(U).$$

□

La vectorización convierte el modelo multirespuesta en un sistema lineal generalizado de dimensión np . La matriz de covarianzas residual sigue siendo $\Sigma \otimes I_n$, lo que obliga a un tratamiento que respete esa estructura [3]. La forma cambia. La dependencia no.

2.5.4. Estimación por mínimos cuadrados

El estimador de mínimos cuadrados ordinarios (MCO) minimiza la traza de la suma de cuadrados de los residuales:

$$\hat{B} = \arg \min_{B \in \mathbb{R}^{q \times p}} \|Y - XB\|_F^2.$$

Teorema 2.39 (Estimador de mínimos cuadrados). *Bajo el supuesto de que $\text{rang}(X) = q$, la matriz de coeficientes estimada por MCO en el modelo lineal multivariado es:*

$$\hat{B} = (X'X)^{-1}X'Y.$$

Demostración. Se define la función objetivo cuadrática como

$$Q(B) = \|Y - XB\|_F^2,$$

la cual se expresa matricialmente mediante el operador traza:

$$Q(B) = \text{tr}((Y - XB)'(Y - XB)).$$

Desarrollando el producto interno de las matrices:

$$(Y - XB)'(Y - XB) = Y'Y - Y'XB - B'X'Y + B'X'XB.$$

Aplicando las propiedades de invarianza cíclica de la traza, se tiene $\text{tr}(Y'XB) = \text{tr}(B'X'Y)$. Simplificando la función:

$$Q(B) = \text{tr}(Y'Y) - 2\text{tr}(B'X'Y) + \text{tr}(B'X'XB).$$

Para minimizar la función, se deriva matricialmente respecto a la matriz B y se iguala a cero:

$$\frac{\partial Q(B)}{\partial B} = -2X'Y + 2X'XB = 0.$$

Esto da lugar al sistema de ecuaciones normales:

$$X'XB = X'Y.$$

Dado que la matriz de diseño X tiene rango completo, el producto $X'X$ es invertible. Multiplicando por su inversa, se despeja la matriz de coeficientes:

$$\hat{B} = (X'X)^{-1}X'Y.$$

Esta solución corresponde a un mínimo global debido a la estricta convexidad de la forma cuadrática empleada. □

En lo computacional, calcular $\hat{B}$ equivale a correr p regresiones univariadas en paralelo. El análisis probabilístico del estimador, en cambio, exige considerar conjuntamente la matriz de varianzas residuales [1].

2.5.5. Propiedades del estimador

Al sustituir el modelo poblacional $Y = XB + U$ en la ecuación del estimador, se obtiene

$$\hat{B} = B + (X'X)^{-1}X'U.$$

Aplicando el operador de vectorización, la expresión se convierte en:

$$\text{vec}(\hat{B}) = \text{vec}(B) + (I_p \otimes (X'X)^{-1}X') \text{vec}(U).$$

Corolario 2.40. *El estimador MCO es insesgado:*

$$\mathbb{E}(\hat{B}) = B.$$

Demostración. Aplicando el valor esperado a la ecuación de la matriz estimada:

$$\mathbb{E}(\hat{B}) = B + (X'X)^{-1}X'\mathbb{E}(U).$$

Como los errores poblacionales tienen esperanza cero ($\mathbb{E}(U) = 0$), se concluye que:

$$\mathbb{E}(\hat{B}) = B.$$

□

Teorema 2.41 (Covarianza y distribución de $\hat{B}$). *La matriz de covarianzas del estimador vectorizado es*

$$\text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes (X'X)^{-1}.$$

Asumiendo normalidad matricial en los errores poblacionales, se tiene:

$$\hat{B} \sim \mathcal{MN}_{q,p}(B, (X'X)^{-1}, \Sigma).$$

Demostración. Utilizando la forma lineal vectorizada

$$\text{vec}(\hat{B}) = \text{vec}(B) + (I_p \otimes (X'X)^{-1}X') \text{vec}(U),$$

la matriz de covarianzas depende exclusivamente del término estocástico $\text{vec}(U)$:

$$\text{Cov}(\text{vec}(\hat{B})) = (I_p \otimes (X'X)^{-1}X') \text{Cov}(\text{vec}(U))(I_p \otimes (X'X)^{-1}X')'.$$

Sustituyendo el supuesto $\text{Cov}(\text{vec}(U)) = \Sigma \otimes I_n$ y aplicando la propiedad $(A \otimes B)(C \otimes D) = (AC) \otimes (BD)$ del producto de Kronecker, junto con la convención de vectorización por columnas:

$$\text{Cov}(\text{vec}(\hat{B})) = (I_p \otimes (X'X)^{-1}X')(\Sigma \otimes I_n)(I_p \otimes X(X'X)^{-1}).$$

Al agrupar los términos de las matrices correspondientes:

$$\text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes ((X'X)^{-1}X' I_n X(X'X)^{-1}).$$

El término central se simplifica, ya que $(X'X)^{-1}X'X(X'X)^{-1} = (X'X)^{-1}$. Se obtiene entonces:

$$\text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes (X'X)^{-1}.$$

Considerando que $U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma)$, su forma vectorizada distribuye como $\mathcal{N}_{np}(0, \Sigma \otimes I_n)$. Dado que el estimador es una combinación lineal de los errores, preserva la normalidad multivariada. En notación matricial paramétrica:

$$\hat{B} \sim \mathcal{MN}_{q,p}(B, (X'X)^{-1}, \Sigma).$$

□

El error de estimación depende, en última instancia, de dos cosas: el diseño muestral codificado en X y las correlaciones residuales codificadas en Σ [5].

2.5.6. Interpretación geométrica

Proposición 2.42. *A partir de la estimación por mínimos cuadrados, se calculan los valores ajustados del modelo:*

$$\hat{Y} = X\hat{B} = P_X Y,$$

donde la matriz

$$P_X = X(X'X)^{-1}X'$$

es el proyector ortogonal sobre el espacio columna $\mathcal{C}(X)$. La matriz de residuales se define como:

$$\hat{U} = (I_n - P_X)Y,$$

cumpléndose la descomposición ortogonal de los datos observados:

$$Y = \hat{Y} + \hat{U}, \quad \hat{Y} \in \mathcal{C}(X), \quad \hat{U} \in \mathcal{C}(X)^\perp.$$

Demostración. Sustituyendo el estimador $\hat{B}$, los valores proyectados son

$$\hat{Y} = X(X'X)^{-1}X'Y = P_X Y.$$

La matriz de error residual resulta de la sustracción respecto a los valores observados:

$$\hat{U} = Y - \hat{Y} = Y - P_X Y = (I_n - P_X)Y,$$

lo cual satisface la identidad geométrica $Y = \hat{Y} + \hat{U}$. Dado que P_X efectúa una proyección ortogonal hacia $\mathcal{C}(X)$, se asegura que $\hat{Y} \in \mathcal{C}(X)$. A su vez, el proyector residual $(I_n - P_X)$ proyecta los datos hacia el complemento ortogonal, demostrando que $\hat{U} \in \mathcal{C}(X)^\perp$. $\square$

La lectura geométrica es directa. El procedimiento estadístico proyecta el vector multidimensional de datos sobre el subespacio que generan las covariables, minimizando la distancia euclidiana generalizada [6]. MCO es proyección ortogonal.

2.5.7. Relación con la estimación por máxima verosimilitud

Asumiendo que las observaciones provienen de una distribución normal matricial $Y \sim \mathcal{MN}_{n,p}(XB, I_n, \Sigma)$, la función de verosimilitud asociada es

$$L(B, \Sigma) \propto |\Sigma|^{-n/2} \exp \left\{ -\frac{1}{2} \text{tr} [(Y - XB)'(Y - XB)\Sigma^{-1}] \right\}.$$

Maximizar esta función respecto a B se reduce, en términos prácticos, a minimizar el argumento de la traza:

$$\text{tr} [(Y - XB)'(Y - XB)\Sigma^{-1}].$$

Corolario 2.43. *Bajo el supuesto estadístico de normalidad multivariada, el estimador de máxima verosimilitud para la matriz B es idéntico al estimador MCO:*

$$\hat{B} = (X'X)^{-1}X'Y.$$

Demostración. Se define la función a minimizar como

$$Q_\Sigma(B) = \text{tr} [(Y - XB)'(Y - XB)\Sigma^{-1}].$$

Expandiendo los productos internos de las matrices:

$$Q_\Sigma(B) = \text{tr}(Y'Y\Sigma^{-1}) - 2\text{tr}(B'X'Y\Sigma^{-1}) + \text{tr}(B'X'XB\Sigma^{-1}).$$

La derivada respecto a la matriz B se iguala al vector nulo:

$$\frac{\partial Q_{\Sigma}(B)}{\partial B} = -2X'Y\Sigma^{-1} + 2X'XB\Sigma^{-1} = 0.$$

Lo que produce la igualdad paramétrica:

$$X'XB\Sigma^{-1} = X'Y\Sigma^{-1}.$$

Dado que la inversa de la matriz de covarianzas Σ^{-1} es no singular, se postmultiplica por Σ para obtener:

$$X'XB = X'Y.$$

Finalmente, despejando la variable poblacional:

$$\hat{B} = (X'X)^{-1}X'Y.$$

□

2.5.8. Matriz de residuos y estimación de Σ

La varianza no explicada por el modelo se cuantifica en la matriz de sumas de cuadrados de los residuales, denotada por E :

$$E = \hat{U}'\hat{U} = Y'(I_n - P_X)Y.$$

Corolario 2.44. *El estimador insesgado de la matriz de covarianzas poblacional Σ es:*

$$\hat{\Sigma} = \frac{1}{n - q}E.$$

Por la teoría de matrices gaussianas, la matriz de error sigue $E \sim \mathcal{W}_p(n - q, \Sigma)$, siendo independiente de $\hat{B}$ [5].

2.5.9. Descomposición de la variabilidad

Definición 2.45 (Descomposición multivariada de la variabilidad). La matriz de suma de cuadrados total, T , se divide en dos componentes ortogonales

$$T = Y'Y = H + E,$$

donde la varianza explicada por el ajuste paramétrico es

$$H = Y'P_XY,$$

y la varianza residual se define por

$$E = Y'(I_n - P_X)Y.$$

Proposición 2.46. *La relación fundamental*

$$T = H + E$$

constituye el análogo multivariado de la descomposición de varianza univariada, proveyendo la estructura base para el análisis de inferencia.

Observación 2.47. Cuando la matriz de diseño X contiene un vector columna constante (intercepto), la descomposición admite la formulación equivalente con matrices centradas $T_c = (Y - \bar{Y})(Y - \bar{Y})'$, $H_c = (Y - \bar{Y})'P_X(Y - \bar{Y})$ y $E_c = E$, también de la forma $T_c = H_c + E_c$. La presentación empírica del Capítulo 3 utiliza esta versión centrada, sobre la cual se define el coeficiente de determinación multivariado por traza $R_{tr}^2 = \text{tr}(H_c)/\text{tr}(T_c)$.

Demostración. Insertando la matriz identidad expresada como $I_n = P_X + (I_n - P_X)$ en la expresión de suma total:

$$Y'Y = Y'I_nY = Y'(P_X + (I_n - P_X))Y.$$

Al aplicar la distribución de las matrices respecto a las sumas:

$$Y'Y = Y'P_XY + Y'(I_n - P_X)Y = H + E.$$

□

2.5.10. Optimalidad del estimador

Teorema 2.48 (Teorema de Gauss–Markov multivariado). *En la clase de estimadores lineales que cumplen $\tilde{B} = AY$, el estimador MCO es el mejor estimador lineal insesgado. Para cualquier estimador competidor lineal e insesgado $\hat{B}$, la matriz diferencia*

$$\text{Cov}(\text{vec}(\tilde{B})) - \text{Cov}(\text{vec}(\hat{B}))$$

resulta ser semidefinida positiva.

Demostración. Sea un estimador alternativo $\tilde{B} = AY$, con $A \in \mathbb{R}^{q \times n}$. La condición estricta de insesgamiento exige que:

$$\mathbb{E}(\tilde{B}) = A\mathbb{E}(Y) = AXB = B.$$

Esto requiere que la relación algebraica cumpla $AX = I_k$.

Se define una matriz constante auxiliar:

$$D = A - (X'X)^{-1}X'.$$

Multiplicando la ecuación por la matriz de diseño X :

$$DX = AX - (X'X)^{-1}X'X = I_k - I_k = 0.$$

En consecuencia, la matriz original puede reescribirse como:

$$A = (X'X)^{-1}X' + D, \quad \text{sujeta a } DX = 0.$$

La matriz de covarianzas de este nuevo operador paramétrico es

$$\text{Cov}(\text{vec}(\tilde{B})) = \Sigma \otimes AA',$$

mientras que el estimador de mínimos cuadrados presenta la covarianza:

$$\text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes (X'X)^{-1}.$$

Evalando el producto matricial AA' :

$$AA' = ((X'X)^{-1}X' + D)(X(X'X)^{-1} + D').$$

Expandiendo los elementos:

$$AA' = (X'X)^{-1} + (X'X)^{-1}X'D' + DX(X'X)^{-1} + DD'.$$

Dado que se verificó $DX = 0$ y por simetría $X'D' = 0$, los componentes cruzados se eliminan:

$$AA' = (X'X)^{-1} + DD'.$$

Al sustituir en la diferencia de covarianzas propuesta:

$$\text{Cov}(\text{vec}(\tilde{B})) - \text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes DD'.$$

Dado que ambas matrices Σ y DD' son por definición semidefinidas positivas, su producto de Kronecker mantiene dicha propiedad estadística. En consecuencia, el estimador MCO posee la covarianza mínima posible [1].

□

2.6. Inferencia en el modelo lineal multivariado

La inferencia conjunta evalúa dos matrices en paralelo. Apoyada en la matriz de sumas de cuadrados del error y en la de las hipótesis, construye sus pruebas sobre criterios matriciales anclados en la descomposición espectral [5]; el escenario es siempre el mismo: $Y = XB + U$ con $U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma)$. El marco no varía. Solo cambian las hipótesis.

2.6.1. Hipótesis lineales generales

Definición 2.49 (Hipótesis lineal general). Para realizar contrastes sobre la matriz de coeficientes poblacionales se define la hipótesis nula

$$H_0 : CB = D,$$

donde las matrices constantes son $C \in \mathbb{R}^{q_h \times q}$ con rango $q_h \leq q$ y $D \in \mathbb{R}^{q_h \times p}$.

La formulación es flexible. Cubre contrastes globales sobre el sistema, evaluaciones de predictores individuales y comparaciones simultáneas [3]; como $\hat{B} \sim \mathcal{MN}_{q,p}(B, (X'X)^{-1}, \Sigma)$, bajo H_0 :

$$C\hat{B} - D \sim \mathcal{MN}_{q_h,p}(0, C(X'X)^{-1}C', \Sigma).$$

2.6.2. Contraste global del modelo: el caso $D = 0$

El contraste de mayor interés práctico es el caso particular en que la hipótesis nula afirma que el bloque de predictores no tiene efecto lineal conjunto sobre el vector de respuestas. Bajo el modelo $Y = XB + U$ con $X = [1, X_1, \dots, X_{q-1}]$, sea

$$C = (0_{(q-1) \times 1} \quad I_{q-1}) \in \mathbb{R}^{(q-1) \times q},$$

la matriz que elimina la primera fila de B (correspondiente al intercepto) y selecciona las $q - 1$ filas asociadas a las covariables. El contraste global del modelo se formula entonces como

$$H_0 : CB = 0 \quad \text{contra} \quad H_1 : CB \neq 0.$$

Bajo H_0 , el bloque de predictores carece de efecto lineal conjunto sobre Y ; bajo H_1 , al menos un predictor afecta linealmente al menos una dimensión o combinación lineal de las respuestas. La elección $D = 0$ es la natural en regresión: la pregunta no es si los coeficientes alcanzan un valor concreto, sino si el bloque de predictores aporta información estadística sobre Y una vez fijado el nivel medio por el intercepto. Por esta razón C excluye la fila del intercepto: probar $H_0 : B = 0$ con el intercepto incluido sería contrastar también que la media del vector de respuestas es cero, lo cual no forma parte del contraste de significancia del modelo [1, 3].

2.6.3. Construcción de las matrices de hipótesis y error

Definición 2.50 (Matrices de hipótesis y error). La variación explicada asociada a la restricción $H_0 : CB = D$ se define como la matriz de sumas de cuadrados de la hipótesis:

$$H = (C\hat{B} - D)' [C(X'X)^{-1}C']^{-1} (C\hat{B} - D).$$

La variación no explicada corresponde a la matriz de error residual:

$$E = Y'(I_n - P_X)Y.$$

La matriz H condensa la discrepancia del ajuste. Mide cuán lejos cae la estimación empírica respecto a los coeficientes hipotéticos, ponderada por la geometría del diseño [4]. Es la suma de cuadrados de la hipótesis.

Proposición 2.51. *Las matrices H y E son simétricas y semidefinidas positivas.*

Demostración. Para el caso de la matriz H , defínase $M = [C(X'X)^{-1}C']^{-1}$. Ya que $X'X$ es definida positiva y C posee rango completo, la matriz interna es definida positiva. Su matriz inversa, M , hereda la misma simetría y positividad. Si se evalúa una forma cuadrática para cualquier vector $a \in \mathbb{R}^p$:

$$a'Ha = [(C\hat{B} - D)a]'M[(C\hat{B} - D)a] \geq 0.$$

Para la matriz de error $E = \hat{U}'\hat{U}$, su transpuesta es equivalente $E' = E$. Evaluando el producto cuadrático escalar:

$$a'Ea = (\hat{U}a)'(\hat{U}a) = \|\hat{U}a\|^2 \geq 0,$$

lo cual confirma rigurosamente que es una matriz semidefinida positiva. $\square$

2.6.4. Distribución de H y E

Teorema 2.52 (Distribución de las matrices de hipótesis y error). *Considerando normalidad matricial poblacional y asumiendo cierta $H_0 : CB = D$, se verifica estadísticamente:*

$$H \sim \mathcal{W}_p(q_h, \Sigma), \quad E \sim \mathcal{W}_p(n - q, \Sigma), \quad H \perp E.$$

Demostración. A partir de la definición de los valores residuales se tiene $(I_n - P_X)X = 0$. Se sigue que $\hat{U} = (I_n - P_X)U$. Esto permite reescribir la matriz cuadrática como

$$E = U'(I_n - P_X)U.$$

La matriz $I_n - P_X$ es un operador idempotente con $\text{rang}(I_n - P_X) = n - q$. Bajo el supuesto de la regresión poblacional $U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma)$, la matriz derivada distribuye como un objeto de tipo Wishart:

$$E \sim \mathcal{W}_p(n - q, \Sigma).$$

Para analizar la distribución de la matriz H , se define la variable aleatoria $A = [C(X'X)^{-1}C']^{-1/2}(C\hat{B} - D)$, donde el factor $[C(X'X)^{-1}C']^{-1/2}$ es una matriz constante determinística que estandariza la dispersión por filas de $C\hat{B} - D$. Este procedimiento transforma el sistema a:

$$A \sim \mathcal{MN}_{q,p}(0, I_q, \Sigma).$$

Como $H = A'A$, por las propiedades estocásticas de la matriz resultante, distribuye analíticamente como una variable de Wishart:

$$H \sim \mathcal{W}_p(q_h, \Sigma).$$

La independencia estocástica obedece a la ortogonalidad de los proyectores involucrados. El operador de la hipótesis H se fundamenta en los parámetros empíricos obtenidos de $\hat{B}$, los cuales residen en el subespacio columna proyectado por $P_X Y$. A su vez, los residuales E se basan exclusivamente en el complemento ortogonal dictaminado por $(I_n - P_X)Y$. Bajo normalidad matricial, las formas cuadráticas asociadas a subespacios perpendiculares son estadísticamente independientes:

$$H \perp E.$$

$\square$

La independencia entre formas cuadráticas asociadas a subespacios ortogonales es el resultado operativo. Esa propiedad vuelve viables, en términos prácticos, los esquemas de prueba multivariados. Sin ella, no hay distribución de referencia.

2.6.5. Estructura espectral del problema inferencial

Proposición 2.53. *La inferencia sobre la hipótesis poblacional nula H_0 depende analíticamente de los valores propios no nulos $\lambda_1, \dots, \lambda_s$ provenientes del problema característico:*

$$|H - \lambda E| = 0,$$

o su forma diagonal simplificada equivalente:

$$|E^{-1}H - \lambda I_p| = 0.$$

El total de valores propios no nulos relevantes es:

$$s = \text{rang}(HE^{-1}) \leq \min(p, q_h).$$

Demostración. Siempre que el número de observaciones empíricas censales rebase la cantidad de variables ($n - q \geq p$), la matriz E es estrictamente definida positiva y cuenta con inversa. Esto legitima sustituir la expresión paramétrica inicial por la ecuación matricial de los valores propios de $E^{-1}H$. Como la matriz poblacional restrictiva $C\hat{B} - D$ es de dimensión $q \times p$, el rango analítico máximo de H es $\text{rang}(H) \leq q$. La dimensión de la matriz resultante define su segundo límite poblacional: $\text{rang}(E^{-1}H) \leq p$. Se sigue, en consecuencia, que la cantidad de variables latentes con raíces no negativas se restringe a $\min(p, q_h)$. $\square$

Cada valor propio mide un cociente concreto. Cuantifica, en términos relativos, cuánto pesa la varianza explicada por la restricción frente al ruido residual del sistema [3]. Señal contra ruido, dirección por dirección.

2.6.6. Estadísticos de prueba clásicos

Los contrastes sobre la matriz de parámetros se construyen agregando esos valores propios. Hay cuatro formas canónicas; cada una resume el espectro de manera distinta. Mismo insumo, lecturas diferentes.

Definición 2.54 (Lambda de Wilks). La prueba de proporción de determinantes, conocida como lambda de Wilks, se define estadísticamente como:

$$\Lambda = \frac{|E|}{|H + E|} = \prod_{i=1}^s \frac{1}{1 + \lambda_i}.$$

Valores pequeños de Λ señalan que la matriz H domina sobre E —indicio de evidencia empírica para rechazar la nula.

Definición 2.55 (Traza de Pillai). La traza propuesta por Pillai corresponde estadísticamente a:

$$V = \text{tr}[H(H + E)^{-1}] = \sum_{i=1}^s \frac{\lambda_i}{1 + \lambda_i}.$$

La traza de Pillai suma las proporciones normalizadas de varianza explicada. Su normalización interna le otorga mayor robustez frente a desviaciones moderadas del supuesto de normalidad. Es el estadístico más resistente del bloque.

Definición 2.56 (Traza de Hotelling–Lawley). La traza calculada sobre la proporción matricial no restringida se define empíricamente como [9]:

$$T_{HL} = \text{tr}(E^{-1}H) = \sum_{i=1}^s \lambda_i.$$

El subíndice HL distingue este estadístico de la matriz total de sumas de cuadrados y productos cruzados $T = H + E$ definida en la Sección 2.5.

Definición 2.57 (Raíz mayor de Roy). Esta aproximación apoya la inferencia exclusivamente en el componente con mayor relación de dispersión [1]:

$$\theta = \lambda_{\max} = \max_{1 \leq i \leq s} \lambda_i.$$

Las distribuciones exactas de estos estadísticos exigen procedimientos numéricos elaborados. La práctica recurre a transformaciones asintóticas que los aproximan a distribuciones F univariadas estándar [5]. La asintótica resuelve el problema computacional.

2.6.7. Región de rechazo

Aunque los cuatro estadísticos clásicos (Wilks, Pillai, Hotelling–Lawley, Roy) admiten distribuciones exactas bajo H_0 que dependen de funciones beta multivariadas [5], con expansiones asintóticas refinadas para los casos no nulos [10], la práctica recurre a aproximaciones a la distribución F univariada cuya forma genérica es

$$F_{\text{obs}} = g(\text{estadístico}, p, q, n - q),$$

donde g es la transformación específica del estadístico empleado. Fijado un nivel de significancia $\alpha \in (0, 1)$, la región de rechazo asociada al contraste $H_0 : CB = 0$ se define como

$$\mathcal{R}_\alpha = \{ F_{\text{obs}} > F_{1-\alpha}(\nu_1, \nu_2) \},$$

con (ν_1, ν_2) los grados de libertad propios de cada aproximación. Se rechaza H_0 si y solo si el estadístico observado cae en $\mathcal{R}_\alpha$, o equivalentemente si el p -valor cumple $p < \alpha$. En el resto del documento se emplea el nivel convencional $\alpha = 0.05$. Cuando H_0 no es rechazada, no se concluye que $CB = 0$ sea cierta: se concluye únicamente que los datos no aportan evidencia suficiente para descartarla al nivel α . La distinción entre *rechazar* y *no rechazar* es esencial en estadística inferencial; la formulación nunca se invierte para afirmar la nula [1, 3].

Tabla 2.1: Aproximaciones a la distribución F para los cuatro estadísticos multivariados clásicos bajo $H_0 : CB = 0$. Aquí $q_h = \text{rang}(C)$, $\nu_e = n - q$ y $s = \min(p, q_h)$.

Estadístico	Aproximación F (esquema)	Grados de libertad (ν_1, ν_2)
Wilks Λ	Aproximación de Rao a partir de $\Lambda^{1/t}$	$(p q_h, r t - p q_h / 2 + 1)$
Pillai V	Aproximación clásica de Pillai–Bartlett	$(s(2m + s + 1), s(2N + s + 1))$
Hotelling–Lawley T_{HL}	Aproximación de McKeon (1974)	$(p q_h, \nu_e - p - 1)$ aprox.
Roy θ	Cota superior basada en $\theta/(1 + \theta)$	$(\max(p, q_h), \nu_e - \max(p, q_h) + q_h)$

Los cuatro estadísticos prueban el mismo juego de hipótesis $H_0 : CB = 0$, pero resumen la información del espectro $\{\lambda_i\}_{i=1}^s$ de manera distinta: Λ acumula multiplicativamente $1/(1 + \lambda_i)$, V acumula aditivamente $\lambda_i/(1 + \lambda_i)$, T_{HL} acumula aditivamente λ_i y θ usa únicamente λ_1 . Por construcción, las cuatro lecturas coinciden cuando $s = 1$ y pueden discrepar para $s > 1$, en particular si la asociación se concentra en una sola dirección canónica (caso en el que Roy resulta más sensible) o si se distribuye de manera uniforme entre direcciones (caso en el que Pillai suele ser el más conservador y robusto frente a desviaciones de normalidad y homocedasticidad) [1, 11].

2.6.8. Regiones de confianza simultáneas

Para un subconjunto particular de combinaciones lineales estimadas de la forma $L = CB \in \mathbb{R}^{q_h \times p}$, la teoría distribucional establece:

$$C\hat{B} \sim \mathcal{MN}_{q,p}(CB, C(X'X)^{-1}C', \Sigma).$$

A partir de esta distribución se construyen regiones elipsoidales de confianza para los coeficientes, fijando un nivel conjunto $1 - \alpha$. La frontera del elipsoide es:

$$(C\hat{B} - CB)' [C(X'X)^{-1}C']^{-1} (C\hat{B} - CB) \leq c_\alpha \hat{\Sigma}.$$

El escalar c_α se obtiene de los cuantiles de la F de Fisher. El volumen del elipsoide en el espacio euclidiano es función directa de la matriz Σ observada [5]. Más covarianza, más volumen.

2.6.9. Invarianza

Proposición 2.58. *La inferencia asintótica poblacional en la regresión lineal multivariada conjunta es invariante frente a multiplicaciones deterministas o transformaciones lineales no singulares aplicadas a la matriz paramétrica empírica respuesta $Y^* = YA$.*

Demostración. Se define una matriz constante invertida A . Al transformar el modelo original empírico $Y^* = YA$, los nuevos coeficientes paramétricos obedecen la equivalencia:

$$Y^* = X(BA) + UA,$$

resultando en estimadores ajustados poblacionalmente $\hat{B}^* = \hat{B}A$. Las matrices de varianza analítica empíricas resultantes son

$$H^* = A'HA, \quad E^* = A'EA.$$

El problema característico original de los residuales se expande analíticamente a

$$|H^* - \lambda E^*| = |A'HA - \lambda A'EA| = |A'| |H - \lambda E| |A|.$$

Debido a que el componente A es explícitamente no singular, el determinante no es nulo ($|A'| |A| \neq 0$). En consecuencia empírica poblacional estadística:

$$|H^* - \lambda E^*| = 0 \quad \Longleftrightarrow \quad |H - \lambda E| = 0.$$

Esta propiedad garantiza que los valores de Wilks, Pillai, Hotelling–Lawley y Roy no se alteran; las conclusiones inferenciales son robustas frente a rotaciones o re-escalamientos de los datos vía una matriz A [4]. $\square$

2.7. Diagnóstico del modelo lineal multivariado

Antes de tomar en serio las proyecciones e inferencias del modelo, hay que confirmar que los datos satisfacen sus supuestos estructurales. La verificación se hace —siempre— sobre los residuales estimados, buscando síntomas de incumplimiento en las propiedades analíticas y estadísticas [12]. Sin tamiz residual no hay garantía. El diagnóstico no es opcional.

2.7.1. Matriz de residuos

Definición 2.59 (Matriz de residuos). La estimación de error paramétrica observacional para el modelo de regresión multivariado conjunto es:

$$\hat{U} = Y - X\hat{B} = (I_n - P_X)Y,$$

donde la matriz

$$P_X = X(X'X)^{-1}X'$$

representa al proyector analítico ortogonal sobre el subespacio de variables empíricas poblacionales.

Cada fila $\hat{u}_i'$ registra la discrepancia entre observado y ajustado para el municipio i . Es la materia prima sobre la que se construye toda la verificación de supuestos. Sin residuales no hay diagnóstico.

2.7.2. Normalidad multivariada

El modelo asume

$$u_i \sim \mathcal{N}_p(0, \Sigma), \quad i = 1, \dots, n.$$

Esa condición se examina mediante la distancia de Mahalanobis aplicada a los vectores de residuales.

Definición 2.60 (Distancia de Mahalanobis residual). Para la observación i , la métrica multivariada residual es:

$$d_i^2 = \hat{u}_i' \hat{\Sigma}^{-1} \hat{u}_i,$$

utilizando el estimador matricial de covarianza

$$\hat{\Sigma} = \frac{1}{n - q} \hat{U}' \hat{U}.$$

Bajo supuestos cumplidos y muestras grandes, la distribución de d_i^2 se acerca a una χ_p^2 . Observaciones con distancias atípicamente elevadas señalan municipios con un ajuste problemático en el subespacio multidimensional —candidatos naturales a un análisis adicional [3, 13]. Las colas marcan el límite.

2.7.3. Homocedasticidad e independencia

El modelo exige que la matriz $\text{Cov}(u_i) = \Sigma$ se mantenga constante para todo i . Cuando esa condición falla aparece la heterocedasticidad multivariada, que erosiona seriamente la eficiencia del estimador MCO [1, 14]. La varianza constante es supuesto duro. La otra exigencia, paralela, es la ausencia de correlación cruzada ($\text{Cov}(u_i, u_j) = 0$ para todo $i \neq j$); esto descarta sesgos correlacionales de origen geográfico o espacial entre los municipios analizados.

2.7.4. Observaciones influyentes

El diagnóstico identifica observaciones cuya presencia mueve el ajuste. Detecta municipios que alteran el ajuste general en el espacio predictivo. La identificación es individual.

Definición 2.61 (Apalancamiento / Leverage). El coeficiente que mide el peso de la observación i en el ajuste del modelo es el elemento diagonal del proyector ortogonal:

$$h_{ii} = x_i'(X'X)^{-1}x_i.$$

Valores altos de h_{ii} delatan municipios situados en los bordes del espacio que generan las covariables. Más allá del leverage, conviene cuantificar también cuánto se desplazan los coeficientes al excluir una observación.

Definición 2.62 (Distancia de Cook multivariada). Esta medida cuantifica el desplazamiento de $\hat{B}$ ante la omisión del municipio i [15]:

$$D_i = \text{tr} \left[(\hat{B} - \hat{B}_{(i)})' (X'X) (\hat{B} - \hat{B}_{(i)}) \Sigma^{-1} \right],$$

donde $\hat{B}_{(i)}$ es la estimación obtenida al excluir la observación i del cálculo.

En la práctica computacional, se aprovecha la equivalencia

$$D_i = \frac{1}{p} \cdot \frac{h_{ii}}{(1 - h_{ii})^2} \hat{u}_i' \hat{\Sigma}^{-1} \hat{u}_i,$$

donde la división por p —con p el número de variables respuesta— normaliza la distancia conforme a la convención multivariada estándar [16]. Valores elevados de D_i marcan observaciones desproporcionadas. Identifican municipios cuyo peso en la estimación global de los coeficientes resulta anómalo [3]. La distancia revela la influencia.

2.7.5. Residuos estandarizados

Para la inspección gráfica y la validación del modelo de covarianza:

Definición 2.63 (Residuos estandarizados). La matriz de residuales transformados se obtiene premultiplicando por la raíz inversa de la covarianza:

$$r_i = \hat{\Sigma}^{-1/2} \hat{u}_i.$$

La operación reescala los residuales. Anula su correlación cruzada y les asigna varianza unitaria, así que detectar desviaciones de la normalidad o anomalías en la dispersión se vuelve considerablemente más limpio tras la transformación [12]. Residuales blancos, diagnóstico nítido.

Con el modelo formalizado, su inferencia conjunta derivada y su diagnóstico operacionalizado queda completo el aparato matemático que sustenta la implementación algorítmica y el análisis empírico del rezago social desarrollado en los capítulos restantes.

Capítulo 3

Implementación computacional del modelo

La implementación computacional traslada la formulación matricial del modelo lineal multivariado a un procedimiento reproducible en Python. En este capítulo se describe el procesamiento de los datos censales, la construcción de las matrices X e Y , la estimación de $\hat{B}$ por mínimos cuadrados, el cálculo de las matrices SSCP y la obtención de los estadísticos usados en las pruebas de hipótesis conjuntas. También se documentan las rutinas de diagnóstico residual, verificación de supuestos y detección de observaciones atípicas o influyentes.

Se desarrolló en Python [17], utilizando NumPy para las operaciones de álgebra lineal [18]. La estimación se programó de forma explícita, sin delegar las etapas centrales a rutinas multivariadas de alto nivel, con el propósito de mantener una correspondencia directa entre la formulación matricial y los resultados numéricos obtenidos. En particular, se implementaron manualmente la estimación de la matriz de coeficientes, la construcción de las matrices SSCP, el cálculo de los residuales y las métricas de diagnóstico asociadas al modelo [1, 3]. La biblioteca `scipy.stats` se utilizó únicamente para evaluar cuantiles y funciones de distribución acumulada de F y χ^2 en el cálculo de los p -valores asintóticos.

La Figura 3.1 sintetiza el procedimiento. El flujo se reparte en seis etapas (limpieza, estructuración matricial, estimación de parámetros, pruebas de hipótesis, análisis residual y análisis canónico); las flechas continuas marcan la ejecución principal, las discontinuas el paso de variables entre módulos. Ajusté el modelo sobre $n = 2469$ municipios con $p = 4$ respuestas y $q = 11$ columnas en la matriz de diseño (intercepto más diez covariables sociodemográficas). El Capítulo 4 justifica la selección.

3.1. Arquitectura del sistema

El código fue desarrollado en Python mediante notebooks ejecutados en Visual Studio Code. Organicé las dieciocho celdas del cuaderno interactivo siguiendo, una a una, las etapas metodológicas que muestra la Figura 3.1; las primeras importan las librerías, fijan la tolerancia de punto flotante —blindaje frente al redondeo— y siembran la semilla pseudoaleatoria. Así replico los resultados sin sorpresas.

Las funciones auxiliares vienen después. Cubren, en orden estricto, la estimación por mínimos cuadrados, el cómputo de las matrices SSCP, las pruebas de hipótesis simultáneas, la verificación de supuestos con análisis de residuales y, al cierre, las variables canónicas. Separo la lógica estadística de la gestión de datos por una razón operativa —no es detalle estético, sino el mecanismo que permite auditar la estimación módulo a módulo. La Tabla 3.1 fija la correspondencia.




Figura 3.1: Esquematización del procedimiento algorítmico subyacente a la estimación multivariada, indicando el flujo de información desde las matrices de datos hasta las pruebas de hipótesis y métricas de diagnóstico.

Tabla 3.1: Relación estructural entre las celdas de código y las matrices estadísticas en el modelo multivariado.

Módulo operativo	Celdas asignadas	Variables y matrices generadas
Inicialización y funciones auxiliares	1, 2	Semilla aleatoria, funciones base
Procesamiento de bases de datos	3, 4, 5, 6	Base depurada, R_{ij} , R^*
Estructuración matricial	7	$X \in \mathbb{R}^{2469 \times 11}$, $Y \in \mathbb{R}^{2469 \times 4}$
Estimación MCO y matrices SSCP	8, 9	$\hat{B}$, $\hat{U}$, $\hat{\Sigma}$, T , H , E
Pruebas de hipótesis conjuntas	10	Λ , V , T_{HL} , θ , $\{H_j\}_{j=1}^{10}$
Evaluación de normalidad (Mardia)	11	$b_{1,p}$, $b_{2,p}$, $D_{i,\text{res}}^2$
Prueba de heterocedasticidad	12	Regresión auxiliar (Prueba de White)
Análisis de matriz residual	13	Correlaciones residuales
Detección de observaciones atípicas	14	h_i , $D_{i,X}^2$, $\text{Cook}_i^{(M)}$
Análisis de sensibilidad	15	Reestimación sin observaciones influyentes
Análisis de correlación canónica	16, 17	M , $\{a_j\}$, Y_c , $\hat{Y}_c$
Visualización de resultados	18	Distribuciones marginales, mapas de calor

3.1.1. Funciones auxiliares

El cálculo matricial exige blindaje aritmético. Programé varias funciones auxiliares dedicadas a esa tarea —optimización del flujo y control de precisión— y las enumero a continuación:

1. Función de proporciones censales. Devuelve un valor válido si numerador y denominador están definidos y este último es estrictamente positivo; en caso contrario, el valor se marca como dato faltante (NA) para evitar divisiones indefinidas.
2. Operador vech. Extrae los elementos únicos del triángulo inferior de una matriz simétrica y permite estructurar la prueba de White multivariada.
3. Función para invertir matrices de covarianzas. Incluye un parámetro de tolerancia de punto flotante que permite detectar posibles problemas de singularidad o multicolinealidad severa antes de calcular la inversa.
4. Cálculo de los coeficientes de asimetría ($b_{1,p}$) y curtosis multivariada ($b_{2,p}$) de Mardia [13]; estos estadísticos se emplean para evaluar la normalidad multivariada de los residuales del modelo.
5. Función principal de mínimos cuadrados ordinarios. Estima la matriz de parámetros $\hat{B}$, los valores ajustados $\hat{Y}$, los residuales $\hat{U}$, la matriz de covarianzas $\hat{\Sigma}$ y las matrices SSCP T , H y E , integrando todos estos cálculos en una misma rutina.
6. Rutina para extraer los valores propios de $E^{-1}H$. A partir de ellos se calculan los estadísticos de Wilks, Pillai, Hotelling–Lawley y Roy, junto con sus aproximaciones a la distribución F .

Programar estas funciones de forma explícita —en lugar de delegarlas a paquetes opacos— deja en evidencia la equivalencia directa entre los axiomas del modelo lineal multivariado y los números finales [4].

3.2. Preparación de la base analítica

3.2.1. Lectura, validación y depuración inicial

La importación abre el pipeline. Una vez uniformados los nombres de las variables, el algoritmo aplica las condiciones de exclusión del Capítulo 4 para conservar únicamente las observaciones a

nivel municipal; de ahí el programa verifica la ausencia de identificadores geográficos duplicados y registra la frecuencia de NA por variable. Esa verificación importa por una razón operativa concreta. Garantiza que X y Y compartan cardinalidad.

Las inconsistencias dimensionales son letales. Una desalineación —por mínima que sea entre filas— inutiliza las operaciones del álgebra matricial sobre las que descansa la estimación [7]; la verificación se ejecuta antes de cualquier operación cuadrática, blindando el resto del flujo. El control corre sin excepciones.

3.2.2. Construcción de variables analíticas

N_{ij} denota el conteo absoluto de la característica j en el municipio i , y D_{ij} su base poblacional. La proporción censal se calcula así:

$$R_{ij} = \begin{cases} \frac{N_{ij}}{D_{ij}}, & \text{si } N_{ij}, D_{ij} \text{ están observados y } D_{ij} > 0, \\ \text{NA}, & \text{en otro caso.} \end{cases} \quad (3.1)$$

La lógica condicional bloquea indeterminaciones. Tras el cómputo, el código verifica que toda R_{ij} caiga dentro de $[0, 1]$ y descarta por listwise las observaciones con NA en variables del modelo; así garantizo una base rectangular completa, requisito sin el cual las formas cuadráticas multivariadas no se calculan.

3.2.3. Transformación y estandarización

Las proporciones reciben raíz cuadrada antes del armado matricial:

$$R^* = \sqrt{R} \quad (3.2)$$

La fundamentación estadística vive en el Capítulo 4. En el plano computacional la operación estabiliza la varianza de los indicadores y mitiga la asimetría —reduce el peso desproporcionado que de otro modo cargarían las observaciones extremas sobre la matriz de covarianzas residual [3, 12]. Las colas dejan de dominar.

Las variables de diseño se estandarizan acto seguido:

$$Z_{ij} = \frac{X_{ij}^{\text{raw}} - \bar{X}_{\cdot j}^{\text{raw}}}{s_j}, \quad (3.3)$$

con s_j como desviación estándar muestral de la variable j ; si alguna variable presenta $s_j = 0$ se le asigna una constante normalizada y se esquivan las divisiones por cero, completándose el diseño con un vector unitario para el intercepto:

$$X = [\mathbf{1}, Z] \in \mathbb{R}^{n \times q}. \quad (3.4)$$

Un punto requiere subrayarse. La estandarización aplica únicamente a la matriz explicativa X , ya que las variables de respuesta en Y conservan la transformación $\sqrt{R}$ —mantengo viva la interpretabilidad respecto a las magnitudes observadas.

3.2.4. Controles numéricos

El rango completo de X debe confirmarse antes del ajuste. El algoritmo verifica que $\text{rang}(X) = q$ porque, sin esa condición, $X'X$ deja de ser invertible y el estimador MCO pierde su solución única; añado un control complementario que calcula el número de condición $\kappa(X)$ vía descomposición en valores singulares [15]. Para la matriz construida, el índice arroja $\kappa(X) = 4.5485$. Descarta colinealidad severa.

3.3. Estimación y descomposición SSCP

El Algoritmo 1 documenta el cómputo. Ejecuta las operaciones algebraicas que producen la matriz de coeficientes $\hat{B}$, las proyecciones $\hat{Y}$, los errores $\hat{U}$ y la matriz de covarianzas $\hat{\Sigma}$; para que el estimador de la dispersión conjunta resulte insesgado, la matriz de productos cruzados residuales se divide entre los grados de libertad correspondientes, $n - q$ [4, 5].

Algoritmo 1: Cálculo de la regresión MCO y partición de la variabilidad SSCP

Datos de Entrada : Matriz respuesta $Y \in \mathbb{R}^{n \times p}$, matriz explicativa $X \in \mathbb{R}^{n \times q}$
Variables de Salida: $\hat{B}, \hat{Y}, \hat{U}, \hat{\Sigma}, T, H, E$

```

// Verificación de rango completo
1 si rang( $X$ )  $\neq q$  entonces
2   | devolver fallo: rango estructural deficiente en la matriz  $X$ 
3 fin
4  $\kappa \leftarrow \text{cond}(X)$ 
5 si  $\kappa > 10^8$  entonces
6   | reportar advertencia por multicolinealidad severa
7 fin

// Estimación del modelo MCO
8  $\hat{B} \leftarrow (X^\top X)^{-1} X^\top Y$ 
9  $\hat{Y} \leftarrow X \hat{B}$ 
10  $\hat{U} \leftarrow Y - \hat{Y}$ 

// Estimación de la matriz de covarianzas residual
11  $\text{gl}_{\text{error}} \leftarrow n - q$ 
12 si  $\text{gl}_{\text{error}} \leq 0$  entonces
13   | devolver fallo: grados de libertad insuficientes
14 fin
15  $\hat{\Sigma} \leftarrow \hat{U}^\top \hat{U} / (n - q)$ 

// Cálculo de matrices SSCP centradas
16  $\bar{Y} \leftarrow \mathbf{1} \bar{y}^\top$ 
17  $T \leftarrow (Y - \bar{Y})^\top (Y - \bar{Y})$ 
18  $E \leftarrow \hat{U}^\top \hat{U}$ 
19  $H \leftarrow T - E$ 

// Verificación de la descomposición ortogonal
20  $\varepsilon \leftarrow \max |T - (H + E)|$ 
21 si  $\varepsilon > 10^{-8}$  entonces
22   | reportar advertencia: error numérico en la suma de cuadrados
23 fin
24 devolver ( $\hat{B}, \hat{Y}, \hat{U}, \hat{\Sigma}, T, H, E$ )

```

3.3.1. Descomposición centrada de la variabilidad

La matriz de medias antecede a la descomposición:

$$\bar{Y} = \mathbf{1} \bar{y}',$$

donde $\bar{y}$ recoge las medias muestrales por variable respuesta; a partir de ahí construyo las matrices de sumas de cuadrados —total (T), residual (E) y de la hipótesis explicada (H)— que armarán toda la inferencia conjunta del modelo lineal multivariado:

$$T = (Y - \bar{Y})'(Y - \bar{Y}), \quad E = \hat{U}'\hat{U}, \quad H = T - E. \quad (3.5)$$

Esta especificación es el cimiento. El algoritmo incorpora una rutina que calcula $\max |T - (H + E)|$ y confirma —numéricamente, entrada por entrada— que las matrices preservan la identidad de la

partición de cuadrados; sin esa verificación, errores de precisión podrían propagarse silenciosamente hacia la inferencia.

3.4. Inferencia multivariada

3.4.1. Contraste global del modelo

H y E ya están armadas. El Algoritmo 2 evalúa la significancia conjunta de los parámetros resolviendo numéricamente el problema de valores propios asociado a $E^{-1}H$; de los eigenvalores λ_i derivan los estadísticos multivariados. Wilks, Pillai, Hotelling–Lawley y Roy salen del mismo espectro. Cuatro lecturas de la misma matriz.

Algoritmo 2: Cálculo de estadísticos de prueba multivariados

Datos de Entrada : Matrices SSCP $H, E \in \mathbb{R}^{p \times p}$, grados de libertad gl_h, gl_{error}
Variables de Salida : Estadísticos $\Lambda, V, T_{HL}, \theta$ y aproximaciones a la distribución F

```

1 si  $|E| \approx 0$  entonces
2   | devolver fallo: matriz de covarianzas residual singular
3 fin

  // Cálculo de valores propios
4  $M \leftarrow \text{solve}(E, H)$  // Resolución numérica de  $E^{-1}H$ 
5  $\{\lambda_i\}_{i=1}^s \leftarrow \text{real}(\text{eig}(M))$  //  $s = \min(p, gl_h)$ 

  // Cálculo de estadísticos multivariados
6  $\Lambda \leftarrow \det(E) / \det(H + E)$  // Lambda de Wilks
7  $V \leftarrow \sum_{i=1}^s \lambda_i / (1 + \lambda_i)$  // Traza de Pillai
8  $T_{HL} \leftarrow \sum_{i=1}^s \lambda_i$  // Traza de Hotelling–Lawley
9  $\theta \leftarrow \max(\lambda_1, \dots, \lambda_s)$  // Raíz mayor de Roy

  // Aproximaciones teóricas a la distribución F
10  $F_\Lambda \leftarrow \text{Aproximación de Rao}(p, gl_h, gl_{\text{error}})$ 
11  $F_V \leftarrow \text{Aproximación de Pillai-Bartlett}(p, gl_h, gl_{\text{error}})$ 
12 devolver  $(\Lambda, V, T_{HL}, \theta, F_\Lambda, F_V)$ 
```

El programa añade un coeficiente descriptivo basado en la traza:

$$R_{\text{tr}}^2 = \frac{\text{tr}(H)}{\text{tr}(T)}, \quad (3.6)$$

que mide la proporción de varianza total en las respuestas modelada linealmente. Las pruebas formales descansan en Wilks y Pillai [4, 5]; esta última destaca por una razón concreta —su mayor robustez ante desviaciones moderadas del supuesto de normalidad multivariada [11, 19]— y Hotelling–Lawley con Roy cierran el cuadro [3, 7, 9]. Cuatro criterios cubriendo el mismo contraste.

3.4.2. Pruebas individuales por variable explicativa

El Algoritmo 3 ejecuta el cómputo. Para cada x_j el código ajusta un modelo reducido —excluye temporalmente esa covariable— y recupera la matriz residual $E_{(-j)}$, de la que se deriva la contribución estadística atribuible en exclusiva al vector x_j :

$$H_j = E_{(-j)} - E, \quad (3.7)$$

con E como matriz de varianza residual del modelo irrestricto.

H_j y E alimentan el Algoritmo 2. La rutina estima la significancia mediante los cocientes asintóticos parcializados [1] y devuelve p -valores variable por variable; así discrimino cuáles covariables aportan, en términos multivariados, sobre el conjunto de respuestas. El barrido es exhaustivo.

Algoritmo 3: Cálculo de significancia marginal para covariables individuales

Datos de Entrada : Matriz $X = [\mathbf{1}, X_1, \dots, X_{q-1}] \in \mathbb{R}^{n \times q}$, matriz $Y \in \mathbb{R}^{n \times p}$
Variables de Salida : Tabla de resultados de significancia marginal para cada predictor (no intercepto)

```

// Estimación del modelo lineal completo
1  $(\cdot, \cdot, \cdot, \cdot, \cdot, E) \leftarrow \text{MCO}(X, Y)$ 
// Iterar sobre las q-1 covariables, excluyendo el intercepto
2 para  $j \leftarrow 2$  a  $q$  hacer
3    $X_{(-j)} \leftarrow$  Matriz  $X$  sin la columna  $j$  (intercepto preservado)
4    $(\cdot, \cdot, \cdot, \cdot, \cdot, E_{(-j)}) \leftarrow \text{MCO}(X_{(-j)}, Y)$ 
5    $H_j \leftarrow E_{(-j)} - E$ 
6    $(\Lambda_j, V_j, p_{\Lambda, j}, p_{V, j}) \leftarrow \text{PruebaSignificancia}(H_j, E)$ 
7   Registrar en resultados la covariable  $j$ 
8 fin
9 devolver Coeficientes parciales y  $p$ -valores para las  $q - 1$  covariables

```

3.5. Análisis de residuales y detección de observaciones atípicas

El análisis residual se organiza en tres componentes: evaluación de normalidad multivariada, diagnóstico de homocedasticidad y detección de municipios atípicos o de alta influencia. El Algoritmo 4 implementa las rutinas correspondientes a cada componente, de modo que la revisión de los residuales quede asociada con supuestos específicos del modelo lineal multivariado. El incumplimiento de estas condiciones puede afectar la validez de las pruebas de hipótesis, la eficiencia del estimador o la estabilidad de la interpretación empírica.

Algoritmo 4: Rutinas de diagnóstico y validación estadística para el modelo MCO multivariado

Datos de Entrada : Matriz de diseño X , Residuales $\hat{U}$, Matriz de covarianza estimada $\hat{\Sigma}$
Variables de Salida : Apalancamiento h_i , distancias $D_{i, res}^2, D_{i, X}^2$, distancias de Cook C_i

```

// Cálculo de apalancamiento (leverage)
1  $P_X \leftarrow X(X^\top X)^{-1}X^\top$ 
2  $h \leftarrow \text{diag}(P_X)$ 
3  $D_X^2 \leftarrow (n - 1) \left( h - \frac{1}{n} \right)$ 
// Cálculo de distancias de Mahalanobis para los residuales
4  $\Sigma^{-1} \leftarrow \text{inv}(\hat{\Sigma})$ 
5 para  $i \leftarrow 1$  a  $n$  hacer
6    $D_{res}^2[i] \leftarrow \hat{U}[i, :] \Sigma^{-1} \hat{U}[i, :]^\top$ 
7 fin
// Cálculo de distancias de Cook multivariadas
8 para  $i \leftarrow 1$  a  $n$  hacer
9    $C[i] \leftarrow \frac{h[i]}{(1 - h[i])^2} D_{res}^2[i]$ 
10 fin
// Prueba de normalidad multivariada de Mardia
11  $b_{1,p} \leftarrow \frac{1}{n^2} \sum_{i,j} \left( \hat{U}[i, :] \Sigma^{-1} \hat{U}[j, :]^\top \right)^3$ 
12  $b_{2,p} \leftarrow \frac{1}{n} \sum_i \left( D_{res}^2[i] \right)^2$ 
13 devolver  $(h, D_{res}^2, D_X^2, C, b_{1,p}, b_{2,p})$ 

```

3.5.1. Distancias de Mahalanobis y coeficientes de Mardia

La Mahalanobis residual abre la inspección. Para cada observación calculo

$$D_{i,\text{res}}^2 = \hat{u}_i' \hat{\Sigma}^{-1} \hat{u}_i, \quad (3.8)$$

distancia que mide qué tan lejos cae el vector de errores respecto al centro multivariado en la métrica inducida por $\hat{\Sigma}^{-1}$. Es la lupa estadística del modelo.

Esas distancias alimentan los coeficientes de Mardia. Sirven —en simultáneo— para construir los estadísticos de asimetría ($b_{1,p}$) y curtosis multivariada ($b_{2,p}$) de la distribución residual [13]; el código produce también un Q-Q plot que enfrenta los $D_{i,\text{res}}^2$ ordenados contra los cuantiles esperados de una χ_p^2 teórica, recurso visual estándar para diagnosticar la normalidad conjunta. La gráfica condensa la evidencia.

3.5.2. Apalancamiento y distancia de Cook

La diagonal principal de P_X contiene la información clave. El código aísla los h_{ii} de la matriz de proyección (*Hat matrix*) porque cuantifican el apalancamiento de cada municipio dentro del hiperespacio paramétrico [15]; cruzando esos índices con los errores ya calculados, la rutina aproxima la distancia de Cook mediante un atajo eficiente:

$$\text{Cook}_i = \frac{1}{p} \cdot \frac{h_{ii}}{(1 - h_{ii})^2} D_{i,\text{res}}^2, \quad (3.9)$$

donde el factor $1/p$ —con p el número de variables respuesta— normaliza la distancia conforme a la convención multivariada estándar, sorteando así la carga computacional —reestimar el modelo, municipio por municipio, excluyendo una observación a la vez— que devoraría el ciclo de cómputo. El atajo conserva la jerarquía relativa entre observaciones influyentes. Cada minuto ahorrado cuenta.

3.5.3. Prueba de homocedasticidad

La varianza residual debe ser constante. El algoritmo evalúa esa constancia mediante la prueba de White en versión multivariada: arma el producto de filas de residuales $\hat{u}_i \hat{u}_i'$, extrae sus elementos únicos vía $\text{vech}(\cdot)$ [14, 20] y plantea una regresión auxiliar contra el conjunto completo de covariables y sus factores cuadráticos cruzados. La confirmación surge al comparar la traza de Pillai del ajuste auxiliar contra su distribución de referencia. Es decir: heterocedasticidad implica V alto. El contraste cierra el bucle.

3.6. Análisis canónico

El análisis canónico cierra el flujo. La técnica busca, en pocas palabras, combinaciones lineales estandarizadas que maximicen la varianza explicada entre el conjunto de respuestas y los predictores [5]; las direcciones latentes resultantes condensan la asociación multivariada en componentes ortogonales jerarquizadas. Su lectura es geométrica.

3.6.1. Resolución del problema de valores propios generalizado

Las variables canónicas surgen del problema $Z = YA$. El sistema resuelve

$$(H - \lambda_i E) \mathbf{a}_i = \mathbf{0}, \quad (3.10)$$

sujeito a $\mathbf{a}_i' E \mathbf{a}_i = 1$; los vectores resultantes definen direcciones latentes y el grado de asociación queda ordenado de mayor a menor según los λ_i . Cada eigenvalor pesa una dirección. La jerarquía es automática.

3.6.2. Cargas canónicas relativas

Las cargas dan la interpretación sustantiva. Para cada dirección latente calculo las proporciones absolutas asociadas a las respuestas originales:

$$w_{ji} = \frac{|a_{ji}|}{\sum_{k=1}^p |a_{ki}|}. \quad (3.11)$$

Esta razón identifica el peso relativo con que cada respuesta original participa en cada componente canónica —es decir, qué dimensión del rezago carga más sobre cada eje latente y, en consecuencia, cuál fenómeno sustantivo domina la varianza compartida en esa dirección. El número habla por sí solo.

3.7. Visualización de resultados

El último módulo cierra con gráficos. La implementación incluye un conjunto de rutinas visuales que examinan el comportamiento matricial del ajuste y cubren tres familias —histogramas de frecuencia para las transformaciones proporcionales, mapas de calor para los índices de correlación empírica y diagramas de dispersión que enfrentan magnitudes esperadas contra sus residuales. Cada gráfico responde a una pregunta específica. La inspección visual completa el diagnóstico.

Capítulo 4

Aplicación del modelo al Censo de Población y Vivienda 2020

Este capítulo presenta la aplicación empírica del modelo al Censo de Población y Vivienda 2020. Se describen la fuente de información, la unidad espacial de observación, el procedimiento de construcción de indicadores proporcionales y la estructuración de las matrices Y y X .

El propósito es evaluar, a escala municipal, distintos componentes de la marginación en México. Dado que el rezago social involucra dimensiones educativas, laborales, habitacionales, sanitarias y demográficas, reducirlo a un único índice escalar implicaría perder información sobre la dirección y magnitud de cada componente. Por ello, se utiliza un modelo multivariado que permite analizar de manera simultánea la variabilidad compartida entre indicadores de vulnerabilidad [21, 22].

4.1. Fuente de información

Los datos provienen del Censo de Población y Vivienda 2020, levantado por el Instituto Nacional de Estadística y Geografía. Su pertinencia para este estudio se debe a tres rasgos principales: cobertura nacional, definición estandarizada de variables y disponibilidad de registros a escala municipal [2, 23]. Además, la documentación metodológica del censo permite identificar los universos de referencia necesarios para construir proporciones comparables [24, 25].

La información corresponde a un único momento de observación. En consecuencia, la estimación cuantifica diferencias espaciales entre municipios en 2020, sin pretender describir trayectorias temporales ni dinámicas longitudinales.

4.2. Unidad de análisis y delimitación territorial

El municipio se define como la unidad de observación del estudio. Esta escala permite comparar divisiones administrativas equivalentes y ofrece un nivel intermedio entre el agregado estatal, que puede ocultar heterogeneidad interna, y el dato submunicipal, cuya definición territorial resulta más heterogénea para los fines del modelo.

Para preservar la comparabilidad de la base, se conservaron únicamente los totales municipales y se descartaron agregados nacionales, resúmenes estatales, localidades submunicipales y registros no comparables con la unidad de análisis. Este filtrado se aplicó antes del cálculo de proporciones.

La base ITER 2020 de partida contiene 195,659 registros, incluyendo localidades urbanas y rurales, agregados estatales, totales nacionales y categorías “No especificado” reportadas por el INEGI. Tras aplicar las condiciones de filtrado —entidad federativa válida, clave municipal numérica, identificador de localidad nulo y registro marcado como total del municipio—, la muestra analítica

queda integrada por 2,469 municipios, equivalentes al 1.26 % de los registros originales. Esta reducción no implica pérdida de información municipal, pues los registros descartados corresponden a niveles de agregación distintos o a agregados que romperían la comparabilidad del análisis.

4.3. Construcción de la base analítica

Los tabulados censales reportan frecuencias absolutas. Usarlas directamente en el ajuste introduciría un problema de escala, ya que municipios con tamaños poblacionales muy distintos tenderían a diferir por volumen antes que por intensidad relativa del fenómeno. Por esta razón, los conteos se transformaron en indicadores proporcionales.

Para cada variable se verificó que el denominador correspondiera al universo demográfico o habitacional pertinente, conservando la nomenclatura del diccionario oficial del INEGI [26]. Después de ensamblar la matriz analítica, se comprobó que las variables incluidas en el modelo no presentaran valores faltantes en los 2,469 municipios.

4.4. Universos de referencia y denominadores

Una proporción es válida solo si el denominador coincide con la población realmente susceptible a la característica analizada. Esa exigencia conceptual ordenó la elección de divisores (residentes totales, personas de 15 años y más, Población Económicamente Activa, población de 3 años y más, población de 5 años y más, y viviendas particulares ocupadas), descartando combinaciones poblacionales que rompen la lectura sustantiva. Este criterio garantiza la validez conceptual de cada indicador proporcional.

Cada decisión sigue una lógica. El analfabetismo se calcula sobre la población en edad de alfabetizarse —no sobre la población total— y la carencia de servicios básicos en vivienda se divide entre el total de viviendas habitadas, no entre habitantes; la Tabla 4.1 consigna, variable por variable, su rol en el modelo, el denominador utilizado y la justificación del cálculo.

Tabla 4.1: Universos de referencia utilizados en la construcción de indicadores.

Variable	Rol	Denominador	Justificación
PCDISC_MEN	Dependiente	POBTOT	La limitación mental se calcula como proporción respecto a la población total del municipio.
P15YM_AN	Dependiente	P_15YMAS	El analfabetismo se calcula utilizando exclusivamente la población de 15 años y más.
PDESOCUP	Dependiente	PEA	El nivel de desempleo se calcula como proporción respecto a la Población Económicamente Activa.
VPH_SNBIEN	Dependiente	TVIVHAB	La carencia de bienes se divide entre el total de viviendas particulares habitadas.
VPH_PISOTI	Independiente	TVIVHAB	La proporción de viviendas con piso de tierra se calcula utilizando las viviendas habitadas.
VPH_NDEAED	Independiente	TVIVHAB	La falta de drenaje y servicio sanitario se calcula respecto a las viviendas habitadas.
PRO_OCUP_C	Independiente	—	Indicador de hacinamiento provisto de forma directa en las bases de datos del INEGI.
P3HLINHE	Independiente	P_3YMAS	La proporción de hablantes de lengua indígena que no hablan español emplea la población de 3 años y más.
PHOG_IND	Independiente	POBHOG	La población en hogares indígenas se calcula respecto a la población total empadronada en hogares.
POB_AFRO	Independiente	POBTOT	La proporción de población afrodescendiente se calcula respecto a la población total.
PSINDER	Independiente	POBTOT	La carencia por acceso a servicios de salud se calcula respecto a la población total.
P15YM_SE	Independiente	P_15YMAS	La proporción de población sin escolaridad se calcula utilizando la población de 15 años y más.
PSIN_RELIG	Independiente	POBTOT	La proporción de población sin religión se calcula utilizando la población total.
PRESOE15	Independiente	P_5YMAS	La proporción de migrantes interestatales recientes se calcula respecto a la población de 5 años y más.

4.5. Especificación empírica del sistema de variables

El modelo separa la información en dos bloques matriciales. El primero agrupa las dimensiones del rezago social que el ajuste analiza en paralelo —variables respuesta—; el segundo reúne características demográficas, educativas y de vivienda que entran como regresores. La frontera entre bloques es estructural. Cada bloque cumple un papel distinto.

¿Por qué esa separación? Responde al planteamiento mismo de la regresión multivariada, ya que el sistema evalúa —dentro de un único ajuste— distintas dimensiones de vulnerabilidad que dependen de una misma matriz de diseño; así que la especificación no asume independencia entre los indicadores de respuesta. Al contrario: postula una covarianza residual y la estima dentro del ajuste matricial. La dependencia entre respuestas queda modelada.

4.5.1. Variables respuesta

La matriz Y reúne indicadores heterogéneos. Al no comprimirllos en un índice escalar, la metodología estima simultáneamente los parámetros asociados a educación, mercado laboral, bienes en la vivienda y vulnerabilidad funcional en salud —cuatro facetas del rezago social municipal con dinámicas propias. La Tabla 4.2 describe estas variables. Cada una conserva su escala.

Tabla 4.2: Variables dependientes del modelo.

Variable	Definición operativa	Interpretación analítica
PCDISC_MEN	Proporción de la población con limitaciones para recordar o concentrarse, respecto a la población total.	Indicador de limitación funcional o cognitiva en la población.
P15YM_AN	Proporción de la población de 15 años y más que no sabe leer ni escribir.	Indicador de rezago educativo en la población adulta.
PDESOCUP	Proporción de la población desocupada respecto a la Población Económicamente Activa.	Indicador de nivel de desempleo en el mercado laboral local.
VPH_SNBIEN	Proporción de viviendas habitadas que no disponen de los bienes tecnológicos y electrodomésticos del indicador.	Indicador de escasez de bienes materiales en la vivienda.

4.5.2. Variables explicativas

La matriz X reúne diez covariables. Incorpora proporciones referidas a la calidad de la vivienda, la composición poblacional, la cobertura sanitaria, el nivel educativo y la migración reciente —materia prima estructural para retratar el perfil de cada municipio— y la Tabla 4.3 fija la definición operativa de cada una. Diez dimensiones del perfil municipal. Cada renglón es auditable.

Tabla 4.3: Variables independientes del modelo.

Variable	Definición operativa	Interpretación analítica
VPH_PISOTI	Proporción de viviendas particulares habitadas que tienen piso de tierra.	Indicador de carencia en la calidad de los espacios de la vivienda.
VPH_NDEAED	Proporción de viviendas habitadas que no disponen de drenaje ni servicio sanitario.	Indicador de carencia en los servicios básicos de infraestructura.
PRO_OCUP_C	Promedio de ocupantes por cuarto en viviendas particulares habitadas.	Indicador de nivel de hacinamiento habitacional.
P3HLINHE	Proporción de población de 3 años y más que habla alguna lengua indígena y no habla español.	Indicador de monolingüismo en lengua indígena.
PHOG_IND	Proporción de población residente en hogares indígenas.	Indicador de concentración demográfica en hogares indígenas.
POB_AFRO	Proporción de población que se autodenomina afrodescendiente o afromexicana.	Variable sociodemográfica sobre composición identitaria.
PSINDER	Proporción de la población sin afiliación a servicios de salud.	Indicador de vulnerabilidad en el acceso a servicios de salud.
P15YM_SE	Proporción de la población de 15 años y más sin escolaridad.	Indicador de falta de formación educativa formal.
PSIN_RELIG	Proporción de la población que reporta no tener religión.	Variable contextual sobre diversidad sociocultural.
PRESOE15	Proporción de la población de 5 años y más residente en otra entidad federativa en 2015.	Indicador de migración y movilidad geográfica reciente.

4.6. Criterios de selección de variables

Dos criterios anclan la selección. Uno sustantivo —incluir las variables sociodemográficas que la literatura reconoce como determinantes del rezago territorial— y uno estadístico, complementario, orientado a contener la multicolinealidad; ya que cuando varias covariables se correlacionan fuertemente entre sí, la estabilidad numérica de $(X'X)^{-1}$ se degrada y la varianza de los parámetros se infla [15]. El balance entre ambos guía la decisión final.

El censo entrega un volumen enorme de indicadores. Meter todos sería un error, ya que un conjunto saturado de covariables correlacionadas se traduce —sin remedio— en inestabilidad paramétrica; así que la especificación final se diseñó buscando parsimonia y la Figura 4.1 inspecciona las correlaciones de Pearson entre las covariables seleccionadas. El mapa de calor condensa la estructura. Es la radiografía del bloque.




Figura 4.1: Mapa de calor de las correlaciones correspondientes al conjunto de covariables explicativas. Las correlaciones de mayor magnitud se concentran entre indicadores de infraestructura, educación e idioma, evidenciando el grado de dependencia lineal entre los atributos municipales.

El patrón de la Figura 4.1 es elocuente. Las deficiencias de vivienda, la escolaridad y los indicadores asociados a lengua indígena muestran correlaciones apreciables entre sí —rasgo característico del comportamiento agrupado de los indicadores de marginación— y esa estructura de covarianza es justamente lo que la estimación parcializada del modelo maneja. Cada coeficiente cuantifica el efecto de su covariable manteniendo el resto del sistema constante. La parcialización es la herramienta.

4.7. Transformaciones previas al análisis

Las variables pasaron por una transformación previa al ajuste. La razón es triple (reducir la asimetría de las distribuciones, estabilizar la varianza empírica y acercar el comportamiento de los datos a los supuestos de la distribución normal multivariada [12]); ya calculadas las proporciones municipales, ese tratamiento es el último filtro antes de armar las matrices del modelo.

Sobre las tasas proporcionales apliqué raíz cuadrada. La transformación preserva el orden monótono de las observaciones, atenúa el peso de los municipios con valores extremos y produce distribuciones más simétricas, condiciones favorables para la estimación por mínimos cuadrados y el análisis residual asintótico; las Figuras 4.2 y 4.3 ilustran el tránsito desde el conteo absoluto, pasando por la proporción, hasta la variable transformada.

La elección de $\sqrt{R}$ sobre alternativas habituales responde a un balance entre estabilización de varianza y conservación de interpretabilidad. La transformación arcoseno-raíz $\arcsin \sqrt{R}$, asintóticamente equivalente para proporciones intermedias, comprime las colas extremas con mayor severidad y dificulta la lectura de los coeficientes en la escala original. La transformación logit $\log(R/(1 - R))$ requiere ajuste explícito de los ceros estructurales que aparecen en `PCDISC_MEN`, `VPH_NDEAED` y `P3HLINHE` —variables en las que varios municipios reportan exactamente cero—, lo cual introduce arbitrariedad. Box-Cox sobre cada proporción produciría exponentes específicos por variable, sacrificando la homogeneidad del bloque Y que el modelo multivariado requiere. La raíz cuadrada conserva el orden monótono, no necesita corrección en los ceros y es la transformación que la literatura clásica del análisis multivariado [12] recomienda como primera opción para tasas censales agregadas.

Aplicación del modelo al Censo de Población y Vivienda 2020

4.7 Transformaciones previas al análisis




Figura 4.2: Distribución empírica de las variables a través del proceso de transformación: valores absolutos, cálculo de proporciones y estabilización mediante la transformación de raíz cuadrada.

Aplicación del modelo al Censo de Población y Vivienda 2020

4.7 Transformaciones previas al análisis




Figura 4.3: Continuación de la distribución empírica de las variables a través del proceso de transformación: valores absolutos, cálculo de proporciones y transformación de raíz cuadrada.

Capítulo 5

Resultados

5.1. Ajuste global del modelo

El primer paso del análisis es evaluar el ajuste global. Una vez consolidada la base municipal y armada la matriz de covariables, antes de revisar efectos marginales o componentes canónicos, conviene verificar algo más básico: si el bloque de variables explicativas reproduce una fracción razonable de la variabilidad conjunta de los indicadores de rezago a escala municipal. El diagnóstico no es univariado. Mido la captura de la estructura de covarianza completa.

El modelo ajustado tiene la forma $Y = X\hat{B} + \hat{U}$. Siguiendo la formulación de los Capítulos 2 y 4, Y recoge las variables respuesta transformadas, X agrupa el vector constante y las diez covariables sociodemográficas, $\hat{B}$ es la matriz de coeficientes obtenida por mínimos cuadrados y $\hat{U}$ almacena los residuos del ajuste matricial; la validez del modelo depende de qué tan cerca caen los valores ajustados $\hat{Y} = X\hat{B}$ de los observados en los 2,469 municipios. No busco ajustar regresiones independientes —ese atajo perdería información— sino preservar la estructura de covarianza que vincula las dimensiones de marginación. Es decir: la unidad del sistema importa.

5.1.1. Descomposición matricial de la variabilidad

La partición ortogonal sostiene la evaluación. La identidad $T = H + E$ quedó establecida en el Capítulo 2 y descansa sobre tres matrices con lectura específica — T representa la variación total centrada de las respuestas, H la variación explicada por las covariables y E la variación residual—; a diferencia del escenario univariado, estas matrices conservan toda la información sobre las covarianzas cruzadas. Por eso un solo escalar no basta. La inferencia exige la matriz completa.

Las matrices obtenidas a partir de la estimación son:

$$T = \begin{pmatrix} 1.530996 & 2.060692 & -0.410203 & 1.882758 \\ 2.060692 & 31.669208 & 1.511161 & 28.614078 \\ -0.410203 & 1.511161 & 9.676945 & 3.412932 \\ 1.882758 & 28.614078 & 3.412932 & 41.964210 \end{pmatrix}, \quad (5.1)$$

$$H = \begin{pmatrix} 0.344769 & 1.706085 & -0.093778 & 1.278873 \\ 1.706085 & 30.240871 & 1.725713 & 27.564451 \\ -0.093778 & 1.725713 & 0.967645 & 2.511555 \\ 1.278873 & 27.564451 & 2.511555 & 33.741809 \end{pmatrix}, \quad (5.2)$$

$$E = \begin{pmatrix} 1.186227 & 0.354607 & -0.316425 & 0.603886 \\ 0.354607 & 1.428337 & -0.214552 & 1.049627 \\ -0.316425 & -0.214552 & 8.709300 & 0.901377 \\ 0.603886 & 1.049627 & 0.901377 & 8.222401 \end{pmatrix}. \quad (5.3)$$

La identidad $T = H + E$ se cumple. La verificación numérica confirmó un error máximo absoluto del orden de la precisión de máquina, lo que avala el cálculo de los coeficientes de determinación individuales como $R_j^2 = h_{jj}/t_{jj}$; el marco teórico queda respetado entrada por entrada y la descomposición está lista para la lectura por dimensión. El paso es estructural. Sin él, no hay tabla.

Tabla 5.1: Descomposición de la diagonal principal $T = H + E$ y varianza explicada por dimensión.

Variable respuesta	t_{jj}	h_{jj}	e_{jj}	R_j^2	Dimensión analizada
PCDISC_MEN	1.530996	0.344769	1.186227	0.2252	Salud funcional
P15YM_AN	31.669208	30.240871	1.428337	0.9549	Educación
PDESOCUP	9.676945	0.967645	8.709300	0.1000	Laboral
VPH_SNBIEN	41.964210	33.741809	8.222401	0.8040	Vivienda

La Tabla 5.1 expone diferencias marcadas. El analfabetismo adulto (P15YM_AN, $R^2 = 0.955$) y la carencia de bienes en la vivienda (VPH_SNBIEN, $R^2 = 0.804$) son las dos respuestas mejor explicadas por el modelo; ya que entre los municipios mexicanos esos indicadores tienden a moverse de manera muy regular junto al resto de características sociodemográficas captadas por el Censo, queda poca varianza fuera del alcance del modelo lineal. La lectura es razonable. El sistema absorbe estas dos dimensiones.

La desocupación cuenta otra historia. PDESOCUP arroja $R^2 = 0.100$ —el ajuste más bajo de las cuatro respuestas— y ese nivel reducido es consistente con la naturaleza del mercado laboral municipal en México, condicionado por factores que un corte transversal no logra registrar bien (informalidad, estacionalidad agrícola, migración interna y economía no monetaria de varias regiones rurales); la limitación cognitiva (PCDISC_MEN, $R^2 = 0.225$) también queda con ajuste modesto y su variabilidad responde a factores clínicos, etarios o de acceso a salud que no aparecen entre las covariables. El Censo no captura ese plano. Los predictores disponibles llegan hasta donde llegan.

5.1.2. Magnitud del ajuste conjunto

El operador traza condensa la bondad de ajuste en un escalar único. Aplicado a las matrices de sumas de cuadrados arroja:

$$\text{tr}(T) = 84.841360, \quad (5.4)$$

$$\text{tr}(H) = 65.295095, \quad (5.5)$$

$$\text{tr}(E) = 19.546265. \quad (5.6)$$

De aquí se calcula el coeficiente de determinación multivariado basado en la traza:

$$R_{\text{tr}}^2 = \frac{\text{tr}(H)}{\text{tr}(T)} = 0.769614. \quad (5.7)$$

Es decir,

$$\boxed{R_{\text{tr}}^2 = 0.769614} \quad (5.8)$$

lo que indica que el modelo, en conjunto, explica el 76.96 % de la variabilidad total contenida en la diagonal de T .

Observación 5.1. El coeficiente R_{tr}^2 no es el promedio de los R_j^2 individuales: representa la fracción de varianza total acumulada en la traza de T absorbida por el modelo y, en consecuencia, queda dominado por las respuestas con mayor varianza total. No reemplaza la interpretación detallada por respuesta.

El valor obtenido apunta a un ajuste agregado satisfactorio. La traza queda fuertemente influida por P15YM_AN y VPH_SNBIEN —las dos respuestas con mayor varianza total y mejor ajuste individual— y ese desequilibrio refleja una asimetría sustantiva del sistema; el modelo describe muy bien las dimensiones educativa y habitacional, y describe menos bien las dimensiones laboral y de salud funcional. La traza acumula sesgo de magnitud. Hay que leerla con cabeza.

Tabla 5.2: Estadísticos escalares de ajuste del modelo multivariado basados en la traza.

Métrica	Valor numérico
$\text{tr}(T)$	84.841360
$\text{tr}(H)$	65.295095
$\text{tr}(E)$	19.546265
R_{tr}^2	0.769614

5.1.3. Pruebas globales de significancia multivariada

La inferencia descansa en cuatro estadísticos clásicos, el contraste global del modelo es

$$H_0 : CB = 0 \quad \text{contra} \quad H_1 : CB \neq 0,$$

donde $C \in \mathbb{R}^{10 \times 11}$ es la matriz que elimina la fila del intercepto y selecciona las diez filas de B asociadas a las covariables sociodemográficas. Bajo H_0 , ninguna covariable aporta información lineal sobre el vector de respuestas (PCDISC_MEN, P15YM_AN, PDESOCUP, VPH_SNBIEN) una vez fijado el intercepto; bajo H_1 , al menos una covariable lo hace sobre alguna dimensión o combinación lineal de las respuestas. Los cuatro estadísticos clásicos [1, 3, 9, 19] se construyen a partir del espectro de $E^{-1}H$:

$$\Lambda_{\text{Wilks}} = 0.014891, \quad (5.9)$$

$$V_{\text{Pillai}} = 1.745274, \quad (5.10)$$

$$T_{HL} = 23.983654, \quad (5.11)$$

$$\theta_{\text{Roy}} = 22.500903. \quad (5.12)$$

Las aproximaciones a la distribución F arrojaron

$$F_{\text{Wilks}} = 1389.185999 \quad \text{con gl } (16, 7501), \quad (5.13)$$

y

$$F_{\text{Pillai}} = 422.890044 \quad \text{con gl } (36, 19668), \quad (5.14)$$

ambas con

$$p < 0.0001. \quad (5.15)$$

Tabla 5.3: Estadísticos de prueba para la significancia global del modelo multivariado.

Estadístico de prueba	Valor	Lectura
Lambda de Wilks	0.014891	La varianza residual es muy pequeña frente a la explicada.
Traza de Pillai	1.745274	La varianza explicada acumulada es altamente significativa.
Traza de Hotelling–Lawley	23.983654	La razón señal-ruido del modelo es muy elevada.
Raíz mayor de Roy	22.500903	Un único vector concentra la mayor parte del efecto.

Fijando el nivel convencional $\alpha = 0.05$, la región de rechazo asociada a la aproximación de Rao para Λ con grados de libertad $(\nu_1, \nu_2) = (16, 7501)$ es

$$\mathcal{R}_{0.05} = \{ F_{\text{obs}} > F_{0.95}(16, 7501) \}.$$

El valor crítico es $F_{0.95}(16, 7501) \approx 1.6449$. El estadístico observado $F_{\text{Wilks}} = 1389.186$ supera el umbral por varios órdenes de magnitud, lo que sitúa el resultado en el interior de $\mathcal{R}_{0.05}$ con holgura sobrada y produce $p < 0.0001$. La conclusión es robusta a la elección del estadístico: las aproximaciones a la F de Pillai con grados de libertad (36, 19668) y de Hotelling–Lawley reproducen la misma decisión. Se **rechaza** $H_0 : CB = 0$ al nivel $\alpha = 0.05$.

Los cuatro estadísticos rechazan la nula. El bloque de covariables sociodemográficas mantiene una asociación sistemática con la variabilidad conjunta del rezago social a escala municipal [5], con un nivel de significancia muy por debajo de cualquier umbral convencional; conviene marcar una salvedad importante —lo que aquí se constata es asociación estadística entre agregados municipales, no causalidad—. Los resultados describen distribución conjunta. No explican origen.

5.1.4. Matriz de covarianza residual y dependencia remanente

La matriz de covarianzas residual estimada cierra el ajuste. Sus varianzas residuales de la diagonal principal resultaron:

$$\hat{\sigma}_{11} = 0.000483, \quad \hat{\sigma}_{22} = 0.000581, \quad \hat{\sigma}_{33} = 0.003543, \quad \hat{\sigma}_{44} = 0.003345, \quad (5.16)$$

para PCDISC_MEN, P15YM_AN, PDESOCUP y VPH_SNBIEN, respectivamente. Su magnitud relativa coincide con los R_j^2 reportados —las dimensiones laboral y habitacional concentran más varianza no explicada y la dimensión educativa queda con un residuo proporcionalmente menor.

Las covarianzas fuera de la diagonal sobreviven al ajuste. En $\hat{\Sigma}$ persisten asociaciones positivas, sobre todo entre los residuos de educación y vivienda y entre los residuos de limitación funcional y analfabetismo; eso quiere decir que después de controlar por las covariables las respuestas siguen compartiendo variabilidad que el modelo no captura. La lectura sustantiva apunta hacia factores estructurales comunes (condiciones históricas regionales, dotación de infraestructura pública, geografía) que afectan simultáneamente a varias dimensiones del rezago y que no figuran entre los predictores incluidos. Algo queda fuera del modelo. La covarianza residual lo evidencia.

Observación 5.2. La presencia de correlación residual cruzada no invalida la estimación por mínimos cuadrados: el estimador sigue siendo insesgado bajo los supuestos del modelo. Más bien, confirma que las respuestas mantienen covarianza significativa después del ajuste, lo cual justifica analíticamente el uso del modelo lineal multivariado en lugar de cuatro regresiones univariadas independientes.

5.2. Análisis de los coeficientes y contribución de las covariables

La contribución individual sigue al contraste global. Confirmada la significancia conjunta, el análisis examina ahora el aporte de cada covariable —y conviene una alerta operativa de entrada—; cuando los predictores están correlacionados entre sí, situación habitual en datos territoriales agregados, leer los coeficientes como efectos aislados puede llevar a conclusiones engañosas [1]. La trampa es la colinealidad. La parcialización corrige la lectura.

La matriz de coeficientes estimados es

$$\hat{B} \in \mathbb{R}^{11 \times 4} \quad (5.17)$$

y resume la asociación entre cada predictor sociodemográfico y cada variable respuesta. Su lectura razonable requiere considerar simultáneamente cuatro elementos: signo, magnitud, respuesta de referencia y patrón de correlación entre las covariables.

El cálculo arrojó:

$$\hat{B} = \begin{pmatrix} 0.106935 & 0.297882 & 0.135322 & 0.189121 \\ 0.004774 & 0.010997 & -0.001897 & 0.052201 \\ 0.001401 & -0.000463 & 0.007862 & 0.018745 \\ -0.008690 & 0.002075 & 0.001652 & 0.006412 \\ -0.006885 & 0.001929 & 0.024141 & 0.024088 \\ 0.003845 & 0.011654 & -0.020712 & 0.018644 \\ 0.000620 & 0.000321 & 0.000888 & -0.004032 \\ -0.001281 & -0.002763 & -0.005936 & -0.016617 \\ 0.010370 & 0.092101 & -0.001975 & 0.019355 \\ -0.003091 & -0.007179 & 0.002934 & 0.001273 \\ 0.004385 & -0.000405 & -0.003951 & -0.003634 \end{pmatrix}. \quad (5.18)$$

La primera fila corresponde al intercepto; siguen, en orden, los coeficientes de VPH_PISOTI, VPH_NDEAED, PRO_OCUP_C, P3HLINHE, PHOG_IND, POB_AFRO, PSINDER, P15YM_SE, PSIN_RELIG y PRESOE15. Las columnas, en ese orden: PCDISC_MEN, P15YM_AN, PDESOCUP y VPH_SNBIEN.

La estandarización fija la lectura comparativa. Como estandaricé las covariables, cada coeficiente representa el cambio esperado en la respuesta —en su escala transformada— ante un incremento de una desviación estándar en la covariable manteniendo el resto constante; esta propiedad habilita la comparación de magnitudes relativas entre coeficientes. Aun así, conviene leerlos con cautela dada la colinealidad de los datos territoriales agregados [3]. La métrica común facilita el ranking.

5.2.1. Jerarquía explicativa por pruebas parciales multivariadas

Confirmada la significancia conjunta, el análisis examina el aporte de cada covariable mediante una sucesión de pruebas parciales. Sea $c_j \in \mathbb{R}^q$ el vector que tiene un uno en la posición correspondiente al predictor j y ceros en las restantes (en particular en la posición del intercepto). Para cada $j \in \{1, \dots, 10\}$ el contraste parcial es

$$H_{0j} : c_j' B = 0_{1 \times p} \quad \text{contra} \quad H_{1j} : c_j' B \neq 0_{1 \times p},$$

de rango 1: bajo H_{0j} , la fila de $\hat{B}$ asociada al predictor j es cero en las $p = 4$ respuestas simultáneamente. Operacionalmente, H_{0j} se evalúa comparando la matriz residual del modelo completo E con la del modelo reducido $E_{(-j)}$ que omite la covariable j :

$$H_j = E_{(-j)} - E.$$

La matriz H_j es semidefinida positiva y mide la contribución marginal del predictor j al ajuste, controlando por las demás covariables (contraste tipo III). Los estadísticos Λ_j , V_j , $T_{HL,j}$ y θ_j se construyen entonces sobre el par (H_j, E) usando la misma aproximación a la F de la Subsección 5.1.3, ahora con $\text{rang}(c_j') = 1$, lo que arroja grados de libertad $(p, n - q - p + 1) = (4, 2455)$. La región de rechazo individual es

$$\mathcal{R}_\alpha^{(j)} = \{ F_{\text{obs}}^{(j)} > F_{1-\alpha}(4, 2455) \}.$$

Los resultados se condensan en la Tabla 5.4; el ordenamiento sigue la traza de Pillai. Cada renglón es un contraste independiente; no se aplica corrección por multiplicidad porque el interés es comparativo, no de control global del error tipo I [1].

Las pruebas parciales miden el aporte marginal. Para cada covariable la hipótesis nula es que su fila de coeficientes en $\hat{B}$ es cero, y el estadístico se construye comparando la matriz de sumas de cuadrados residuales del modelo completo con la del reducido —el que omite esa covariable. La diferencia hace la prueba. El esquema es estricto.

La matriz de hipótesis marginal cierra la formulación. En forma matricial esa diferencia define el bloque H_j correspondiente al predictor (Sección 3.4.2) [1] y los resultados quedan condensados

Tabla 5.4: Significancia marginal de las covariables explicativas (pruebas parciales tipo III), ordenada por el estadístico Traza de Pillai.

Variable explicativa	Λ Wilks	V Pillai	F_{Wilks}	p_{Wilks}	F_{Pillai}	p_{Pillai}
P15YM_SE	0.125925	0.874075	4260.18	< 0.0001	3792.23	< 0.0001
VPH_PISOTI	0.730536	0.269464	226.39	< 0.0001	201.52	< 0.0001
P3HLINHE	0.881024	0.118976	82.86	< 0.0001	73.43	< 0.0001
PHOG_IND	0.886819	0.113181	78.33	< 0.0001	69.43	< 0.0001
PRO_OCUP_C	0.898604	0.101396	69.25	< 0.0001	61.55	< 0.0001
PSIN_RELIG	0.910306	0.089694	60.50	< 0.0001	53.81	< 0.0001
VPH_NDEAED	0.914510	0.085490	57.43	< 0.0001	51.07	< 0.0001
PSINDER	0.924133	0.075867	50.39	< 0.0001	44.83	< 0.0001
PRESOE15	0.955161	0.044839	28.79	< 0.0001	25.65	< 0.0001
POB_AFRO	0.992282	0.007718	4.77	0.0008	4.25	0.0021

Nota: Las pruebas parciales corresponden a contrastes tipo III en los que cada covariable individual genera una hipótesis de rango 1 (una fila de $B = 0$). Las aproximaciones F siguen la fórmula de Rao con grados de libertad $(p, n - q - p + 1) = (4, 2455)$.

en la Tabla 5.4; el ordenamiento sigue la traza de Pillai. Cada renglón es un contraste. El cuadro lo dice todo.

El cuadro deja ver algo elocuente. La contribución parcial no se reparte de manera pareja entre los predictores —al contrario, una porción enorme de la varianza explicada se concentra en una sola covariable— y la jerarquía resulta marcadamente asimétrica desde el primer escalón. La Figura 5.1 grafica esa jerarquía. Una variable domina el sistema.




Figura 5.1: Contribución explicativa marginal de cada covariable medida mediante la traza de Pillai. El ajuste del modelo descansa fuertemente en unas pocas variables.

P15YM_SE encabeza el ranking con

$$V_{\text{P15YM_SE}} = 0.874075, \quad F_{\text{Pillai}} = 3792.228825. \quad (5.19)$$

La proporción de población de 15 años o más sin escolaridad es, con bastante margen, el predictor que más varianza marginal explica del sistema conjunto de respuestas; el hallazgo se alinea con la

lectura habitual de la literatura sobre rezago social en México —los municipios con menor acceso a educación formal acumulan también las demás carencias [3]. Educación arrastra al resto.

VPH_PISOTI ocupa el segundo lugar con

$$V_{\text{VPH_PISOTI}} = 0.269464. \quad (5.20)$$

La proporción de viviendas con piso de tierra sostiene una contribución significativa aun controlando por las demás variables; un reflejo de que la calidad básica de la vivienda actúa como marcador territorial robusto del rezago.

El resto de las covariables aporta menos varianza marginal —con una excepción que merece subrayarse—. POB_AFRO no alcanza significancia estadística:

$$p_{\text{Wilks}} = 0.2665, \quad p_{\text{Pillai}} = 0.3775. \quad (5.21)$$

El resultado no niega la relevancia demográfica de la población afrodescendiente. Indica algo más sutil —una vez controlando por el resto de covariables, la proporción de población afrodescendiente no añade información explicativa adicional sobre las cuatro dimensiones de rezago consideradas— y por tanto el hallazgo es estrictamente condicional; descriptivamente la asociación puede existir, pero queda absorbida por los predictores con mayor poder. La parcialización borra la huella. No es lectura ingenua.

Esta no significancia no implica ausencia de marginación entre la población afrodescendiente en México. Significa, en términos estrictamente estadísticos, que la variación espacial de la proporción de población afromexicana entre municipios no añade información explicativa marginal sobre el rezago una vez que se controla por educación, vivienda y lengua. Un análisis dirigido específicamente a evaluar marginación étnica requeriría microdatos a nivel individual o de hogar y una unidad de análisis distinta. El hallazgo es estrictamente condicional al conjunto de covariables incluido y no descriptivo de la situación social de esta población.

El ordenamiento de las covariables por su contribución parcial queda así:

$$\begin{aligned} \text{P15YM_SE} &\gg \text{VPH_PISOTI} > \text{P3HLINHE} \approx \text{PHOG_IND} \\ &> \text{PRO_OCUP_C} > \text{PSIN_RELIG} > \text{VPH_NDEAED} \\ &> \text{PSINDER} > \text{PRESOE15} \gg \text{POB_AFRO}. \end{aligned} \quad (5.22)$$

5.2.2. Distribución de efectos por respuesta y patrones de signo

La lectura por columnas refina el análisis. Establecida la jerarquía global de los predictores, conviene revisar cómo se reparten sus efectos sobre cada respuesta —dimensión por dimensión— y la matriz $\hat{B}$ admite directamente esa partición:

$$\hat{B} = (\hat{\beta}^{(1)}, \hat{\beta}^{(2)}, \hat{\beta}^{(3)}, \hat{\beta}^{(4)}), \quad (5.23)$$

donde cada $\hat{\beta}^{(k)}$ recoge los efectos parciales sobre la respuesta k . Examinar las columnas saca a flote magnitud y dirección de cada efecto, dejando ver asimetrías entre dimensiones.

Estructura de coeficientes para P15YM_AN

P15YM_SE domina la columna del analfabetismo. El coeficiente de mayor magnitud corresponde a

$$\hat{\beta}_{\text{P15YM_SE, P15YM_AN}} = 0.092101. \quad (5.24)$$

La relación cae por su propio peso —los municipios con mayor proporción de población sin escolaridad registran mayores tasas de analfabetismo adulto—. Son dos caras del mismo fenómeno educativo. El modelo también detecta efectos positivos —de menor cuantía— asociados a PHOG_IND, VPH_PISOTI y PRO_OCUP_C:

$$0.011654, \quad 0.010997, \quad 0.002075. \quad (5.25)$$

Es decir: la tasa de analfabetismo municipal se asocia positivamente con la presencia de hogares indígenas, con viviendas de piso de tierra y con hacinamiento, manteniendo lo demás constante. La lectura es consistente con la geografía del rezago educativo en México.

Estructura de coeficientes para VPH_SNBIEN

VPH_PISOTI encabeza la columna de bienes. Para la proporción de viviendas sin bienes, el coeficiente dominante corresponde a

$$\hat{\beta}_{\text{VPH_PISOTI, VPH_SNBIEN}} = 0.052201. \quad (5.26)$$

La relación tiene sentido directo. Precariedad estructural de la vivienda (piso de tierra) y ausencia de bienes son dos caras de la misma carencia material. A su lado, efectos positivos de magnitud apreciable provienen de P3HLINHE, P15YM_SE, VPH_NDEAED y PHOG_IND:

$$0.024088, \quad 0.019355, \quad 0.018745, \quad 0.018644. \quad (5.27)$$

Las viviendas sin bienes se concentran, así que, en municipios con mayor proporción de población que no habla español, mayor falta de escolaridad, peor acceso a drenaje y mayor presencia de hogares indígenas. El patrón remite a un rezago habitacional con raíz cruzada.

Estructura de coeficientes para PDESOCUP

P3HLINHE aporta el mayor efecto positivo. Los coeficientes para la desocupación presentan una mezcla de signos más amplia y el efecto positivo dominante corresponde a

$$\hat{\beta}_{\text{P3HLINHE, PDESOCUP}} = 0.024141, \quad (5.28)$$

seguido por VPH_NDEAED:

$$\hat{\beta}_{\text{VPH_NDEAED, PDESOCUP}} = 0.007862. \quad (5.29)$$

En contraste, PHOG_IND y PSINDER aparecen con signos negativos:

$$-0.020712, \quad -0.005936. \quad (5.30)$$

La mezcla de signos confirma algo que ya insinuaba el bajo $R^2_{\text{PDESOCUP}} = 0.100$. La desocupación municipal en México no responde de manera uniforme a las covariables consideradas porque buena parte de la dinámica laboral fluye por canales que el Censo no captura bien (informalidad, autoempleo en zonas rurales, migración estacional, actividad económica de subsistencia); el coeficiente negativo de PHOG_IND es consistente con el hecho de que en municipios con alta presencia indígena la actividad económica predominante (agrícola, de autoconsumo o informal) no se reporta sistemáticamente como desocupación bajo la definición censal, lo cual produce tasas medidas de desocupación menores sin que ello implique mayor bienestar laboral. Esta limitación de medición es inherente a los datos censales transversales.

Estructura de coeficientes para PCDISC_MEN

La columna de salud funcional exhibe los coeficientes más pequeños. Los efectos positivos de mayor magnitud provienen de P15YM_SE, VPH_PISOTI y PRESOE15:

$$\hat{\beta}_{\text{P15YM_SE, PCDISC_MEN}} = 0.010370, \quad \hat{\beta}_{\text{VPH_PISOTI, PCDISC_MEN}} = 0.004774, \quad \hat{\beta}_{\text{PRESOE15, PCDISC_MEN}} = 0.004385. \quad (5.31)$$

La pequeña magnitud de estos efectos confirma una intuición razonable: las características educativas, habitacionales o lingüísticas no son predictores naturales de una limitación cognitiva. La prevalencia municipal depende, sobre todo, de factores etarios, clínicos y de acceso a servicios de salud—dimensiones que el Censo 2020 no desagrega.

Análisis del vector paramétrico asociado a PSINDER

PSINDER arrastra signos uniformemente negativos. La fila de coeficientes de la población sin afiliación a servicios de salud, leída horizontalmente en la matriz, exhibe:

$$\hat{\beta}_{\text{PSINDER}} = (-0.001281, -0.002763, -0.005936, -0.016617). \quad (5.32)$$

Una lectura ingenua diría que la falta de seguro médico reduce el rezago —conclusión patentemente errónea—. La explicación es estadística. En un modelo de regresión múltiple los coeficientes son efectos parciales que ya descuentan la covariación con los demás predictores [3], así que como PSINDER está fuertemente correlacionada con la falta de escolaridad y con la precariedad habitacional —una vez que esas covariables absorbieron la mayor parte del efecto— el coeficiente residual puede invertirse o reducirse a valores cercanos a cero. Los signos negativos no contradicen la asociación real entre falta de servicios de salud y rezago. La asociación queda absorbida.

La evidencia cuantitativa de la absorción colineal es directa. En la matriz de diseño estandarizada se observan correlaciones bivariadas de PSINDER con los demás indicadores de rezago: $\text{corr}(\text{PSINDER}, \text{P15YM_SE}) = -0.193$, $\text{corr}(\text{PSINDER}, \text{P15YM_AN}) = -0.174$, $\text{corr}(\text{PSINDER}, \text{P3HLINHE}) = -0.198$ y $\text{corr}(\text{PSINDER}, \text{VPH_SNBIEN}) = -0.267$. Es decir, PSINDER se correlaciona *negativamente* con todos los demás indicadores de rezago —un artefacto del Censo 2020 según el cual los municipios con mayor cobertura del esquema universal de salud no contributivo (Seguro Popular hasta su disolución en enero de 2020, transición al INSABI durante el mismo año) presentan alta proporción de no afiliados a IMSS/ISSSTE y son precisamente los más rurales y marginados, donde el esquema universal sustituyó a los esquemas contributivos formales—. El coeficiente de PSINDER en el modelo conjunto recibe entonces signos negativos en las cuatro respuestas porque, una vez controlado por P15YM_SE, VPH_PISOTI y el resto del bloque, el residuo informativo de PSINDER mide variación intra-grupo —heterogeneidad entre municipios igualmente educados o igualmente carenciados en vivienda—, no la asociación bivariada bruta.

5.2.3. Colinealidad sustantiva y lectura de efectos parciales

Los coeficientes de $\hat{B}$ son efectos condicionales. Construidos en la Sección 2.5, capturan asociación neta una vez descontada la covariación con el resto de predictores, y cuando los predictores comparten varianza algunos coeficientes pueden aparecer atenuados o con signos contraintuitivos [15]. La colinealidad en estos datos es regla, no excepción —las dimensiones de educación, vivienda, lengua y salud tienden a moverse al unísono en el territorio mexicano. El fenómeno empuja en bloque.

Las correlaciones bivariadas más altas en la matriz de diseño son:

$$\text{corr}(\text{P15YM_SE}, \text{P15YM_AN}) = 0.963527, \quad (5.33)$$

$$\text{corr}(\text{VPH_SNBIEN}, \text{VPH_PISOTI}) = 0.796176, \quad (5.34)$$

$$\text{corr}(\text{P3HLINHE}, \text{PHOG_IND}) = 0.787081. \quad (5.35)$$

Valores tan altos hacen que la reducción de los residuos se concentre en uno o dos predictores dominantes, así que las covariables correlacionadas con ellos quedan con coeficientes pequeños; por eso un predictor como PSINDER, descriptivamente asociado al rezago, recibe en el modelo conjunto un peso modesto.

Observación 5.3. A pesar de la colinealidad sustantiva, el cálculo numérico es estable. El número de condición de la matriz de diseño fue $\kappa(X) = 4.5485$, un nivel cómodamente lejos de los umbrales asociados a inestabilidad en la inversión [15]. La colinealidad observada es un rasgo del fenómeno medido —las dimensiones de la marginación viajan juntas en el territorio mexicano— y no un problema computacional para el ajuste por mínimos cuadrados.

Los coeficientes de $\hat{B}$ deben leerse como medidas de asociación condicionada, no como efectos aislados de cada variable; su signo y magnitud cobran sentido únicamente a la luz del bloque completo de covariables.

5.3. Estructura canónica del modelo

La descomposición espectral afina la lectura. Esta herramienta condensa las relaciones cruzadas entre respuestas y predictores en un puñado de combinaciones lineales —las direcciones canónicas— ordenadas por la fuerza de la asociación que recogen [5]; cada dirección comprime un patrón de covariación cruzada en un solo eje. El espectro habla. Cuatro ejes, cuatro lecturas.

5.3.1. Problema espectral del modelo

El problema de valores propios generalizado de la Sección 2.6.5 genera las direcciones. El valor propio λ_i mide la razón entre varianza explicada y varianza residual en la dirección del i -ésimo vector, y el cálculo arrojó cuatro raíces:

$$\lambda_1 = 22.500903, \quad \lambda_2 = 1.198835, \quad \lambda_3 = 0.208738, \quad \lambda_4 = 0.075177. \quad (5.36)$$

La asimetría $\lambda_1 \gg \lambda_2 > \lambda_3 > \lambda_4$ destapa un hecho central. Aunque el modelo tiene cuatro respuestas, la asociación con los predictores se concentra prácticamente en una sola dirección; en el plano de las covarianzas explicadas, el sistema se comporta como si tuviera un único eje dominante. Un eje carga todo. Los demás aportan poco.

Las proporciones normalizadas sintetizan la asimetría:

$$\pi_1 \approx 0.9380, \quad (5.37)$$

$$\pi_2 \approx 0.0500, \quad (5.38)$$

$$\pi_3 \approx 0.0087, \quad (5.39)$$

$$\pi_4 \approx 0.0031. \quad (5.40)$$

El primer componente concentra cerca del 93.8 % de la asociación cruzada que el modelo captura. Los tres restantes apenas suman el 6.2 %, de modo que la mayor parte de la variabilidad conjunta del rezago municipal admite una lectura sobre una única dimensión principal —los predictores actúan colectivamente sobre ese eje y dejan al resto un papel marginal. Es la dimensión maestra y tres dimensiones marginales.

Tabla 5.5: Valores propios de la matriz $E^{-1}H$ y varianza relativa explicada.

Componente	Valor propio λ_i	Proporción π_i
CAN1	22.500903	0.9380
CAN2	1.198835	0.0500
CAN3	0.208738	0.0087
CAN4	0.075177	0.0031

5.3.2. Correlaciones canónicas y fuerza de asociación

La relación $\rho_i^2 = \lambda_i / (1 + \lambda_i)$ del Marco Teórico entrega los valores:

$$\rho_1^2 \approx 0.957449, \quad (5.41)$$

$$\rho_2^2 \approx 0.545214, \quad (5.42)$$

$$\rho_3^2 \approx 0.172696, \quad (5.43)$$

$$\rho_4^2 \approx 0.069919, \quad (5.44)$$

con las correspondientes correlaciones canónicas:

$$\rho_1 \approx 0.978493, \quad (5.45)$$

$$\rho_2 \approx 0.738386, \quad (5.46)$$

$$\rho_3 \approx 0.415561, \quad (5.47)$$

$$\rho_4 \approx 0.264425. \quad (5.48)$$

La correlación del primer par

$$\rho_1 \approx 0.9785, \quad (5.49)$$

es extremadamente alta. Existe una combinación lineal de las respuestas y otra de los predictores que están casi perfectamente correlacionadas entre sí, y esa asociación dominante es justamente la que produce los valores extremos de los estadísticos globales (Wilks, Pillai, Hotelling–Lawley) y el rechazo categórico de la hipótesis nula. El primer par carga la inferencia. El resto la complementa.

Tabla 5.6: Correlaciones canónicas asociadas a cada dirección.

Componente	λ_i	ρ_i^2	ρ_i
CAN1	22.500903	0.957449	0.978493
CAN2	1.198835	0.545214	0.738386
CAN3	0.208738	0.172696	0.415561
CAN4	0.075177	0.069919	0.264425

La caída tras CAN1 es brusca. La Tabla 5.6 muestra que solo el primer par alcanza una asociación muy alta; las direcciones siguientes recogen patrones secundarios de variabilidad cruzada con fuerza decreciente. Un componente eclipsa a los demás.

5.3.3. Normalización canónica y matriz de coeficientes

Los vectores canónicos del lado de las respuestas se ordenan en una matriz A cuyas columnas son las direcciones $\mathbf{a}_i$:

$$A = \begin{pmatrix} -0.212586 & 0.205839 & -0.869525 & -0.300174 \\ 0.839132 & 0.327738 & 0.087898 & 0.013811 \\ 0.017153 & 0.019384 & 0.076632 & -0.334646 \\ 0.037178 & -0.366911 & -0.049312 & 0.024407 \end{pmatrix}, \quad (5.50)$$

con las filas correspondientes a PCDISC_MEN, P15YM_AN, PDESOCUP y VPH_SNBIEN. La normalización utilizada satisface $A'EA = I_4$ [1], lo que habilita comparar magnitudes entre columnas. La proyección $Z_i = \mathbf{a}_i'Y$ define la variable canónica asociada a cada dirección.




Figura 5.2: Valor absoluto de los coeficientes canónicos para cada dirección.

El heatmap revela la distribución de los pesos. La Figura 5.2 muestra de un vistazo que CAN1 está casi totalmente dominada por P15YM_AN, CAN2 contrasta VPH_SNBIEN con P15YM_AN, CAN3 está dominada por PCDISC_MEN y CAN4 reparte el peso entre PDESOCUP y PCDISC_MEN. Cada componente tiene su firma. Ninguna se solapa con otra.

5.3.4. Primera dirección canónica: eje educativo

La primera variable canónica tiene la forma

$$\text{CAN1} = -0.212586 \text{PCDISC_MEN} + 0.839132 \text{P15YM_AN} + 0.017153 \text{PDESOCUP} + 0.037178 \text{VPH_SNBIEN}, \quad (5.51)$$

con la siguiente distribución de pesos relativos (en valor absoluto, normalizados por suma):

$$w_{\text{P15YM_AN},1} = 0.758675, \quad (5.52)$$

$$w_{\text{PCDISC_MEN},1} = 0.192203, \quad (5.53)$$

$$w_{\text{VPH_SNBIEN},1} = 0.033613, \quad w_{\text{PDESOCUP},1} = 0.015508. \quad (5.54)$$

Más del 75 % del peso recae en el analfabetismo adulto. Cruzar este dato con el hecho de que CAN1 absorbe el 93.8 % de la varianza explicable lleva a una conclusión nítida —la asociación principal entre los predictores sociodemográficos y el rezago municipal pasa, en buena medida, por la dimensión educativa— y el analfabetismo adulto funciona como indicador-eje del sistema; eso encaja con la observación, ya reportada en el análisis de coeficientes, de que P15YM_SE es el predictor con mayor contribución marginal. Educación define el eje. Lo demás gira a su alrededor.

5.3.5. Segunda dirección canónica: contraste educación-vivienda

La segunda variable canónica tiene la forma

$$\text{CAN2} = 0.205839 \text{PCDISC_MEN} + 0.327738 \text{P15YM_AN} + 0.019384 \text{PDESOCUP} - 0.366911 \text{VPH_SNBIEN}, \quad (5.55)$$

con pesos relativos dominantes:

$$w_{\text{VPH_SNBIEN},2} = 0.398872, \quad w_{\text{P15YM_AN},2} = 0.356287. \quad (5.56)$$

El contraste de signos define CAN2. P15YM_AN entra con signo positivo (0.327738) y VPH_SNBIEN con signo negativo (−0.366911), de modo que la segunda dirección captura una asociación residual donde el analfabetismo y la carencia de bienes no se mueven juntos —sino en sentidos opuestos—; en la geografía mexicana este componente recoge la heterogeneidad entre municipios donde la dimensión educativa y la habitacional no van perfectamente alineadas (municipios con cierta carencia material pero menor analfabetismo, o viceversa). Es variabilidad de segundo orden. CAN1 no la alcanza.

5.3.6. Tercera dirección canónica: eje cognitivo

La tercera variable canónica tiene la forma

$$\text{CAN3} = -0.869525 \text{PCDISC_MEN} + 0.087898 \text{P15YM_AN} + 0.076632 \text{PDESOCUP} - 0.049312 \text{VPH_SNBIEN}, \quad (5.57)$$

con pesos relativos altamente concentrados:

$$w_{\text{PCDISC_MEN},3} = 0.802614, \quad (5.58)$$

$$w_{\text{P15YM_AN},3} = 0.081134, \quad w_{\text{PDESOCUP},3} = 0.070735, \quad w_{\text{VPH_SNBIEN},3} = 0.045517. \quad (5.59)$$

Más del 80 % del peso recae en PCDISC_MEN; las tres respuestas restantes aportan en conjunto menos del 20 %. La correlación canónica $\rho_3 = 0.4156$ es moderada pero estadísticamente real,

y el componente absorbe el 0.87 % de la asociación total. Esta dirección revela un hallazgo que escapa al análisis univariado: PCDISC_MEN, la respuesta peor explicada por el ajuste marginal ($R^2_{\text{PCDISC_MEN}} = 0.225$), domina un eje canónico propio. Aunque las covariables sociodemográficas no expliquen bien la magnitud media de la limitación cognitiva municipal, el sistema multivariado sí identifica una dirección donde la variación residual de PCDISC_MEN se asocia coherentemente con los predictores. Cuatro regresiones univariadas separadas, por construcción, no habrían detectado esta estructura. El eje cognitivo emerge en el espacio canónico.

5.3.7. Cuarta dirección canónica: contraste laboral-cognitivo

La cuarta variable canónica tiene la forma

$$\text{CAN4} = -0.300174 \text{PCDISC_MEN} + 0.013811 \text{P15YM_AN} - 0.334646 \text{PDESOCUP} + 0.024407 \text{VPH_SNBIEN}, \quad (5.60)$$

con pesos repartidos entre dos respuestas:

$$w_{\text{PDESOCUP},4} = 0.497217, \quad w_{\text{PCDISC_MEN},4} = 0.445999. \quad (5.61)$$

Casi el 95 % del peso se concentra en PDESOCUP y PCDISC_MEN, ambos con coeficiente negativo. La correlación canónica $\rho_4 = 0.2644$ es la más débil del bloque y la dimensión absorbe únicamente el 0.31 % de la asociación total, por lo que su interpretación es secundaria. No obstante, el patrón conjunto de signos negativos en las dos respuestas peor ajustadas por el modelo lineal sugiere una lectura sustantiva: en municipios donde la actividad económica informal o de autoconsumo subreporta sistemáticamente la desocupación medida (la población económicamente activa se contrae a la fuerza laboral monetarizada) y, simultáneamente, el acceso reducido a servicios de salud limita el diagnóstico formal de limitaciones cognitivas, ambos indicadores se mueven a la baja por un mismo mecanismo estructural de medición del Censo. El eje recoge así un componente residual de subreporte que las covariables disponibles no logran explicar marginalmente.

5.3.8. Representación geométrica del espacio canónico

Las proyecciones visualizan la estructura. Proyectar los municipios sobre el subespacio que generan las variables canónicas permite leer geoméricamente la organización del rezago.




Figura 5.3: Distribución de los municipios en el subespacio tridimensional definido por las tres primeras variables canónicas. La dispersión se concentra de manera marcada a lo largo de CAN1.




Figura 5.4: Proyecciones bidimensionales de los municipios sobre los planos canónicos. La dispersión a lo largo de CAN1 es notoriamente mayor que en las direcciones secundarias.

Ambas figuras refuerzan el hallazgo numérico. La mayor parte de la variabilidad municipal en el espacio canónico se acomoda sobre una sola dirección y esa concentración geométrica respalda la idea de que el rezago municipal en México —fenómeno multidimensional por construcción— admite una lectura sintética a lo largo de un eje principal asociado al rezago educativo; las direcciones secundarias aportan información útil, pero marginal frente a CAN1 [1]. La geometría confirma el espectro. Un eje basta.

5.4. Diagnóstico del modelo y evaluación de supuestos

Los supuestos sobre los residuos faltan por verificar. Antes de cerrar la lectura sustantiva, evalúo empíricamente normalidad multivariada, homocedasticidad, independencia y ausencia de observaciones que dominen indebidamente la estimación; el diagnóstico se ejecutó sobre $\hat{U}$ y $\hat{\Sigma}$ (Sección 3.5). Cada supuesto exige su tamiz. Ningún tamiz se salta.

5.4.1. Normalidad multivariada de los residuos

El modelo postula que las filas del término de error siguen una distribución normal multivariada con matriz de covarianzas común. Sobre los residuos estimados, el juego de hipótesis es

$$H_0 : u_i \sim N_p(0, \Sigma), \quad i = 1, \dots, n \quad \text{contra} \quad H_1 : u_i \not\sim N_p(0, \Sigma).$$

Los coeficientes de Mardia [13] permiten construir dos contrastes asintóticos:

- **Asimetría multivariada:** bajo H_0 , el estadístico $n b_{1,p}/6$ sigue asintóticamente una distribución χ^2 con $\nu = p(p+1)(p+2)/6$ grados de libertad. Con $p = 4$, $\nu = 20$. La región de rechazo al nivel α es

$$\mathcal{R}_\alpha^{\text{asim}} = \{ n b_{1,p}/6 > \chi_{20, 1-\alpha}^2 \}.$$

- **Curtosis multivariada:** bajo H_0 , el estadístico

$$Z_{2,p} = \frac{b_{2,p} - p(p+2)}{\sqrt{8p(p+2)/n}}$$

sigue asintóticamente una distribución $N(0, 1)$. La región de rechazo bilateral al nivel α es

$$\mathcal{R}_\alpha^{\text{curt}} = \{ |Z_{2,p}| > z_{1-\alpha/2} \}.$$

Los valores observados se reportan en la Tabla 5.7; ambos exceden los umbrales convencionales con $\alpha = 0.05$. Conviene subrayar el papel de este diagnóstico: **no** es una prueba global del modelo de regresión, sino una verificación del supuesto distribucional residual. Su rechazo no invalida la estimación de $\hat{B}$ —que sigue siendo insesgada—, pero sí pone en cautela la exactitud finita de los p -valores asintóticos, especialmente para Wilks y Hotelling–Lawley, y favorece la lectura sustantiva basada en Pillai por su robustez documentada frente a desviaciones de normalidad [11].

La Tabla 5.7 exhibe rechazo claro. La distancia de Mahalanobis residual al cuadrado, que bajo normalidad debería seguir aproximadamente una χ_p^2 , se contrastó con los umbrales:

$$\chi_{4, 0.975}^2 = 11.143287, \quad \chi_{4, 0.990}^2 = 13.276704. \quad (5.62)$$

La cantidad de municipios que rebasa estos umbrales es de 184 y 134 respectivamente, un patrón que confirma la presencia de colas pesadas en la distribución residual.

El Q-Q plot hace visible la separación. La Figura 5.5 expone la divergencia entre la distribución empírica y la teórica sobre todo en los cuantiles superiores, y la interpretación sustantiva apunta a un grupo de municipios cuyas combinaciones de respuestas se desvían del comportamiento típico del resto —como se verá enseguida, perfiles de rezago extremo.

Tabla 5.7: Pruebas de normalidad multivariada de Mardia sobre los residuos.

Componente	Estadístico	Valor	gl	p-valor
Asimetría multivariada $b_{1,p}$	descriptivo	5.4096	—	—
Curtosis multivariada $b_{2,p}$	descriptivo	54.0395	—	—
χ^2 para asimetría	$n b_{1,p}/6$	2226.0326	20	< 0.0001
Z para curtosis	$(b_{2,p} - p(p+2))/\sqrt{8p(p+2)/n}$	107.7217	—	< 0.0001

Nota: Bajo normalidad multivariada $E(b_{2,p}) = p(p+2) = 24$ para $p = 4$; el valor observado $b_{2,p} = 54.04$ indica colas pesadas respecto a la normal.




Figura 5.5: Gráfico Q-Q de la distancia de Mahalanobis residual contra la distribución χ^2_4 de referencia.

5.4.2. Estructura residual y diagnóstico de heterocedasticidad

La homocedasticidad pasa por dos tamices. Examiné los residuos estandarizados frente a los valores ajustados y apliqué una versión multivariada del diagnóstico tipo White [14, 20].




Figura 5.6: Residuos estandarizados frente a valores ajustados, por variable respuesta.

Tabla 5.8: Diagnóstico auxiliar de heterocedasticidad multivariada (extensión tipo White sobre $\text{vech}(u_i u_i')$).

Estadístico auxiliar	Valor calculado
Lambda de Wilks	0.2898085
Traza de Pillai	1.120100
F_{Wilks}	32.39199 ($p = 0.0000$)
F_{Pillai}	28.87376 ($p = 0.0000$)

Observación 5.4. Conviene aclarar que este procedimiento es un diagnóstico auxiliar tipo White aplicado sobre $\text{vech}(u_i u_i')$, no la prueba clásica univariada de White. Es útil como evidencia complementaria de heterogeneidad en la dispersión, pero no debe presentarse como un test formal estándar.

Inspección visual y diagnóstico auxiliar coinciden. La dispersión de los residuos no es constante a lo largo del rango de valores ajustados —el modelo es más preciso en municipios con perfiles cercanos a la media y menos preciso en los extremos— y la estructura empírica del fenómeno lo explica; en México el rezago se distribuye de forma muy desigual entre regiones, así que los municipios con privaciones extremas exhiben mayor variabilidad residual que los urbanos consolidados. La heterogeneidad geográfica entre municipios induce variabilidad residual no constante, en violación del supuesto de homocedasticidad.

El presente trabajo no implementa corrección de varianzas tipo Huber–White (sandwich) para los errores estándar de $\hat{B}$. Esta extensión es natural dada la heterocedasticidad detectada y queda señalada como una de las líneas de mejora identificadas en el Capítulo de Conclusiones. En su lugar, la inferencia global descansa en la robustez asintótica de la traza de Pillai frente a desviaciones moderadas de homocedasticidad [11]; los p -valores reportados deben interpretarse en consecuencia como aproximaciones razonables, no exactas. La estimación puntual de $\hat{B}$ permanece insesgada bajo los supuestos del modelo, lo cual no se ve afectado por la corrección sandwich; lo que la corrección modifica es la matriz de covarianzas del estimador y, por tanto, los intervalos de confianza individuales.

5.4.3. Correlación residual remanente

La matriz de correlaciones residuales conserva dependencia. Aun después del ajuste, persisten asociaciones moderadas entre algunas respuestas:

$$\text{CORR}(\hat{u}_{\text{P15YM_AN}}, \hat{u}_{\text{VPH_SNBIEN}}) \approx 0.306, \quad (5.63)$$

$$\text{CORR}(\hat{u}_{\text{PCDISC_MEN}}, \hat{u}_{\text{P15YM_AN}}) \approx 0.272. \quad (5.64)$$

Las cuatro correlaciones residuales restantes son menores pero informativas:

$$\text{CORR}(\hat{u}_{\text{PCDISC_MEN}}, \hat{u}_{\text{VPH_SNBIEN}}) \approx 0.193, \quad \text{CORR}(\hat{u}_{\text{PDESOCUP}}, \hat{u}_{\text{VPH_SNBIEN}}) \approx 0.107, \quad (5.65)$$

$$\text{CORR}(\hat{u}_{\text{PCDISC_MEN}}, \hat{u}_{\text{PDESOCUP}}) \approx -0.098, \quad \text{CORR}(\hat{u}_{\text{P15YM_AN}}, \hat{u}_{\text{PDESOCUP}}) \approx -0.061. \quad (5.66)$$

Esos valores indican que tras controlar por los predictores sobreviven asociaciones moderadas entre respuestas, con un patrón sustantivo claro: la dimensión laboral (PDESOCUP) se separa parcialmente del bloque al exhibir signos negativos con educación y salud funcional —y una asociación débilmente positiva con vivienda—, mientras que las tres restantes respuestas mantienen covariación positiva mutua. La existencia de esa covarianza residual respalda, una vez más, el uso del modelo multivariado: si hubiera ajustado regresiones univariadas separadas, esa información estructural se habría perdido sin remedio.

5.4.4. Observaciones influyentes y geometría del espacio explicativo

El peso de cada municipio cierra el diagnóstico. Evalué la influencia individual sobre la estimación mediante el leverage h_{ii} y la distancia de Cook multivariada.




Figura 5.7: Leverage frente a la distancia de Mahalanobis sobre la matriz de covariables X .




Figura 5.8: Distancia de Cook multivariada frente al leverage. Los puntos más altos corresponden a municipios con perfiles extremos.

Los umbrales utilizados son $2q/n = 0.008910$ y $3q/n = 0.013366$ para leverage, y $4/n = 0.001620$ para la distancia de Cook. El conteo final arroja 226 municipios con leverage alto y 1,226 con Cook por encima del umbral, y entre los casos extremos destacan municipios como Cochoapa el Grande y San Simón Zahuatlán (Guerrero y Oaxaca) —conocidos por concentrar niveles extraordinariamente

altos de marginación en el contexto nacional—; su presencia en las colas del análisis no es artefacto estadístico, sino la geografía real del rezago en México, donde un conjunto reducido de municipios acumula carencias muy por encima de la media nacional. Los casos extremos




Figura 5.9: Distancia de Mahalanobis residual frente al leverage.

La robustez exige un análisis de sensibilidad. Aplicando el umbral convencional $D_{\text{Cook}} > 4/n = 0.00162$ (Bollen y Jackman [27]), se identifican 1,226 municipios cuya distancia de Cook supera el corte —aproximadamente la mitad de la base—. La magnitud del conteo no es un artefacto: refleja que la geografía del rezago mexicano genera una cola larga de municipios con perfiles atípicos respecto al centroide multivariado, fenómeno consistente con la concentración del rezago en las regiones de Oaxaca, Guerrero y Chiapas reportada en la literatura aplicada al CONEVAL [21]. Reestimando el modelo sobre los 1,243 municipios restantes, los estadísticos de ajuste se modifican como sigue: R^2_{tr} pasa de 0.7696 a 0.8553 ($|\Delta R^2_{tr}| = 0.0857$), Λ de Wilks pasa de 0.01489 a 0.00767, y la traza de Pillai pasa de 1.7453 a 1.8790. La jerarquía completa de predictores por contribución parcial se preserva, así como los signos dominantes en cada columna de $\hat{B}$.

5.4.5. Evaluación integrada del diagnóstico

Observación 5.5 (Validez asintótica del modelo). El hecho de que la jerarquía de predictores y los signos dominantes se preserven al excluir aproximadamente la mitad de la base es una señal fuerte de robustez estructural del modelo. El incremento del R^2_{tr} tras la exclusión no debe leerse como mejora del modelo: refleja que las observaciones retiradas son precisamente las que el modelo ajustaba peor, por lo que al excluirlas el promedio de ajuste sube mecánicamente. El hallazgo relevante del análisis de sensibilidad es que las conclusiones cualitativas P15YM_SE como predictor dominante, concentración del 93,8 % de la asociación en CAN1, no significancia condicional de POB_AFRO se preservan bajo la exclusión masiva. Esto respalda la estructura cualitativa de los hallazgos, no la magnitud puntual de los coeficientes individuales.

1. El tamaño muestral ($n = 2,469$) supera holgadamente los requisitos para las aproximaciones asintóticas de los estadísticos multivariados, en particular la traza de Pillai.
2. Las desviaciones respecto a la normalidad están documentadas y no son sistemáticas en todo el rango.
3. El análisis de sensibilidad muestra que el ajuste global cambia de manera apreciable al excluir los municipios más influyentes, lo cual debe reportarse como limitación.

El diagnóstico se resume en cinco puntos:

- Se rechaza la normalidad multivariada de los residuos.
- Hay evidencia de heterocedasticidad estadísticamente significativa entre municipios.
- Persiste correlación residual moderada entre algunas respuestas.
- No se detectan curvaturas sistemáticas que comprometan la forma lineal del modelo.
- Existen municipios con alta influencia local que afectan la magnitud del ajuste global, pero no alteran las conclusiones cualitativas.

Los resultados son asociación cruzada, no causalidad. Tomados en conjunto, los hallazgos deben interpretarse como evidencia de asociación cruzada entre dimensiones del rezago a escala municipal y no como inferencia causal estricta —bajo ese encuadre, la traza de Pillai funciona como el estadístico más robusto del bloque, ya que su comportamiento es relativamente insensible a desviaciones moderadas de normalidad y homocedasticidad [11]. Los datos del Censo 2020 no se ajustan al ideal teórico de un modelo lineal con errores gaussianos perfectos (ningún corpus empírico de esta naturaleza lo hace), pero sí ofrecen una base lo bastante rica como para identificar, mediante el modelo multivariado, la estructura conjunta de las carencias municipales en México.

Capítulo 6

Conclusiones

6.1. Síntesis de hallazgos

Esta investigación tuvo un propósito acotado. Especifiqué, programé y estimé un modelo de regresión lineal multivariada para analizar el rezago social a escala municipal en México empleando datos del Censo de Población y Vivienda 2020; el planteamiento estadístico se articuló sobre una matriz con cuatro variables respuesta —educación, infraestructura de vivienda, situación laboral y limitaciones funcionales— vinculadas con una matriz de diseño compuesta por diez covariables sociodemográficas. La cobertura abarcó la totalidad de los municipios registrados.

La traza confirmó el ajuste global. Anclada en las matrices de sumas de cuadrados, la evaluación arrojó un $R^2_{tr} \approx 0.77$ con rechazo categórico de la nula global —Wilks, Pillai, Hotelling–Lawley y Roy convergieron en la misma lectura inferencial. El primer vector canónico absorbió el 93.8 % de la asociación, dominado por el analfabetismo adulto. A primera vista parece un defecto, ya que casi toda la asociación cae sobre una sola dirección, así que se podría pensar que el sistema es esencialmente unidimensional. Pero la lectura va al revés. Fue justamente el modelo multivariado el que permitió ver esa unidimensionalidad, porque cuatro regresiones univariadas separadas no comparten matriz residual y por eso no la habrían detectado.

Las dimensiones no se comportaron igual. Educación ($R^2 = 0.955$) y vivienda ($R^2 = 0.804$) acumularon ajustes altos, mientras que desocupación ($R^2 = 0.100$) quedó muy por debajo; P15YM_SE y VPH_PISOTI cargaron la mayor parte del aporte marginal sobre todo el sistema. Esta asimetría interna refleja la heterogeneidad estructural del rezago social entre las dimensiones consideradas y es consistente con la geografía empírica de la marginación en México.

6.2. Aportaciones del estudio

La contribución central es de integración rigurosa entre teoría, cómputo y aplicación empírica. Modelé la marginación municipal como un conjunto de variables aleatorias correlacionadas —enfoque que esquivó las dos limitaciones más frecuentes del análisis aplicado: comprimir la información en un índice escalar o ajustar regresiones univariadas independientes—; el aporte se concreta en tres frentes específicos.

1. **Aplicación del marco teórico multivariado:** La inferencia sobre cada respuesta incorpora algebraicamente su covarianza cruzada con las demás dimensiones. Algo que el ajuste univariado, por construcción, descarta.
2. **Implementación computacional transparente:** La programación explícita en Python aseguró correspondencia estricta entre fundamentos algebraicos, estimación MCO, matrices SSCP, pruebas de hipótesis y evaluación residual. Reproducibilidad completa.

3. **Identificación del componente principal:** El análisis espectral mostró que el rezago educativo —específicamente el analfabetismo adulto— es la variable que mayor covarianza conjunta capta dentro de la explicación de las desigualdades municipales.

6.3. Limitaciones y consideraciones diagnósticas

El análisis residual reveló incumplimientos parciales. Pese al rechazo categórico de la nula global, normalidad y homocedasticidad no se sostuvieron —la dispersión residual modifica su comportamiento según el perfil sociodemográfico de cada observación—; las pruebas se sostuvieron en la robustez asintótica de la traza de Pillai [11]. Una limitación de fondo conviene marcarla. Los coeficientes son asociaciones ecológicas entre agregados municipales —no admiten lectura sobre individuos u hogares—, así que toda extrapolación hacia microcomportamientos cae en la falacia ecológica. El alcance es territorial. No causal.

El análisis de sensibilidad excluyó 1,226 municipios (el 49.7% de la base) bajo el umbral convencional $D_{\text{Cook}} > 4/n = 0.00162$. Bajo esta exclusión masiva, R_{tr}^2 pasa de 0.770 a 0.855 ($|\Delta R_{tr}^2| = 0.086$), Λ de Wilks de 0.015 a 0.008 y la traza de Pillai de 1.745 a 1.879. La jerarquía completa de predictores y los signos dominantes en $\hat{B}$ se preservan, lo que apoya la robustez estructural de los hallazgos sustantivos. El incremento del R_{tr}^2 refleja la exclusión de las observaciones peor ajustadas —municipios de Oaxaca, Guerrero y Chiapas con perfiles extremos de rezago—, no una mejora intrínseca del modelo. La magnitud de la exclusión, sin embargo, debe reportarse explícitamente como limitación: las cifras puntuales de los coeficientes individuales sí dependen de cuáles municipios se incluyan, aunque su signo y jerarquía no.

6.4. Recomendaciones para investigaciones futuras

Tres líneas se desprenden del trabajo. La más prometedora —y la que yo seguiría primero— es la regresión espacial multivariada, ya que la heterocedasticidad documentada y la concentración geográfica del rezago en Guerrero y Oaxaca apuntan a que la matriz de covarianzas residuales arrastra autocorrelación territorial no modelada. Una matriz de pesos espaciales debería absorber buena parte de esa varianza residual.

Las otras dos líneas son complementarias. Integrar datos longitudinales (ENOE, DENUe) mejoraría el ajuste sobre PDESOCUP, donde el bajo $R^2 = 0.100$ refleja dinámica laboral que un corte transversal no captura; modelos de variables latentes —análisis factorial confirmatorio o ecuaciones estructurales— aprovecharían la concentración del 93.8% sobre CAN1 para condensar las dimensiones observables en un único factor de vulnerabilidad sociodemográfica.

Las tres extensiones complementan el ajuste actual sin invalidarlo. Cada una toma como punto de partida la estimación paramétrica y la matriz de datos estructurada en este trabajo. La regresión lineal multivariada cumple su papel como herramienta de análisis integrado del rezago municipal; las extensiones espaciales y temporales quedan delineadas como pasos naturales.

Una cuarta línea de mejora directa es la implementación de errores estándar robustos tipo Huber–White (sandwich) en la matriz de covarianzas de $\hat{B}$. La heterocedasticidad hace que los p -valores individuales reportados sean aproximaciones; una corrección sandwich permitiría una inferencia marginal más precisa sin alterar la estimación puntual. La extensión es algebraicamente directa: la versión multivariada HC0 de la covarianza del estimador vectorizado se escribe


$$\widehat{\text{Cov}}(\text{vec } \hat{B}) = (I_p \otimes (X'X)^{-1}X') \hat{\Omega} (I_p \otimes X(X'X)^{-1}),$$

donde $\hat{\Omega}$ es la matriz de bloques construida a partir de los productos $\hat{u}_i \hat{u}_i'$ [14, 20]. La forma preserva la estructura de Kronecker del modelo y respeta la dependencia entre respuestas; reduce la sensibilidad de los errores estándar a la heterocedasticidad entre municipios documentada en el Capítulo de Resultados.

Apéndice A

Acceso al código fuente

El notebook con la implementación matricial completa, las funciones auxiliares definidas para el modelo multivariado y todos los resultados numéricos discutidos en el Capítulo 5 están disponibles públicamente en el siguiente repositorio:



<https://github.com/israelcervantes31416/regresion-multivariada-censo2020>

El repositorio contiene:

- Notebook con 18 celdas ejecutables (Python + NumPy), correspondientes a las etapas descritas en el Capítulo 3: carga y depuración del archivo ITER, construcción de tasas y proporciones, transformación por raíz cuadrada, estimación MCO multivariada, descomposición SSCP, pruebas globales y parciales, diagnóstico residual, análisis de sensibilidad y análisis canónico.
- Instrucciones para obtener el archivo `datos.csv` directamente desde el Censo de Población y Vivienda 2020 del INEGI.
- Archivo `requirements.txt` con la lista mínima de dependencias del entorno Python.
- Documentación de uso, reproducibilidad y citación del trabajo.

Toda la estimación reportada en este documento se reproduce con la semilla fija `SEED = 2026` y el nivel de significancia `ALPHA = 0.05`. El compromiso de transparencia computacional permite que cualquier lector audite, paso a paso, la correspondencia entre la formulación matricial del Capítulo 2 y los valores empíricos del Capítulo 5.

Bibliografía

- [1] A. C. Rencher, *Methods of Multivariate Analysis*, 2nd ed. New York, NY, USA: John Wiley & Sons, 2002.
- [2] Instituto Nacional de Estadística y Geografía, “Censo de Población y Vivienda (CPV) 2020,” 2020, consultado el 13 de mayo de 2026. [Online]. Available: <https://www.inegi.org.mx/programas/ccpv/2020/>
- [3] R. A. Johnson and D. W. Wichern, *Applied Multivariate Statistical Analysis*, 6th ed. Upper Saddle River, NJ, USA: Pearson Prentice Hall, 2007.
- [4] K. V. Mardia, J. T. Kent, and J. M. Bibby, *Multivariate Analysis*. London, UK: Academic Press, 1979.
- [5] T. W. Anderson, *An Introduction to Multivariate Statistical Analysis*, 2nd ed. New York, NY, USA: John Wiley & Sons, 1984.
- [6] G. Strang, *Introduction to Linear Algebra*, 5th ed. Wellesley, MA, USA: Wellesley-Cambridge Press, 2016.
- [7] G. A. F. Seber, *Multivariate Observations*. Hoboken, NJ, USA: John Wiley & Sons, 2004.
- [8] R. A. Horn and C. R. Johnson, *Matrix Analysis*, 2nd ed. Cambridge, UK: Cambridge University Press, 2013.
- [9] H. Hotelling, “A generalized T test and measure of multivariate dispersion,” in *Proceedings of the Second Berkeley Symposium on Mathematical Statistics and Probability*, J. Neyman, Ed. Berkeley, CA, USA: University of California Press, 1951, pp. 23–42.
- [10] R. W. Kulp and B. N. Nagarsenker, “An asymptotic expansion of the nonnull distribution of Wilks’ criterion for testing the multivariate linear hypothesis,” *The Annals of Statistics*, vol. 12, no. 4, pp. 1576–1583, 1984.
- [11] C. L. Olson, “On choosing a test statistic in multivariate analysis of variance,” *Psychological Bulletin*, vol. 83, no. 4, pp. 579–586, 1976.
- [12] B. G. Tabachnick and L. S. Fidell, *Using Multivariate Statistics*, 7th ed. Boston, MA, USA: Pearson, 2019.
- [13] K. V. Mardia, “Measures of multivariate skewness and kurtosis with applications,” *Biometrika*, vol. 57, no. 3, pp. 519–530, 1970.
- [14] H. White, “A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity,” *Econometrica*, vol. 48, no. 4, pp. 817–838, 1980.
- [15] D. A. Belsley, E. Kuh, and R. E. Welsch, *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. New York, NY, USA: John Wiley & Sons, 1980.

- [16] A. Hossain and D. N. Naik, "Detection of influential observations in multivariate regression," *Journal of Applied Statistics*, vol. 16, no. 1, pp. 25–37, 1989.
- [17] D. J. Denis, *Applied Univariate, Bivariate, and Multivariate Statistics Using Python: A Beginner's Guide to Advanced Data Analysis*. Hoboken, NJ, USA: John Wiley & Sons, 2021.
- [18] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. F. del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke, and T. E. Oliphant, "Array programming with NumPy," *Nature*, vol. 585, no. 7825, pp. 357–362, 2020.
- [19] K. C. S. Pillai, "Some new test criteria in multivariate analysis," *The Annals of Mathematical Statistics*, vol. 26, no. 1, pp. 117–121, 1955.
- [20] F. Cribari-Neto, "Asymptotic inference under heteroskedasticity of unknown form," *Computational Statistics and Data Analysis*, vol. 45, no. 2, pp. 215–233, 2004.
- [21] Consejo Nacional de Evaluación de la Política de Desarrollo Social, "Índice de rezago social 2020," CONEVAL, Ciudad de México, México, Tech. Rep., 2020.
- [22] Instituto Nacional de Estadística y Geografía, "Censo de Población y Vivienda 2020: Principales resultados EUM," INEGI, Aguascalientes, México, Tech. Rep., 2021.
- [23] —, "Banco de indicadores," 2020, consultado el 13 de mayo de 2026. [Online]. Available: <https://www.inegi.org.mx/app/indicadores/>
- [24] —, "Características de las localidades 2020: Síntesis metodológica y conceptual," INEGI, Aguascalientes, México, Tech. Rep., 2021.
- [25] —, "Clasificaciones del Censo de Población y Vivienda 2020," INEGI, Aguascalientes, México, Tech. Rep., 2021.
- [26] —, "Variables Censo de Población y Vivienda 2020," INEGI, Aguascalientes, México, Tech. Rep., 2020.
- [27] K. A. Bollen and R. W. Jackman, "Regression diagnostics: An expository treatment of outliers and influential cases," *Sociological Methods and Research*, vol. 13, no. 4, pp. 510–542, 1985.