



Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias Físico Matemáticas

La regresión multivariada como marco estadístico para el
análisis conjunto de indicadores socioeconómicos: una
aplicación al Censo de Población y Vivienda 2020

Tesis presentada al

Colegio de Matemáticas

como requisito parcial para la obtención del grado de

Licenciado en Matemáticas Aplicadas

por

Israel Cervantes Juárez

Dirigido por

Dr. Bulmaro Juárez Hernández

Puebla Pue.
1 de junio de 2026



Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias Físico Matemáticas

La regresión multivariada como marco estadístico para el
análisis conjunto de indicadores socioeconómicos: una
aplicación al Censo de Población y Vivienda 2020

Tesis presentada al

Colegio de Matemáticas

como requisito parcial para la obtención del grado de

Licenciado en Matemáticas Aplicadas

por

Israel Cervantes Juárez

Dirigido por

Dr. Bulmaro Juárez Hernández

Puebla Pue.
1 de junio de 2026

Título: La regresión multivariada como marco estadístico para el análisis conjunto de indicadores socioeconómicos: una aplicación al Censo de Población y Vivienda 2020

Estudiante: ISRAEL CERVANTES JUÁREZ

COMITÉ

Dr. José Juan Castro Alva
Presidente

Dr. Fernando Velasco Luna
Secretario

Dr. Carlos Camilo Garay
Vocal

Dra. Hortensia Josefina Reyes Cervantes
Vocal

Dr. Bulmaro Juárez Hernández
Director de Tesis

“No sabía cómo hacerlo, así que intenté, fallé, fallé y fallé, hasta que lo logré.”

— Elon Musk

Agradecimientos

Agradezco profundamente a mi director de tesis, el Dr. Bulmaro Juárez Hernández, por su tiempo, orientación y por todo el conocimiento compartido durante el desarrollo de este trabajo.

Al Dr. José Juan Castro Alva, profesor y amigo, le agradezco las experiencias, conversaciones y aprendizajes compartidos a lo largo de mi formación universitaria. Gracias también por motivarme a acercarme al análisis de datos, camino que hoy forma parte de mi desarrollo profesional.

A mis amigos Yessica, Daniela, Carlos, Zariel, Fernando y Jorge, gracias por acompañarme en los buenos y malos momentos. Haberlos encontrado durante la universidad hizo que estos años fueran más llevaderos, valiosos y memorables.

A mi familia, especialmente a mis padres, gracias por darme siempre lo necesario para seguir adelante, por apoyar mis decisiones y por estar presentes en los momentos importantes de mi vida. Gracias por su esfuerzo, paciencia y cariño, y por enseñarme con su ejemplo el valor del trabajo y la perseverancia. De manera especial, agradezco a mi madre por enseñarme a no rendirme, incluso en los momentos más difíciles. A mi hermano y a mi tía Mimy, gracias por formar parte de mi vida y de este logro.

A mi pareja, Ximena, gracias por acompañarme durante estos últimos meses de universidad, por tu paciencia, tu apoyo y tu compañía en un periodo lleno de presión, cambios y aprendizajes. Gracias por estar presente cuando más lo necesitaba y por hacer más llevadero este cierre tan importante.

Al Lic. Mauricio y al Lic. Jorge, de mi trabajo actual, les agradezco el apoyo, la flexibilidad y las facilidades que me brindaron durante la etapa final de esta tesis y del proceso de examen profesional. Su comprensión me permitió atender mis compromisos académicos sin descuidar mis responsabilidades laborales.

A Newt, mi iguana, y a Rocky y Makey, mis perros, gracias por acompañarme en tantos días de trabajo, desvelo y cansancio. Su compañía me ayudó a sobrellevar el estrés y me regaló momentos de alegría cuando más los necesitaba.

También quiero agradecerme por haber creído en mí, por no rendirme cuando el cansancio, las dudas y la exigencia personal pesaban más de lo esperado. Gracias por insistir, por cuidar cada detalle, por volver a empezar las veces que fueron necesarias y por llegar hasta aquí.

Finalmente, gracias a todos mis amigos, familiares, profesores, compañeros y conocidos que, aunque no mencione de manera individual, también estuvieron presentes de alguna forma en este recorrido. Sin sus palabras, los consejos, el cariño o cualquier gesto de por medio, no se habría cerrado esta etapa de la manera en que lo ha hecho.

Resumen

Con el fin de analizar en conjunto los indicadores de vulnerabilidad social a escala municipal en México, esta investigación pone en práctica un modelo de regresión lineal multivariada usando los datos obtenidos en el Censo de Población y Vivienda 2020 del INEGI. La idea es ir más allá de lo que permiten los enfoques univariados por separado y modelar de forma simultánea un sistema de variables respuesta entre sí relacionadas, de modo que su estructura de dependencia quede explícita. El trabajo se sustenta en la formulación matricial $Y = XB + U$ y abarca desde el método de Mínimos Cuadrados Ordinarios (MCO) hasta la descomposición de la Suma de Cuadrados y Productos Cruzados (SSCP) y las pruebas pertinentes. Para la parte computacional se ha recurrido al lenguaje de programación Python y al álgebra lineal de forma explícita, dada la falta de una librería multivariada, para así asegurar que la ejecución numérica se corresponda con la teoría. En la aplicación se toma como base a los 2469 municipios de la República Mexicana, se integran como variables dependientes a los indicadores de rezago social junto a un bloque de covariables demográficas, de vivienda y educativas. Los resultados son significativos, ya que el coeficiente de determinación multivariado por traza $R_{tr}^2 = 0.77$. La traza de Pillai ($V_{Pillai} \approx 1.745$, $F_{Pillai} \approx 190.26$, grados de libertad (40, 9832) y $p < 0.0001$) deja claro el efecto global de las covariables. Al hacer el análisis espectral de la matriz $E^{-1}H$, se encontró el eigenvalor principal de 22.5 y una correlación canónica de 0.98, lo que denota una dimensión dominante en la dependencia. En definitiva, una combinación lineal absorbe gran parte de la varianza conjunta y el sistema permite una lectura sintética. El estudio pone de manifiesto asimetrías internas, con ajustes muy buenos en lo educativo o habitacional pero menor poder explicativo en las variables laborales y de salud, con una dependencia residual que se mantiene entre respuestas. Todo ello confirma la multidimensionalidad propia del rezago social y valida la regresión lineal multivariada como la herramienta adecuada para un análisis integrado que une la estadística y la evidencia.

Índice general

Agradecimientos	vii
1. Introducción	1
1.1. Planteamiento del problema	1
1.2. Justificación	2
1.3. Objetivos	2
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
1.4. Alcance del estudio	3
1.5. Estructura del documento	3
2. Marco Teórico	5
2.1. Fundamentos matemáticos del análisis multivariado	5
2.1.1. Vectores, matrices y producto interno	5
2.1.2. Traza, determinante y matrices simétricas	6
2.1.3. Formas cuadráticas y matrices definidas positivas	6
2.1.4. Rango, independencia lineal e invertibilidad	7
2.1.5. Descomposición espectral	7
2.1.6. Espacios columna y proyecciones ortogonales	7
2.1.7. Norma de Frobenius y aproximación matricial	9
2.1.8. El operador vec y el producto de Kronecker	9
2.2. Estructura de covarianza y vectores aleatorios multivariados	9
2.2.1. Vector de medias y matriz de covarianza	10
2.2.2. Transformaciones lineales	10
2.2.3. Estructura de muestras multivariadas	11
2.2.4. Media muestral	12
2.2.5. Matriz de dispersión muestral	13
2.2.6. Estructura de dependencia	13
2.3. Distribución normal multivariada	13
2.3.1. Definición y propiedades básicas	14
2.3.2. Caracterización mediante transformaciones lineales	14
2.3.3. Forma cuadrática y distribución χ^2	15
2.3.4. Combinaciones lineales	15
2.3.5. Marginales y distribución condicional	16
2.3.6. Independencia y covarianza	16
2.3.7. Distribución normal matricial	17
2.3.8. Muestras normales	18
2.4. Matrices de dispersión y la distribución Wishart	18
2.4.1. Definición de la Wishart	18
2.4.2. Vínculo con la chi-cuadrada	19

2.4.3.	Propiedades fundamentales	19
2.4.4.	Matriz de covarianza muestral	20
2.4.5.	Estructura espectral	22
2.4.6.	Distribución de submatrices	22
2.4.7.	La Wishart en el modelo lineal multivariado	22
2.4.8.	Matrices de suma de cuadrados y productos cruzados	23
2.5.	Modelo lineal multivariado	24
2.5.1.	Dos formas de ver el modelo	25
2.5.2.	Supuestos del modelo	25
2.5.3.	Formulación vectorizada	25
2.5.4.	Estimación por mínimos cuadrados	26
2.5.5.	Propiedades del estimador	27
2.5.6.	Interpretación geométrica	28
2.5.7.	Relación con la estimación por máxima verosimilitud	28
2.5.8.	Matriz de residuos y estimación de Σ	29
2.5.9.	Descomposición de la variabilidad	29
2.5.10.	Optimalidad del estimador	30
2.6.	Inferencia en el modelo lineal multivariado	31
2.6.1.	Hipótesis lineales generales	31
2.6.2.	Contraste global del modelo: el caso $D = 0$	31
2.6.3.	Construcción de las matrices de hipótesis y error	32
2.6.4.	Distribución de H y E	32
2.6.5.	Estructura espectral del problema inferencial	33
2.6.6.	Estadísticos de prueba clásicos	33
2.6.7.	Región de rechazo	34
2.6.8.	Regiones de confianza simultáneas	35
2.6.9.	Invarianza	35
2.7.	Diagnóstico del modelo lineal multivariado	36
2.7.1.	Matriz de residuos	36
2.7.2.	Normalidad multivariada	36
2.7.3.	Homocedasticidad e independencia	36
2.7.4.	Observaciones influyentes	37
2.7.5.	Residuos estandarizados	37
3.	Implementación computacional del modelo	39
3.1.	Arquitectura del sistema	39
3.1.1.	Funciones auxiliares	41
3.2.	Preparación de la base analítica	41
3.2.1.	Lectura, validación y depuración inicial	41
3.2.2.	Construcción de variables analíticas	42
3.2.3.	Transformación y estandarización	42
3.2.4.	Controles numéricos	42
3.3.	Estimación y descomposición SSCP	42
3.3.1.	Descomposición centrada de la variabilidad	43
3.4.	Inferencia multivariada	44
3.4.1.	Contraste global del modelo	44
3.4.2.	Pruebas individuales por variable explicativa	44
3.5.	Análisis de residuales y detección de observaciones atípicas	45
3.5.1.	Distancias de Mahalanobis y coeficientes de Mardia	46
3.5.2.	Apalancamiento y distancia de Cook	46
3.5.3.	Prueba de homocedasticidad	46
3.6.	Análisis canónico	46

3.6.1. Resolución del problema de valores propios generalizado	46
3.6.2. Cargas canónicas relativas	46
3.7. Visualización de resultados	47
4. Modelación del Censo de Población y Vivienda 2020	49
4.1. Fuente de información	49
4.2. Unidad de análisis y delimitación territorial	49
4.3. Construcción de indicadores proporcionales	50
4.4. Especificación empírica del sistema de variables	51
4.4.1. Variables respuesta	51
4.4.2. Variables explicativas	52
4.5. Transformaciones previas al análisis	53
5. Resultados	57
5.1. Ajuste global del modelo	57
5.1.1. Descomposición matricial de la variabilidad	57
5.1.2. Magnitud del ajuste conjunto	58
5.1.3. Pruebas globales de significancia multivariada	59
5.1.4. Matriz de covarianza residual y dependencia remanente	60
5.2. Análisis de los coeficientes y contribución de las covariables	60
5.2.1. Jerarquía explicativa por pruebas parciales multivariadas	61
5.2.2. Distribución de efectos por respuesta y patrones de signo	63
5.2.3. Colinealidad sustantiva y lectura de efectos parciales	65
5.3. Estructura canónica del modelo	66
5.3.1. Problema espectral del modelo	66
5.3.2. Correlaciones canónicas y fuerza de asociación	66
5.3.3. Normalización canónica y matriz de coeficientes	67
5.3.4. Primera dirección canónica: eje educativo	68
5.3.5. Segunda dirección canónica: contraste educación-vivienda	68
5.3.6. Tercera dirección canónica: eje cognitivo	69
5.3.7. Cuarta dirección canónica: contraste laboral-cognitivo	69
5.3.8. Representación geométrica del espacio canónico	69
5.4. Diagnóstico del modelo y evaluación de supuestos	71
5.4.1. Normalidad multivariada de los residuos	71
5.4.2. Estructura residual y diagnóstico de heterocedasticidad	73
5.4.3. Correlación residual remanente	74
5.4.4. Observaciones influyentes y geometría del espacio explicativo	74
5.4.5. Evaluación integrada del diagnóstico	76
6. Conclusiones	79
6.1. Síntesis de hallazgos	79
6.2. Aportaciones del estudio	79
6.3. Limitaciones y consideraciones diagnósticas	80
6.4. Recomendaciones para investigaciones futuras	80
A. Acceso al código fuente	81
Bibliografía	83

Índice de tablas

2.1. Aproximaciones y referencia F para los estadísticos multivariados clásicos.	34
3.1. Correspondencia entre celdas de código y matrices del modelo.	41
4.1. Universos de referencia utilizados en la construcción de indicadores.	50
4.2. Variables dependientes del modelo.	51
4.3. Variables independientes del modelo.	52
5.1. Descomposición de la diagonal principal $T = H + E$ y varianza explicada por dimensión.	58
5.2. Estadísticos escalares de ajuste del modelo multivariado basados en la traza.	59
5.3. Estadísticos de prueba para la significancia global del modelo multivariado.	59
5.4. Pruebas parciales tipo III por covariable, ordenadas por traza de Pillai.	62
5.5. Valores propios de la matriz $E^{-1}H$ y varianza relativa explicada.	66
5.6. Correlaciones canónicas asociadas a cada dirección.	67
5.7. Pruebas de normalidad multivariada de Mardia sobre los residuos.	71
5.8. Diagnóstico auxiliar de heterocedasticidad multivariada.	73

Índice de figuras

3.1. Esquema del procedimiento algorítmico de estimación multivariada.	40
4.1. Mapa de calor de correlaciones entre covariables explicativas.	53
4.2. Distribución empírica de las variables transformadas (parte 1).	54
4.3. Distribución empírica de las variables transformadas (parte 2).	55
5.1. Contribución marginal de cada covariable (traza de Pillai).	62
5.2. Valor absoluto de los coeficientes canónicos para cada dirección.	68
5.3. Municipios en el subespacio canónico tridimensional.	70
5.4. Proyecciones bidimensionales sobre los planos canónicos.	70
5.5. Gráfico Q-Q de la distancia de Mahalanobis residual.	72
5.6. Residuos estandarizados frente a valores ajustados, por variable respuesta.	73
5.7. Leverage frente a la distancia de Mahalanobis sobre la matriz de covariables X . . .	75
5.8. Distancia de Cook multivariada frente al leverage.	75
5.9. Distancia de Mahalanobis residual frente al leverage.	76

Capítulo 1

Introducción

El análisis de la marginación social con información territorial agregada exige distinguir entre el comportamiento individual de cada indicador y su comportamiento conjunto cuando todos se observan sobre la misma unidad de análisis. Las variables no son piezas independientes, están correlacionadas entre sí porque miden facetas del mismo fenómeno y por eso conviene tratarlas conjuntamente, no por separado. Analfabetismo en mayores de 15 años, desocupación laboral, limitaciones funcionales, ausencia de servicios básicos en la vivienda, cada una cuenta una parte distinta del rezago. El hecho de que todas se agreguen al mismo municipio hace estadísticamente esperable que aparezcan interdependencias no triviales entre ellas, así que ignorar esa estructura de correlación, como ocurre al ajustar modelos univariados independientes, descarta información relevante del fenómeno [1].

La información utilizada proviene del Censo de Población y Vivienda 2020, levantado por el Instituto Nacional de Estadística y Geografía [2]. A partir de los registros agregados a nivel municipal se construyeron indicadores proporcionales, es decir tasas, razones y porcentajes, con el fin de hacer comparables municipios con poblaciones y dinámicas radicalmente distintas no tiene sentido sin alguna normalización previa. Esa base, ya procesada, es la que alimenta las matrices de variables respuesta y de covariables que el modelo multivariado necesita.

La elección de un modelo multivariado responde a la naturaleza del problema. Cada municipio reporta al mismo tiempo un conjunto de indicadores de rezago social que ya se sabe de antemano que están correlacionados entre sí, así que las variables respuesta se organizan en una matriz Y que se vincula con un mismo bloque de covariables sociodemográficas a través de una matriz de coeficientes B . Lo que se gana con esta especificación es la preservación íntegra de la estructura de dependencia entre respuestas, ya que estimar el sistema de manera conjunta obliga a modelar de forma explícita la varianza no explicada mediante una matriz de covarianzas residuales. De ahí que se analice la vulnerabilidad como lo que es, un objeto multidimensional, y se evadan de paso los defectos estadísticos que aparecen al correr regresiones lineales ordinarias por separado, una por respuesta [3–5].

1.1. Planteamiento del problema

Si se va al fondo de la cuestión, el núcleo estadístico de esta tesis es una materia de representación: ¿cuál es la manera más adecuada de modelar las diferentes facetas del rezago social en un municipio? Un índice escalar que lo resuma todo facilita la comunicación de los resultados, no hay duda, pero a cambio se pierde información sobre la dirección y magnitud de cada carencia, la cual ya no se recupera. Por otro lado, si se opta por ajustar una regresión univariada para cada respuesta se mantiene la interpretación marginal de los efectos, pero se asume un costo silencioso al dar por nula la correlación entre los residuales de unas ecuaciones y otras.

Este trabajo de tesis propone un nivel intermedio. En lugar de lo anterior, se preserva la dimensionalidad del vector de respuestas y se estiman sus parámetros a la vez dentro de un mismo sistema matricial. Al tener que ver con agregados censales territoriales este método tiene toda su lógica observacional. La distribución de los indicadores de demografía, vivienda o mercado laboral es muy dispar a escala nacional y el rezago se acumula en unos mismos municipios; esa dependencia queda mejor atendida con un tratamiento conjunto.

Así pues, el objetivo analítico no se limita a seleccionar bien las covariables para cada indicador, sino a comprobar si una formulación multivariada, al hacer explícita la dependencia entre respuestas, da un panorama más informativo del problema social. De ahí surge la pregunta central de la investigación:

¿Qué información estadística adicional se obtiene al estimar conjuntamente los indicadores de rezago social municipal mediante un modelo de regresión lineal multivariada, en comparación con el ajuste aislado de modelos univariados independientes?

1.2. Justificación

Al considerar a cada municipio como un vector de observaciones de varios atributos sociales, la formulación matricial para poner en relación ese vector de respuestas con un conjunto de covariables es, en buena medida, lo que se impone. Y el beneficio es inmediato: uno dispone de un andamiaje analítico de rigor que sobrepasa el enfoque univariado y posibilita una inferencia simultánea a partir de las matrices de sumas de cuadrados y productos cruzados, de error o de hipótesis que sean [3–5].

El trabajo da una lectura cuantitativa de la marginación regional, pero conviene matizarlo desde el principio. La solidez de nuestras conclusiones y de la inferencia estadística no va más allá del plano municipal; pretender extrapolarlos para conocer a un individuo o a un hogar en particular carecería de base metodológica y sería caer en una falacia ecológica. El censo nos habla de lo que hay entre municipios, no de lo que pasa dentro de un domicilio. Nuestro modelo está concebido para estimar esas dinámicas territoriales, no para adentrarse en las causas de carácter personal.

Por otro lado, cabe resaltar el aspecto computacional. En la estimación de parámetros se ha optado por el uso de álgebra elemental antes que delegar en rutinas multivariadas de alto nivel. Python ofrece ciertas herramientas para modelos de múltiples respuestas, sin embargo, no se encontró con ninguna librería de propósito general que aborde de forma transparente e integrada todo lo que esta tesis requiere, sea el diagnóstico residual, los estadísticos y pruebas multivariadas, el cálculo de las SSCP o de $\hat{B}$. Por ello, el código es un reflejo fiel de la formulación matricial, para que quede constancia verificable de la correspondencia entre la teoría, la práctica y los datos empíricos.

1.3. Objetivos

1.3.1. Objetivo general

El propósito es especificar y llevar a cabo el desarrollo computacional de un modelo de regresión lineal multivariada, así como su estimación. De este modo podremos examinar la relación que se da entre varias variables de rezago social y un abanico de explicativas procedentes del Censo de Población y Vivienda 2020 [2], todo ello con un enfoque municipal.

1.3.2. Objetivos específicos

1. Hacer una escritura formal de la teoría matemática subyacente al modelo de regresión lineal multivariada y dejar claros sus supuestos estadísticos.
2. Construir las matrices de datos Y y X para lo cual haremos unos indicadores censales en forma de proporciones o tasas que sean comparables a nivel espacial.

3. Desarrollar e implementar la programación en Python necesaria para obtener el estimador de mínimos cuadrados de la matriz de coeficientes $\hat{B}$, valiéndose de operaciones de álgebra lineal de manera directa.
4. Hacer los cálculos de las matrices de sumas de cuadrados y productos cruzados (de la regresión, el error y totales) ya que son necesarias para las pruebas de hipótesis conjuntas.
5. Verificar la bondad de ajuste del modelo por medio de la matriz de covarianzas residuales, comprobar los supuestos y poner de manifiesto cualquier observación atípica o con influencia.
6. Dar sentido a la asociación empírica entre las dimensiones de vulnerabilidad y las covariables demográficas de los municipios interpretando la significancia y los coeficientes que nos arroje el modelo.

1.4. Alcance del estudio

Para este análisis se basó en la información de corte transversal que ofrece el Censo de Población y Vivienda 2020 [2], tomando al municipio como la unidad espacial. Dicha decisión ha conllevado un riguroso proceso de selección: de forma sistemática se han descartado los totales de nación, los resúmenes a nivel estatal, las localidades por debajo del municipio o cualquier otra clasificación imprecisa que pudiera mermar la comparabilidad de la base de datos.

En lo metodológico se limitó al modelo clásico de regresión lineal multivariada. No hay aquí modelación de autocorrelación espacial, estimación bayesiana, relaciones estocásticas no lineales ni variables latentes. La razón es sencilla, se trata de comprobar en la práctica si la formulación matricial lineal da un buen ajuste para captar el comportamiento del rezago en conjunto con sus covariables. Los números que se obtienen miden una covariación estadística entre lo observado; no pretenden avalar determinismos ni plantear causalidad alguna sobre el individuo.

El plano computacional se rige por dos preceptos: la reproducibilidad y una adherencia rigurosa a la teoría. Cualquier operación de transformación se representa utilizando matrices y se pasa al código fuente. Así se asegura de que todo el proceso numérico sea trazable, bien sea en la fase de depuración y normalización de las bases o cuando llegamos a estimar algebraicamente los residuales y hacer la verificación de la significancia conjunta.

1.5. Estructura del documento

Se ha expuesto en este capítulo el alcance y los objetivos del estudio, así como el problema de partida. A lo largo de las seis secciones en que se divide el documento, se desarrollan los siguientes temas: el Capítulo 2 pone de manifiesto las bases matemáticas de la regresión multivariada; en él se introduce la notación matricial y los supuestos del modelo, se deriva el estimador de mínimos cuadrados y se revisa la teoría de las pruebas de hipótesis simultáneas. En el Capítulo 3 se presenta la parte computacional, con la documentación de la programación en Python para llevar a cabo las operaciones de álgebra lineal que se precisan. El Capítulo 4 se centra en el análisis de la matriz de datos censal, detallando su estructura y dando razón de la elección de las variables y del cálculo de los indicadores a nivel municipal. En el Capítulo 5 se encuentran los resultados propiamente dichos, una valoración pormenorizada de la varianza residual para cotejar los supuestos, junto con los coeficientes estimados y los valores propios de los estadísticos de prueba. Por último, el Capítulo 6 da por terminado el trabajo con las conclusiones, señalando las limitaciones analíticas que se han detectado y abriendo la puerta a futuras líneas de investigación.

Capítulo 2

Marco Teórico

2.1. Fundamentos matemáticos del análisis multivariado

En el modelo de regresión lineal con múltiples respuestas, la notación matricial es el recurso natural para representar datos, parámetros y métricas de variabilidad. Esta formulación admite además una interpretación geométrica en términos de proyecciones ortogonales y subespacios vectoriales [4].

Definición 2.1 (Modelo lineal multivariado). El modelo se define por la ecuación

$$Y = XB + U,$$

donde $Y \in \mathbb{R}^{n \times p}$ es la matriz de variables respuesta, $X \in \mathbb{R}^{n \times q}$ la matriz de covariables, $B \in \mathbb{R}^{q \times p}$ la matriz de parámetros y $U \in \mathbb{R}^{n \times p}$ la matriz de errores aleatorios.

El desarrollo formal del modelo requiere álgebra lineal, geometría euclidiana y probabilidad multidimensional [5]. Las secciones siguientes establecen los fundamentos necesarios para la estimación e inferencia.

2.1.1. Vectores, matrices y producto interno

Llamemos $\mathbb{R}^p$ al espacio euclidiano real de dimensión p . El producto interno canónico para cualquier par $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ viene dado por

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}'\mathbf{y},$$

de donde se deriva la norma euclidiana

$$\|\mathbf{x}\| = (\mathbf{x}'\mathbf{x})^{1/2}.$$

Diremos que dos vectores son ortogonales en el momento en que su producto interno es nulo, o lo que es lo mismo, $\mathbf{x}'\mathbf{y} = 0$.

Matricialmente, una observación de p variables no es más que un vector columna

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p,$$

y si tenemos un conjunto empírico de n observaciones, las pondremos en orden transponiendo cada vector para formar las filas de una matriz

$$\mathcal{X} = \begin{pmatrix} \mathbf{x}'_1 \\ \mathbf{x}'_2 \\ \vdots \\ \mathbf{x}'_n \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

Esta representación admite dos interpretaciones geométricas equivalentes: n puntos en $\mathbb{R}^p$, o bien p vectores en $\mathbb{R}^n$. Ambas perspectivas sustentan el análisis de proyecciones ortogonales y dependencia lineal que fundamenta la estimación por mínimos cuadrados [6].

2.1.2. Traza, determinante y matrices simétricas

Se dice que una matriz cuadrada $A \in \mathbb{R}^{p \times p}$ es simétrica cuando es igual a su transpuesta,

$$A' = A.$$

De hecho, es un tipo de estructura muy común en la estadística multivariada para las matrices de covarianzas o de sumas de cuadrados y productos cruzados [4].

La traza es el operador que da cuenta de la suma de los elementos de la diagonal principal:

$$\text{tr}(A) = \sum_{i=1}^p a_{ii},$$

y tiene la ventaja de ser invariante ante la conmutatividad del producto de matrices, de modo que $\text{tr}(AB) = \text{tr}(BA)$. En cuanto al determinante, lo denotamos por $|A|$ y geométricamente representa el factor por el que se modifica el volumen cuando se aplica una transformación lineal asociada con A [7].

2.1.3. Formas cuadráticas y matrices definidas positivas

Definición 2.2. Decimos que una matriz simétrica $A \in \mathbb{R}^{p \times p}$ es definida positiva cuando

$$x'Ax > 0 \quad \text{para cualquier } x \neq 0.$$

En el caso de que se dé $x'Ax \geq 0$, la calificación será la de semidefinida positiva.

No son de menos importancia a la hora de modelar la varianza residual multivariada. De hecho, toda matriz de covarianzas lo es por definición, al ser simétrica y como mínimo semidefinida positiva; pero si no hay colinealidad exacta entre las explicativas, pasamos a tener una definida positiva [5].

Al escalar

$$Q(x) = x'Ax$$

se le conoce como forma cuadrática y su presencia se hace notar, por ejemplo, en el exponente de la densidad normal multivariada o en la función que el estimador MCO ha de minimizar. Con un A definida positiva, el conjunto

$$\{x \in \mathbb{R}^p : x'Ax \leq c\}$$

que es un elipsoide con centro en el origen. Los valores y vectores propios de A son los que determinan la longitud y orientación de sus ejes [7].

2.1.4. Rango, independencia lineal e invertibilidad

Proposición 2.3. *Consideremos una matriz $X \in \mathbb{R}^{n \times q}$. En el caso de que*

$$\text{rango}(X) = q,$$

sus columnas resultan linealmente independientes y la matriz $X'X$ se muestra simétrica, definida positiva e invertible.

Demostración. Que $\text{rango}(X) = q$ es sinónimo de que las q columnas son linealmente independientes. Lo mismo ocurre con la simetría de $X'X$, algo que se ve a simple vista al aplicar la propiedad de la transpuesta:

$$(X'X)' = X'X.$$

Para lo que respecta a la definición positiva de $X'X$, tomemos un vector $z \in \mathbb{R}^q$ no nulo. Al calcular

$$z'(X'X)z = (Xz)'(Xz) = \|Xz\|^2,$$

nos encontramos con que, por la independencia lineal de las columnas de X , la ecuación homogénea $Xz = 0$ no tiene más remedio que tener la solución trivial. Así pues, si $z \neq 0$, entonces $Xz \neq 0$ y por ende

$$\|Xz\|^2 > 0.$$

Esto certifica que la forma cuadrática $z'(X'X)z$ es estrictamente positiva para cualquier vector distinto de cero. De ahí se desprende su invertibilidad; si la matriz fuera singular, habría algún $z \neq 0$ con $(X'X)z = 0$, y premultiplicando por z' llegaríamos a $z'(X'X)z = 0$, en abierta contradicción con lo anterior. Por tanto, $(X'X)^{-1}$ está bien definida. $\square$

El rango completo de X no es un supuesto arbitrario, sin él, los parámetros B no son estimables y el estimador de mínimos cuadrados no tiene solución única [8].

2.1.5. Descomposición espectral

Teorema 2.4 (Descomposición espectral). *Se puede factorizar cualquier matriz simétrica $A \in \mathbb{R}^{p \times p}$ de la forma*

$$A = P\Lambda P',$$

con P siendo una matriz ortogonal y $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$, la diagonal con los valores propios de A .

Gracias a esta descomposición, la traza y el determinante se pueden poner en función de los valores propios, esto es:

$$\text{tr}(A) = \sum_{i=1}^p \lambda_i, \quad |A| = \prod_{i=1}^p \lambda_i.$$

Asimismo, una matriz simétrica será definida positiva cuando todos sus valores propios lo sean (estrictamente positivos). Si nos ponemos en el contexto de las matrices de covarianzas, son los vectores propios los que nos indican hacia dónde va la mayor variabilidad de los datos, mientras que los valores propios cuantifican la varianza en dichas direcciones [4].

2.1.6. Espacios columna y proyecciones ortogonales

Para una matriz de diseño $X \in \mathbb{R}^{n \times q}$ de rango completo, el espacio columna generado por sus vectores se define como

$$\mathcal{C}(X) = \{Xb : b \in \mathbb{R}^q\}.$$

Proposición 2.5. *La matriz*

$$P_X = X(X'X)^{-1}X'$$

es un proyector ortogonal, lo cual implica que es idempotente y simétrica:

$$P_X^2 = P_X, \quad P_X' = P_X.$$

Demostración. Para verificar que P_X es una matriz de proyección ortogonal, se comprueba su idempotencia y simetría. Para la idempotencia, se calcula P_X^2 :

$$P_X^2 = (X(X'X)^{-1}X')(X(X'X)^{-1}X').$$

Aplicando la propiedad asociativa del producto matricial:

$$P_X^2 = X(X'X)^{-1}(X'X)(X'X)^{-1}X'.$$

Como $(X'X)^{-1}(X'X) = I_q$, se obtiene

$$P_X^2 = X(X'X)^{-1}X' = P_X.$$

Para la simetría, se aplica la transpuesta al operador:

$$P_X' = (X(X'X)^{-1}X')'.$$

Utilizando la propiedad distributiva de la transpuesta $(ABC)' = C'B'A'$:

$$P_X' = (X')'((X'X)^{-1})'X'.$$

Sabiendo que $(X')' = X$ y que la inversa de una matriz simétrica es simétrica, es decir, $((X'X)^{-1})' = (X'X)^{-1}$, se tiene que:

$$P_X' = X(X'X)^{-1}X' = P_X.$$

Al verificarse las propiedades de simetría ($P_X' = P_X$) e idempotencia ($P_X^2 = P_X$), se concluye que la matriz es un proyector ortogonal. $\square$

La matriz complementaria

$$M_X = I_n - P_X$$

es el proyector ortogonal sobre el complemento ortogonal de $\mathcal{C}(X)$.

Corolario 2.6. *Toda matriz $Y \in \mathbb{R}^{n \times p}$ puede descomponerse de la forma*

$$Y = P_X Y + M_X Y,$$

donde $P_X Y \in \mathcal{C}(X)$ y $M_X Y$ pertenece a su complemento ortogonal.

Demostración. A partir de la definición de la matriz de proyección residual

$$M_X = I_n - P_X,$$

se establece la identidad matricial

$$P_X + M_X = I_n.$$

Postmultiplicando esta ecuación por la matriz Y , se obtiene

$$(P_X + M_X)Y = P_X Y + M_X Y = Y,$$

lo que establece la descomposición ortogonal del sistema. $\square$

Esta partición geométrica es la base matemática de la descomposición de sumas de cuadrados en el ajuste del modelo lineal [6].

2.1.7. Norma de Frobenius y aproximación matricial

Para una matriz $A \in \mathbb{R}^{m \times n}$, la norma de Frobenius se define como

$$\|A\|_F^2 = \text{tr}(A'A).$$

Definición 2.7. En el modelo lineal multivariado, el estimador de mínimos cuadrados se obtiene encontrando la matriz $\hat{B}$ que minimiza la norma de Frobenius de los residuales:

$$\hat{B} = \arg \min_{B \in \mathbb{R}^{q \times p}} \|Y - XB\|_F^2.$$

La norma de Frobenius generaliza el criterio de mínimos cuadrados al caso multivariado: minimiza la distancia entre Y y su proyección sobre el subespacio columna de X , lo que define el estimador $\hat{B}$ [3].

2.1.8. El operador vec y el producto de Kronecker

Definición 2.8. Para pasar de una matriz a un vector columna, el operador vec se encarga de apilar las columnas en secuencia. Por su parte, cuando se trata del producto de Kronecker de dos matrices A y B , lo escribimos como $A \otimes B$.

Proposición 2.9. Con tal de que las dimensiones de las matrices lo permitan, tenemos la identidad

$$\text{vec}(ABC) = (C' \otimes A) \text{vec}(B).$$

Vectorizando la ecuación del modelo $Y = XB + U$ se obtiene el sistema equivalente

$$\text{vec}(Y) = (I_p \otimes X) \text{vec}(B) + \text{vec}(U),$$

que expresa el problema matricial de una manera diferente como uno vectorial de dimensión np . Esta representación resulta más conveniente para derivar propiedades asintóticas de los estimadores y la estructura de covarianzas residuales [5].

2.2. Estructura de covarianza y vectores aleatorios multivariados

La noción de vector aleatorio es el cimiento del análisis multivariado. La regresión lineal multivariada se distingue del caso univariado por un aspecto esencial, parte de la base de que cada observación es un vector y que sus componentes, es decir, las diferentes variables respuesta, tienen entre sí una correlación estadística con su propia estructura [5].

Definición 2.10 (Vector aleatorio multivariado). Sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, diremos que un vector aleatorio multivariado es una función medible

$$X : \Omega \rightarrow \mathbb{R}^p, \quad X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix},$$

donde $X_1, \dots, X_p$ son variables aleatorias continuas de tipo real.

Para dar cuenta de la distribución conjunta de dichas componentes nos valdremos de dos elementos: la matriz de covarianzas cruzadas y el vector de esperanzas.

2.2.1. Vector de medias y matriz de covarianza

Definición 2.11 (Vector de medias y matriz de covarianza). Sea $X \in \mathbb{R}^p$ un vector aleatorio. El vector de medias es

$$\mu = \mathbb{E}(X) = \begin{pmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \\ \vdots \\ \mathbb{E}(X_p) \end{pmatrix} \in \mathbb{R}^p.$$

La matriz de covarianzas poblacional se define como

$$\Sigma = \text{Cov}(X) = \mathbb{E}[(X - \mu)(X - \mu)'] \in \mathbb{R}^{p \times p},$$

donde $\sigma_{ij} = \text{Cov}(X_i, X_j) = \mathbb{E}[(X_i - \mu_i)(X_j - \mu_j)]$.

La matriz Σ es simétrica y semidefinida positiva. Es estrictamente definida positiva cuando

$$\text{Var}(a'X) > 0 \quad \text{para todo } a \neq 0,$$

condición que garantiza la no degeneración de la distribución conjunta. Σ modela la dependencia estocástica entre las variables respuesta y es central en el modelo de regresión multivariado [4].

2.2.2. Transformaciones lineales

Proposición 2.12. Sea $X \in \mathbb{R}^p$ un vector aleatorio con media μ y covarianza Σ , y sea $A \in \mathbb{R}^{q \times p}$ una matriz constante. Para la transformación lineal $Y = AX$:

$$\mathbb{E}(Y) = A\mu, \quad \text{Cov}(Y) = A\Sigma A'.$$

Para la transformación afín $Y = AX + b$ con $b \in \mathbb{R}^q$:

$$\mathbb{E}(Y) = A\mu + b, \quad \text{Cov}(Y) = A\Sigma A'.$$

Demostración. Por linealidad de la esperanza:

$$\mathbb{E}(AX) = A\mathbb{E}(X) = A\mu.$$

La desviación respecto a la media es $Y - \mathbb{E}(Y) = A(X - \mu)$, por lo que

$$\text{Cov}(Y) = \mathbb{E}[A(X - \mu)(X - \mu)'A'] = A\mathbb{E}[(X - \mu)(X - \mu)']A' = A\Sigma A'.$$

Para $Y = AX + b$, la constante b no afecta la desviación:

$$Y - \mathbb{E}(Y) = (AX + b) - (A\mu + b) = A(X - \mu),$$

de modo que $\text{Cov}(Y) = A\Sigma A'$ y $\mathbb{E}(Y) = A\mu + b$. □

Este resultado es la base para analizar proyecciones de residuales en la inferencia multivariada [5].

Corolario 2.13. Para cualquier vector constante $a \in \mathbb{R}^p$, la varianza poblacional de la combinación lineal $a'X$ es

$$\text{Var}(a'X) = a'\Sigma a.$$

Demostración. Definiendo la matriz $A = a'$ (un vector fila) y aplicando la proposición anterior, la covarianza se define como

$$\text{Cov}(a'X) = a'\Sigma(a')'.$$

Dado que $(a')' = a$, y que para un escalar la covarianza es equivalente a la varianza, se obtiene que

$$\text{Var}(a'X) = a'\Sigma a.$$

□

2.2.3. Estructura de muestras multivariadas

Considérese una muestra aleatoria de vectores

$$X_1, \dots, X_n \in \mathbb{R}^p,$$

constituida por observaciones independientes e idénticamente distribuidas, con parámetros poblacionales

$$\mathbb{E}(X_i) = \mu, \quad \text{Cov}(X_i) = \Sigma.$$

Los datos empíricos se organizan en la matriz observacional

$$\mathcal{X} = \begin{pmatrix} X_1' \\ X_2' \\ \vdots \\ X_n' \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

Hay una independencia de un municipio a otro, pero también una dependencia en su interior. Si se pone atención en la covarianza nula entre las filas, es decir, unidades censales diferentes, se vea que se trata de un muestreo independiente. Las columnas son otro caso, al ser variables de rezago mantienen la dependencia que Σ pone de manifiesto. En definitiva, las filas no tienen por qué verse afectadas, pero las columnas sí.

Proposición 2.14. *Si las observaciones son independientes entre municipios, entonces*

$$\text{Cov}(\text{vec}(\mathcal{X})) = \Sigma \otimes I_n.$$

Demostración. El operador vec apila las columnas de $\mathcal{X}$. Sea $X^{(j)} \in \mathbb{R}^n$ la j -ésima columna, de modo que

$$\text{vec}(\mathcal{X}) = \begin{pmatrix} X^{(1)} \\ X^{(2)} \\ \vdots \\ X^{(p)} \end{pmatrix} \in \mathbb{R}^{np}.$$

La matriz $\text{Cov}(\text{vec}(\mathcal{X}))$ tiene dimensión $np \times np$ y se descompone en bloques $n \times n$. El bloque (j, k) tiene entradas

$$\text{Cov}(X_{ij}, X_{\ell k}) = \begin{cases} \Sigma_{jk}, & i = \ell, \\ 0, & i \neq \ell, \end{cases}$$

por independencia entre municipios. Por tanto $\text{Cov}(X^{(j)}, X^{(k)}) = \Sigma_{jk} I_n$, y la matriz completa es

$$\text{Cov}(\text{vec}(\mathcal{X})) = \begin{pmatrix} \Sigma_{11} I_n & \cdots & \Sigma_{1p} I_n \\ \vdots & \ddots & \vdots \\ \Sigma_{p1} I_n & \cdots & \Sigma_{pp} I_n \end{pmatrix} = \Sigma \otimes I_n.$$

□

La estructura $\Sigma \otimes I_n$ sintetiza el supuesto del modelo: independencia entre municipios y dependencia entre indicadores dentro de cada municipio [3].

2.2.4. Media muestral

Definición 2.15 (Media muestral). Dada una muestra aleatoria multivariada $X_1, \dots, X_n$, el estimador de la media muestral es el vector

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Los momentos asociados son:

$$\mathbb{E}(\bar{X}) = \mu, \quad \text{Cov}(\bar{X}) = \frac{1}{n} \Sigma.$$

Proposición 2.16. La media muestral $\bar{X}$ es un estimador insesgado de μ y su matriz de covarianzas poblacional es $\frac{1}{n} \Sigma$.

Demostración. La propiedad de estimador insesgado se verifica utilizando la linealidad del operador esperanza matemática:

$$\mathbb{E}(\bar{X}) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = \frac{1}{n} \sum_{i=1}^n \mu = \mu.$$

Para analizar la matriz de covarianzas, se calcula la desviación respecto a la media:

$$\bar{X} - \mu = \frac{1}{n} \sum_{i=1}^n (X_i - \mu),$$

y se determina la covarianza:

$$\text{Cov}(\bar{X}) = \mathbb{E}[(\bar{X} - \mu)(\bar{X} - \mu)'] = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n \mathbb{E}[(X_i - \mu)(X_j - \mu)'].$$

Por el supuesto de independencia estadística poblacional, la covarianza cruzada para índices distintos es nula,

$$\mathbb{E}[(X_i - \mu)(X_j - \mu)'] = 0 \quad \text{si } i \neq j.$$

Para los índices iguales, la covarianza corresponde al parámetro poblacional,

$$\mathbb{E}[(X_i - \mu)(X_i - \mu)'] = \Sigma.$$

La suma se reduce únicamente a los n términos donde $i = j$:

$$\text{Cov}(\bar{X}) = \frac{1}{n^2} \sum_{i=1}^n \Sigma = \frac{n\Sigma}{n^2} = \frac{1}{n} \Sigma.$$

□

El estimador muestral es insesgado. Su dispersión disminuye en proporción inversa al tamaño de la muestra [5]. Más datos, menor varianza.

2.2.5. Matriz de dispersión muestral

Para estimar la matriz de covarianzas poblacional se recurre a la matriz de sumas de cuadrados y productos cruzados centrada en la media:

$$S = \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})'.$$

Matricialmente, este estimador se reescribe como

$$S = (\mathcal{X} - \mathbf{1}\bar{X}')'(\mathcal{X} - \mathbf{1}\bar{X}'),$$

donde $\mathbf{1} \in \mathbb{R}^n$ es un vector columna de unos. Por construcción, la matriz S es simétrica y semidefinida positiva.

Definición 2.17 (Estimador muestral de la covarianza). El estimador insesgado de la matriz de covarianzas Σ se calcula como

$$\hat{\Sigma} = \frac{1}{n-1} S.$$

2.2.6. Estructura de dependencia

La matriz Σ condensa la dependencia entre las variables respuesta. Sus elementos tienen interpretación directa:

- La diagonal contiene las varianzas marginales de cada indicador.
- Los elementos fuera de la diagonal miden la asociación lineal entre pares de indicadores.
- Los vectores propios de Σ determinan las direcciones de mayor dispersión.
- La varianza de cualquier combinación lineal $a'X$ es $a'\Sigma a$.

Suponer Σ diagonal equivale a postular independencia entre indicadores, supuesto que en datos sociodemográficos raramente se sostiene. El modelo lineal multivariado estima Σ explícitamente; esta matriz interviene tanto en el diagnóstico del ajuste como en la inferencia [4].

2.3. Distribución normal multivariada

Normalidad multivariada habilita el aparato inferencial completo. El supuesto permite derivar estadísticos exactos en los modelos de regresión, calcular pruebas de significancia para los coeficientes y caracterizar analíticamente las distribuciones de los residuales y sus varianzas [5]. Es el cimiento del régimen exacto.

Convención de notación. A lo largo de este capítulo se utiliza la notación $X \sim N_p(\mu, \Sigma)$ para indicar que X es un vector aleatorio p -dimensional con distribución normal multivariada de vector de medias $\mu \in \mathbb{R}^p$ y matriz de covarianzas $\Sigma \in \mathbb{R}^{p \times p}$ simétrica y definida positiva. El subíndice indica explícitamente la dimensión del vector: $N_1(\mu, \sigma^2) \equiv N(\mu, \sigma^2)$ corresponde al caso escalar; $N_n(\cdot, \cdot)$ al caso n -dimensional asociado a la columna completa de una muestra; y $N_{p_1}(\mu_1, \Sigma_{11})$ a la marginal de un subvector X_1 de dimensión p_1 cuando se considera una partición $X = (X'_1, X'_2)'$. Para el caso matricial se emplea $\mathcal{MN}_{n,p}(M, V, \Sigma)$ (distribución normal matricial), que se introduce en la Subsección 2.3.8.

2.3.1. Definición y propiedades básicas

Definición 2.18 (Distribución normal multivariada). Un vector aleatorio poblacional $X \in \mathbb{R}^p$ sigue una distribución normal multivariada paramétrica definida por su vector de medias $\mu \in \mathbb{R}^p$ y matriz de covarianzas $\Sigma \in \mathbb{R}^{p \times p}$ (simétrica y definida positiva), si su función de densidad es:

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)' \Sigma^{-1} (x - \mu) \right\}, \quad x \in \mathbb{R}^p.$$

La notación estándar para esta distribución es

$$X \sim N_p(\mu, \Sigma).$$

La densidad depende de la forma cuadrática

$$(x - \mu)' \Sigma^{-1} (x - \mu),$$

cuyas curvas de nivel son hiper-elipsoides centrados en μ y cuya forma queda determinada por Σ [4].

2.3.2. Caracterización mediante transformaciones lineales

Teorema 2.19. Considerando un vector normal estándar $Z \sim N_p(0, I_p)$. Para una matriz paramétrica definida positiva Σ existe una matriz no singular $\Sigma^{1/2}$ tal que

$$\Sigma = \Sigma^{1/2} (\Sigma^{1/2})'.$$

La transformación afín

$$X = \mu + \Sigma^{1/2} Z$$

sigue exactamente una distribución

$$X \sim N_p(\mu, \Sigma).$$

Inversamente, si $X \sim N_p(\mu, \Sigma)$, la estandarización lineal

$$Z = \Sigma^{-1/2} (X - \mu)$$

transforma los datos en un vector normal estándar $Z \sim N_p(0, I_p)$.

Demostración. Dado que Σ es simétrica y definida positiva, su descomposición espectral arroja P ortogonal y Λ diagonal con $\lambda_i > 0$, tal que

$$\Sigma = P \Lambda P'.$$

Al definir la matriz

$$\Sigma^{1/2} = P \Lambda^{1/2} P',$$

se verifica directamente que

$$\Sigma^{1/2} (\Sigma^{1/2})' = P \Lambda^{1/2} P' P \Lambda^{1/2} P' = P \Lambda P' = \Sigma.$$

Dado que todos los valores propios son estrictamente positivos, $\Sigma^{1/2}$ no es una matriz singular. Definiendo la variable aleatoria $X = \mu + \Sigma^{1/2} Z$. A partir de la transformación matemática,

$$X - \mu = \Sigma^{1/2} Z, \quad Z = \Sigma^{-1/2} (X - \mu).$$

El determinante del jacobiano de la transformación matemática es

$$\left| \det \left(\frac{\partial z}{\partial x} \right) \right| = |\Sigma^{-1/2}| = |\Sigma|^{-1/2}.$$

Considerando la densidad paramétrica de $Z \sim N_p(0, I_p)$,

$$f_Z(z) = \frac{1}{(2\pi)^{p/2}} \exp\left(-\frac{1}{2}z'z\right),$$

y sustituyendo la equivalencia $z = \Sigma^{-1/2}(x - \mu)$, se obtiene:

$$f_X(x) = f_Z(\Sigma^{-1/2}(x - \mu))|\Sigma|^{-1/2} = \frac{1}{(2\pi)^{p/2}|\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(x - \mu)'\Sigma^{-1}(x - \mu)\right\},$$

lo cual corresponde exactamente a la definición paramétrica de la distribución normal poblacional $N_p(\mu, \Sigma)$. Para la segunda implicación de la prueba, partiendo de $X \sim N_p(\mu, \Sigma)$ y aplicando la transformación

$$Z = \Sigma^{-1/2}(X - \mu)$$

se obtiene de forma analítica que el resultado se distribuye estadísticamente como $Z \sim N_p(0, I_p)$. $\square$

La estandarización permite descomponer variables censales interrelacionadas en combinaciones lineales de proyecciones independientes, separando la estructura de dependencia mediante un cambio de coordenadas [5].

2.3.3. Forma cuadrática y distribución χ^2

Teorema 2.20. *Si el vector poblacional sigue la distribución $X \sim N_p(\mu, \Sigma)$, entonces su proyección paramétrica cuadrática es*

$$(X - \mu)'\Sigma^{-1}(X - \mu) \sim \chi_p^2.$$

Demostración. Sustituyendo la estandarización comprobada $Z = \Sigma^{-1/2}(X - \mu)$, que sigue una distribución $N_p(0, I_p)$, se tiene:

$$(X - \mu)'\Sigma^{-1}(X - \mu) = (X - \mu)'(\Sigma^{-1/2})'\Sigma^{-1/2}(X - \mu) = Z'Z.$$

Dado que los componentes del vector Z son variables estocásticas normales independientes, el resultado paramétrico equivale a una chi-cuadrada con grados de libertad proporcionales a p :

$$Z'Z = \sum_{i=1}^p Z_i^2 \sim \chi_p^2.$$

$\square$

La distancia de Mahalanobis es la métrica canónica para detectar observaciones atípicas en el contexto multivariado, al incorporar la estructura de covarianza Σ en el cálculo de distancias [3].

2.3.4. Combinaciones lineales

Proposición 2.21. *Para todo vector escalar paramétrico $a \in \mathbb{R}^p$, si $X \sim N_p(\mu, \Sigma)$, la distribución de la proyección lineal escalar es*

$$a'X \sim N(a'\mu, a'\Sigma a).$$

Demostración. Empleando el teorema de estandarización paramétrica poblacional $X = \mu + \Sigma^{1/2}Z$ con $Z \sim N_p(0, I_p)$, se establece la relación

$$a'X = a'\mu + a'\Sigma^{1/2}Z.$$

El primer término es la media determinista del vector. El segundo, $a'\Sigma^{1/2}Z$, es una combinación lineal de las componentes independientes de $Z \sim N_p(0, I_p)$ y por tanto sigue una distribución normal univariada. La esperanza poblacional paramétrica y la varianza son:

$$\mathbb{E}(a'X) = a'\mathbb{E}(X) = a'\mu, \quad \text{Var}(a'X) = a'\Sigma a.$$

□

Corolario 2.22. *Un vector poblacional aleatorio $X \in \mathbb{R}^p$ presenta una distribución paramétrica normal multivariada si y sólo si cualquier proyección analítica $a'X$ se distribuye como normal univariada.*

Esta caracterización permite verificar empíricamente si los residuales del modelo se ajustan a una distribución gaussiana multivariada [5].

2.3.5. Marginales y distribución condicional

Al particionar las matrices:

$$X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix},$$

donde $X_1 \in \mathbb{R}^{p_1}$ y $X_2 \in \mathbb{R}^{p_2}$.

Proposición 2.23. *Asumiendo que la distribución poblacional es*

$$X \sim N_p(\mu, \Sigma),$$

se comprueban analíticamente las siguientes características:

1. *Marginalización paramétrica: El bloque X_1 distribuye según*

$$X_1 \sim N_{p_1}(\mu_1, \Sigma_{11}).$$

2. *Distribución condicional poblacional: La variable X_1 condicionada a $X_2 = x_2$ se parametriza por:*

$$X_1 | X_2 = x_2 \sim N_{p_1}(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}).$$

Estas propiedades garantizan que la distribución gaussiana multivariada se preserva bajo marginalización y condicionamiento, lo que asegura la coherencia del modelo al trabajar con subconjuntos de variables [4].

2.3.6. Independencia y covarianza

Proposición 2.24. *Partiendo del supuesto asintótico de normalidad multivariada, una covarianza estadística nula es sinónimo de independencia. En efecto, si tenemos*

$$X \sim N_p(\mu, \Sigma)$$

y el término cruzado de la población se anula ($\Sigma_{12} = 0$), entonces las subvariables X_1 y X_2 gozan de independencia paramétrica.

Demostración. Basta con tomar los momentos condicionales ya demostrados e insertar el valor $\Sigma_{12} = 0$:

$$X_1 | X_2 = x_2 \sim N_{p_1}(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}).$$

De las equivalencias matemáticas se desprende una simplificación:

$$\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2) = \mu_1, \quad \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = \Sigma_{11}.$$

Con lo cual la variable se reduce a su comportamiento marginal:

$$X_1 \mid X_2 = x_2 \sim N_{p_1}(\mu_1, \Sigma_{11}).$$

Puesto que el parámetro estadístico no se ve alterado por x_2 , la probabilidad condicional empírica pasa a ser equivalente a la marginal para todo x_2 :

$$\mathcal{L}(X_1 \mid X_2 = x_2) = \mathcal{L}(X_1),$$

una garantía matemática de la independencia asintótica entre los bloques observacionales. □

En la distribución normal multivariada, covarianza nula es equivalente a independencia. Esta propiedad, exclusiva de la familia gaussiana, simplifica la validación de supuestos residuales en la estimación [5].

2.3.7. Distribución normal matricial

Definición 2.25 (Distribución normal matricial). Se dice que una matriz aleatoria $Y \in \mathbb{R}^{n \times p}$ sigue una distribución normal matricial con parámetros $M \in \mathbb{R}^{n \times p}$, $\Omega \in \mathbb{R}^{n \times n}$ y $\Sigma \in \mathbb{R}^{p \times p}$, denotado como

$$Y \sim \mathcal{MN}_{n,p}(M, \Omega, \Sigma),$$

si su vectorización sigue la distribución:

$$\text{vec}(Y) \sim N_{np}(\text{vec}(M), \Sigma \otimes \Omega).$$

Corolario 2.26. *Tomemos el caso de*

$$Y \sim \mathcal{MN}_{n,p}(M, I_n, \Sigma),$$

en el que las filas de Y son independientes y su distribución viene dada por

$$Y_{i\cdot} \sim N_p(m_i, \Sigma), \quad i = 1, \dots, n.$$

Demostración. De la definición de matriz normal se tiene

$$\text{vec}(Y) \sim N_{np}(\text{vec}(M), \Sigma \otimes I_n).$$

Dado que el producto de Kronecker $\Sigma \otimes I_n$ anula la covarianza entre unas y otras filas, cada una de ellas, $Y_{i\cdot}$, mantiene su distribución:

$$Y_{i\cdot} \sim N_p(m_i, \Sigma), \quad i = 1, \dots, n.$$

□

Este supuesto determina la estructura de los errores y hace posible la inferencia: define la distribución de la matriz aleatoria U sobre la que se fundamenta la estimación por mínimos cuadrados [3].

2.3.8. Muestras normales

Proposición 2.27. *Dado un conjunto de observaciones independientes $X_1, \dots, X_n$ que siguen $N_p(\mu, \Sigma)$, el modelo arroja:*

1. *El estimador de media empírico sigue:*

$$\bar{X} \sim N_p\left(\mu, \frac{1}{n}\Sigma\right).$$

2. *La matriz central de productos sigue una Wishart:*

$$\sum_{i=1}^n (X_i - \mu)(X_i - \mu)' \sim W_p(n, \Sigma).$$

3. *La media muestral y la matriz central son estadísticamente independientes:*

$$\bar{X} \perp S, \quad S = \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})'.$$

La independencia entre $\hat{B}$ y $\hat{\Sigma}$ separa los componentes de localización y dispersión, resultado que fundamenta la teoría inferencial basada en distribuciones Wishart [5].

2.4. Matrices de dispersión y la distribución Wishart

Podría decirse que la Wishart es la versión matricial de la chi-cuadrada. Para ser más precisos, se trata de una generalización del χ^2 a las matrices simétricas semidefinidas positivas. De hecho, en el análisis conjunto de estimadores, es la que determina el comportamiento de las sumas de cuadrados y los productos cruzados propios de las proyecciones empíricas [4, 5].

2.4.1. Definición de la Wishart

Definición 2.28 (Distribución Wishart). Sea un conjunto de observaciones independientes $X_1, \dots, X_n$ provenientes de $N_p(0, \Sigma)$, con Σ definida positiva. La matriz central de productos [4]

$$S = \sum_{i=1}^n X_i X_i'$$

sigue la distribución Wishart con n grados de libertad y matriz de escala Σ . Se denota como

$$S \sim \mathcal{W}_p(n, \Sigma).$$

Si las observaciones se organizan en $\mathcal{X} \in \mathbb{R}^{n \times p}$,

$$S = \mathcal{X}'\mathcal{X} \sim \mathcal{W}_p(n, \Sigma).$$

La familia Wishart es la herramienta natural ya que modela los residuos multivariados en el ajuste de regresión.

2.4.2. Vínculo con la chi-cuadrada

Proposición 2.29. *En el caso escalar, es decir, cuando $p = 1$, la Wishart que se obtiene de $X_i \sim N(0, \sigma^2)$ no es más que:*

$$S = \sum_{i=1}^n X_i^2 \sim \sigma^2 \chi_n^2.$$

Demostración. Pongamos $p = 1$ y el parámetro Σ se convierte en σ^2 . Si estandarizamos las variables de la forma

$$X_i = \sigma Z_i, \quad Z_i \sim N(0, 1),$$

y lo llevamos a la suma de cuadrados tenemos

$$S = \sum_{i=1}^n X_i^2 = \sum_{i=1}^n (\sigma Z_i)^2 = \sigma^2 \sum_{i=1}^n Z_i^2.$$

Dado que la suma de los cuadrados de normales estándar independientes obedece por definición a una chi-cuadrada, resulta

$$S \sim \sigma^2 \chi_n^2.$$

□

La distribución Wishart generaliza al caso matricial las sumas de cuadrados de la teoría univariada, la estructura es análoga al caso de dimensión p [5].

2.4.3. Propiedades fundamentales

Proposición 2.30. *Para una matriz $S \sim \mathcal{W}_p(n, \Sigma)$ se cumple:*

1. **Esperanza:**

$$\mathbb{E}(S) = n\Sigma.$$

2. **Escalamiento:** para toda proyección $A \in \mathbb{R}^{q \times p}$,

$$ASA' \sim \mathcal{W}_q(n, A\Sigma A').$$

3. **Adición:** Para matrices $S_1 \sim \mathcal{W}_p(n_1, \Sigma)$ y $S_2 \sim \mathcal{W}_p(n_2, \Sigma)$ independientes,

$$S_1 + S_2 \sim \mathcal{W}_p(n_1 + n_2, \Sigma).$$

4. **Invarianza ortogonal:** si se emplea una matriz ortogonal Q ($Q'Q = I$),

$$Q'SQ \sim \mathcal{W}_p(n, Q'\Sigma Q).$$

Demostración. Sea $\mathcal{X} \in \mathbb{R}^{n \times p}$ tal que cada fila proviene de $N_p(0, \Sigma)$. La matriz central de productos es

$$S = \mathcal{X}'\mathcal{X} = \sum_{i=1}^n X_i X_i'.$$

1. **Esperanza.** Aplicando la linealidad del operador esperanza:

$$\mathbb{E}(S) = \sum_{i=1}^n \mathbb{E}(X_i X_i').$$

Con centroide nulo, se deduce que $\mathbb{E}(X_i X_i') = \Sigma$. Por tanto:

$$\mathbb{E}(S) = \sum_{i=1}^n \Sigma = n\Sigma.$$

2. Escalamiento. Sea $Y_i = AX_i$. Como las combinaciones lineales de normales conservan su carácter gaussiano,

$$Y_i \sim N_q(0, A\Sigma A').$$

Para el agregado:

$$ASA' = A\mathcal{X}'\mathcal{X}A' = (\mathcal{X}A')'(\mathcal{X}A') = \sum_{i=1}^n Y_i Y_i'.$$

Esta suma sigue, por la misma definición Wishart:

$$ASA' \sim \mathcal{W}_q(n, A\Sigma A').$$

3. Adición. Considérense $S_1 = \mathcal{X}'\mathcal{X}$ y $S_2 = \mathcal{Y}'\mathcal{Y}$ provenientes de $\mathcal{X} \in \mathbb{R}^{n_1 \times p}$ e $\mathcal{Y} \in \mathbb{R}^{n_2 \times p}$ sin covarianza cruzada y con distribución común $N_p(0, \Sigma)$. El apilamiento

$$\mathcal{Z} = \begin{pmatrix} \mathcal{X} \\ \mathcal{Y} \end{pmatrix} \in \mathbb{R}^{(n_1+n_2) \times p},$$

contiene $n_1 + n_2$ filas independientes. Por ende:

$$\mathcal{Z}'\mathcal{Z} = \mathcal{X}'\mathcal{X} + \mathcal{Y}'\mathcal{Y} = S_1 + S_2,$$

y la suma distribuye:

$$S_1 + S_2 \sim \mathcal{W}_p(n_1 + n_2, \Sigma).$$

4. Invarianza ortogonal. Se obtiene tomando $A = Q'$ en la propiedad de escalamiento:

$$Q'SQ \sim \mathcal{W}_p(n, Q'\Sigma Q).$$

□

Las propiedades de la Wishart sostienen la estructura inferencial, pues respaldan desde su núcleo, la metodología de pruebas multivariadas basadas en sumas de cuadrados [4].

2.4.4. Matriz de covarianza muestral

Para una muestra $X_1, \dots, X_n \sim N_p(\mu, \Sigma)$, con la media muestral

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

y la suma de productos centrada

$$S = \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})'.$$

Teorema 2.31. *Se verifica que:*

1. *La matriz centrada sigue:*

$$S \sim \mathcal{W}_p(n-1, \Sigma).$$

2. El estimador insesgado de la covarianza es:

$$\widehat{\Sigma} = \frac{1}{n-1} S, \quad \mathbb{E}(\widehat{\Sigma}) = \Sigma.$$

3. La media muestral y la matriz S son independientes:

$$\bar{X} \perp S.$$

Demostración. Considérese la representación matricial:

$$\mathcal{X} = \begin{pmatrix} X_1' \\ \vdots \\ X_n' \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

Para una muestra con distribución común $N_p(\mu, \Sigma)$, la matriz $\mathcal{X}$ sigue:

$$\mathcal{X} \sim \mathcal{MN}_{n,p}(\mathbf{1}\mu', I_n, \Sigma),$$

donde $\mathbf{1} \in \mathbb{R}^n$. Sea el proyector centralizador

$$J_n = I_n - \frac{1}{n} \mathbf{1}\mathbf{1}',$$

idempotente, con rango $n-1$, que anula al vector constante:

$$J_n \mathbf{1} = 0.$$

La suma de productos centrada se reescribe como

$$S = \mathcal{X}' J_n \mathcal{X},$$

dado que $J_n \mathcal{X} = \mathcal{X} - \mathbf{1}\bar{X}'$ produce:

$$\mathcal{X}' J_n \mathcal{X} = (\mathcal{X} - \mathbf{1}\bar{X}')' (\mathcal{X} - \mathbf{1}\bar{X}') = \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})'.$$

Como la proyección elimina la media ($J_n(\mathbf{1}\mu') = 0$), la matriz centrada distribuye:

$$J_n \mathcal{X} \sim \mathcal{MN}_{n,p}(0, J_n, \Sigma).$$

Dado que es una matriz simétrica de rango $n-1$, podemos diagonalizarla con una transformación ortogonal $Q \in \mathbb{R}^{n \times n}$. Optamos por tomar su última fila como $(1/\sqrt{n})\mathbf{1}'$ de modo que se ajuste al espacio nulo de J_n , esto es, la dirección que anula la centrada:

$$J_n = Q' \begin{pmatrix} I_{n-1} & 0 \\ 0 & 0 \end{pmatrix} Q.$$

Si hacemos $Z = Q\mathcal{X}$, las primeras $n-1$ filas, $Z_1, \dots, Z_{n-1}$, serán combinaciones lineales centradas de las de $\mathcal{X}$ (ortogonales a la media) y, en virtud de la normalidad de $\mathcal{X}$ y la ortogonalidad de Q , independientes con ley $N_p(0, \Sigma)$. La última, $Z_n = \sqrt{n}\bar{X}$, se encarga de la media muestral y no tiene nada que ver con S . Al sustituir:

$$S = \mathcal{X}' J_n \mathcal{X} = Z' \begin{pmatrix} I_{n-1} & 0 \\ 0 & 0 \end{pmatrix} Z = \sum_{i=1}^{n-1} Z_i Z_i'.$$

De aquí se desprende que $S \sim \mathcal{W}_p(n-1, \Sigma)$.

La esperanza nos da el sesgo del estimador:

$$\mathbb{E}(\hat{\Sigma}) = \mathbb{E}\left(\frac{1}{n-1}S\right) = \frac{1}{n-1}(n-1)\Sigma = \Sigma.$$

Cuanto a la independencia de $\bar{X}$ y S , basta observar que

$$\bar{X} = \frac{1}{n}\mathcal{X}'\mathbf{1}.$$

El vector $\mathbf{1}$ y el proyector J_n son ortogonales, por ello, los estimadores se dividen en componentes normales independientes:

$$\bar{X} \perp S.$$

□

Es una dicotomía estructural entre localización y dispersión, dos ejes de análisis disjuntos que dan pie a gran parte del modelado multivariado que viene después [5].

2.4.5. Estructura espectral

Proposición 2.32. *Para una matriz S que sigue una $\mathcal{W}_p(n, \Sigma)$ con $n \geq p$, tenemos que S es definida positiva y su descomposición espectral se escribe como*

$$S = Q\Lambda Q',$$

siendo Q de tipo ortogonal y $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$.

De esta factorización se obtienen las direcciones principales, en las que se asienta la visión geométrica del análisis multivariado [4], los autovectores son los ejes.

2.4.6. Distribución de submatrices

Si hacemos un particionamiento de

$$S = \begin{pmatrix} S_{11} & S_{12} \\ S_{21} & S_{22} \end{pmatrix} \sim \mathcal{W}_p(n, \Sigma),$$

los distintos bloques carecen de independencia. No obstante, al aplicar operaciones de condicionamiento se mantiene la estructura Wishart en las submatrices de que se trate [4].

2.4.7. La Wishart en el modelo lineal multivariado

Dado el modelo

$$Y = XB + U,$$

junto con el supuesto

$$U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma).$$

Teorema 2.33. *Para este ajuste, la matriz residual*

$$E = \hat{U}'\hat{U} = Y'(I_n - P_X)Y$$

se distribuye como

$$E \sim \mathcal{W}_p(n - q, \Sigma),$$

y existe independencia:

$$\hat{B} \perp E.$$

Demostración. Dado que $(I_n - P_X)X = 0$, el proyector residual se encarga de filtrar la parte sistemática:

$$(I_n - P_X)Y = (I_n - P_X)XB + (I_n - P_X)U = (I_n - P_X)U.$$

Esto nos lleva a la forma cuadrática

$$E = Y'(I_n - P_X)Y = U'(I_n - P_X)U.$$

Puesto que $(I_n - P_X)$ es un operador simétrico e idempotente de rango $n - q$, y partiendo de

$$U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma),$$

la distribución de su forma cuadrática será

$$(I_n - P_X)U \sim \mathcal{MN}_{n,p}(0, I_n - P_X, \Sigma).$$

Si hacemos una descomposición ortogonal de la forma

$$I_n - P_X = Q' \begin{pmatrix} I_{n-q} & 0 \\ 0 & 0 \end{pmatrix} Q,$$

y operamos con $Z = QU$, obtenemos

$$E = U'(I_n - P_X)U = Z' \begin{pmatrix} I_{n-q} & 0 \\ 0 & 0 \end{pmatrix} Z = \sum_{i=1}^{n-q} Z_i Z_i',$$

donde los Z_i son independientes y $N_p(0, \Sigma)$. Por tanto, el estimador residual tiene la distribución

$$E \sim \mathcal{W}_p(n - q, \Sigma).$$

La independencia de $\hat{B}$ respecto de E se debe a la ortogonalidad de los proyectores. Mientras el estimador

$$\hat{B} = (X'X)^{-1}X'Y$$

va de la mano con $P_X Y$, el operador E depende del componente ortogonal $(I_n - P_X)Y$. En condiciones de normalidad, las formas correspondientes a subespacios perpendiculares son estadísticamente independientes, es decir,

$$\hat{B} \perp E.$$

□

Este resultado habilita el análisis de varianza multivariado y constituye la base del andamiaje inferencial del modelo [3].

2.4.8. Matrices de suma de cuadrados y productos cruzados

En regresión lineal multivariada aparecen dos formas cuadráticas matriciales centrales, conocidas como matrices SSCP (*Sum of Squares and Cross-Products*, por sus siglas en inglés; en español, sumas de cuadrados y productos cruzados):

Definición 2.34 (Matrices SSCP). La matriz explicada por el modelo es

$$H = Y'P_X Y,$$

y la matriz residual es

$$E = Y'(I_n - P_X)Y.$$

Proposición 2.35. *La descomposición de la suma de cuadrados total se expresa como*

$$Y'Y = H + E.$$

Demostración. Usando la identidad

$$P_X + (I_n - P_X) = I_n,$$

la suma total se reescribe:

$$Y'Y = Y'I_nY = Y'(P_X + (I_n - P_X))Y.$$

Al distribuir:

$$Y'Y = Y'P_XY + Y'(I_n - P_X)Y = H + E.$$

□

Teorema 2.36. *Bajo normalidad multivariada, la matriz residual distribuye como*

$$E \sim \mathcal{W}_p(n - q, \Sigma),$$

y es independiente de H . Cuando también se cumple la hipótesis nula sobre los coeficientes:

$$H \sim \mathcal{W}_p(q, \Sigma).$$

Demostración. La independencia de $\hat{B}$ y E es un hecho ya demostrado. En el caso de

$$H = Y'P_XY,$$

esta proviene del espacio columna por intermedio de P_XY , en tanto que E se forma en el complemento ortogonal $(I_n - P_X)Y$; con la estructura gaussiana de por medio, la independencia entre una y otra está asegurada:

$$H \perp E.$$

Veamos la distribución de H . Dado que $P_XY = XB + P_XU$, si nos situamos en la hipótesis nula donde la parte sistemática XB se hace cero, entonces H no es más que una Wishart central $\mathcal{W}_p(q, \Sigma)$. □

La partición matricial de la varianza en H y E es el fundamento de la inferencia y el contraste de hipótesis conjuntas en el modelo lineal multivariado [3, 4].

2.5. Modelo lineal multivariado

El modelo lineal multivariado extiende la regresión múltiple clásica al caso de varias respuestas simultáneas. Su ventaja metodológica central es incorporar explícitamente la correlación entre las respuestas, evitando los problemas de estimación que surgen al ajustar regresiones univariadas de forma independiente [3].

Definición 2.37 (Modelo lineal multivariado). Formalmente, si $Y \in \mathbb{R}^{n \times p}$ es la matriz de variables respuesta, $X \in \mathbb{R}^{n \times q}$ la de covariables explicativas (de rango completo q) y $B \in \mathbb{R}^{q \times p}$ la de coeficientes poblacionales, tenemos la siguiente definición:

$$Y = XB + U,$$

siendo $U \in \mathbb{R}^{n \times p}$ la matriz de errores aleatorios [4].

2.5.1. Dos formas de ver el modelo

El sistema matricial $Y = XB + U$ admite dos lecturas complementarias.

Por filas La i -ésima fila satisface

$$y'_i = x'_i B + u'_i,$$

donde $y'_i \in \mathbb{R}^p$ es el vector de respuestas del municipio i y x'_i su vector de covariables.

Por columnas Denotando $Y_{.j}$ y $\beta^{(j)}$ las j -ésimas columnas de Y y B , el modelo se descompone en p ecuaciones:

$$Y_{.j} = X\beta^{(j)} + U_{.j}, \quad j = 1, \dots, p.$$

Aunque esto sugiere estimar cada $\beta^{(j)}$ por separado, los vectores de error $U_{.j}$ están correlacionados entre sí. El enfoque multivariado modela explícitamente esa estructura de covarianza residual, que es precisamente lo que distingue este análisis de p regresiones independientes [1].

2.5.2. Supuestos del modelo

■ **Linealidad:** $Y = XB + U$.

■ **Rango completo:** $\text{rango}(X) = q$.

■ **Media cero:** $\mathbb{E}(U) = 0$.

■ **Estructura de covarianza:**

$$\text{Cov}(\text{vec}(U)) = \Sigma \otimes I_n,$$

con $\Sigma \in \mathbb{R}^{p \times p}$ simétrica y definida positiva.

■ **Normalidad multivariada:**

$$U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma).$$

La estructura $\Sigma \otimes I_n$ codifica simultáneamente la independencia entre observaciones y la dependencia entre respuestas dentro de cada observación [5].

2.5.3. Formulación vectorizada

Proposición 2.38. *Mediante el operador matricial vec podemos reescribir el modelo de regresión multivariada como*

$$\text{vec}(Y) = (I_p \otimes X) \text{vec}(B) + \text{vec}(U).$$

Demostración. Partimos de la ecuación de la población

$$Y = XB + U$$

y aplicamos de forma lineal el operador vec :

$$\text{vec}(Y) = \text{vec}(XB) + \text{vec}(U).$$

Usando la propiedad del producto de Kronecker para la vectorización de productos, $\text{vec}(ABC) = (C' \otimes A) \text{vec}(B)$, y poniendo $A = X$, $B = B$ e $C = I_p$, se tiene que

$$\text{vec}(XB) = \text{vec}(XB I_p) = (I'_p \otimes X) \text{vec}(B) = (I_p \otimes X) \text{vec}(B).$$

Con esto, el sistema adopta la forma

$$\text{vec}(Y) = (I_p \otimes X) \text{vec}(B) + \text{vec}(U).$$

□

La vectorización no es más que convertir el modelo de múltiples respuestas en un sistema lineal generalizado de dimensión np . La forma varía, pero la dependencia no; la matriz de covarianzas residual $\Sigma \otimes I_n$ exige un tratamiento que la tenga en cuenta [3].

2.5.4. Estimación por mínimos cuadrados

El estimador de mínimos cuadrados ordinarios (MCO) minimiza la traza de la suma de cuadrados de los residuales:

$$\hat{B} = \arg \min_{B \in \mathbb{R}^{q \times p}} \|Y - XB\|_F^2.$$

Teorema 2.39 (Estimador de mínimos cuadrados). *Bajo el supuesto de que $\text{rango}(X) = q$, la matriz de coeficientes estimada por MCO en el modelo lineal multivariado es:*

$$\hat{B} = (X'X)^{-1}X'Y.$$

Demostración. Se define la función objetivo cuadrática como

$$Q(B) = \|Y - XB\|_F^2,$$

la cual se expresa matricialmente mediante el operador traza:

$$Q(B) = \text{tr}((Y - XB)'(Y - XB)).$$

Desarrollando el producto interno de las matrices:

$$(Y - XB)'(Y - XB) = Y'Y - Y'XB - B'X'Y + B'X'XB.$$

Aplicando las propiedades de invarianza cíclica de la traza, se tiene $\text{tr}(Y'XB) = \text{tr}(B'X'Y)$. Simplificando la función:

$$Q(B) = \text{tr}(Y'Y) - 2\text{tr}(B'X'Y) + \text{tr}(B'X'XB).$$

Para minimizar la función, se deriva matricialmente respecto a la matriz B y se iguala a cero:

$$\frac{\partial Q(B)}{\partial B} = -2X'Y + 2X'XB = 0.$$

Esto da lugar al sistema de ecuaciones normales:

$$X'XB = X'Y.$$

Dado que la matriz de diseño X tiene rango completo, el producto $X'X$ es invertible. Multiplicando por su inversa, se despeja la matriz de coeficientes:

$$\hat{B} = (X'X)^{-1}X'Y.$$

Esta solución corresponde a un mínimo global debido a la estricta convexidad de la forma cuadrática empleada. $\square$

Calcular $\hat{B}$ equivale a correr p regresiones univariadas en paralelo. El análisis probabilístico del estimador, en cambio, exige considerar conjuntamente la matriz de varianzas residuales [1].

2.5.5. Propiedades del estimador

Al sustituir el modelo poblacional $Y = XB + U$ en la ecuación del estimador, se obtiene

$$\hat{B} = B + (X'X)^{-1}X'U.$$

Aplicando el operador de vectorización, la expresión se convierte en:

$$\text{vec}(\hat{B}) = \text{vec}(B) + (I_p \otimes (X'X)^{-1}X') \text{vec}(U).$$

Corolario 2.40. *El estimador MCO es insesgado:*

$$\mathbb{E}(\hat{B}) = B.$$

Demostración. Aplicando el valor esperado a la ecuación de la matriz estimada:

$$\mathbb{E}(\hat{B}) = B + (X'X)^{-1}X'\mathbb{E}(U).$$

Como los errores poblacionales tienen esperanza cero ($\mathbb{E}(U) = 0$), se concluye que:

$$\mathbb{E}(\hat{B}) = B.$$

□

Teorema 2.41 (Covarianza y distribución de $\hat{B}$). *La matriz de covarianzas del estimador vectorizado es*

$$\text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes (X'X)^{-1}.$$

Asumiendo normalidad matricial en los errores poblacionales, se tiene:

$$\hat{B} \sim \mathcal{MN}_{q,p}(B, (X'X)^{-1}, \Sigma).$$

Demostración. Utilizando la forma lineal vectorizada

$$\text{vec}(\hat{B}) = \text{vec}(B) + (I_p \otimes (X'X)^{-1}X') \text{vec}(U),$$

la matriz de covarianzas depende exclusivamente del término estocástico $\text{vec}(U)$:

$$\text{Cov}(\text{vec}(\hat{B})) = (I_p \otimes (X'X)^{-1}X') \text{Cov}(\text{vec}(U))(I_p \otimes (X'X)^{-1}X')'.$$

Sustituyendo el supuesto $\text{Cov}(\text{vec}(U)) = \Sigma \otimes I_n$ y aplicando la propiedad $(A \otimes B)(C \otimes D) = (AC) \otimes (BD)$ del producto de Kronecker, junto con la convención de vectorización por columnas:

$$\text{Cov}(\text{vec}(\hat{B})) = (I_p \otimes (X'X)^{-1}X')(\Sigma \otimes I_n)(I_p \otimes X(X'X)^{-1}).$$

Al agrupar los términos de las matrices correspondientes:

$$\text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes ((X'X)^{-1}X' I_n X (X'X)^{-1}).$$

El término central se simplifica, ya que $(X'X)^{-1}X'X(X'X)^{-1} = (X'X)^{-1}$. Se obtiene entonces:

$$\text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes (X'X)^{-1}.$$

Considerando que $U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma)$, su forma vectorizada se distribuye como $N_{np}(0, \Sigma \otimes I_n)$. La normalidad multivariada se preserva ya que el estimador es una combinación lineal de los errores. En notación matricial paramétrica:

$$\hat{B} \sim \mathcal{MN}_{q,p}(B, (X'X)^{-1}, \Sigma).$$

□

El error de estimación depende del diseño muestral codificado en X y las correlaciones residuales codificadas en Σ [5].

2.5.6. Interpretación geométrica

Proposición 2.42. *De la estimación por mínimos cuadrados se obtienen los valores ajustados del modelo:*

$$\hat{Y} = X\hat{B} = P_X Y,$$

con P_X como el proyector ortogonal en el espacio columna $\mathcal{C}(X)$, a saber,

$$P_X = X(X'X)^{-1}X'.$$

En cuanto a la matriz de residuales, queda definida por

$$\hat{U} = (I_n - P_X)Y,$$

de modo que los datos observados admiten una descomposición ortogonal:

$$Y = \hat{Y} + \hat{U}, \quad \hat{Y} \in \mathcal{C}(X), \quad \hat{U} \in \mathcal{C}(X)^\perp.$$

Demostración. Basta con reemplazar el estimador $\hat{B}$ para ver que los valores proyectados son

$$\hat{Y} = X(X'X)^{-1}X'Y = P_X Y.$$

Al restar esto de lo observado se tiene la matriz de error residual:

$$\hat{U} = Y - \hat{Y} = Y - P_X Y = (I_n - P_X)Y,$$

cumpliendo así con la identidad geométrica $Y = \hat{Y} + \hat{U}$. Como es de esperar, al ser P_X un proyector ortogonal sobre $\mathcal{C}(X)$ tenemos $\hat{Y} \in \mathcal{C}(X)$; el término $(I_n - P_X)$, por su parte, envía los datos al complemento ortogonal, por lo que $\hat{U} \in \mathcal{C}(X)^\perp$. $\square$

Una lectura geométrica inmediata: el MCO es una proyección ortogonal. El método estadístico toma el vector de datos y lo proyecta en el subespacio de las covariables para reducir a su mínimo la distancia euclidiana generalizada [6].

2.5.7. Relación con la estimación por máxima verosimilitud

Asumiendo que las observaciones provienen de una distribución normal matricial $Y \sim \mathcal{MN}_{n,p}(XB, I_n, \Sigma)$, la función de verosimilitud asociada es

$$L(B, \Sigma) \propto |\Sigma|^{-n/2} \exp \left\{ -\frac{1}{2} \text{tr} [(Y - XB)'(Y - XB)\Sigma^{-1}] \right\}.$$

Maximizar esta función respecto a B se reduce, en términos prácticos, a minimizar el argumento de la traza:

$$\text{tr} [(Y - XB)'(Y - XB)\Sigma^{-1}].$$

Corolario 2.43. *Bajo el supuesto estadístico de normalidad multivariada, el estimador de máxima verosimilitud para la matriz B es idéntico al estimador MCO:*

$$\hat{B} = (X'X)^{-1}X'Y.$$

Demostración. Se define la función a minimizar como

$$Q_\Sigma(B) = \text{tr} [(Y - XB)'(Y - XB)\Sigma^{-1}].$$

Expandiendo los productos internos de las matrices:

$$Q_\Sigma(B) = \text{tr}(Y'Y\Sigma^{-1}) - 2\text{tr}(B'X'Y\Sigma^{-1}) + \text{tr}(B'X'XB\Sigma^{-1}).$$

La derivada respecto a la matriz B se iguala al vector nulo:

$$\frac{\partial Q_{\Sigma}(B)}{\partial B} = -2X'Y\Sigma^{-1} + 2X'XB\Sigma^{-1} = 0.$$

Lo que produce la igualdad paramétrica:

$$X'XB\Sigma^{-1} = X'Y\Sigma^{-1}.$$

Dado que la inversa de la matriz de covarianzas Σ^{-1} es no singular, se postmultiplica por Σ para obtener:

$$X'XB = X'Y.$$

Finalmente, despejando la variable poblacional:

$$\hat{B} = (X'X)^{-1}X'Y.$$

□

2.5.8. Matriz de residuos y estimación de Σ

La varianza no explicada por el modelo se cuantifica en la matriz de sumas de cuadrados de los residuales, denotada por E :

$$E = \hat{U}'\hat{U} = Y'(I_n - P_X)Y.$$

Corolario 2.44. *El estimador insesgado de la matriz de covarianzas poblacional Σ es:*

$$\hat{\Sigma} = \frac{1}{n - q}E.$$

Por la teoría de matrices gaussianas, la matriz de error sigue $E \sim \mathcal{W}_p(n - q, \Sigma)$, siendo independiente de $\hat{B}$ [5].

2.5.9. Descomposición de la variabilidad

Definición 2.45 (Descomposición multivariada de la variabilidad). La matriz de suma de cuadrados total, T , se divide en dos componentes ortogonales

$$T = Y'Y = H + E,$$

donde la varianza explicada por el ajuste paramétrico es

$$H = Y'P_XY,$$

y la varianza residual se define por

$$E = Y'(I_n - P_X)Y.$$

Proposición 2.46. *La relación fundamental*

$$T = H + E$$

constituye el análogo multivariado de la descomposición de varianza univariada, proveyendo la estructura base para el análisis de inferencia.

Observación 2.47. Cuando la matriz de diseño X contiene un vector columna constante (intercepto), la descomposición admite la formulación equivalente con matrices centradas $T_c = (Y - \bar{Y})(Y - \bar{Y})'$, $H_c = (Y - \bar{Y})'P_X(Y - \bar{Y})$ y $E_c = E$, también de la forma $T_c = H_c + E_c$. La presentación empírica del Capítulo 3 utiliza esta versión centrada, sobre la cual se define el coeficiente de determinación multivariado por traza $R_{tr}^2 = \text{tr}(H_c)/\text{tr}(T_c)$. Por comodidad de notación, en los capítulos de implementación y resultados se escriben simplemente T y H para referirse a estas versiones centradas T_c y H_c ; salvo mención expresa, toda aparición empírica de T , H y R_{tr}^2 corresponde a la descomposición centrada.

Demostración. Insertando la matriz identidad expresada como $I_n = P_X + (I_n - P_X)$ en la expresión de suma total:

$$Y'Y = Y'I_nY = Y'(P_X + (I_n - P_X))Y.$$

Al aplicar la distribución de las matrices respecto a las sumas:

$$Y'Y = Y'P_XY + Y'(I_n - P_X)Y = H + E.$$

□

2.5.10. Optimalidad del estimador

Teorema 2.48 (Teorema de Gauss–Markov multivariado). *En la clase de estimadores lineales que cumplen $\tilde{B} = AY$, el estimador MCO es el mejor estimador lineal insesgado. Para cualquier estimador competidor lineal e insesgado $\tilde{B}$, la matriz diferencia*

$$\text{Cov}(\text{vec}(\tilde{B})) - \text{Cov}(\text{vec}(\hat{B}))$$

resulta ser semidefinida positiva.

Demostración. Sea un estimador alternativo $\tilde{B} = AY$, con $A \in \mathbb{R}^{q \times n}$. La condición estricta de insesgamiento exige que:

$$\mathbb{E}(\tilde{B}) = A\mathbb{E}(Y) = AXB = B.$$

Esto requiere que la relación algebraica cumpla $AX = I_q$.

Se define una matriz constante auxiliar:

$$D = A - (X'X)^{-1}X'.$$

Multiplicando la ecuación por la matriz de diseño X :

$$DX = AX - (X'X)^{-1}X'X = I_q - I_q = 0.$$

En consecuencia, la matriz original puede reescribirse como:

$$A = (X'X)^{-1}X' + D, \quad \text{sujeta a } DX = 0.$$

La matriz de covarianzas de este nuevo operador paramétrico es

$$\text{Cov}(\text{vec}(\tilde{B})) = \Sigma \otimes AA',$$

mientras que el estimador de mínimos cuadrados presenta la covarianza:

$$\text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes (X'X)^{-1}.$$

Evaluando el producto matricial AA' :

$$AA' = ((X'X)^{-1}X' + D)(X(X'X)^{-1} + D').$$

Expandiendo los elementos:

$$AA' = (X'X)^{-1} + (X'X)^{-1}X'D' + DX(X'X)^{-1} + DD'.$$

Dado que se verificó $DX = 0$ y por simetría $X'D' = 0$, los componentes cruzados se eliminan:

$$AA' = (X'X)^{-1} + DD'.$$

Al sustituir en la diferencia de covarianzas propuesta:

$$\text{Cov}(\text{vec}(\tilde{B})) - \text{Cov}(\text{vec}(\hat{B})) = \Sigma \otimes DD'.$$

Dado que ambas matrices Σ y DD' son por definición semidefinidas positivas, su producto de Kronecker mantiene dicha propiedad estadística. En consecuencia, el estimador MCO posee la covarianza mínima posible [1]. $\square$

2.6. Inferencia en el modelo lineal multivariado

La inferencia conjunta evalúa dos matrices en paralelo. Apoyada en la matriz de sumas de cuadrados del error y en la de las hipótesis, construye sus pruebas sobre criterios matriciales anclados en la descomposición espectral [5], quedando $Y = XB + U$ con $U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma)$.

2.6.1. Hipótesis lineales generales

Definición 2.49 (Hipótesis lineal general). Para realizar contrastes sobre la matriz de coeficientes poblacionales se define la hipótesis nula

$$H_0 : CB = D,$$

donde las matrices constantes son $C \in \mathbb{R}^{q_h \times q}$, con $q_h = \text{rango}(C) \leq q$, y $D \in \mathbb{R}^{q_h \times p}$. Por tanto, q_h es una propiedad teórica del contraste especificado y no debe estimarse mediante el rango numérico de una matriz SSCP observada.

La formulación cubre contrastes globales sobre el sistema, evaluaciones de predictores individuales y comparaciones simultáneas [3]. Como $\hat{B} \sim \mathcal{MN}_{q,p}(B, (X'X)^{-1}, \Sigma)$, bajo H_0 :

$$C\hat{B} - D \sim \mathcal{MN}_{q_h,p}(0, C(X'X)^{-1}C', \Sigma).$$

2.6.2. Contraste global del modelo: el caso $D = 0$

El contraste de mayor interés práctico es el caso particular en que la hipótesis nula afirma que el bloque de predictores no tiene efecto lineal conjunto sobre el vector de respuestas. Bajo el modelo $Y = XB + U$ con $X = [\mathbf{1}, X_1, \dots, X_{q-1}]$, sea

$$C = (0_{(q-1) \times 1} \quad I_{q-1}) \in \mathbb{R}^{(q-1) \times q},$$

la matriz que elimina la primera fila de B (correspondiente al intercepto) y selecciona las $q - 1$ filas asociadas a las covariables. El contraste global del modelo se formula como

$$H_0 : CB = 0 \quad \text{contra} \quad H_1 : CB \neq 0.$$

Bajo H_0 , el bloque de predictores carece de efecto lineal conjunto sobre Y ; bajo H_1 , al menos un predictor afecta linealmente al menos una dimensión o combinación lineal de las respuestas. La elección $D = 0$ es la natural en regresión: la pregunta no es si los coeficientes alcanzan un valor concreto, sino si el bloque de predictores aporta información estadística sobre Y una vez fijado el nivel medio por el intercepto. Por esta razón C excluye la fila del intercepto: probar $H_0 : B = 0$ con el intercepto incluido sería contrastar también que la media del vector de respuestas es cero, lo cual no forma parte del contraste de significancia del modelo [1, 3].

2.6.3. Construcción de las matrices de hipótesis y error

Definición 2.50 (Matrices de hipótesis y error). La variación explicada asociada a la restricción $H_0 : CB = D$ se define como la matriz de sumas de cuadrados de la hipótesis:

$$H = (C\hat{B} - D)' [C(X'X)^{-1}C']^{-1} (C\hat{B} - D).$$

La variación no explicada corresponde a la matriz de error residual:

$$E = Y'(I_n - P_X)Y.$$

La matriz H condensa la discrepancia del ajuste, siendo la suma de cuadrados de la hipótesis y mide cuán lejos cae la estimación empírica respecto a los coeficientes hipotéticos, ponderada por la geometría del diseño [4].

Proposición 2.51. Las matrices H y E son simétricas y semidefinidas positivas.

Demostración. Para el caso de la matriz H , defínase $G = [C(X'X)^{-1}C']^{-1}$. Ya que $X'X$ es definida positiva y C posee rango completo, la matriz interna es definida positiva. Su matriz inversa, G , hereda la simetría y positividad. Si se evalúa una forma cuadrática para cualquier vector $a \in \mathbb{R}^p$:

$$a'Ha = [(C\hat{B} - D)a]' G [(C\hat{B} - D)a] \geq 0.$$

Para la matriz de error $E = \hat{U}'\hat{U}$, su transpuesta es equivalente $E' = E$. Evaluando el producto cuadrático escalar:

$$a'Ea = (\hat{U}a)'(\hat{U}a) = \|\hat{U}a\|^2 \geq 0,$$

lo cual confirma rigurosamente que es una matriz semidefinida positiva. $\square$

2.6.4. Distribución de H y E

Teorema 2.52 (Distribución de las matrices de hipótesis y error). Considerando normalidad matricial poblacional y asumiendo cierta $H_0 : CB = D$, se verifica estadísticamente:

$$H \sim \mathcal{W}_p(q_h, \Sigma), \quad E \sim \mathcal{W}_p(n - q, \Sigma), \quad H \perp E.$$

Demostración. A partir de la definición de los valores residuales se tiene $(I_n - P_X)X = 0$. Se sigue que $\hat{U} = (I_n - P_X)U$. Esto permite reescribir la matriz cuadrática como

$$E = U'(I_n - P_X)U.$$

La matriz $I_n - P_X$ es un operador idempotente con $\text{rango}(I_n - P_X) = n - q$. Bajo el supuesto de la regresión poblacional $U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma)$, la matriz derivada distribuye como un objeto de tipo Wishart:

$$E \sim \mathcal{W}_p(n - q, \Sigma).$$

Para analizar la distribución de la matriz H , se define la variable aleatoria $A = [C(X'X)^{-1}C']^{-1/2} (C\hat{B} - D)$, donde el factor $[C(X'X)^{-1}C']^{-1/2}$ es una matriz constante determinística que estandariza la dispersión por filas de $C\hat{B} - D$. Este procedimiento transforma el sistema a:

$$A \sim \mathcal{MN}_{q_h,p}(0, I_{q_h}, \Sigma).$$

Como $H = A'A$, por las propiedades estocásticas de la matriz resultante, distribuye analíticamente como una variable de Wishart:

$$H \sim \mathcal{W}_p(q_h, \Sigma).$$

La independencia estocástica obedece a la ortogonalidad de los proyectores involucrados. El operador de la hipótesis H se fundamenta en los parámetros empíricos obtenidos de $\widehat{B}$, los cuales residen en el subespacio columna proyectado por $P_X Y$. A su vez, los residuales E se basan exclusivamente en el complemento ortogonal dictaminado por $(I_n - P_X)Y$. Bajo normalidad matricial, las formas cuadráticas asociadas a subespacios perpendiculares son estadísticamente independientes:

$$H \perp E.$$

□

La independencia entre formas cuadráticas asociadas a subespacios ortogonales es el resultado operativo. Esa propiedad vuelve viables, en términos prácticos, los esquemas de prueba multivariados.

2.6.5. Estructura espectral del problema inferencial

Proposición 2.53. *Para hacer inferencia de la hipótesis nula poblacional H_0 nos basamos analíticamente en los valores propios $\lambda_1, \dots, \lambda_{s_0}$ que se desprenden del problema característico:*

$$|H - \lambda E| = 0,$$

o bien en su equivalente diagonal simplificado:

$$|E^{-1}H - \lambda I_p| = 0.$$

donde el parámetro teórico que entra en las distribuciones nulas es

$$s_0 = \min(p, q_h).$$

El rango numérico observado satisface $\text{rango}(HE^{-1}) \leq s_0$, pero no sustituye a q_h ni a s_0 en los grados de libertad de las aproximaciones inferenciales.

Demostración. Con tal de que las observaciones empíricas censales superen el número de variables ($n - q \geq p$), la matriz E resulta estrictamente definida positiva y con inversa, lo cual nos autoriza a reemplazar la expresión paramétrica de partida por la ecuación matricial de los valores propios de $E^{-1}H$. Dado que $C\widehat{B} - D$ tiene dimensión $q_h \times p$, el rango de H no puede exceder q_h ; además, por la dimensión de H , tampoco puede exceder p . Por ello hay a lo sumo $\min(p, q_h)$ raíces no nulas. En una realización concreta pueden aparecer raíces numéricamente nulas por precisión finita o por la configuración de la muestra, sin que ello modifique el rango de la hipótesis lineal especificada por C . □

En el fondo, cada valor propio es un cociente que cuantifica de forma relativa el peso de la varianza debida a la restricción sobre el ruido residual del sistema [3].

2.6.6. Estadísticos de prueba clásicos

Al sumar esos valores propios se arman los contrastes de la matriz de parámetros. Existen cuatro canónicas para resumir el espectro, con el mismo insumo se obtienen lecturas dispares.

Definición 2.54 (Lambda de Wilks). Se define como una prueba de proporción de determinantes:

$$\Lambda = \frac{|E|}{|H + E|} = \prod_{i=1}^s \frac{1}{1 + \lambda_i}.$$

En este símbolo, Λ denota el estadístico de Wilks, un escalar en $[0, 1]$; no debe confundirse con la matriz diagonal de valores propios $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ de la descomposición espectral presentada al inicio del capítulo, que es de dimensión $p \times p$. El contexto distingue ambos usos.

Un Λ bajo indica que H está dominando a E , lo que constituye una evidencia para rechazar la hipótesis nula.

Definición 2.55 (Traza de Pillai). Estadísticamente viene dada por

$$V = \text{tr} [H(H + E)^{-1}] = \sum_{i=1}^s \frac{\lambda_i}{1 + \lambda_i}.$$

Al agregar las proporciones normalizadas de variación explicada, la traza de Pillai suele mostrar mayor estabilidad relativa ante desviaciones moderadas de los supuestos distribucionales.

Definición 2.56 (Traza de Hotelling–Lawley). Una definición empírica de la traza sobre la proporción no restringida es [9]:

$$T_{HL} = \text{tr}(E^{-1}H) = \sum_{i=1}^s \lambda_i.$$

Ponemos el subíndice HL para no confundirlo con la $T = H + E$, la matriz total de sumas de cuadrados y productos cruzados de la Sección 2.5.

Definición 2.57 (Raíz mayor de Roy). Esta vía de inferencia se apoya en el componente de mayor relación de dispersión [1]:

$$\theta = \lambda_{\text{máx}} = \max_{1 \leq i \leq s} \lambda_i.$$

Las distribuciones exactas de estos estadísticos requieren procedimientos numéricos o tablas especializadas. En la práctica se emplean aproximaciones a una distribución F para Wilks, Pillai y Hotelling–Lawley. Roy exige una distinción: cuando $s = 1$ conduce a una prueba F exacta, pero cuando $s > 1$ la expresión usual es solo una cota superior y no una aproximación F válida [1, 5].

2.6.7. Región de rechazo

Para Wilks, Pillai y Hotelling–Lawley, la práctica recurre a aproximaciones a la distribución F univariada cuya forma genérica es

$$F_{\text{obs}} = g(\text{estadístico}, p, q, n - q),$$

donde g es la transformación específica del estadístico empleado. Fijado un nivel de significancia $\alpha \in (0, 1)$, la región de rechazo asociada al contraste $H_0 : CB = 0$ se define como

$$\mathcal{R}_\alpha = \{ F_{\text{obs}} > F_{1-\alpha}(\nu_1, \nu_2) \},$$

con (ν_1, ν_2) los grados de libertad propios para cada aproximación. Para esos tres criterios se rechaza H_0 si el estadístico observado cae en $\mathcal{R}_\alpha$, o equivalentemente si el p -valor cumple que $p < \alpha$. En el resto del documento se emplea el nivel convencional $\alpha = 0.05$. Cuando H_0 no es rechazada, no se concluye que $CB = 0$ sea cierta, se concluye únicamente que los datos no aportan evidencia suficiente para descartarla al nivel α . La distinción entre *rechazar* y *no rechazar* es esencial en estadística inferencial [1, 3].

Tabla 2.1: Aproximaciones a la distribución F para Wilks, Pillai y Hotelling–Lawley, y referencia descriptiva para Roy, bajo $H_0 : CB = 0$. Aquí $q_h = \text{rango}(C)$, $\nu_e = n - q$ y $s = \min(p, q_h)$.

Estadístico	Aproximación F (esquema)	Grados de libertad (ν_1, ν_2)
Wilks Λ	Aproximación de Rao a partir de $\Lambda^{1/t}$	$(p q_h, r t - p q_h/2 + 1)$
Pillai V	Aproximación clásica de Pillai–Bartlett	$(s(2m + s + 1), s(2N + s + 1))$
Hotelling–Lawley T_{HL}	$F = T_{HL}/c$	(a, b)
Roy θ	Cota superior descriptiva $F_{\text{ref}} = (\nu_e - d - 1)\theta/d$	$(d, \nu_e - d - 1)$

En las aproximaciones de la Tabla 2.1, las constantes auxiliares para Wilks y Pillai son $m = \frac{1}{2}(|p - q_h| - 1)$, $N = \frac{1}{2}(\nu_e - p - 1)$, $r = \nu_e - \frac{1}{2}(p - q_h + 1)$ y $t = \sqrt{(p^2 q_h^2 - 4)/(p^2 + q_h^2 - 5)}$ (con $t = 1$ cuando $p q_h = 2$). Para Hotelling–Lawley se emplean

$$a = p q_h, \quad B_* = \frac{(\nu_e + q_h - p - 1)(\nu_e - 1)}{(\nu_e - p - 3)(\nu_e - p)}, \quad b = 4 + \frac{a + 2}{B_* - 1}, \quad c = \frac{a(b - 2)}{b(\nu_e - p - 1)},$$

y para la cota de Roy, $d = \max(p, q_h)$. Aquí $\nu_e = n - q$. Rencher advierte que, cuando $s_0 > 1$, esta cota excede la F verdadera y no es una aproximación válida: una indicación de rechazo basada en ella no sustenta una decisión inferencial autónoma. Por ello se conserva únicamente como referencia descriptiva, sin p -valor; la decisión global descansa en Wilks, Pillai y Hotelling–Lawley [1].

Los cuatro estadísticos prueban el mismo juego de hipótesis $H_0 : CB = 0$, pero resumen la información del espectro $\{\lambda_i\}_{i=1}^{s_0}$ de manera distinta: Λ acumula multiplicativamente $1/(1 + \lambda_i)$, V acumula aditivamente $\lambda_i/(1 + \lambda_i)$, T_{HL} acumula aditivamente λ_i y θ usa únicamente λ_1 . Cuando $s_0 = 1$, sus transformaciones exactas conducen a la misma prueba F , aunque los valores de los cuatro estadísticos no sean iguales. Para $s_0 > 1$ pueden diferir en potencia, en particular si la asociación se concentra en una sola dirección canónica o si se distribuye entre varias direcciones [1, 10].

2.6.8. Regiones de confianza simultáneas

Consideremos un subconjunto dado de combinaciones lineales estimadas, digamos $L = CB \in \mathbb{R}^{q_h \times p}$. Según la teoría distribucional, tenemos que

$$C\hat{B} \sim \mathcal{MN}_{q,p}(CB, C(X'X)^{-1}C', \Sigma).$$

De ahí partimos para armar las regiones elipsoidales de confianza de los coeficientes a un nivel conjunto de $1 - \alpha$. El límite del elipsoide viene dado por

$$(C\hat{B} - CB)' [C(X'X)^{-1}C']^{-1} (C\hat{B} - CB) \leq c_\alpha \hat{\Sigma},$$

donde el valor de c_α lo tomamos de los cuantiles de la F de Fisher. En cuanto al volumen del elipsoide en el espacio euclidiano, este depende directamente de la matriz Σ que se observa [5], basta con tener mayor covarianza para ver crecer el volumen.

2.6.9. Invarianza

Proposición 2.58. *La inferencia asintótica poblacional en la regresión lineal multivariada conjunta es invariante frente a multiplicaciones deterministas o transformaciones lineales no singulares aplicadas a la matriz paramétrica empírica respuesta $Y^* = YA$.*

Demostración. Se define una matriz constante invertida A . Al transformar el modelo original empírico $Y^* = YA$, los nuevos coeficientes paramétricos obedecen la equivalencia:

$$Y^* = X(BA) + UA,$$

resultando en estimadores ajustados poblacionalmente $\hat{B}^* = \hat{B}A$. Las matrices de varianza analítica empíricas resultantes son

$$H^* = A'HA, \quad E^* = A'EA.$$

El problema característico original de los residuales se expande analíticamente a

$$|H^* - \lambda E^*| = |A'HA - \lambda A'EA| = |A'| |H - \lambda E| |A|.$$

Debido a que el componente A es explícitamente no singular, el determinante no es nulo ($|A'| |A| \neq 0$). En consecuencia empírica poblacional estadística:

$$|H^* - \lambda E^*| = 0 \iff |H - \lambda E| = 0.$$

Esta propiedad garantiza que los valores de Wilks, Pillai, Hotelling–Lawley y Roy no se alteran; las conclusiones inferenciales son robustas frente a rotaciones o re-escalamientos de los datos vía una matriz A [4]. $\square$

2.7. Diagnóstico del modelo lineal multivariado

La validez de las inferencias del modelo depende del cumplimiento de sus supuestos estructurales. La verificación se realiza sobre los residuales estimados, examinando si exhiben las propiedades analíticas y estadísticas requeridas [11].

2.7.1. Matriz de residuos

Definición 2.59 (Matriz de residuos). La estimación de error paramétrica observacional para el modelo de regresión multivariado conjunto es:

$$\hat{U} = Y - X\hat{B} = (I_n - P_X)Y,$$

donde la matriz

$$P_X = X(X'X)^{-1}X'$$

representa al proyector analítico ortogonal sobre el subespacio de variables empíricas poblacionales.

Cada fila $\hat{u}'_i$ registra la discrepancia entre observado y ajustado para el municipio i . Es la materia prima sobre la que se construye toda la verificación de supuestos. Sin residuales no hay diagnóstico.

2.7.2. Normalidad multivariada

Partimos de la suposición del modelo

$$u_i \sim N_p(0, \Sigma), \quad i = 1, \dots, n.$$

Para comprobar si se da esta condición recurrimos a la distancia de Mahalanobis sobre los vectores de residuales.

Definición 2.60 (Distancia de Mahalanobis residual). La métrica multivariada residual para una observación i queda definida como

$$D_{i,\text{res}}^2 = \hat{u}'_i \hat{\Sigma}^{-1} \hat{u}_i,$$

en la que interviene el estimador matricial de covarianza

$$\hat{\Sigma} = \frac{1}{n - q} \hat{U}' \hat{U}.$$

Bajo los supuestos del modelo y para muestras grandes, $D_{i,\text{res}}^2 \sim \chi_p^2$. Un valor inusualmente elevado indica mal ajuste en el subespacio multidimensional e identifica al municipio i como observación atípica, candidata a un análisis adicional [3, 12].

2.7.3. Homocedasticidad e independencia

El modelo no permite que la matriz $\text{Cov}(u_i) = \Sigma$ varíe con i ; debe ser constante. De lo contrario surge una heterocedasticidad multivariada que mermaría la eficiencia del estimador MCO [1, 13], y la varianza constante es un requisito sin concesiones.

De forma paralela se exige que no haya correlación cruzada ($\text{Cov}(u_i, u_j) = 0$ cuando $i \neq j$), para evitar cualquier sesgo de tipo geográfico o espacial entre los municipios de la muestra.

2.7.4. Observaciones influyentes

A través del diagnóstico podemos individualizar aquellas observaciones que, por su presencia, mueven el ajuste. Es decir, detectar qué municipios están afectando el panorama general en el espacio predictivo.

Definición 2.61 (Apalancamiento / Leverage). Nos servimos del elemento diagonal del proyector ortogonal para medir el peso de la observación i en el modelo:

$$h_{ii} = x_i'(X'X)^{-1}x_i.$$

Un h_{ii} alto delata un municipio en los confines del espacio de las covariables. Pero el leverage no es todo; también hay que cuantificar el desplazamiento de los coeficientes si nos quitamos una observación de en medio.

Definición 2.62 (Distancia de Cook multivariada). Con esta medida se valora cuánto se mueve $\hat{B}$ al dejar fuera al municipio i [14]:

$$D_i = \text{tr} \left[(\hat{B} - \hat{B}_{(i)})'(X'X)(\hat{B} - \hat{B}_{(i)})\hat{\Sigma}^{-1} \right],$$

siendo $\hat{B}_{(i)}$ la estimación sin la observación i .

En la práctica computacional resulta más ágil usar la equivalencia

$$D_i = \frac{1}{p} \cdot \frac{h_{ii}}{(1 - h_{ii})^2} \hat{u}_i' \hat{\Sigma}^{-1} \hat{u}_i,$$

que normaliza la distancia según la convención (dividiendo por p , el número de variables respuesta) [15]. Un valor de D_i desproporcionado pone de manifiesto la influencia anómala de un municipio en la estimación global de los coeficientes [3].

2.7.5. Residuos estandarizados

Para validar el modelo de covarianza y hacer una inspección gráfica:

Definición 2.63 (Residuos estandarizados). Se premultiplica por la raíz inversa de la covarianza para obtener la matriz transformada:

$$r_i = \hat{\Sigma}^{-1/2} \hat{u}_i.$$

Esta operación reescala los residuales, les da varianza unitaria y elimina la correlación cruzada. Después de la transformación, examinar si hay desviaciones de la normalidad o alguna anomalía en la dispersión [11].

Una vez formalizado el modelo, implementado el diagnóstico y derivada la inferencia conjunta, se tiene el sistema matemático necesario para dar soporte al análisis empírico del rezago social y su implementación algorítmica en los siguientes capítulos.

Capítulo 3

Implementación computacional del modelo

La implementación computacional traslada la formulación matricial del modelo lineal multivariado a un procedimiento reproducible en Python. Este capítulo detalla cómo se han procesado los datos censales para armar las matrices X e Y , la estimación por mínimos cuadrados de $\hat{B}$, el cálculo de las matrices SSCP y la obtención de los estadísticos necesarios para las pruebas de hipótesis conjuntas. De igual modo, se documentan las rutinas de diagnóstico residual, verificación de supuestos y detección de observaciones atípicas e influyentes.

El desarrollo, hecho con Python [16], recurre a NumPy para lo que requiere de álgebra lineal [17]. La estimación está programada de manera explícita para que haya una relación directa entre la teoría matricial y los resultados obtenidos, aparte de que no existe ningún paquete o librería adecuada para realizar regresión multivariada. Así, la construcción de las SSCP, los residuales, la matriz de coeficientes y sus métricas de diagnóstico se han hecho a mano [1, 3]. Se utilizó `scipy.stats` para los cuantiles y las funciones de distribución acumulada de F y χ^2 al calcular los p -valores asintóticos.

Todo el proceso queda resumido en la Figura 3.1: un flujo de seis pasos (desde la limpieza y la estructuración hasta el análisis canónico) donde las flechas de trazo continuo son la ejecución y las discontinuas el intercambio de variables. El ajuste del modelo se ha realizado en 2469 municipios (n), con $p = 4$ respuestas y once columnas en la matriz de diseño (q), es decir, el intercepto junto a diez covariables sociodemográficas. La razón de esta selección se expone en el Capítulo 4.

3.1. Arquitectura del sistema

El código fue desarrollado en Python mediante notebooks ejecutados en Visual Studio Code. Se programaron dieciocho celdas del cuaderno interactivo de forma que vayan en sintonía con la metodología de la Figura 3.1. En un primer lugar se importan las librerías, se pone a punto la tolerancia de punto flotante para no tener problemas de redondeo y se siembra la semilla pseudoaleatoria, de este modo se asegura reproducir los resultados.

Le siguen las funciones auxiliares. Van cubriendo por orden estricto desde la estimación por mínimos cuadrados o el cálculo de las SSCP hasta las pruebas de hipótesis simultáneas y la validación de supuestos a través de los residuales, para terminar con las variables canónicas. La separación entre la capa estadística y la de datos responde a un criterio operativo, permite auditar la estimación módulo a módulo. La Tabla 3.1 detalla la correspondencia entre ambas capas.




Figura 3.1: Esquemización del procedimiento algorítmico subyacente a la estimación multivariada, indicando el flujo de información desde las matrices de datos hasta las pruebas de hipótesis y métricas de diagnóstico.

Tabla 3.1: Relación estructural entre las celdas de código y las matrices estadísticas en el modelo multivariado.

Módulo operativo	Celdas asignadas	Variables y matrices generadas
Inicialización y funciones auxiliares	1, 2	Semilla aleatoria, funciones base
Procesamiento de bases de datos	3, 4, 5, 6	Base depurada, R_{ij} , R^*
Estructuración matricial	7	$X \in \mathbb{R}^{2469 \times 11}$, $Y \in \mathbb{R}^{2469 \times 4}$
Estimación MCO y matrices SSCP	8, 9	$\hat{B}$, $\hat{U}$, $\hat{\Sigma}$, T , H , E
Pruebas de hipótesis conjuntas	10	Λ , V , T_{HL} , θ , $\{H_j\}_{j=1}^{10}$
Evaluación de normalidad (Mardia)	11	$b_{1,p}$, $b_{2,p}$, $D_{i,\text{res}}^2$
Prueba de heterocedasticidad	12	Regresión auxiliar (Prueba de White)
Análisis de matriz residual	13	Correlaciones residuales
Detección de observaciones atípicas	14	h_i , $D_{i,X}^2$, D_i
Análisis de sensibilidad	15	Reestimación sin observaciones influyentes
Análisis de correlación canónica	16, 17	M , $\{a_j\}$, Y_c , $\hat{Y}_c$
Visualización de resultados	18	Distribuciones marginales, mapas de calor

3.1.1. Funciones auxiliares

El cálculo matricial requiere control aritmético explícito. Se implementaron las siguientes funciones auxiliares:

1. **Proporciones censales.** Devuelve el cociente cuando numerador y denominador están definidos y el denominador es estrictamente positivo; en caso contrario asigna NA.
2. **Operador vech.** Extrae los elementos únicos del triángulo inferior de una matriz simétrica; se emplea en la prueba de White multivariada.
3. **Inversión de matrices de covarianzas.** Incluye un parámetro de tolerancia para detectar singularidad o multicolinealidad severa antes de calcular la inversa.
4. **Estadísticos de Mardia.** Calcula los coeficientes de asimetría ($b_{1,p}$) y curtosis ($b_{2,p}$) multivariada para evaluar la normalidad de los residuales [12].
5. **Mínimos cuadrados ordinarios.** Estima $\hat{B}$, $\hat{Y}$, $\hat{U}$, $\hat{\Sigma}$ y las matrices SSCP T , H y E en una sola rutina.
6. **Valores propios de $E^{-1}H$.** Calcula los estadísticos de Wilks, Pillai, Hotelling–Lawley y Roy con sus aproximaciones a la distribución F .

La implementación explícita hace verificable la correspondencia entre los fundamentos teóricos del modelo y los resultados numéricos [4].

3.2. Preparación de la base analítica

3.2.1. Lectura, validación y depuración inicial

La importación abre el *pipeline* (flujo secuencial de procesamiento de datos en el que la salida de cada etapa alimenta directamente a la siguiente). Una vez uniformados los nombres de las variables, el algoritmo aplica las condiciones de exclusión del Capítulo 4 para conservar únicamente las observaciones a nivel municipal; de ahí el programa verifica la ausencia de identificadores geográficos duplicados y registra la frecuencia de NA por variable. Esa verificación es importante por una razón, garantiza que X y Y compartan cardinalidad.

Una desalineación dimensional, por mínima que sea, invalida las operaciones matriciales sobre las que descansa la estimación [8]. La verificación de dimensiones se ejecuta antes de cualquier operación cuadrática.

3.2.2. Construcción de variables analíticas

N_{ij} denota el conteo absoluto de la característica j en el municipio i , y D_{ij} su base poblacional. La proporción censal se calcula así:

$$R_{ij} = \begin{cases} \frac{N_{ij}}{D_{ij}}, & \text{si } N_{ij}, D_{ij} \text{ están observados y } D_{ij} > 0, \\ \text{NA}, & \text{en otro caso.} \end{cases} \quad (3.1)$$

Tras el cómputo, se verifica que toda $R_{ij} \in [0, 1]$ y se eliminan por listwise las observaciones con NA en variables del modelo, garantizando una base rectangular completa, requisito indispensable para el cálculo de formas cuadráticas multivariadas.

3.2.3. Transformación y estandarización

Las proporciones reciben raíz cuadrada antes del armado matricial:

$$R^* = \sqrt{R} \quad (3.2)$$

En el plano computacional, la transformación estabiliza la varianza de los indicadores y reduce el peso de las observaciones extremas sobre la matriz de covarianzas residual [3, 11]. Las variables de diseño se estandarizan mediante

$$Z_{ij} = \frac{X_{ij}^{\text{raw}} - \bar{X}_{\cdot j}^{\text{raw}}}{s_j}, \quad (3.3)$$

donde s_j es la desviación estándar muestral de la variable j . Si $s_j = 0$, la variable recibe una constante normalizada para evitar divisiones por cero. La matriz de diseño incorpora un vector unitario para el intercepto:

$$X = [\mathbf{1}, Z] \in \mathbb{R}^{n \times q}. \quad (3.4)$$

La estandarización aplica únicamente a X ; las variables respuesta en Y conservan la transformación $\sqrt{R}$ para mantener la interpretabilidad respecto a las magnitudes observadas.

3.2.4. Controles numéricos

Antes de proceder al ajuste hay que confirmar que X tiene rango completo. El algoritmo se encarga de comprobar que $\text{rango}(X) = q$, ya que de no ser así $X'X$ no sería invertible y no habría una solución única para el estimador MCO. Se puso un control adicional que, partiendo de la descomposición en valores singulares [14], da el número de condición $\kappa(X) = 4.5485$, lo que indica que no hay colinealidad severa.

3.3. Estimación y descomposición SSCP

El Algoritmo 1 expuesto más adelante indica como se realiza el cómputo. Ejecuta las operaciones algebraicas que producen la matriz de coeficientes $\hat{B}$, las proyecciones $\hat{Y}$, los errores $\hat{U}$ y la matriz de covarianzas $\hat{\Sigma}$, para que el estimador de la dispersión conjunta resulte insesgado, la matriz de productos cruzados residuales se divide entre los grados de libertad correspondientes, $n - q$ [4, 5].

Algoritmo 1: Cálculo de la regresión MCO y partición de la variabilidad SSCP

```

Datos de Entrada : Matriz respuesta  $Y \in \mathbb{R}^{n \times p}$ , matriz explicativa  $X \in \mathbb{R}^{n \times q}$ 
Variables de Salida:  $\hat{B}, \hat{Y}, \hat{U}, \hat{\Sigma}, T, H, E$ 

// Verificación de rango completo
1 si  $\text{rang}(X) \neq q$  entonces
2   | devolver fallo: rango estructural deficiente en la matriz  $X$ 
3 fin
4  $\kappa \leftarrow \text{cond}(X)$ 
5 si  $\kappa > 10^8$  entonces
6   | bandera de advertencia por multicolinealidad severa
7 fin

// Estimación del modelo MCO
8  $\hat{B} \leftarrow (X'X)^{-1}X'Y$ 
9  $\hat{Y} \leftarrow X\hat{B}$ 
10  $\hat{U} \leftarrow Y - \hat{Y}$ 

// Estimación de la matriz de covarianzas residual
11  $\text{gl}_{\text{error}} \leftarrow n - q$ 
12 si  $\text{gl}_{\text{error}} \leq 0$  entonces
13   | devolver fallo: grados de libertad insuficientes
14 fin
15  $\hat{\Sigma} \leftarrow \hat{U}'\hat{U}/(n - q)$ 

// Cálculo de matrices SSCP centradas
16  $\bar{Y} \leftarrow \mathbf{1}\bar{y}'$ 
17  $T \leftarrow (Y - \bar{Y})'(Y - \bar{Y})$ 
18  $E \leftarrow \hat{U}'\hat{U}$ 
19  $H \leftarrow T - E$ 

// Verificación de la descomposición ortogonal
20  $\varepsilon \leftarrow \max |T - (H + E)|$ 
21 si  $\varepsilon > 10^{-8}$  entonces
22   | bandera de advertencia por error numérico en la suma de cuadrados
23 fin
24 devolver  $(\hat{B}, \hat{Y}, \hat{U}, \hat{\Sigma}, T, H, E)$ 

```

3.3.1. Descomposición centrada de la variabilidad

Antes de proceder con la descomposición, se tiene la matriz de medias:

$$\bar{Y} = \mathbf{1}\bar{y}',$$

donde $\bar{y}$ es el vector de medias muestrales de las variables respuesta. A partir de estos residuales se construyen las matrices total (T), residual (E) e hipótesis (H), que sostienen la inferencia conjunta del modelo lineal multivariado:

$$T = (Y - \bar{Y})'(Y - \bar{Y}), \quad E = \hat{U}'\hat{U}, \quad H = T - E. \quad (3.5)$$

De hecho, esta es la base de todo. El algoritmo va provisto de una rutina para hallar $\max |T - (H + E)|$ y así constatar, entrada a entrada, que las matrices respetan la identidad de la partición de cuadrados. Es una comprobación numérica necesaria, de lo contrario, cualquier imprecisión podría filtrarse en la inferencia.

3.4. Inferencia multivariada

3.4.1. Contraste global del modelo

A partir de H y E , el Algoritmo 2 evalúa la significancia conjunta resolviendo una versión simétrica del problema de valores propios generalizado. De los valores propios λ_i se derivan los cuatro estadísticos multivariados: Wilks, Pillai, Hotelling–Lawley y Roy. El argumento gl_h se proporciona explícitamente como $\text{rango}(C)$; el rango numérico observado de H se conserva solo como diagnóstico y no interviene en los grados de libertad.

Algoritmo 2: Cálculo de estadísticos de prueba multivariados

Datos de Entrada : Matrices SSCP $H, E \in \mathbb{R}^{p \times p}$, $gl_h = \text{rango}(C)$ y gl_{error}
Variables de Salida : Estadísticos $\Lambda, V, T_{HL}, \theta$ y aproximaciones a la distribución F

```

1 si  $|E| \approx 0$  entonces
2   | devolver fallo: matriz de covarianzas residual singular
3 fin

  // Cálculo estable de valores propios
4  $L \leftarrow \text{chol}(E)$ ;  $M \leftarrow L^{-1}HL^{-T}$ 
5  $\{\lambda_i\}_{i=1}^s \leftarrow \text{eig}((M + M')/2)$  //  $s = \min(p, gl_h)$ 
6 Anular únicamente raíces de magnitud inferior a la tolerancia relativa de punto flotante

  // Cálculo de estadísticos multivariados
7  $\Lambda \leftarrow \exp\{\text{slogdet}(E) - \text{slogdet}(H + E)\}$  // Lambda de Wilks
8  $V \leftarrow \sum_{i=1}^s \lambda_i / (1 + \lambda_i)$  // Traza de Pillai
9  $T_{HL} \leftarrow \sum_{i=1}^s \lambda_i$  // Traza de Hotelling–Lawley
10  $\theta \leftarrow \max(\lambda_1, \dots, \lambda_s)$  // Raíz mayor de Roy

  // Aproximaciones teóricas a la distribución F
11  $F_\Lambda \leftarrow \text{Aproximación de Rao}(\Lambda, p, gl_h, gl_{\text{error}})$ 
12  $F_V \leftarrow \text{Aproximación de Pillai–Bartlett}(V, p, gl_h, gl_{\text{error}})$ 
13  $F_{HL} \leftarrow \text{Aproximación clásica}(T_{HL}, p, gl_h, gl_{\text{error}})$ 
14  $F_\theta \leftarrow \text{Transformación exacta si } s = 1; \text{ cota superior si } s > 1$ 
15 devolver  $(\Lambda, V, T_{HL}, \theta, F_\Lambda, F_V, F_{HL}, F_\theta)$ 
```

El coeficiente descriptivo basado en la traza $R_{\text{tr}}^2 = \frac{\text{tr}(H)}{\text{tr}(T)}$ mide la proporción de varianza total explicada linealmente por el modelo. Las pruebas formales de significancia global emplean los criterios de Wilks y Pillai [4, 5]; el criterio de Pillai es preferible ante desviaciones moderadas de la normalidad multivariada [10, 18]. Los criterios de Hotelling–Lawley y Roy completan el conjunto [3, 8, 9].

3.4.2. Pruebas individuales por variable explicativa

Es el Algoritmo 3 el que se encarga de hacer el cómputo. Para cada x_j se forma el vector de contraste c'_j y se calcula directamente la matriz de hipótesis

$$H_j = (c'_j \hat{B})' [c'_j (X'X)^{-1} c_j]^{-1} (c'_j \hat{B}). \quad (3.6)$$

Como verificación independiente, el código ajusta además el modelo reducido que omite x_j y comprueba la equivalencia

$$H_j = E_{(-j)} - E, \quad (3.7)$$

donde E es la SSCP residual del modelo completo. La equivalencia se verificó con error máximo menor que 10^{-14} . Con H_j y E se alimenta al Algoritmo 2 usando siempre $gl_h = \text{rango}(c'_j) = 1$. El rango numérico de $E_{(-j)} - E$, que puede fluctuar por redondeo, no se usa para parametrizar la prueba [1].

Algoritmo 3: Cálculo de significancia marginal para covariables individuales

Datos de Entrada : Matriz $X = [\mathbf{1}, X_1, \dots, X_{q-1}] \in \mathbb{R}^{n \times q}$, matriz $Y \in \mathbb{R}^{n \times p}$
Variables de Salida : Tabla de resultados de significancia marginal para cada predictor (no intercepto)

```

// Estimación del modelo lineal completo
1   $(\cdot, \cdot, \cdot, \cdot, \cdot, E) \leftarrow \text{MCO}(X, Y)$ 
// Iterar sobre las q-1 covariables, excluyendo el intercepto
2  para  $j \leftarrow 2$  a  $q$  hacer
3       $X_{(-j)} \leftarrow$  Matriz  $X$  sin la columna  $j$  (intercepto preservado)
4       $(\cdot, \cdot, \cdot, \cdot, \cdot, E_{(-j)}) \leftarrow \text{MCO}(X_{(-j)}, Y)$ 
5      Construir  $c'_j$  y calcular  $H_j$  mediante la forma cuadrática del contraste
6      Verificar  $\max |H_j - (E_{(-j)} - E)| < 10^{-8}$ 
7       $(\Lambda_j, V_j, p_{\Lambda, j}, p_{V, j}) \leftarrow \text{PruebaSignificancia}(H_j, E, g|_h = 1)$ 
8      Registrar en resultados la covariable  $j$ 
9  fin
10 devolver Coeficientes parciales y  $p$ -valores para las  $q - 1$  covariables

```

3.5. Análisis de residuales y detección de observaciones atípicas

El análisis residual se organiza en tres componentes: evaluación de normalidad multivariada, diagnóstico de homocedasticidad y detección de municipios atípicos o de alta influencia. El Algoritmo 4 implementa las rutinas correspondientes a cada componente, de modo que la revisión de los residuales quede asociada con supuestos específicos del modelo lineal multivariado. El incumplimiento de estas condiciones puede afectar la validez de las pruebas de hipótesis, la eficiencia del estimador o la estabilidad de la interpretación empírica.

Algoritmo 4: Rutinas de diagnóstico y validación estadística para el modelo MCO multivariado

Datos de Entrada : Matriz de diseño X , Residuales $\hat{U}$, Matriz de covarianza estimada $\hat{\Sigma}$
Variables de Salida : Apalancamiento h_i , distancias $D_{i, res}^2, D_{i, X}^2$, distancias de Cook D_i

```

// Cálculo de apalancamiento (leverage)
1   $P_X \leftarrow X(X'X)^{-1}X'$ 
2   $h \leftarrow \text{diag}(P_X)$ 
3   $D_X^2 \leftarrow (n-1)(h - \frac{1}{n})$ 
// Cálculo de distancias de Mahalanobis para los residuales
4   $\Sigma^{-1} \leftarrow \text{inv}(\hat{\Sigma})$ 
5  para  $i \leftarrow 1$  a  $n$  hacer
6       $D_{res}^2[i] \leftarrow \hat{U}[i, :] \Sigma^{-1} \hat{U}[i, :]'$ 
7  fin
// Cálculo de distancias de Cook multivariadas
8  para  $i \leftarrow 1$  a  $n$  hacer
9       $D[i] \leftarrow \frac{h[i]}{(1-h[i])^2} D_{res}^2[i]$ 
10 fin
// Prueba de normalidad multivariada de Mardia
11  $b_{1,p} \leftarrow \frac{1}{n^2} \sum_{i,j} \left( \hat{U}[i, :] \Sigma^{-1} \hat{U}[j, :]' \right)^3$ 
12  $b_{2,p} \leftarrow \frac{1}{n} \sum_i \left( D_{res}^2[i] \right)^2$ 
13 devolver  $(h, D_{res}^2, D_X^2, D, b_{1,p}, b_{2,p})$ 

```

3.5.1. Distancias de Mahalanobis y coeficientes de Mardia

Para cada observación se calcula la distancia de Mahalanobis residual

$$D_{i,\text{res}}^2 = \hat{u}_i' \hat{\Sigma}^{-1} \hat{u}_i, \quad (3.8)$$

que mide la distancia del vector de errores respecto al centro multivariado en la métrica inducida por $\hat{\Sigma}^{-1}$. Estas distancias se emplean para calcular los estadísticos de asimetría ($b_{1,p}$) y curtosis multivariada ($b_{2,p}$) de Mardia [12], y para construir un Q-Q plot que contrasta los $D_{i,\text{res}}^2$ ordenados contra los cuantiles teóricos de una χ_p^2 , herramienta estándar para diagnosticar la normalidad conjunta.

3.5.2. Apalancamiento y distancia de Cook

La diagonal principal de P_X contiene los valores de apalancamiento h_{ii} , que cuantifican la influencia de cada municipio en el hiperespacio paramétrico [14]. Combinando estos índices con los residuales, la distancia de Cook multivariada se aproxima mediante

$$D_i = \frac{1}{p} \cdot \frac{h_{ii}}{(1 - h_{ii})^2} D_{i,\text{res}}^2, \quad (3.9)$$

donde p es el número de variables respuesta. Esta aproximación evita reestimar el modelo para cada observación, preservando la jerarquía relativa entre observaciones influyentes.

3.5.3. Prueba de homocedasticidad

La homocedasticidad se evalúa mediante la prueba de White multivariada: se construye el producto $\hat{u}_i \hat{u}_i'$ para cada observación, se extraen sus elementos únicos vía $\text{vech}(\cdot)$ [13, 19] y se ajusta una regresión auxiliar contra las covariables y sus productos cruzados cuadráticos. La significancia se evalúa mediante la traza de Pillai del ajuste auxiliar, un valor elevado de V indica heterocedasticidad.

3.6. Análisis canónico

El análisis canónico busca combinaciones lineales que maximicen la varianza explicada entre el conjunto de respuestas y los predictores [5]. Las direcciones latentes resultantes condensan la asociación multivariada en componentes ortogonales jerarquizadas.

3.6.1. Resolución del problema de valores propios generalizado

Las variables canónicas surgen del problema $Z = YA$, donde los vectores $\mathbf{a}_i$ satisfacen

$$(H - \lambda_i E) \mathbf{a}_i = \mathbf{0}, \quad (3.10)$$

sujeto a $\mathbf{a}_i' E \mathbf{a}_i = 1$. Los valores propios λ_i ordenan las direcciones latentes de mayor a menor asociación.

3.6.2. Cargas canónicas relativas

Para cada dirección latente se calculan las proporciones

$$w_{ji} = \frac{|a_{ji}|}{\sum_{k=1}^p |a_{ki}|}, \quad (3.11)$$

que identifican el peso relativo de cada variable respuesta en cada componente canónica.

3.7. Visualización de resultados

El módulo de visualización incluye tres familias de gráficos: histogramas de frecuencia para las transformaciones proporcionales, mapas de calor para los índices de correlación empírica, y diagramas de dispersión de valores ajustados contra residuales. Cada gráfico examina un aspecto específico del ajuste.

Capítulo 4

Modelación del Censo de Población y Vivienda 2020

En este capítulo se describe la aplicación del método al Censo de Población y Vivienda 2020. Se revisan la fuente de datos, la unidad espacial de observación, la construcción de los indicadores proporcionales y la estructuración de las matrices Y y X .

Resumir el rezago social en un único índice numérico implica pérdida de información sobre la magnitud y dirección de sus componentes educativos, laborales, demográficos, habitacionales y sanitarios. Para evitarlo, se recurre a un modelo multivariado que analiza conjuntamente la variabilidad común entre los indicadores de vulnerabilidad municipal [20, 21].

4.1. Fuente de información

Los datos provienen del Censo de Población y Vivienda 2020, levantado por el INEGI. Tres características justifican su uso: cobertura nacional, definición estandarizada de variables y disponibilidad de registros a escala municipal [2, 22]. La documentación metodológica del censo permite identificar los universos de referencia para construir proporciones comparables [23, 24].

Al corresponder a un único momento de observación, la estimación cuantifica diferencias espaciales entre municipios en 2020, sin describir trayectorias temporales ni dinámicas longitudinales.

4.2. Unidad de análisis y delimitación territorial

La unidad de observación es el municipio. Esta escala permite comparar divisiones administrativas equivalentes y ofrece un nivel intermedio entre el agregado estatal, que puede ocultar heterogeneidad interna, y el dato submunicipal, cuya definición territorial es más heterogénea.

Para preservar la comparabilidad, se conservaron únicamente los totales municipales y se descartaron agregados nacionales, resúmenes estatales, localidades submunicipales y registros no equiparables con la unidad de análisis. El filtrado se aplicó antes del cálculo de proporciones.

La base ITER 2020 contiene 195,659 registros, incluyendo localidades urbanas y rurales, agregados estatales, totales nacionales y categorías “No especificado”. Aplicando las condiciones de filtrado (entidad federativa válida, clave municipal numérica, identificador de localidad nulo y registro marcado como total municipal), la muestra analítica queda integrada por 2,469 municipios, equivalentes al 1.26 % de los registros originales. Los registros descartados corresponden a niveles de agregación distintos y no implican pérdida de información municipal.

4.3. Construcción de indicadores proporcionales

Los tabulados censales reportan frecuencias absolutas. Usarlas directamente introduciría un problema de escala, pues municipios con poblaciones muy distintas tenderían a diferir por volumen antes que por intensidad relativa del fenómeno. Por esta razón, los conteos se transformaron en indicadores proporcionales.

Una proporción es válida solo si el denominador corresponde a la población realmente susceptible a la característica analizada. Este criterio ordenó la elección de divisores: residentes totales, personas de 15 años y más, Población Económicamente Activa, población de 3 años y más, población de 5 años y más, y viviendas particulares ocupadas. Se descartaron combinaciones que rompen la lectura sustantiva del indicador.

Tabla 4.1: Universos de referencia utilizados en la construcción de indicadores.

Variable	Rol	Denominador	Justificación
PCDISC_MEN	Dependiente	POBTOT	La limitación mental se calcula como proporción respecto a la población total del municipio.
P15YM_AN	Dependiente	P_15YMAS	El analfabetismo se calcula utilizando exclusivamente la población de 15 años y más.
PDESOCUP	Dependiente	PEA	El nivel de desempleo se calcula como proporción respecto a la Población Económicamente Activa.
VPH_SNBIEN	Dependiente	TVIVHAB	La carencia de bienes se divide entre el total de viviendas particulares habitadas.
VPH_PISOTI	Independiente	TVIVHAB	La proporción de viviendas con piso de tierra se calcula utilizando las viviendas habitadas.
VPH_NDEAED	Independiente	TVIVHAB	La falta de drenaje y servicio sanitario se calcula respecto a las viviendas habitadas.
PRO_OCUP_C	Independiente	—	Indicador de hacinamiento provisto de forma directa en las bases de datos del INEGI.
P3HLINHE	Independiente	P_3YMAS	La proporción de hablantes de lengua indígena que no hablan español emplea la población de 3 años y más.
PHOG_IND	Independiente	POBHOG	La población en hogares indígenas se calcula respecto a la población total empadronada en hogares.
POB_AFRO	Independiente	POBTOT	La proporción de población afrodescendiente se calcula respecto a la población total.
PSINDER	Independiente	POBTOT	La carencia por acceso a servicios de salud se calcula respecto a la población total.
P15YM_SE	Independiente	P_15YMAS	La proporción de población sin escolaridad se calcula utilizando la población de 15 años y más.
PSIN_RELIG	Independiente	POBTOT	La proporción de población sin religión se calcula utilizando la población total.
PRESOE15	Independiente	P_5YMAS	La proporción de migrantes interestatales recientes se calcula respecto a la población de 5 años y más.

El analfabetismo se calcula sobre la población en edad de alfabetizarse, no sobre la población total; la carencia de servicios básicos en vivienda se divide entre el total de viviendas habitadas, no entre habitantes. La Tabla 4.1 consigna, variable por variable, el rol en el modelo, el denominador

utilizado y la justificación del cálculo.

Para cada variable se verificó que el denominador correspondiera al universo demográfico o habitacional pertinente, conservando la nomenclatura del diccionario oficial del INEGI [25]. Tras ensamblar la matriz analítica, se comprobó que ninguna de las variables del modelo presentara valores faltantes en los 2,469 municipios.

4.4. Especificación empírica del sistema de variables

El modelo separa la información en dos bloques matriciales. El primero agrupa las dimensiones del rezago social que el ajuste analiza en paralelo, el segundo reúne características demográficas, educativas y de vivienda que entran como regresores. La frontera entre bloques es estructural, cada bloque cumple un papel distinto.

¿Por qué esa separación? Porque responde al planteamiento mismo de la regresión multivariada, ya que el sistema evalúa distintas dimensiones de vulnerabilidad que dependen de una misma matriz de diseño, así que la especificación no asume independencia entre los indicadores de respuesta. Al contrario, postula una covarianza residual y la estima dentro del ajuste matricial.

4.4.1. Variables respuesta

La matriz Y reúne indicadores heterogéneos. Al no comprimirllos en un índice escalar, la metodología estima simultáneamente los parámetros asociados a educación, mercado laboral, bienes en la vivienda y vulnerabilidad funcional en salud, cuatro facetas del rezago social municipal con dinámicas propias.

La elección de estas cuatro variables responde al criterio de cubrir dimensiones diferenciadas del rezago social sin redundancia entre ellas. PCDISC_MEN capta la vulnerabilidad funcional asociada a limitaciones cognitivas, dimensión habitualmente ausente de los índices agregados de marginación pese a su relevancia para la política social [20]. P15YM_AN mide el rezago educativo en la población adulta, es un indicador estructural que refleja privaciones acumuladas a lo largo del ciclo de vida. PDESOCUP recoge la dimensión laboral a través del desempleo relativo a la población económicamente activa, faceta coyuntural que complementa a los indicadores estructurales. VPH_SNBIEN cuantifica la escasez de bienes materiales en la vivienda, dimensión patrimonial que aproxima el nivel de bienestar del hogar [21]. La heterogeneidad de estas dimensiones (funcional, educativa, laboral y patrimonial) es precisamente lo que justifica el tratamiento multivariado: cada una posee dinámicas propias, pero comparten una estructura de covarianza que el modelo estima de forma explícita. La Tabla 4.2 describe estas variables.

Tabla 4.2: Variables dependientes del modelo.

Variable	Definición operativa	Interpretación analítica
PCDISC_MEN	Proporción de la población con limitaciones para recordar o concentrarse, respecto a la población total.	Indicador de limitación funcional o cognitiva en la población.
P15YM_AN	Proporción de la población de 15 años y más que no sabe leer ni escribir.	Indicador de rezago educativo en la población adulta.
PDESOCUP	Proporción de la población desocupada respecto a la Población Económicamente Activa.	Indicador de nivel de desempleo en el mercado laboral local.
VPH_SNBIEN	Proporción de viviendas habitadas que no disponen de los bienes tecnológicos y electrodomésticos del indicador.	Indicador de escasez de bienes materiales en la vivienda.

4.4.2. Variables explicativas

La matriz X reúne diez covariables que retratan el perfil estructural de cada municipio a partir de cinco ejes: calidad de la vivienda, composición poblacional, cobertura sanitaria, nivel educativo y migración reciente.

La selección de cada eje responde a su papel reconocido como determinante del rezago territorial. La calidad de la vivienda se incorpora mediante VPH_PISOTI (piso de tierra), VPH_NDEAED (ausencia de drenaje y servicio sanitario) y PRO_OCUP_C (hacinamiento), tres carencias que aproximan privaciones materiales y de infraestructura del hogar [20]. La composición poblacional se representa con P3HLINHE (monolingüismo en lengua indígena), PHOG_IND (residencia en hogares indígenas) y POB_AFRO (población afrodescendiente), variables que capturan la concentración de grupos históricamente asociados a mayores niveles de marginación. La cobertura sanitaria entra mediante PSINDER (población sin afiliación a servicios de salud), dimensión central del acceso efectivo a la protección social [21]. El nivel educativo se mide con P15YM_SE (población sin escolaridad), complemento estructural de las variables de rezago educativo. Finalmente, PSIN_RELIG y PRESOE15 incorporan, respectivamente, la diversidad sociocultural y la movilidad geográfica reciente como variables de contexto.

La Tabla 4.3 fija la definición operativa de cada una.

Tabla 4.3: Variables independientes del modelo.

Variable	Definición operativa	Interpretación analítica
VPH_PISOTI	Proporción de viviendas particulares habitadas que tienen piso de tierra.	Indicador de carencia en la calidad de los espacios de la vivienda.
VPH_NDEAED	Proporción de viviendas habitadas que no disponen de drenaje ni servicio sanitario.	Indicador de carencia en los servicios básicos de infraestructura.
PRO_OCUP_C	Promedio de ocupantes por cuarto en viviendas particulares habitadas.	Indicador de nivel de hacinamiento habitacional.
P3HLINHE	Proporción de población de 3 años y más que habla alguna lengua indígena y no habla español.	Indicador de monolingüismo en lengua indígena.
PHOG_IND	Proporción de población residente en hogares indígenas.	Indicador de concentración demográfica en hogares indígenas.
POB_AFRO	Proporción de población que se autodenomina afrodescendiente o afromexicana.	Variable sociodemográfica sobre composición identitaria.
PSINDER	Proporción de la población sin afiliación a servicios de salud.	Indicador de vulnerabilidad en el acceso a servicios de salud.
P15YM_SE	Proporción de la población de 15 años y más sin escolaridad.	Indicador de falta de formación educativa formal.
PSIN_RELIG	Proporción de la población que reporta no tener religión.	Variable contextual sobre diversidad sociocultural.
PRESOE15	Proporción de la población de 5 años y más residente en otra entidad federativa en 2015.	Indicador de migración y movilidad geográfica reciente.

El patrón de la Figura 4.1 es bastante claro. Hay una correlación de peso entre las deficiencias en la vivienda, el nivel de estudios y lo que corresponde a la lengua indígena ya que es un comportamiento típico de los indicadores de marginación, los cuales tienden a agruparse. El modelo se encarga de esa estructura de covarianza con su estimación parcializada. De ese modo, cada coeficiente mide el efecto de su covariable sin mover el resto del sistema, pues la parcialización es el instrumento de trabajo.




Figura 4.1: Mapa de calor de las correlaciones correspondientes al conjunto de covariables explicativas. Las correlaciones de mayor magnitud se concentran entre indicadores de infraestructura, educación e idioma, evidenciando el grado de dependencia lineal entre los atributos municipales.

4.5. Transformaciones previas al análisis

Las variables pasaron por una transformación previa al ajuste. La razón es triple (reducir la asimetría de las distribuciones, estabilizar la varianza empírica y acercar el comportamiento de los datos a los supuestos de la distribución normal multivariada [11]), ya calculadas las proporciones municipales, ese tratamiento es el último filtro antes de construir las matrices del modelo.

Sobre las tasas proporcionales se aplicó raíz cuadrada. La transformación preserva el orden monótono de las observaciones, atenúa el peso de los municipios con valores extremos y produce distribuciones más simétricas, condiciones favorables para la estimación por mínimos cuadrados y el análisis residual asintótico; las Figuras 4.2 y 4.3 ilustran el transición desde el conteo absoluto, pasando por la proporción, hasta la variable transformada.

La elección de $\sqrt{R}$ sobre alternativas habituales responde a un balance entre estabilización de varianza y conservación de interpretabilidad. Es cierto que una transformación $\arcsin \sqrt{R}$ es asintóticamente equivalente con proporciones de mediano calibre, pero al comprimir las colas extremas de forma más drástica empeora la lectura de los coeficientes en su escala original. $\text{Logit} = \log(R/(1 - R))$ tampoco es adecuado pues obliga a hacer un ajuste explícito de los ceros estructurales de variables como PCDISC_MEN, VPH_NDEAED o P3HLINHE y eso trae consigo cierta arbitrariedad. Por otro lado, aplicar Box-Cox a cada proporción generaría exponentes distintos para cada variable y perjudicaría la homogeneidad del bloque Y que el modelo multivariado exige. La raíz cuadrada es la opción que la literatura clásica de análisis multivariado [11] pone como primera recomendación para tasas censales de este tipo.

Modelación del Censo de Población y Vivienda 2020

4.5 Transformaciones previas al análisis




Figura 4.2: Distribución empírica de las variables a través del proceso de transformación: valores absolutos, cálculo de proporciones y estabilización mediante la transformación de raíz cuadrada.

Modelación del Censo de Población y Vivienda 2020

4.5 Transformaciones previas al análisis




Figura 4.3: Continuación de la distribución empírica de las variables a través del proceso de transformación: valores absolutos, cálculo de proporciones y transformación de raíz cuadrada.

Capítulo 5

Resultados

5.1. Ajuste global del modelo

En el análisis, parte del ajuste global, antes de examinar efectos marginales o componentes canónicos, se verifica si las covariables sociodemográficas reproducen una parte razonable de la variabilidad conjunta de los indicadores de rezago municipal. Con la notación de los capítulos 2 y 4, Y contiene las respuestas transformadas, X el intercepto y las diez covariables, $\hat{B}$ la matriz de coeficientes por mínimos cuadrados y $\hat{U}$ los residuales. La solidez del modelo se juzga por la proximidad entre $\hat{Y} = X\hat{B}$ y los valores observados en los 2,469 municipios, preservando la estructura de covarianza que vincula las distintas dimensiones de la marginación.

5.1.1. Descomposición matricial de la variabilidad

Es la partición ortogonal la que se encarga de sostener la evaluación. Ya en el Capítulo 2 se presentó la identidad $T = H + E$, la cual se apoya en tres matrices de lectura particular: con T nos referimos a la variación total centrada de las respuestas, con H a lo que explican las covariables y con E a la residual. No es como en el caso univariado, pues aquí las matrices no pierden información de las covarianzas cruzadas. De ahí que uno no se conforma con un simple escalar ya que para hacer la inferencia se necesita la matriz entera.

Las matrices obtenidas a partir de la estimación son:

$$T = \begin{pmatrix} 1.530996 & 2.060692 & -0.410203 & 1.882758 \\ 2.060692 & 31.669208 & 1.511161 & 28.614078 \\ -0.410203 & 1.511161 & 9.676945 & 3.412932 \\ 1.882758 & 28.614078 & 3.412932 & 41.964210 \end{pmatrix}, \quad (5.1)$$

$$H = \begin{pmatrix} 0.344769 & 1.706085 & -0.093778 & 1.278873 \\ 1.706085 & 30.240871 & 1.725713 & 27.564451 \\ -0.093778 & 1.725713 & 0.967645 & 2.511555 \\ 1.278873 & 27.564451 & 2.511555 & 33.741809 \end{pmatrix}, \quad (5.2)$$

$$E = \begin{pmatrix} 1.186227 & 0.354607 & -0.316425 & 0.603886 \\ 0.354607 & 1.428337 & -0.214552 & 1.049627 \\ -0.316425 & -0.214552 & 8.709300 & 0.901377 \\ 0.603886 & 1.049627 & 0.901377 & 8.222401 \end{pmatrix}. \quad (5.3)$$

La identidad $T = H + E$ se cumple. La verificación numérica confirmó un error máximo absoluto del orden de la precisión de máquina, lo que avala el cálculo de los coeficientes de determinación

individuales como $R_j^2 = h_{jj}/t_{jj}$; el marco teórico queda respetado entrada por entrada y la descomposición está lista para la lectura por dimensión.

Tabla 5.1: Descomposición de la diagonal principal $T = H + E$ y varianza explicada por dimensión.

Variable respuesta	t_{jj}	h_{jj}	e_{jj}	R_j^2	Dimensión analizada
PCDISC_MEN	1.530996	0.344769	1.186227	0.2252	Salud funcional
P15YM_AN	31.669208	30.240871	1.428337	0.9549	Educación
PDESOCUP	9.676945	0.967645	8.709300	0.1000	Laboral
VPH_SNBIEN	41.964210	33.741809	8.222401	0.8040	Vivienda

Con la Tabla 5.1 se ponen exponen diferencias notables. Por un lado, el modelo encuentra un alto nivel del analfabetismo en adultos (P15YM_AN, $R^2 = 0.955$) y de lo que falta en materia de bienes dentro del hogar (VPH_SNBIEN, $R^2 = 0.804$). Son las dos respuestas que mejor se explican, algo lógico si se tiene en cuenta que en los municipios mexicanos tales indicadores van muy de la mano con el resto de lo sociodemográfico que recoge el Censo, de modo que al modelo lineal no le quedaría mucha varianza por cubrir.

La desocupación PDESOCUP, es caso contrario, da el peor de los ajustes entre los cuatro, con un R^2 de 0.100. No es de extrañar, una cifra tan pequeña tiene que ver con el comportamiento del mercado laboral en los municipios mexicanos. La informalidad, la estacionalidad propia del campo o los flujos migratorios internos son variables que un estudio transversal no termina de captar con exactitud. Lo mismo ocurre con la limitación cognitiva (PCDISC_MEN), cuyo ajuste es modesto ($R^2 = 0.225$) dado que su variabilidad responde a factores clínicos o de acceso a la salud que escapan a nuestras covariables.

5.1.2. Magnitud del ajuste conjunto

El operador traza condensa la bondad de ajuste en un escalar único. Aplicado a las matrices de sumas de cuadrados arroja:

$$\text{tr}(T) = 84.841360, \quad (5.4)$$

$$\text{tr}(H) = 65.295095, \quad (5.5)$$

$$\text{tr}(E) = 19.546265. \quad (5.6)$$

De aquí se calcula el coeficiente de determinación multivariado basado en la traza:

$$R_{\text{tr}}^2 = \frac{\text{tr}(H)}{\text{tr}(T)} = 0.769614. \quad (5.7)$$

Es decir,

$$\boxed{R_{\text{tr}}^2 = 0.769614} \quad (5.8)$$

lo que indica que el modelo, en conjunto, explica el 76.96 % de la variabilidad total contenida en la diagonal de T .

Observación 5.1. No se trata de simple promedio de los R_j^2 por separado, ese no es el coeficiente R_{tr}^2 . Lo que refleja es la parte de la varianza total de la traza de T que el modelo ha sido capaz de absorber, de modo que tiende a estar distribuido en las respuestas con más varianza. Por eso no debe sustituirse una lectura pormenorizada de cada respuesta.

Con el valor obtenido, puede afirmarse que el ajuste agregado es de lo más satisfactorio. No obstante, la traza está en gran medida dominada por P15YM_AN y VPH_SNBIEN, las dos respuestas que a su vez presentan un mejor ajuste individual y la varianza total más alta; de ahí el desequilibrio

que pone de manifiesto una asimetría de fondo en el sistema. Por lo que el modelo se ajusta con propiedad a los planos educativo y habitacional, pero no tanto a los de salud funcional o laboral.

Tabla 5.2: Estadísticos escalares de ajuste del modelo multivariado basados en la traza.

Métrica	Valor numérico
$\text{tr}(T)$	84.841360
$\text{tr}(H)$	65.295095
$\text{tr}(E)$	19.546265
R_{tr}^2	0.769614

5.1.3. Pruebas globales de significancia multivariada

La inferencia descansa en cuatro estadísticos clásicos, el contraste global del modelo es

$$H_0 : CB = 0 \quad \text{contra} \quad H_1 : CB \neq 0,$$

donde $C \in \mathbb{R}^{10 \times 11}$ es la matriz que elimina la fila del intercepto y selecciona las diez filas de B asociadas a las covariables sociodemográficas. Bajo H_0 , ninguna covariable aporta información lineal sobre el vector de respuestas (PCDISC_MEN, P15YM_AN, PDESOCUP, VPH_SNBIEN) una vez fijado el intercepto; bajo H_1 , al menos una covariable lo hace sobre alguna dimensión o combinación lineal de las respuestas. Los cuatro estadísticos clásicos [1, 3, 9, 18] se construyen a partir del espectro de $E^{-1}H$:

$$\Lambda_{\text{Wilks}} = 0.014891, \quad (5.9)$$

$$V_{\text{Pillai}} = 1.745274, \quad (5.10)$$

$$T_{HL} = 23.983654, \quad (5.11)$$

$$\theta_{\text{Roy}} = 22.500903. \quad (5.12)$$

El grado de libertad de hipótesis se obtiene de la matriz de contraste, $q_h = \text{rango}(C) = 10$. Con este parámetro teórico, las aproximaciones a la distribución F de Wilks, Pillai y Hotelling–Lawley arrojaron los resultados de la Tabla 5.3; en esos tres criterios se obtuvo $p < 0.0001$. Para Roy se conserva la cota superior F_{ref} solo como referencia descriptiva.

Tabla 5.3: Estadísticos de prueba para la significancia global del modelo multivariado.

Prueba	Valor	F/F_{ref}	ν_1	ν_2	Decisión ($\alpha = 0.05$)
Lambda de Wilks	0.014891	473.178895	40	9310.928671	Rechazar H_0
Traza de Pillai	1.745274	190.261817	40	9832	Rechazar H_0
Traza de Hotelling–Lawley	23.983654	1471.226393	40	6861.769851	Rechazar H_0
Raíz mayor de Roy	22.500903	5505.971037 ^a	10	2447	Referencia descriptiva

^aPara Roy se reporta una cota superior F_{ref} ; cuando $s > 1$ no es una aproximación F válida. No se calcula p -valor ni se toma una decisión autónoma con esta fila.

Fijando el nivel convencional $\alpha = 0.05$, la región de rechazo asociada a la aproximación de Rao para Λ con grados de libertad $(\nu_1, \nu_2) = (40, 9310.9287)$ es

$$\mathcal{R}_{0.05} = \{ F_{\text{obs}} > F_{0.95}(40, 9310.9287) \}.$$

El valor crítico es $F_{0.95}(40, 9310.9287) \approx 1.3953$. El estadístico observado $F_{\text{Wilks}} = 473.1789$ supera ampliamente el umbral y produce $p < 0.0001$. Las aproximaciones de Pillai y Hotelling–Lawley reproducen la misma decisión, por lo que se **rechaza** $H_0 : CB = 0$ al nivel $\alpha = 0.05$. La raíz mayor de Roy, $\theta = 22.500903$, muestra que la asociación se concentra en la primera dirección; su cota $F_{\text{ref}} = 5505.971037$ se presenta únicamente como descriptor y no interviene en el rechazo.

El bloque de covariables sociodemográficas guarda una asociación sistemática con la variabilidad conjunta del rezago social a nivel municipal [5], y su significancia está muy lejos de cualquier estándar convencional. Pero hay que hacer una aclaración importante, lo que se ve aquí es la asociación estadística entre los agregados municipales, no la causalidad.

5.1.4. Matriz de covarianza residual y dependencia remanente

Con la matriz de covarianzas residual ajustada se concluye el ajuste. Sus varianzas residuales de la diagonal principal resultaron:

$$\hat{\sigma}_{11} = 0.000483, \quad \hat{\sigma}_{22} = 0.000581, \quad \hat{\sigma}_{33} = 0.003543, \quad \hat{\sigma}_{44} = 0.003345, \quad (5.13)$$

para PCDISC_MEN, P15YM_AN, PDESOCUP y VPH_SNBIEN, respectivamente. Su magnitud relativa coincide con los R_j^2 reportados, las dimensiones laboral y habitacional concentran más varianza no explicada y la dimensión educativa queda con un residuo proporcionalmente menor.

Con el ajuste hecho, las covarianzas fuera de la diagonal se mantienen. En $\hat{\Sigma}$ se aprecian asociaciones positivas que se conservan, particularmente si uno mira los residuos de educación y vivienda o bien los de analfabetismo y limitación funcional. La conclusión es que, una vez controladas las covariables, hay variabilidad en las respuestas que el modelo no logra captar. Si se le da un sentido sustantivo a la lectura, se encuentra con factores estructurales de fondo, como, condiciones históricas de la región, la geografía y lo que haya de infraestructura pública. Las cuales son comunes a varias facetas del rezago y que actúan de forma simultánea, aunque no estén entre los predictores que hemos puesto así la covarianza residual deja claro que algo se escapa al modelo.

Observación 5.2. No se puede decir que la estimación por mínimos cuadrados pierda validez por la correlación residual cruzada, el estimador conserva su insesgadez dentro de los supuestos. Lo que sí hace es corroborar que las respuestas siguen teniendo una covarianza importante tras el ajuste, y eso da pie para preferir un modelo lineal multivariado a cuatro regresiones univariadas hechas por separado.

5.2. Análisis de los coeficientes y contribución de las covariables

Una vez que se ha contrastado el conjunto y se da por buena la significancia conjunta, pasamos a la contribución individual. En el análisis que estudia el papel de cada covariable en datos territoriales agregados es muy común que los predictores estén correlacionados unos con otros, y si uno se deja llevar para interpretar los coeficientes como efectos por separado saldrán conclusiones de poco valor [1]. Ese es el riesgo de la colinealidad y la parcialización, viene a poner orden en la lectura.

La matriz de coeficientes estimados es

$$\hat{B} \in \mathbb{R}^{11 \times 4} \quad (5.14)$$

la cual resume la asociación entre cada predictor sociodemográfico y cada variable respuesta. Su lectura razonable requiere considerar simultáneamente cuatro elementos: signo, magnitud, respuesta de referencia y patrón de correlación entre las covariables.

El cálculo arrojó:

$$\hat{B} = \begin{pmatrix} 0.106935 & 0.297882 & 0.135322 & 0.189121 \\ 0.004774 & 0.010997 & -0.001897 & 0.052201 \\ 0.001401 & -0.000463 & 0.007862 & 0.018745 \\ -0.008690 & 0.002075 & 0.001652 & 0.006412 \\ -0.006885 & 0.001929 & 0.024141 & 0.024088 \\ 0.003845 & 0.011654 & -0.020712 & 0.018644 \\ 0.000620 & 0.000321 & 0.000888 & -0.004032 \\ -0.001281 & -0.002763 & -0.005936 & -0.016617 \\ 0.010370 & 0.092101 & -0.001975 & 0.019355 \\ -0.003091 & -0.007179 & 0.002934 & 0.001273 \\ 0.004385 & -0.000405 & -0.003951 & -0.003634 \end{pmatrix}. \quad (5.15)$$

La primera fila corresponde al intercepto; siguen, en orden, los coeficientes de VPH_PISOTI, VPH_NDEAED, PRO_OCUP_C, P3HLINHE, PHOG_IND, POB_AFRO, PSINDER, P15YM_SE, PSIN_RELIG y PRESOE15. Las columnas, en ese orden: PCDISC_MEN, P15YM_AN, PDESOCUP y VPH_SNBIEN.

Con la estandarización se logra la igualdad de la lectura comparativa. Se han estandarizado las covariables, por lo que el valor de cada coeficiente indica el cambio que se puede esperar en la respuesta (en su escala transformada) si la covariable sube una desviación estándar y todo lo demás se mantiene inalterado; de este modo es posible cotejar las magnitudes relativas de los coeficientes. No obstante, hay que tomarlos con reservas a causa de la colinealidad propia de los datos territoriales agregados [3]. En cualquier caso, usar una métrica de referencia hace más sencillo tener un ranking.

5.2.1. Jerarquía explicativa por pruebas parciales multivariadas

Confirmada la significancia conjunta, el análisis examina el aporte de cada covariable mediante una sucesión de pruebas parciales. Sea $c_j \in \mathbb{R}^q$ el vector que tiene un uno en la posición correspondiente al predictor j y ceros en las restantes. Para cada $j \in \{1, \dots, 10\}$ el contraste parcial es

$$H_{0j} : c_j' B = 0_{1 \times p} \quad \text{contra} \quad H_{1j} : c_j' B \neq 0_{1 \times p},$$

de rango 1: bajo H_{0j} , la fila de $\hat{B}$ asociada al predictor j es cero en las $p = 4$ respuestas simultáneamente. Operacionalmente, H_{0j} se evalúa comparando la matriz residual del modelo completo E con la del modelo reducido $E_{(-j)}$ que omite la covariable j :

$$H_j = E_{(-j)} - E.$$

La matriz H_j es semidefinida positiva y mide la contribución marginal del predictor j al ajuste, una vez controlado por las demás covariables (contraste tipo III). Los estadísticos Λ_j , V_j , $T_{HL,j}$ y θ_j se construyen entonces sobre el par (H_j, E) usando la misma aproximación a la F de la Subsección 5.1.3, ahora con $\text{rango}(c_j') = 1$, con lo cual se obtiene los siguientes grados de libertad $(p, n - q - p + 1) = (4, 2455)$. La región de rechazo individual es

$$\mathcal{R}_\alpha^{(j)} = \{ F_{\text{obs}}^{(j)} > F_{1-\alpha}(4, 2455) \}.$$

En la Tabla 5.4 se ha resumido los resultados, ordenados de acuerdo con la traza de Pillai. De primera podemos notar que cada renglón es un contraste independiente y no hemos recurrido a ninguna corrección por multiplicidad, ya que nuestro interés es de carácter comparativo y no al control global del error tipo I [1].

Lo que miden las pruebas parciales es el aporte marginal. Para ello partimos de una hipótesis nula en la que la fila de coeficientes de la covariable en $\hat{B}$ vale cero. El estadístico se obtiene de la

diferencia entre la matriz de sumas de cuadrados residuales del modelo completo y la del reducido, es decir, el que se queda sin esa covariable.

La formulación se cierra con la matriz de hipótesis marginal, en su forma matricial dicha diferencia nos da el bloque H_j del predictor [1].

Tabla 5.4: Significancia marginal de las covariables explicativas (pruebas parciales tipo III), ordenada por el estadístico Trazo de Pillai.

Variable explicativa	Λ Wilks	V Pillai	F_{Wilks}	p_{Wilks}	F_{Pillai}	p_{Pillai}
P15YM_SE	0.125925	0.874075	4260.18	< 0.0001	4260.18	< 0.0001
VPH_PISOTI	0.730536	0.269464	226.39	< 0.0001	226.39	< 0.0001
P3HLINHE	0.881024	0.118976	82.88	< 0.0001	82.88	< 0.0001
PHOG_IND	0.886819	0.113181	78.33	< 0.0001	78.33	< 0.0001
PRO_OCUP_C	0.898604	0.101396	69.25	< 0.0001	69.25	< 0.0001
PSIN_RELIG	0.910306	0.089694	60.47	< 0.0001	60.47	< 0.0001
VPH_NDEAED	0.914510	0.085490	57.37	< 0.0001	57.37	< 0.0001
PSINDER	0.924133	0.075867	50.39	< 0.0001	50.39	< 0.0001
PRESOE15	0.955161	0.044839	28.81	< 0.0001	28.81	< 0.0001
POB_AFRO	0.992282	0.007718	4.77	0.0008	4.77	0.0008

Nota: Las pruebas parciales corresponden a contrastes tipo III en los que cada covariable individual genera una hipótesis de rango 1 (una fila de $B = 0$). Para $q_h = 1$, las transformaciones de Wilks y Pillai son exactas y coinciden, con grados de libertad $(p, n - q - p + 1) = (4, 2455)$.




Figura 5.1: Contribución explicativa marginal de cada covariable medida mediante la traza de Pillai. El ajuste del modelo descansa fuertemente en unas pocas variables.

La repartición de la contribución parcial entre los predictores no es equitativa: buena parte de la señal se aglomera en torno a una única covariable. De ahí que la jerarquía muestre una asimetría muy marcada desde el primer peldaño, tal como se puede apreciar en la Figura 5.1.

P15YM_SE encabeza el ranking con

$$V_{\text{P15YM_SE}} = 0.874075, \quad F_{\text{Pillai}} = 4260.183846. \quad (5.16)$$

Es claro que el indicador con mayor poder explicativo de la varianza marginal en el conjunto de respuestas es la proporción de gente de 15 o más años que no ha tenido escolaridad. Es un predictor

que tiene una gran importancia, y concuerda con lo que suele encontrarse al hojear la literatura sobre el rezago social en México, donde el acceso a una educación formal es escaso, como se observa en algunos municipios, lo cual tiene relación con todas las demás carencias [3].

VPH_PISOTI ocupa el segundo lugar con

$$V_{VPH_PISOTI} = 0.269464. \quad (5.17)$$

La proporción de viviendas con piso de tierra sostiene una contribución significativa aun controlando las demás variables, un reflejo de que la calidad básica de la vivienda actúa como fuerte marcador territorial del rezago.

El resto de las covariables aporta una contribución incremental menor. En particular, POB_AFRO presenta la traza parcial más pequeña, pero alcanza significancia estadística:

$$p_{Wilks} = 0.000775, \quad p_{Pillai} = 0.000775. \quad (5.18)$$

Presenta una contribución incremental estadísticamente detectable, aunque de magnitud reducida dentro del conjunto de covariables consideradas. La traza de Pillai parcial $V = 0.007718$ no debe interpretarse como un porcentaje directo de varianza explicada; resume una función del único valor propio asociado al contraste de rango 1.

El resultado es una asociación condicionada a las otras nueve covariables y se refiere a agregados municipales. No permite trasladar la inferencia a personas ni atribuir un efecto causal individual a la pertenencia afromexicana. La magnitud parcial reducida tampoco implica irrelevancia social: para estudiar desigualdad étnica individual harían falta microdatos de hogar o persona, otra unidad de análisis y un diseño causal apropiado.

El ordenamiento de las covariables por su contribución parcial queda así:

$$\begin{aligned} P15YM_SE &\gg VPH_PISOTI > P3HLINHE \approx PHOG_IND \\ &> PRO_OCUP_C > PSIN_RELIG > VPH_NDEAED \\ &> PSINDER > PRESOE15 \gg POB_AFRO. \end{aligned} \quad (5.19)$$

5.2.2. Distribución de efectos por respuesta y patrones de signo

Con la interpretación por columnas se pone a punto el análisis. Una vez que se tiene la jerarquía global de los predictores, es bueno ver de qué manera sus efectos se distribuyen en cada respuesta, dimensión a dimensión. La matriz $\hat{B}$ lo permite, pues acepta esa partición:

$$\hat{B} = (\hat{\beta}^{(1)}, \hat{\beta}^{(2)}, \hat{\beta}^{(3)}, \hat{\beta}^{(4)}), \quad (5.20)$$

donde cada $\hat{\beta}^{(k)}$ recoge los efectos parciales sobre la respuesta k . Examinar las columnas saca a flote magnitud y dirección de cada efecto, dejando ver asimetrías entre dimensiones.

Estructura de coeficientes para P15YM_AN

P15YM_SE domina la columna del analfabetismo. El coeficiente de mayor magnitud corresponde a

$$\hat{\beta}_{P15YM_SE, P15YM_AN} = 0.092101. \quad (5.21)$$

Hay una relación que se sostiene por sí misma donde los municipios tienen un mayor porcentaje de gente sin estudios, las cifras de analfabetismo en adultos son más altas. No es más que dos facetas de un mismo hecho educativo. Por otro lado, el modelo evidencia algunos efectos positivos, aunque de menor envergadura, en torno a PHOG_IND, VPH_PISOTI y PRO_OCUP_C:

$$0.011654, \quad 0.010997, \quad 0.002075. \quad (5.22)$$

Es decir, la tasa de analfabetismo municipal se asocia positivamente con la presencia de hogares indígenas, con viviendas de piso de tierra y con hacinamiento, manteniendo lo demás constante. La lectura es consistente con la geografía del rezago educativo en México.

Estructura de coeficientes para VPH_SNBIEN

VPH_PISOTI encabeza la columna de bienes. Para la proporción de viviendas sin bienes, el coeficiente dominante corresponde a

$$\hat{\beta}_{\text{VPH_PISOTI, VPH_SNBIEN}} = 0.052201. \quad (5.23)$$

La relación tiene sentido directo. Precariedad estructural de la vivienda (piso de tierra) y ausencia de bienes son dos caras de la misma carencia material. A su lado, efectos positivos de magnitud apreciable provienen de P3HLINHE, P15YM_SE, VPH_NDEAED y PHOG_IND:

$$0.024088, \quad 0.019355, \quad 0.018745, \quad 0.018644. \quad (5.24)$$

Es de esperar que las casas carentes de bienes se den en mayor medida en aquellos municipios donde hay una población con menos instrucción, un acceso deficiente al drenaje y más hogares de origen indígena, sin olvidar la proporción de gente que no se expresa en español. En definitiva, es un patrón que pone de manifiesto un rezago habitacional de raíz cruzada.

Estructura de coeficientes para PDESOCUP

P3HLINHE aporta el mayor efecto positivo. Los coeficientes para la desocupación presentan una mezcla de signos más amplia y el efecto positivo dominante corresponde a

$$\hat{\beta}_{\text{P3HLINHE, PDESOCUP}} = 0.024141, \quad (5.25)$$

seguido por VPH_NDEAED:

$$\hat{\beta}_{\text{VPH_NDEAED, PDESOCUP}} = 0.007862. \quad (5.26)$$

En contraste, PHOG_IND y PSINDER aparecen con signos negativos:

$$-0.020712, \quad -0.005936. \quad (5.27)$$

La mezcla de signos confirma algo que ya insinuaba el bajo $R^2_{\text{PDESOCUP}} = 0.100$. La desocupación municipal en México no responde de manera uniforme a las covariables consideradas porque buena parte de la dinámica laboral fluye por canales que el Censo no captura bien (informalidad, autoempleo en zonas rurales, migración estacional, actividad económica de subsistencia); el coeficiente negativo de PHOG_IND es consistente con el hecho de que en municipios con alta presencia indígena la actividad económica predominante (agrícola, de autoconsumo o informal) no se reporta sistemáticamente como desocupación bajo la definición censal, lo cual produce tasas medidas de desocupación menores sin que ello implique mayor bienestar laboral. Esta limitación de medición es inherente a los datos censales transversales.

Estructura de coeficientes para PCDISC_MEN

La columna de salud funcional exhibe los coeficientes más pequeños. Los efectos positivos de mayor magnitud provienen de P15YM_SE, VPH_PISOTI y PRESOE15:

$$\hat{\beta}_{\text{P15YM_SE, PCDISC_MEN}} = 0.010370, \quad \hat{\beta}_{\text{VPH_PISOTI, PCDISC_MEN}} = 0.004774, \quad \hat{\beta}_{\text{PRESOE15, PCDISC_MEN}} = 0.004385. \quad (5.28)$$

Que la envergadura de tales efectos sea tan modesta no hace más que avalar una intuición de sentido común, y es que uno no puede esperar que las condiciones de vivienda, el idioma o el nivel educativo sean un indicio natural de limitación cognitiva. Lo que determina la prevalencia a nivel municipal son, ante todo, cuestiones clínicas, etarias o de acceso a la sanidad, aspectos que por cierto el Censo 2020 no se ha encargado de desglosar.

Análisis del vector paramétrico asociado a PSINDER

PSINDER arrastra signos uniformemente negativos. La fila de coeficientes de la población sin afiliación a servicios de salud, leída horizontalmente en la matriz, exhibe:

$$\hat{\beta}_{\text{PSINDER}} = (-0.001281, -0.002763, -0.005936, -0.016617). \quad (5.29)$$

Con una interpretación errónea podría pensar que no tener seguro médico acorta el rezago, pero es una conclusión de todo punto falsa. La razón es de orden estadístico es que en un modelo de regresión múltiple los coeficientes son efectos parciales y ya han hecho las deducciones por la covariación con los otros predictores [3]. Dado que PSINDER tiene una correlación fuerte con la precariedad de la vivienda o la falta de estudios, una vez que estas covariables se han llevado gran parte del efecto, el coeficiente que queda puede volverse cero o incluso invertirse. Por tanto, no hay que ver en los signos negativos una contradicción a la asociación real entre el rezago y la carencia de servicios de salud ha sido absorbida.

Basta con observar la matriz de diseño estandarizada para ver las correlaciones bivariadas entre PSINDER y los indicadores de rezago: $\text{corr}(\text{PSINDER}, \text{P15YM_SE})$ es de -0.193, $\text{corr}(\text{PSINDER}, \text{P15YM_AN})$ de -0.174, $\text{corr}(\text{PSINDER}, \text{P3HLINHE})$ de -0.198 y $\text{corr}(\text{PSINDER}, \text{VPH_SNBIEN})$ de -0.267. Dicho de otro modo, PSINDER tiene una correlación negativa con el resto.

No hay que extrañarse, es un efecto del Censo 2020. En los municipios más marginados y de corte rural, donde prima el esquema universal no contributivo (el Seguro Popular hasta su cierre en enero de 2020 y el paso al INSABI), se encuentra una gran cantidad de población sin afiliación al IMSS/ISSSTE. De ahí que, al controlar en el modelo conjunto a P15YM_SE, VPH_PISOTI y demás variables, el coeficiente de PSINDER se vuelva negativo en las cuatro respuestas. El residuo informativo no está captando la relación bruta, sino la heterogeneidad intra-grupo de unos municipios a otros con idénticas carencias de vivienda o nivel de estudios.

5.2.3. Colinealidad sustantiva y lectura de efectos parciales

Se trata de efectos condicionados los coeficientes de $\hat{B}$, estos reflejan la asociación neta tras restar la covariación con el resto de predictores. Si hay varianza compartida entre ellos, no es de extrañar que algún coeficiente se muestre atenuado o con un signo que choca con la intuición [14]. En el caso de estos datos la colinealidad es lo habitual y no una rareza, las variables de educación, vivienda, salud o lengua van de la mano en el territorio mexicano, todo el fenómeno avanza en bloque. Las correlaciones bivariadas más altas en la matriz de diseño son:

$$\text{corr}(\text{P15YM_SE}, \text{P15YM_AN}) = 0.963527, \quad (5.30)$$

$$\text{corr}(\text{VPH_SNBIEN}, \text{VPH_PISOTI}) = 0.796176, \quad (5.31)$$

$$\text{corr}(\text{P3HLINHE}, \text{PHOG_IND}) = 0.787081. \quad (5.32)$$

Valores tan altos hacen que la reducción de los residuos se concentre en uno o dos predictores dominantes, así que las covariables correlacionadas con ellos quedan con coeficientes pequeños; por eso un predictor como PSINDER, descriptivamente asociado al rezago, recibe en el modelo conjunto un peso modesto.

Observación 5.3. El cálculo numérico se mantiene estable a pesar de la colinealidad que hay, el número de condición para la matriz de diseño es $\kappa(X) = 4.5485$, una cifra que está a buena distancia de los umbrales de inestabilidad en la inversión [14]. Lo que se ve como colinealidad no es un obstáculo computacional a la hora de hacer el ajuste por mínimos cuadrados, sino algo inherente al fenómeno, en el territorio mexicano las distintas facetas de la marginación van relacionadas.

Los coeficientes de $\hat{B}$ deben leerse como medidas de asociación condicionada, no como efectos aislados de cada variable; su signo y magnitud cobran sentido únicamente a la luz del bloque completo de covariables.

5.3. Estructura canónica del modelo

Con la descomposición espectral se pone punto final a la lectura, esta es una herramienta que resume las relaciones cruzadas de predictores y respuestas en unas pocas combinaciones lineales, las llamadas direcciones canónicas, y las va ordenando según el grado de su asociación [5]. En cada una de esas direcciones se condensa un patrón de covariación cruzada para reducirla a un único eje.

5.3.1. Problema espectral del modelo

El problema de valores propios generalizado de la Subsección 2.6.5 genera las direcciones. El valor propio λ_i mide la razón entre varianza explicada y varianza residual en la dirección del i -ésimo vector, y el cálculo arrojó cuatro raíces:

$$\lambda_1 = 22.500903, \quad \lambda_2 = 1.198835, \quad \lambda_3 = 0.208738, \quad \lambda_4 = 0.075177. \quad (5.33)$$

La asimetría $\lambda_1 \gg \lambda_2 > \lambda_3 > \lambda_4$ destapa un hecho central. Aunque el modelo tiene cuatro respuestas, la asociación con los predictores se concentra prácticamente en una sola dirección; en el plano de las covarianzas explicadas, el sistema se comporta como si tuviera un único eje dominante. Las proporciones normalizadas sintetizan la asimetría:

$$\pi_1 \approx 0.9380, \quad (5.34)$$

$$\pi_2 \approx 0.0500, \quad (5.35)$$

$$\pi_3 \approx 0.0087, \quad (5.36)$$

$$\pi_4 \approx 0.0031. \quad (5.37)$$

El primer componente se concentra casi un 93.8% de la asociación cruzada que el modelo es capaz de captar. Los otros tres no llegan a un 6.2% en total, por lo que buena parte de la variabilidad conjunta del rezago municipal puede interpretarse desde una sola dimensión principal, los predictores se mueven en conjunto sobre ese eje y lo demás queda en un plano secundario. En definitiva, tenemos una dimensión maestra frente a otras tres de carácter marginal.

Tabla 5.5: Valores propios de la matriz $E^{-1}H$ y varianza relativa explicada.

Componente	Valor propio λ_i	Proporción π_i
CAN1	22.500903	0.9380
CAN2	1.198835	0.0500
CAN3	0.208738	0.0087
CAN4	0.075177	0.0031

5.3.2. Correlaciones canónicas y fuerza de asociación

La relación $\rho_i^2 = \lambda_i / (1 + \lambda_i)$ del Marco Teórico entrega los valores:

$$\rho_1^2 \approx 0.957449, \quad (5.38)$$

$$\rho_2^2 \approx 0.545214, \quad (5.39)$$

$$\rho_3^2 \approx 0.172696, \quad (5.40)$$

$$\rho_4^2 \approx 0.069919, \quad (5.41)$$

con las correspondientes correlaciones canónicas:

$$\rho_1 \approx 0.978493, \quad (5.42)$$

$$\rho_2 \approx 0.738386, \quad (5.43)$$

$$\rho_3 \approx 0.415561, \quad (5.44)$$

$$\rho_4 \approx 0.264425. \quad (5.45)$$

La correlación del primer par

$$\rho_1 \approx 0.9785, \quad (5.46)$$

es extremadamente alta. Hay una correlación casi perfecta entre una combinación lineal de los predictores y otra de las respuestas; esa asociación hegemónica es la que empuja a los estadísticos globales (Wilks, Pillai, Hotelling-Lawley) a cifras tan extremas y conlleva el rechazo de la hipótesis nula. En definitiva, es el primer par el que pondera la inferencia, mientras que el resto no hace más que complementarla.

Tabla 5.6: Correlaciones canónicas asociadas a cada dirección.

Componente	λ_i	ρ_i^2	ρ_i
CAN1	22.500903	0.957449	0.978493
CAN2	1.198835	0.545214	0.738386
CAN3	0.208738	0.172696	0.415561
CAN4	0.075177	0.069919	0.264425

La caída tras CAN1 es brusca. La Tabla 5.6 muestra que solo el primer par alcanza una asociación muy alta; las direcciones siguientes recogen patrones secundarios de variabilidad cruzada con fuerza decreciente.

5.3.3. Normalización canónica y matriz de coeficientes

Los vectores canónicos del lado de las respuestas se ordenan en una matriz A cuyas columnas son las direcciones $\mathbf{a}_i$:

$$A = \begin{pmatrix} -0.212586 & 0.205839 & -0.869525 & -0.300174 \\ 0.839132 & 0.327738 & 0.087898 & 0.013811 \\ 0.017153 & 0.019384 & 0.076632 & -0.334646 \\ 0.037178 & -0.366911 & -0.049312 & 0.024407 \end{pmatrix}, \quad (5.47)$$

con las filas correspondientes a PCDISC_MEN, P15YM_AN, PDESOCUP y VPH_SNBIEN. La normalización utilizada satisface $A'EA = I_4$ [1], lo que habilita comparar magnitudes entre columnas. La proyección $Z_i = Y\mathbf{a}_i$ define la variable canónica asociada a cada dirección.




Figura 5.2: Valor absoluto de los coeficientes canónicos para cada dirección.

El heatmap revela la distribución de los pesos. La Figura 5.2 muestra de un vistazo que CAN1 está casi totalmente dominada por P15YM_AN, CAN2 contrasta VPH_SNBIEN con P15YM_AN, CAN3 está dominada por PCDISC_MEN y CAN4 reparte el peso entre PDESOCUP y PCDISC_MEN.

5.3.4. Primera dirección canónica: eje educativo

La primera variable canónica tiene la forma

$$\text{CAN1} = -0.212586 \text{PCDISC_MEN} + 0.839132 \text{P15YM_AN} + 0.017153 \text{PDESOCUP} + 0.037178 \text{VPH_SNBIEN}, \quad (5.48)$$

con la siguiente distribución de pesos relativos (en valor absoluto, normalizados por suma):

$$w_{\text{P15YM_AN},1} = 0.758675, \quad (5.49)$$

$$w_{\text{PCDISC_MEN},1} = 0.192203, \quad (5.50)$$

$$w_{\text{VPH_SNBIEN},1} = 0.033613, \quad w_{\text{PDESOCUP},1} = 0.015508. \quad (5.51)$$

El analfabetismo adulto es el que soporta más del 75 % del peso. Si se coteja esa cifra con la propensión de CAN1 a absorber el 93.8 % de la varianza explicable, se llega a una conclusión de lo más clara: la principal conexión entre los predictores sociodemográficos y el rezago municipal tiene mucho que ver con la dimensión educativa. En ese sentido el analfabetismo adulto actúa como un indicador-eje del sistema, algo coherente con lo que ya se vio en el análisis de coeficientes cuando P15YM_SE se revelaba como el predictor de mayor contribución marginal.

5.3.5. Segunda dirección canónica: contraste educación-vivienda

La segunda variable canónica tiene la forma

$$\text{CAN2} = 0.205839 \text{PCDISC_MEN} + 0.327738 \text{P15YM_AN} + 0.019384 \text{PDESOCUP} - 0.366911 \text{VPH_SNBIEN}, \quad (5.52)$$

con pesos relativos dominantes:

$$w_{\text{VPH_SNBIEN},2} = 0.398872, \quad w_{\text{P15YM_AN},2} = 0.356287. \quad (5.53)$$

CAN2 se distingue por el contraste de sus signos. Así lo demuestran P15YM_AN, que se presenta con un valor positivo de 0.327738, y VPH_SNBIEEN en negativo (-0.366911). La segunda dirección va a por esa asociación residual en la que analfabetismo y falta de bienes no van de la mano, sino en direcciones contrarias. En el mapa de México este componente es el que da cuenta de la heterogeneidad municipal cuando lo educativo y lo habitacional no están del todo en sintonía, como puede ocurrir en un municipio con menos analfabetas pero con carencias materiales, o al revés.

5.3.6. Tercera dirección canónica: eje cognitivo

La tercera variable canónica tiene la forma

$$\text{CAN3} = -0.869525 \text{PCDISC_MEN} + 0.087898 \text{P15YM_AN} + 0.076632 \text{PDESOCUP} - 0.049312 \text{VPH_SNBIEEN}, \quad (5.54)$$

con pesos relativos altamente concentrados:

$$w_{\text{PCDISC_MEN},3} = 0.802614, \quad (5.55)$$

$$w_{\text{P15YM_AN},3} = 0.081134, \quad w_{\text{PDESOCUP},3} = 0.070735, \quad w_{\text{VPH_SNBIEEN},3} = 0.045517. \quad (5.56)$$

Más del 80 % del peso recae en PCDISC_MEN; las tres respuestas restantes aportan en conjunto menos del 20 %. La correlación canónica $\rho_3 = 0.4156$ es moderada pero estadísticamente real, y el componente absorbe el 0.87 % de la asociación total. El eje cognitivo emerge en el espacio canónico y revela un hallazgo que escapa al análisis univariado, PCDISC_MEN, la respuesta peor explicada por el ajuste marginal ($R^2_{\text{PCDISC_MEN}} = 0.225$), domina un eje canónico propio. Aunque las covariables sociodemográficas no expliquen bien la magnitud media de la limitación cognitiva municipal, el sistema multivariado sí identifica una dirección donde la variación residual de PCDISC_MEN se asocia coherentemente con los predictores.

5.3.7. Cuarta dirección canónica: contraste laboral-cognitivo

La cuarta variable canónica tiene la forma

$$\text{CAN4} = -0.300174 \text{PCDISC_MEN} + 0.013811 \text{P15YM_AN} - 0.334646 \text{PDESOCUP} + 0.024407 \text{VPH_SNBIEEN}, \quad (5.57)$$

con pesos repartidos entre dos respuestas:

$$w_{\text{PDESOCUP},4} = 0.497217, \quad w_{\text{PCDISC_MEN},4} = 0.445999. \quad (5.58)$$

Casi el 95 % del peso se concentra en PDESOCUP y PCDISC_MEN, ambos con coeficiente negativo. La correlación canónica $\rho_4 = 0.2644$ es la más débil del bloque y la dimensión absorbe únicamente el 0.31 % de la asociación total, por lo que su interpretación es secundaria. No obstante, el patrón conjunto de signos negativos en las dos respuestas peor ajustadas por el modelo lineal sugiere una lectura sustantiva, en municipios donde la actividad económica informal o de autoconsumo subreporta sistemáticamente la desocupación medida, es decir, la población económicamente activa se contrae a la fuerza laboral monetarizada y, simultáneamente, el acceso reducido a servicios de salud limita el diagnóstico formal de limitaciones cognitivas, ambos indicadores se mueven a la baja por un mismo mecanismo estructural de medición del Censo. El eje recoge así un componente residual desglosado que las covariables disponibles no logran explicar marginalmente.

5.3.8. Representación geométrica del espacio canónico

Las proyecciones de los municipios sobre el subespacio que generan las variables canónicas permite leer geoméricamente la organización del rezago.




Figura 5.3: Distribución de los municipios en el subespacio tridimensional definido por las tres primeras variables canónicas. La dispersión se concentra de manera marcada a lo largo de CAN1.




Figura 5.4: Proyecciones bidimensionales de los municipios sobre los planos canónicos. La dispersión a lo largo de CAN1 es notoriamente mayor que en las direcciones secundarias.

Ambas figuras no hacen más que reforzarlo el espacio canónico, la mayor parte de la variabilidad municipal se agrupa en una única dirección, esa concentración geométrica viene a confirmar de que el rezago en los municipios mexicanos, un fenómeno que por su propia naturaleza es multidimensional, puede leerse de forma sintética siguiendo un eje principal vinculado a la educación. Las otras direcciones son de utilidad, pero resultan marginales si se comparan con CAN1 [1].

5.4. Diagnóstico del modelo y evaluación de supuestos

Los supuestos sobre los residuos faltan por verificar y antes de cerrar la lectura sustantiva, se evalúa empíricamente normalidad multivariada, homocedasticidad, independencia y ausencia de observaciones que dominen indebidamente la estimación, el diagnóstico se ejecutó sobre $\hat{U}$ y $\hat{\Sigma}$.

5.4.1. Normalidad multivariada de los residuos

El modelo postula que las filas del término de error siguen una distribución normal multivariada con matriz de covarianzas común. Sobre los residuos estimados, el juego de hipótesis es

$$H_0 : u_i \sim N_p(0, \Sigma), \quad i = 1, \dots, n \quad \text{contra} \quad H_1 : u_i \not\sim N_p(0, \Sigma).$$

Los coeficientes de Mardia [12] permiten construir dos contrastes asintóticos:

- **Asimetría multivariada:** bajo H_0 , el estadístico $n b_{1,p}/6$ sigue asintóticamente una distribución χ^2 con $\nu = p(p+1)(p+2)/6$ grados de libertad. Con $p = 4$, $\nu = 20$. La región de rechazo al nivel α es

$$\mathcal{R}_\alpha^{\text{asim}} = \{ n b_{1,p}/6 > \chi_{20, 1-\alpha}^2 \}.$$

- **Curtosis multivariada:** bajo H_0 , el estadístico

$$Z_{2,p} = \frac{b_{2,p} - p(p+2)}{\sqrt{8p(p+2)/n}}$$

sigue asintóticamente una distribución $N(0, 1)$. La región de rechazo bilateral al nivel α es

$$\mathcal{R}_\alpha^{\text{curt}} = \{ |Z_{2,p}| > z_{1-\alpha/2} \}.$$

En la Tabla 5.7 se dan los valores observados, los cuales superan los umbrales habituales para un $\alpha = 0.05$. Hay que hacer hincapié en la función de este diagnóstico no se trata de una prueba global sobre el modelo de regresión, sino de comprobar el supuesto distribucional de los residuos. Que se rechace no desvirtúa la estimación de $\hat{B}$, que se mantiene insesgada, pero sí debe hacernos dudar de la exactitud finita de los p -valores asintóticos (en particular los de Wilks y Hotelling–Lawley). En tales casos, lo más sensato es inclinarse por una interpretación sustantiva con Pillai, dada su conocida robustez ante cualquier desviación de la normalidad [10].

Tabla 5.7: Pruebas de normalidad multivariada de Mardia sobre los residuos.

Componente	Estadístico	Valor	gl	p -valor
Asimetría multivariada $b_{1,p}$	descriptivo	5.4096	—	—
Curtosis multivariada $b_{2,p}$	descriptivo	54.0395	—	—
χ^2 para asimetría	$n b_{1,p}/6$	2226.0326	20	< 0.0001
Z para curtosis	$(b_{2,p} - p(p+2))/\sqrt{8p(p+2)/n}$	107.7217	—	< 0.0001

Nota: Bajo normalidad multivariada $E(b_{2,p}) = p(p+2) = 24$ para $p = 4$; el valor observado $b_{2,p} = 54.04$ indica colas pesadas respecto a la normal.

La Tabla 5.7 exhibe de manera clara la significancia de la no normalidad. La distancia de Mahalanobis residual al cuadrado, que bajo normalidad debería seguir aproximadamente una χ_p^2 , se contrastó con los umbrales:

$$\chi_{4,0.975}^2 = 11.143287, \quad \chi_{4,0.990}^2 = 13.276704. \quad (5.59)$$

La cantidad de municipios que rebasa estos umbrales es de 184 y 134 respectivamente, un patrón que confirma la presencia de colas pesadas en la distribución residual.

Con el Q-Q plot la separación queda de manifiesto. Si se observa la Figura 5.5 se aprecia la divergencia de la distribución empírica con respecto a la teórica, en particular en los cuantiles de arriba. De fondo, una lectura más sustantiva nos lleva a un conjunto de municipios que no siguen el patrón habitual del resto por sus combinaciones de respuestas; son perfiles de un rezago extremo, como se vera enseguida.




Figura 5.5: Gráfico Q-Q de la distancia de Mahalanobis residual contra la distribución χ_4^2 de referencia.

5.4.2. Estructura residual y diagnóstico de heterocedasticidad

La homocedasticidad se examinó de dos formas, con los residuos estandarizados frente a los valores ajustados y se aplicó una versión multivariada del diagnóstico tipo White [13, 19].




Figura 5.6: Residuos estandarizados frente a valores ajustados, por variable respuesta.

Tabla 5.8: Diagnóstico auxiliar de heterocedasticidad multivariada (extensión tipo White sobre $\text{vech}(u_i u_i')$).

Estadístico auxiliar	Valor calculado
Lambda de Wilks	0.2898085
Traza de Pillai	1.120100
F_{Wilks}	4.86614 ($p < 0.0001$)
F_{Pillai}	4.66325 ($p < 0.0001$)

Observación 5.4. Conviene aclarar que este procedimiento es un diagnóstico auxiliar tipo White aplicado sobre $\text{vech}(u_i u_i')$, no la prueba clásica univariada de White. Es útil como evidencia complementaria de heterogeneidad en la dispersión, pero no debe presentarse como un test formal estándar.

Como se ve en la inspección visual y el diagnóstico auxiliar no hay una dispersión uniforme de los residuos en el rango de valores que hemos ajustado: el modelo da un resultado más certero en aquellos municipios cuyo perfil se aproxima a la media, pero pierde precisión en los extremos, algo

que tiene su razón de ser en la propia estructura empírica del fenómeno. En México el rezago no se reparte por igual entre las regiones, de modo que un municipio con fuertes privaciones tendrá una variabilidad residual mayor que uno urbano bien asentado. Al fin y al cabo, la heterogeneidad geográfica de un municipio a otro es lo que provoca esa variabilidad residual inconstante, rompiendo con el supuesto de homocedasticidad.

El presente trabajo no implementa una matriz de covarianzas robusta tipo Huber–White (sandwich) para el estimador vectorizado $\text{vec}(\hat{B})$. Esta extensión es natural dada la heterocedasticidad detectada y queda señalada como línea futura en el Capítulo de Conclusiones. La fórmula MCO de $\hat{B}$ no cambia y, bajo exogeneidad adecuada $\mathbb{E}(U | X) = 0$, la heterocedasticidad no elimina su insesgamiento; sí altera la covarianza de $\text{vec}(\hat{B})$, los errores estándar y la calibración de intervalos y pruebas. La robustez comparativa de Pillai ante desviaciones moderadas [10] no sustituye esa corrección, por lo que los p -valores reportados se interpretan como aproximaciones y no como resultados exactos bajo homocedasticidad.

5.4.3. Correlación residual remanente

La matriz de correlaciones residuales conserva dependencia aun después del ajuste, persisten asociaciones moderadas entre algunas respuestas:

$$\text{corr}(\hat{u}_{\text{P15YM_AN}}, \hat{u}_{\text{VPH_SNBIEN}}) \approx 0.306, \quad (5.60)$$

$$\text{corr}(\hat{u}_{\text{PCDISC_MEN}}, \hat{u}_{\text{P15YM_AN}}) \approx 0.272. \quad (5.61)$$

Las cuatro correlaciones residuales restantes son menores pero informativas:

$$\text{corr}(\hat{u}_{\text{PCDISC_MEN}}, \hat{u}_{\text{VPH_SNBIEN}}) \approx 0.193, \quad \text{corr}(\hat{u}_{\text{PDESOCUP}}, \hat{u}_{\text{VPH_SNBIEN}}) \approx 0.107, \quad (5.62)$$

$$\text{corr}(\hat{u}_{\text{PCDISC_MEN}}, \hat{u}_{\text{PDESOCUP}}) \approx -0.098, \quad \text{corr}(\hat{u}_{\text{P15YM_AN}}, \hat{u}_{\text{PDESOCUP}}) \approx -0.061. \quad (5.63)$$

Lo que muestran estos valores es que, una vez controlados los predictores, persisten unas asociaciones de nivel intermedio entre las respuestas. El patrón es bastante convincente, la dimensión laboral (PDESOCUP) se aparta en parte del resto del bloque al dar números negativos con educación y salud funcional, a la par que una ligera relación positiva con la vivienda. Las otras tres, por su parte, covarían positivamente entre sí. Y es precisamente esa covarianza residual lo que vuelve a justificar el modelo multivariado, de lo contrario, de haber optado por hacer regresiones univariadas de forma independiente, se habría perdido esa información estructural.

5.4.4. Observaciones influyentes y geometría del espacio explicativo

El peso de cada municipio cierra el diagnóstico y posteriormente se evalúa la influencia individual sobre la estimación mediante el leverage h_{ii} y la distancia de Cook multivariada.




Figura 5.7: Leverage frente a la distancia de Mahalanobis sobre la matriz de covariables X .




Figura 5.8: Distancia de Cook multivariada frente al leverage. Los puntos más altos corresponden a municipios con perfiles extremos.

Para el leverage se han puesto como umbrales $2q/n = 0.008910$ y $3q/n = 0.013366$, mientras que la distancia de Cook se ha fijado en $4/n = 0.001620$. Al realizar las operaciones, nos encontramos con 226 municipios de alto leverage y 1,226 superando el umbral de Cook. Hay casos extremos que llaman la atención, como Cochoapa el Grande o San Simón Zahuatlán (de Guerrero y Oaxaca

respectivamente), que se quedan en las colas del análisis. No es únicamente un resultado estadístico, sino la realidad geográfica del rezago en México, un puñado de municipios que arrastra carencias muy por encima de la media nacional, algo que ya se sabe dado su historial de marginación.




Figura 5.9: Distancia de Mahalanobis residual frente al leverage.

Para la robustez hay que hacer un análisis de sensibilidad donde tomamos el umbral de costumbre $D_{Cook} > 4/n = 0.00162$ (Bollen y Jackman [26]), como se vio, con 1,226 municipios la distancia de Cook supera el límite, o sea, la mitad de la base. Esa cifra tiene que ver con la geografía del rezago en México, que deja una cola de municipios con perfiles poco habituales en relación al centroide multivariado lo cual es algo que coincide con lo que se ha escrito sobre la concentración del rezago en Oaxaca, Guerrero y Chiapas en la literatura del CONEVAL [20].

Una vez reestimado el modelo con los 1,243 municipios que quedan, los estadísticos de ajuste varían de la siguiente manera: el R_{tr}^2 se eleva de 0.7696 a 0.8553 ($|\Delta R_{tr}^2| = 0.0857$), el Λ de Wilks baja de 0.01489 a 0.00767 y la traza de Pillai de 1.7453 a 1.8790. La asociación global se conserva, aunque las magnitudes puntuales de $\hat{B}$ y $\hat{\Sigma}$ cambian. Este módulo no recalcula las pruebas parciales ni las direcciones canónicas en la submuestra y, por tanto, no se usa para sostener la estabilidad de sus jerarquías.

5.4.5. Evaluación integrada del diagnóstico

Observación 5.5 (Validez asintótica del modelo). La persistencia del rechazo global al dejar fuera de la base a casi la mitad de las observaciones respalda únicamente la existencia de asociación conjunta en ambas muestras. No hay que interpretar el aumento del R_{tr}^2 como una ventaja: es un efecto mecánico de retirar observaciones con peor ajuste. La significancia parcial corregida de POB_AFR0 y la estructura canónica corresponden al modelo completo de 2,469 municipios; el análisis de sensibilidad implementado no autoriza a extenderlas a la submuestra.

En cuanto a los detalles:

1. Con $n = 2,469$ el tamaño de la muestra es más que suficiente para las aproximaciones asintóticas de los estadísticos multivariados, la traza de Pillai entre ellos.
2. Las desviaciones de la normalidad están debidamente documentadas y no muestran un patrón sistemático en todo el rango.

3. Hay que tener en cuenta como limitación que el ajuste global varía de forma notable si se apartan los municipios de mayor influencia, tal como revela el análisis de sensibilidad.

El diagnóstico se resume en cinco puntos:

- Se rechaza la normalidad multivariada de los residuos.
- Hay evidencia de heterocedasticidad estadísticamente significativa entre municipios.
- Persiste correlación residual moderada entre algunas respuestas.
- No se detectan curvaturas sistemáticas que comprometan la forma lineal del modelo.
- Existen municipios con alta influencia local que afectan la magnitud del ajuste global, pero no alteran las conclusiones cualitativas.

Los resultados son asociación cruzada, no causalidad. Tomados en conjunto, los hallazgos deben interpretarse como evidencia de asociación cruzada entre dimensiones del rezago a escala municipal y no como inferencia causal estricta, bajo ese encuadre, la traza de Pillai funciona como el estadístico más robusto del bloque, ya que su comportamiento es relativamente insensible a desviaciones moderadas de normalidad y homocedasticidad [10]. Los datos del Censo 2020 no se ajustan al ideal teórico de un modelo lineal con errores gaussianos perfectos, pero sí ofrecen una base lo bastante rica como para identificar, mediante el modelo multivariado, la estructura conjunta de las carencias municipales en México.

Capítulo 6

Conclusiones

6.1. Síntesis de hallazgos

Esta investigación especificó, programó y estimó un modelo de regresión lineal multivariada para analizar el rezago social a escala municipal en México con datos del Censo de Población y Vivienda 2020. El modelo relaciona cuatro variables respuesta (rezago educativo, carencias de vivienda, desocupación y limitaciones funcionales) con diez covariables sociodemográficas sobre los 2,469 municipios del censo.

El ajuste global fue relevante, con un coeficiente $R_{tr}^2 = 0.770$. Wilks, Pillai y Hotelling–Lawley rechazan la hipótesis nula global y confirman que las covariables capturan una proporción sustancial de la variabilidad conjunta; la raíz mayor de Roy se conserva como descriptor de la concentración espectral, sin decisión autónoma cuando $s > 1$. El primer vector canónico concentra el 93.8 % de la asociación, con el analfabetismo adulto como variable dominante. Esta concentración no indica un sistema unidimensional: refleja una dirección de máxima covarianza compartida entre las cuatro respuestas, que cuatro regresiones univariadas independientes no consideran al no compartir matriz residual.

El ajuste es heterogéneo entre respuestas dado que en educación ($R^2 = 0.955$) y vivienda ($R^2 = 0.804$) presentan ajustes elevados; la desocupación ($R^2 = 0.100$) queda muy por debajo. Las covariables P15YM_SE y VPH_PISOTI son las de mayor contribución marginal al ajuste conjunto. Esta asimetría es coherente con la heterogeneidad estructural del rezago social y con la distribución territorial de la marginación en el país.

6.2. Aportaciones del estudio

La contribución central es la integración rigurosa entre teoría estadística, implementación computacional y análisis empírico. La marginación municipal se modeló como un sistema de variables aleatorias correlacionadas, evitando dos limitaciones frecuentes en el análisis aplicado como comprimir la información en un índice escalar o estimar regresiones univariadas de forma independiente. De este planteamiento se derivan tres aportaciones concretas.

1. **Aplicación del marco teórico multivariado:** La inferencia sobre cada variable respuesta incorpora algebraicamente su covarianza cruzada con las demás dimensiones, a diferencia del ajuste univariado que la descarta por construcción.
2. **Implementación computacional transparente:** La programación explícita en Python garantiza correspondencia estricta entre la estimación MCO, las pruebas de hipótesis, la evaluación residual y los fundamentos algebraicos, incluyendo las matrices SSCP, con total reproducibilidad.

3. **Identificación del componente principal:** El análisis espectral muestra que el rezago educativo, específicamente el analfabetismo adulto, es la variable que mayor peso tiene en la covarianza conjunta entre municipios.

6.3. Limitaciones y consideraciones diagnósticas

El análisis residual evidencia incumplimientos parciales de los supuestos. La normalidad multivariada y la homocedasticidad son rechazadas; la dispersión residual varía según el perfil sociodemográfico del municipio. La inferencia se sostiene mediante la robustez asintótica de la traza de Pillai [10].

Los coeficientes expresan asociaciones ecológicas entre agregados municipales y no admiten lectura sobre individuos u hogares. Cualquier extrapolación hacia microcomportamientos incurre en la falacia ecológica, el alcance del modelo es estrictamente territorial.

El análisis de sensibilidad aplicó el umbral $D_{\text{Cook}} > 4/n = 0.00162$, resultando en la exclusión de 1,226 municipios (49.7 % de la base). Bajo esta exclusión, Λ de Wilks pasa de 0.015 a 0.008, la traza de Pillai de 1.745 a 1.879 y el R_{tr}^2 de 0.770 a 0.855 ($|\Delta R_{tr}^2| = 0.086$). El incremento refleja la eliminación de perfiles de rezago extremo, concentrados en municipios de Oaxaca, Guerrero y Chiapas, no una mejora intrínseca del modelo. La asociación global se conserva en ambas muestras, pero las cifras puntuales de los coeficientes dependen de la muestra utilizada. Como el módulo no recalcula pruebas parciales ni direcciones canónicas, no se extienden a la submuestra sus jerarquías inferencial y canónica. La magnitud de la exclusión debe reportarse como limitación.

6.4. Recomendaciones para investigaciones futuras

Se identifican cuatro extensiones naturales del trabajo, en primera instancia, la más prometedora es la regresión espacial multivariada ya que la heterocedasticidad documentada y la concentración geográfica del rezago en Guerrero y Oaxaca sugieren autocorrelación territorial en la matriz de covarianzas residuales que una matriz de pesos espaciales podría absorber.

La incorporación de datos longitudinales (ENOE, DENUe) mejoraría el ajuste sobre PDESOCUP, cuyo $R^2 = 0.100$ refleja una dinámica laboral que un corte transversal no captura. Modelos de variables latentes, análisis factorial confirmatorio o ecuaciones estructurales, permitirían condensar las dimensiones observables en un factor de vulnerabilidad sociodemográfica, aprovechando la concentración del 93.8 % en CAN1.

Una cuarta extensión es construir una matriz de covarianzas robusta tipo Huber–White para el estimador vectorizado. Conceptualmente, una versión HC0 multivariada adopta la forma sandwich


$$\widehat{\text{Cov}}(\text{vec } \widehat{B}) = A^{-1} \left[\sum_{i=1}^n (\widehat{u}_i \widehat{u}_i') \otimes (x_i x_i') \right] A^{-1}, \quad A = I_p \otimes (X'X),$$

con x_i como vector de diseño y $\widehat{u}_i$ como residual multivariado de la observación i [13, 19]. Bajo heterocedasticidad, el término central no se reduce en general a un único producto de Kronecker. Esta corrección no modifica la fórmula ni los valores puntuales de MCO; bajo $E(U | X) = 0$, tampoco cambia su propiedad de insesgamiento. Su efecto recae en la covarianza estimada de $\text{vec}(\widehat{B})$, los errores estándar y la calibración de intervalos y pruebas. Las tres extensiones restantes complementan el ajuste actual sin invalidarlo, todas parten de la estimación paramétrica y la matriz de datos estructurada en este trabajo.

Apéndice A

Acceso al código fuente

El notebook con la implementación matricial completa, las funciones auxiliares definidas para el modelo multivariado y todos los resultados numéricos discutidos en el Capítulo 5 están disponibles públicamente en el siguiente repositorio:



<https://github.com/israelcervantes31416/regresion-multivariada-censo2020>

El repositorio contiene:

- Notebook con 18 celdas ejecutables (Python + NumPy), correspondientes a las etapas descritas en el Capítulo 3: carga y depuración del archivo ITER, construcción de tasas y proporciones, transformación por raíz cuadrada, estimación MCO multivariada, descomposición SSCP, pruebas globales y parciales, diagnóstico residual, análisis de sensibilidad y análisis canónico.
- Instrucciones para obtener el archivo `datos.csv` directamente desde el Censo de Población y Vivienda 2020 del INEGI.
- Archivo `requirements.txt` con la lista mínima de dependencias del entorno Python.
- Documentación de uso, reproducibilidad y citación del trabajo.

Toda la estimación reportada en este documento se reproduce con la semilla fija `SEED = 2026` y el nivel de significancia `ALPHA = 0.05`. El compromiso de transparencia computacional permite que cualquier lector audite, paso a paso, la correspondencia entre la formulación matricial del Capítulo 2 y los valores empíricos del Capítulo 5.

Bibliografía

- [1] A. C. Rencher, *Methods of Multivariate Analysis*, 2nd ed. New York, NY, USA: John Wiley & Sons, 2002.
- [2] Instituto Nacional de Estadística y Geografía, “Censo de Población y Vivienda (CPV) 2020,” 2020, consultado el 13 de mayo de 2026. [Online]. Available: <https://www.inegi.org.mx/programas/ccpv/2020/>
- [3] R. A. Johnson and D. W. Wichern, *Applied Multivariate Statistical Analysis*, 6th ed. Upper Saddle River, NJ, USA: Pearson Prentice Hall, 2007.
- [4] K. V. Mardia, J. T. Kent, and J. M. Bibby, *Multivariate Analysis*. London, UK: Academic Press, 1979.
- [5] T. W. Anderson, *An Introduction to Multivariate Statistical Analysis*, 2nd ed. New York, NY, USA: John Wiley & Sons, 1984.
- [6] G. Strang, *Introduction to Linear Algebra*, 5th ed. Wellesley, MA, USA: Wellesley-Cambridge Press, 2016.
- [7] R. A. Horn and C. R. Johnson, *Matrix Analysis*, 2nd ed. Cambridge, UK: Cambridge University Press, 2013.
- [8] G. A. F. Seber, *Multivariate Observations*. Hoboken, NJ, USA: John Wiley & Sons, 2004.
- [9] H. Hotelling, “A generalized T test and measure of multivariate dispersion,” in *Proceedings of the Second Berkeley Symposium on Mathematical Statistics and Probability*, J. Neyman, Ed. Berkeley, CA, USA: University of California Press, 1951, pp. 23–42.
- [10] C. L. Olson, “On choosing a test statistic in multivariate analysis of variance,” *Psychological Bulletin*, vol. 83, no. 4, pp. 579–586, 1976.
- [11] B. G. Tabachnick and L. S. Fidell, *Using Multivariate Statistics*, 7th ed. Boston, MA, USA: Pearson, 2019.
- [12] K. V. Mardia, “Measures of multivariate skewness and kurtosis with applications,” *Biometrika*, vol. 57, no. 3, pp. 519–530, 1970.
- [13] H. White, “A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity,” *Econometrica*, vol. 48, no. 4, pp. 817–838, 1980.
- [14] D. A. Belsley, E. Kuh, and R. E. Welsch, *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. New York, NY, USA: John Wiley & Sons, 1980.
- [15] A. Hossain and D. N. Naik, “Detection of influential observations in multivariate regression,” *Journal of Applied Statistics*, vol. 16, no. 1, pp. 25–37, 1989.

- [16] D. J. Denis, *Applied Univariate, Bivariate, and Multivariate Statistics Using Python: A Beginner's Guide to Advanced Data Analysis*. Hoboken, NJ, USA: John Wiley & Sons, 2021.
- [17] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. F. del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke, and T. E. Oliphant, "Array programming with NumPy," *Nature*, vol. 585, no. 7825, pp. 357–362, 2020.
- [18] K. C. S. Pillai, "Some new test criteria in multivariate analysis," *The Annals of Mathematical Statistics*, vol. 26, no. 1, pp. 117–121, 1955.
- [19] F. Cribari-Neto, "Asymptotic inference under heteroskedasticity of unknown form," *Computational Statistics and Data Analysis*, vol. 45, no. 2, pp. 215–233, 2004.
- [20] Consejo Nacional de Evaluación de la Política de Desarrollo Social, "Índice de rezago social 2020," CONEVAL, Ciudad de México, México, Tech. Rep., 2020.
- [21] Instituto Nacional de Estadística y Geografía, "Censo de Población y Vivienda 2020: Principales resultados EUM," INEGI, Aguascalientes, México, Tech. Rep., 2021.
- [22] —, "Banco de indicadores," 2020, consultado el 13 de mayo de 2026. [Online]. Available: <https://www.inegi.org.mx/app/indicadores/>
- [23] —, "Características de las localidades 2020: Síntesis metodológica y conceptual," INEGI, Aguascalientes, México, Tech. Rep., 2021.
- [24] —, "Clasificaciones del Censo de Población y Vivienda 2020," INEGI, Aguascalientes, México, Tech. Rep., 2021.
- [25] —, "Variables Censo de Población y Vivienda 2020," INEGI, Aguascalientes, México, Tech. Rep., 2020.
- [26] K. A. Bollen and R. W. Jackman, "Regression diagnostics: An expository treatment of outliers and influential cases," *Sociological Methods and Research*, vol. 13, no. 4, pp. 510–542, 1985.