



**Facultad de Ciencias
Físico Matemáticas**

Licenciatura en
Matemáticas Aplicadas

TESIS PARA OBTENER EL TÍTULO DE
LICENCIADO EN MATEMÁTICAS APLICADAS

La regresión multivariada como marco estadístico para el análisis conjunto de indicadores socioeconómicos:

*una aplicación al Censo de Población y
Vivienda 2020*

Israel Cervantes Juárez

Director: **Dr. Bulmaro Juárez Hernández**

EXAMEN PROFESIONAL • 3 DE JULIO DE 2026

I. Problema y motivación

- ▶ Rezago multidimensional
- ▶ Pregunta de investigación

II. Datos y variables

- ▶ Base analítica
- ▶ Variables respuesta Y y diseño X
- ▶ Transformación $\sqrt{R}$

III. Modelo e inferencia

- ▶ Modelo $Y = XB + U$
- ▶ Estimación, SSCP, contraste
- ▶ Cuatro estadísticos clásicos

IV. Implementación

- ▶ Arquitectura y reproducibilidad

V. Resultados

- ▶ Ajuste global y por respuesta
- ▶ Pruebas globales y parciales
- ▶ Dependencia residual

VI–VIII. Estructura, diagnóstico y cierre

- ▶ Análisis canónico (CAN1)
- ▶ Diagnóstico, sensibilidad
- ▶ Falacia ecológica
- ▶ Conclusiones y aportación

El rezago social municipal es multidimensional

- ▶ El rezago abarca al menos cuatro dimensiones: **educativa, habitacional, laboral y salud**.
- ▶ Cada municipio se observa simultáneamente en todas ellas.
- ▶ Estas dimensiones covarían sistemáticamente en el territorio mexicano.
- ▶ Tratarlas por separado descarta información estructural relevante.



Pregunta central

¿Qué información estadística adicional se obtiene al estimar **conjuntamente** los indicadores de rezago social municipal, en lugar de analizarlos como respuestas aisladas?

Tratamiento de las respuestas	Qué conserva	Qué pierde
Índice escalar	Una lectura global del rezago.	La contribución específica de cada dimensión.
Cuatro modelos separados	La interpretación marginal de cada indicador.	La dependencia residual entre respuestas.
Modelo multivariado	La estructura conjunta de las cuatro respuestas.	Nada esencial: recupera lo que las otras pierden.

Objetivo y delimitación del alcance

Objetivo general. Especificar, implementar y estimar un modelo de regresión lineal multivariada para analizar el rezago social municipal con datos del Censo 2020.

Dentro del alcance

- ▶ Modelo lineal multivariado clásico.
- ▶ Estimación MCO multivariado.
- ▶ Inferencia conjunta y marginal.
- ▶ Diagnóstico residual completo.
- ▶ Análisis canónico.

Fuera del alcance

- ▶ Autocorrelación espacial.
- ▶ Estimación bayesiana.
- ▶ Relaciones no lineales.
- ▶ Variables latentes.
- ▶ Errores robustos Huber–White.

Alcance asociativo, no causal. Inferencia válida a nivel municipal.

- ▶ Censo de Población y Vivienda 2020 (INEGI), Principales Resultados por Localidad (ITER).
- ▶ Filtros: entidad válida, clave municipal numérica, localidad nula, total municipal.
- ▶ Reducción: 195,659 registros → 2,469 municipios y 286 columnas → 14 variables.
- ▶ Cobertura final: todos los municipios del país.

Los registros descartados son agregaciones distintas al municipio; no es pérdida de información.

Variables respuesta: cuatro dimensiones del rezago

Variable	Denominador	Dimensión	Orden
PCDISC_MEN	POBTOT	Salud funcional	1
P15YM_AN	P_15YMAS	Educación	2
PDESOCUP	PEA	Mercado laboral	3
VPH_SNBIEN	TVIVHAB	Vivienda	4

- ▶ Cada indicador es **proporción** con denominador conceptualmente apropiado.
- ▶ Transformación $\sqrt{R}$ aplicada antes del ajuste.
- ▶ **Orden matricial:** se respeta en toda la presentación.

Tablas 4.1 y 4.2

Variables explicativas: diez covariables sociodemográficas

Bloque vivienda

- ▶ VPH_PISOTI
- ▶ VPH_NDEAED
- ▶ PRO_OCUP_C (*)

Demográfico / cultural

- ▶ P3HLINHE
- ▶ PHOG_IND
- ▶ POB_AFRO
- ▶ PSIN_RELIG
- ▶ PRESOE15

Servicios / educación


- ▶ PSINDER
- ▶ P15YM_SE

(*) *PRO_OCUP_C* (promedio de ocupantes por cuarto) es un indicador directo provisto por INEGI, no se construye como proporción; sí se estandariza junto con las demás.

Todas las demás son proporciones, transformadas por $\sqrt{R}$ y estandarizadas.

Tabla 4.3 (tab:variables_independientes_aplicacion)

Transformación $\sqrt{R}$ y estandarización



Variables respuesta: conteo $\rightarrow$ proporción $\rightarrow \sqrt{R}$

Tres pasos:

- 1 Proporciones $R_{ij} = N_{ij}/D_{ij}$ verificadas en $[0, 1]$.
- 2 Transformación $R^* = \sqrt{R}$.
- 3 Estandarización solo en X :
 $Z_{ij} = (X_{ij} - \bar{X}_{.j})/s_j$ (Y conserva escala interpretable).

$\sqrt{R}$ porque:

- ▶ Estabiliza varianza, reduce asimetría.
- ▶ Sin tratar ceros (vs. *logit*).
- ▶ Exponente único para Y (vs. *Box-Cox*).
- ▶ Recomendación clásica (Tabachnick).

Figura 4.2 (*fig:hist_transformaciones_1*)

$$Y = XB + U$$

Dimensiones aplicadas:

- ▶ $Y \in \mathbb{R}^{2469 \times 4}$ — respuestas
- ▶ $X \in \mathbb{R}^{2469 \times 11}$ — diseño
- ▶ $B \in \mathbb{R}^{11 \times 4}$ — parámetros
- ▶ $U \in \mathbb{R}^{2469 \times 4}$ — errores

Lectura por fila / columna:

- ▶ Fila de Y : un municipio observado en 4 dimensiones.
- ▶ Columna de Y : una dimensión del rezago.
- ▶ U es **matriz**, no vector: Σ residual modelable.

Supuestos del modelo

- 1 $\mathbb{E}(U) = 0$.
- 2 Filas de U independientes con covarianza común Σ : $\text{Cov}(\text{vec } U) = \Sigma \otimes I_n$ (independencia entre municipios, dependencia entre respuestas).
- 3 $U \sim \mathcal{MN}_{n,p}(0, I_n, \Sigma)$ — normalidad matricial (requerida para inferencia exacta).
- 4 $\text{rango}(X) = 11$ — rango completo.

Verificación empírica

Número de condición de X : $\kappa(X) = 4.5485$ — **descarta colinealidad severa**.

La independencia entre municipios es un supuesto del modelo clásico; la autocorrelación espacial no se modela en este trabajo.

Función objetivo (cuadrática estrictamente convexa):

$$\hat{B} = \arg \min_{B \in \mathbb{R}^{q \times p}} \|Y - XB\|_F^2.$$

Condición de primer orden — ecuaciones normales:

$$X'XB = X'Y.$$

Solución cerrada (única bajo rango completo):

$$\hat{B} = (X'X)^{-1}X'Y$$

- ▶ Insesgado: $\mathbb{E}(\hat{B}) = B$.
- ▶ Gauss–Markov multivariado: mejor estimador lineal insesgado.
- ▶ Covarianza: $\text{Cov}(\text{vec } \hat{B}) = \Sigma \otimes (X'X)^{-1}$.

$$T = H + E$$

$$T = (Y - \bar{Y})(Y - \bar{Y})'$$

variación total centrada

$$H = T - E$$

variación explicada

$$E = \hat{U}'\hat{U}$$

variación residual

Diferencia con el caso univariado

T , H , E son matrices $p \times p$ — no escalares. Conservan toda la información sobre covarianzas cruzadas entre respuestas. Toda la inferencia conjunta se construye sobre ellas.

Contraste global del modelo: $H_0 : CB = 0$

Objeto del contraste: la matriz de coeficientes B , no las respuestas aisladas.

$$H_0 : CB = 0 \quad \text{vs.} \quad H_1 : CB \neq 0$$

donde $C \in \mathbb{R}^{10 \times 11}$ elimina la fila del intercepto:

$$C = (0_{10 \times 1} \quad I_{10}) .$$

$$q_h = \text{rango}(C) = 10.$$

Lectura

- ▶ Bajo H_0 : ningún predictor aporta información lineal conjunta sobre el vector de respuestas, fijado el nivel medio por el intercepto.
- ▶ Bajo H_1 : al menos un predictor afecta linealmente alguna dimensión o combinación lineal de las respuestas.
- ▶ **C excluye el intercepto:** probar también el intercepto sería contrastar que la media de Y es cero, lo cual no forma parte del contraste de significancia del modelo.

Inferencia conjunta: cuatro estadísticos, un mismo espectro

Base distribucional (bajo H_0): $H \sim \mathcal{W}_p(q_h, \Sigma)$, $E \sim \mathcal{W}_p(n - q, \Sigma)$ independientes. **Problema espectral:**

$$|H - \lambda E| = 0, \quad \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_s.$$

$$\Lambda_{\text{Wilks}} = \frac{|E|}{|H + E|} = \prod_{i=1}^s \frac{1}{1 + \lambda_i}$$


$$T_{HL} = \text{tr}(E^{-1}H) = \sum_{i=1}^s \lambda_i$$

$$V_{\text{Pillai}} = \text{tr}[H(H + E)^{-1}] = \sum_{i=1}^s \frac{\lambda_i}{1 + \lambda_i}$$

$$\theta_{\text{Roy}} = \lambda_{\text{máx}}$$

- ▶ Mismo insumo espectral $\{\lambda_i\}_{i=1}^s$, cuatro lecturas distintas del mismo H_0 : $CB = 0$.
- ▶ Wilks, Pillai y Hotelling–Lawley sustentan la decisión; Roy es descriptivo cuando $s > 1$ porque su F usual es solo una cota superior.
- ▶ **Pillai** suele ser el criterio más estable frente a desviaciones moderadas de los supuestos (Olson, 1976).

Implementación: arquitectura, algoritmos y reproducibilidad



- ▶ **Tres algoritmos en NumPy (álgebra explícita):** MCO y SSCP ($\hat{B}, \hat{\Sigma}, T, H, E$); inferencia vía un problema generalizado simétrico; pruebas tipo III con H_j directa y verificación $H_j = E_{(-j)} - E$.
- ▶ **Correspondencia teoría-cómputo:** verificación numérica $\max |T - (H + E)| < 10^{-8}$; `scipy.stats` solo para cuantiles F y χ^2 .
- ▶ **Grados de libertad:** $q_h = \text{rango}(C)$ se pasa explícitamente; no se infiere de $\text{rango}_{\text{num}}(H)$.
- ▶ **Reproducibilidad:** semilla fija SEED=2026 y repositorio público (apéndice).

Figura 3.1 de la tesis (fig:arquitectura)

Ajuste global: descomposición de la traza

84.84

$\text{tr}(T)$ variación total

65.30

$\text{tr}(H)$ variación explicada

19.55

$\text{tr}(E)$ variación residual

0.7696

R_{tr}^2 ajuste global

$$R_{\text{tr}}^2 = \frac{\text{tr}(H)}{\text{tr}(T)} = \frac{65.295095}{84.841360} = 0.7696$$

Precisiones:

- ▶ **No** es el promedio de los R_j^2 .
- ▶ Es cociente de trazas $\Rightarrow$ promedio ponderado por t_{jj} .
- ▶ Promedio aritmético de los R_j^2 : ≈ 0.521 vs. $R_{\text{tr}}^2 = 0.7696$.
- ▶ Dominado por las respuestas con mayor varianza total: P15YM_AN y VPH_SNBIEN.
- ▶ **Es descriptivo**, no un estadístico contrastable: la evidencia formal son los cuatro criterios multivariados.

Tabla 5.2 (tab:ajuste_global_resumen)

Ajuste por respuesta: asimetría interna del sistema

0.2252 PCDISC_MEN	0.9549 P15YM_AN	0.1000 PDESOCUP	0.8040 VPH_SNBIEN
----------------------	--------------------	--------------------	----------------------

R_j^2 por respuesta — orden matricial: salud funcional, educación, mercado laboral, vivienda.

- ▶ Educación y vivienda muy ajustadas; salud funcional y desocupación bajas.
- ▶ La asimetría refleja qué tan directamente observa el Censo cada dimensión.
- ▶ PDESOCUP: informalidad, autoempleo agrícola y migración estacional escapan al corte transversal.
- ▶ PCDISC_MEN: depende de factores etarios y clínicos no presentes en X .

Tabla 5.1 (tab:r2_por_respuesta)

Evidencia global contra $H_0 : CB = 0$

Hipótesis: $H_0 : CB = 0$ vs. $H_1 : CB \neq 0$, con $C \in \mathbb{R}^{10 \times 11}$.

Nivel: $\alpha = 0.05$.

0.0149

Λ_{Wilks}

1.7453

V_{Pillai}

23.98

T_{HL}

22.50

θ_{Roy}

Prueba	F/F_{ref}	ν_1	ν_2
Wilks	473.18	40	9310.93
Pillai	190.26	40	9832
Hotelling–Lawley	1471.23	40	6861.77
Roy ^a	5505.97	10	2447

$p < 0.0001$ en Wilks, Pillai y Hotelling–Lawley.

^aRoy: cota superior F_{ref} , sin p -valor ni decisión.

- ▶ Wilks, Pillai y Hotelling–Lawley exceden sus referencias y coinciden en **rechazar** H_0 .
- ▶ $\theta_{\text{Roy}} = 22.50$ describe concentración en la primera raíz; su cota no decide el contraste.
- ▶ Lo que se establece es **asociación estadística** entre agregados municipales, no causalidad.

Tabla 5.3

Dependencia residual: la covarianza que sobrevive al ajuste

Tras controlar las diez covariables, los residuos de las respuestas **siguen correlacionados**:

Par de respuestas (residuos $\hat{U}$)	corr
P15YM_AN – VPH_SNBIEN (educación–vivienda)	0.306
PCDISC_MEN – P15YM_AN (funcional–educación)	0.272
PCDISC_MEN – VPH_SNBIEN	0.193
PDESOCUP – VPH_SNBIEN	0.107
PCDISC_MEN – PDESOCUP	–0.098
P15YM_AN – PDESOCUP	–0.061

- ▶ Esa covarianza residual **no es ruido**: es estructura compartida que el modelo estima en $\hat{\Sigma}$.
- ▶ Cuatro regresiones univariadas independientes la descartan **por construcción**.
- ▶ Es la justificación **empírica** del enfoque multivariado, no solo conceptual.
- ▶ Habilitan la inferencia **conjunta** (Wilks, Pillai) y el control simultáneo del error que cuatro pruebas univariadas separadas ignoran.

Resultados: correlación residual remanente

Pruebas parciales: $H_{0j} : c_j' B = 0$

Contraste por covariable ($j = 1, \dots, 10$, sin intercepto):

$$H_{0j} : c_j' B = 0_{1 \times 4} \quad \text{vs.} \quad H_{1j} : c_j' B \neq 0_{1 \times 4}$$


donde c_j es el vector que selecciona la fila del predictor j . **Operacionalización (tipo III):**

$$H_j = (c_j' \hat{B})' [c_j' (X' X)^{-1} c_j]^{-1} (c_j' \hat{B})$$

con verificación independiente $H_j = E_{(-j)} - E$ (error máximo $< 10^{-14}$).

- ▶ H_j semidefinida positiva, $q_h = \text{rango}(c_j') = 1$.
- ▶ Grados de libertad: $(p, n - q - p + 1) = (4, 2455)$.
- ▶ Región de rechazo individual: $\mathcal{R}_{0.05}^{(j)} = \{F_{\text{obs}}^{(j)} > F_{0.95}(4, 2455)\}$.
- ▶ Bajo H_{0j} : el predictor j no aporta información lineal adicional sobre Y condicionado al resto.

Jerarquía de predictores: P15YM_SE domina



Pillai parcial top:

- ▶ P15YM_SE: 0.8741
 - ▶ VPH_PISOTI: 0.2695
 - ▶ P3HLINHE: 0.1190
 - ▶ PHOG_IND: 0.1132
 - ▶ ...
 - ▶ POB_AFRO: 0.0077
- $F = 4.77$, $p_{\Lambda} = p_V = 0.0008$

POB_AFRO tiene una contribución incremental **significativa pero pequeña**. Es una asociación condicionada entre agregados municipales, no una medida de relevancia social ni un efecto causal individual.

Figura 5.1 (*fig:importancia_pillai*), Tabla 5.4 (*tab:pruebas-parciales*)

PSINDER: asociación parcial negativa e interpretación condicionada

Fila de PSINDER en $\hat{B}$:

$$\hat{\beta}_{\text{PSINDER}} = (-0.0013, -0.0028, -0.0059, -0.0166)$$

Lectura ingenua: “más no afiliados $\Rightarrow$ menos rezago” — claramente errónea.

Explicación: colinealidad sustantiva

PSINDER se correlaciona **negativamente** con todos los demás indicadores de rezago a nivel bivariado:

$$\text{corr}(\text{PSINDER}, \text{P15YM_SE}) = -0.193, \quad \text{corr}(\text{PSINDER}, \text{VPH_SNBIEN}) = -0.267$$

Artefacto plausible asociado a la estructura de afiliación del Seguro Popular: los municipios rurales marginados se afiliaron mayoritariamente al esquema universal y no a IMSS/ISSSTE. Una vez controlado por escolaridad y vivienda, el residuo informativo de PSINDER mide variación **intra-grupo**, no la asociación bivariada bruta.

Comp.	λ_i	π_i	ρ_i
CAN1	22.5009	0.9380	0.9785
CAN2	1.1988	0.0500	0.7384
CAN3	0.2087	0.0087	0.4156
CAN4	0.0752	0.0031	0.2644

93.8 %
absorbido por CAN1


$\rho_1 = 0.978$
correlación canónica

Lectura espectral:

- ▶ Caída brusca tras CAN1: $\lambda_1/\lambda_2 \approx 19$.
- ▶ La asociación compartida se concentra en una dirección (CAN1), pero el sistema *no* se reduce a un índice escalar: CAN3 revela una dimensión propia (lámina siguiente).
- ▶ Relación espectral: $\rho_i^2 = \lambda_i/(1 + \lambda_i)$.

Tablas 5.5 y 5.6

Interpretación canónica: dos hallazgos contrastados



Coeficientes canónicos absolutos por dirección

CAN1 — eje del rezago educativo

Pesos: P15YM_AN **75.87 %**, PCDISC_MEN 19.22 %, VPH_SNBIEN 3.36 %, PDESOCUP 1.55 %.

Coherencia con X: P15YM_SE domina en predictores, P15YM_AN domina en respuestas.


CAN3 — eje cognitivo emergente

Pesos: PCDISC_MEN **80.26 %**, P15YM_AN 8.11 %, PDESOCUP 7.07 %, VPH_SNBIEN 4.55 %.

*PCDISC_MEN: $R^2_{univ} = 0.225$, pero **domina su propio eje canónico** con $\rho_3 = 0.42$.*

El sistema multivariado capta una estructura que cuatro regresiones univariadas no detectarían por construcción.


Figura 5.2, Subsecciones 5.3.4 y 5.3.6 de la tesis



- Dispersión a lo largo de CAN1 notoriamente mayor que en CAN2 o CAN3.
- La geometría confirma el espectro: un eje estructura el sistema.
- Aun así, el sistema no se reduce a un índice escalar: CAN3 mantiene una dimensión propia.

Figura 5.4 (*fig:planos_canonicos*)

Diagnóstico residual: normalidad y heterocedasticidad



Q-Q de Mahalanobis al cuadrado vs. χ^2_4

Mardia (normalidad):

- ▶ Asimetría: $\chi^2 = 2226.03$, $gl = 20$, $p < 0.0001$.
- ▶ **Rechazo formal**; curtosis también alta (colas pesadas).

Heterocedasticidad (White aux.):


- ▶ $q_h = 65$; $\Lambda = 0.2898$, $V = 1.1201$, $p < 0.0001$.
- ▶ **Rechazo formal**.

Lectura inferencial:

- ▶ $\hat{B}$ conserva su fórmula y es insesgado bajo $\mathbb{E}(U | X) = 0$.
- ▶ La inferencia se apoya en Pillai, comparativamente estable ante estas desviaciones (Olson, 1976).
- ▶ Extensión estándar: errores robustos Huber–White (sandwich) para $\text{vec}(\hat{B})$.

Tablas 5.7, 5.8; Figura 5.5

Observaciones influyentes: el umbral $4/n$ y su lectura



Umbrales aplicados:

- ▶ Leverage: $2q/n = 0.0089$.
- ▶ Cook: $4/n = 0.00162$.

Conteos:

- ▶ 226 con leverage alto.
- ▶ 1226 con $\text{Cook} > 4/n$.

Interpretación:

- ▶ $4/n$ es heurístico (Bollen–Jackman), no criterio binario.
- ▶ Con $n = 2469$ marca toda la cola larga.
- ▶ Refleja geografía real del rezago (Oaxaca, Guerrero, Chiapas).
- ▶ Señala heterogeneidad territorial estructural, coherente con la geografía del rezago.

Figura 5.8 (*fig:cook_leverage*)

Análisis de sensibilidad: persiste la asociación global

Prueba de esfuerzo: se reestima el modelo *sin* los 1226 municipios de mayor distancia de Cook (49.7 %): con n grande, el umbral $4/n$ marca toda la cola peor ajustada (Oaxaca, Guerrero, Chiapas).

Métrica	Completa ($n=2469$)	Sin cola ($n=1243$)
$H_0 : CB = 0$	Rechazo	Rechazo
Λ_{Wilks}	0.01489	0.00767
V_{Pillai}	1.7453	1.8790
R_{tr}^2	0.7696	0.8553

- Lo invariante es la decisión: quitada la cola influyente, H_0 se **sigue rechazando**; la significancia global **no** la produce ese 49.7 %.
- El alza de R_{tr}^2 ($0.77 \rightarrow 0.86$) es **mecánica** ya que se excluyen los peor ajustados, **no** es una mejora del modelo ni justifica excluir municipios. El alto rezago es el objeto de estudio.
- La jerarquía de predictores y la estructura canónica descansan en los **2469 municipios**; esta prueba está dirigida a la **conclusión global**.

Principio (Robinson, 1950)

Una asociación entre tasas municipales **no implica** una asociación a nivel individual.

Qué describe este modelo:

- ▶ Variación territorial entre 2469 municipios.
- ▶ Estructura conjunta de tasas agregadas.
- ▶ Asociaciones **ecológicas**.

Qué **no** describe:

- ▶ Microcomportamientos de personas u hogares.
- ▶ Mecanismos causales individuales.
- ▶ Inferencia a nivel de la persona o vivienda.

*Ejemplo: que un municipio con más PSINDER tenga menor VPH_SNBIEN **no significa** que los individuos sin seguro habiten viviendas con más bienes. Reconocido explícitamente en la introducción (Cap. 1) y conclusiones (Cap. 6) de la tesis.*

Declaradas desde el Cap. 1

- ▶ Sin autocorrelación espacial.
- ▶ Sin estimación bayesiana.
- ▶ Sin relaciones no lineales.
- ▶ Sin variables latentes.
- ▶ Asociaciones territoriales, no causalidad.
- ▶ Falacia ecológica: no extrapolar a individuos.

Extensiones a partir del diagnóstico

- ▶ Errores robustos Huber–White (extensión inmediata).
- ▶ R^2 bajo en PDESOCUP (Censo no captura informalidad).
- ▶ Heterogeneidad territorial residual.
- ▶ Posible mejora con ENOE / DENUE longitudinal.

Las limitaciones se reconocen explícitamente como agenda de investigación futura, no como omisiones inadvertidas.

Aporte:

- ▶ Se unifican la notación, la formulación matricial y la secuencia inferencial presentes de forma dispersa en la bibliografía clásica.
- ▶ Se programan explícitamente la estimación MCO, las matrices SSCP, los contrastes multivariados, el diagnóstico residual y el análisis canónico, en un procedimiento reproducible y adaptable a otros problemas con múltiples variables respuesta.

Extensiones futuras:

- ▶ Regresión espacial multivariada para incorporar la dependencia entre municipios.
- ▶ Errores estándar robustos tipo Huber–White ante la heterocedasticidad detectada.
- ▶ Integración longitudinal de ENOE / DINUE para fortalecer la dimensión laboral.
- ▶ Estudio territorial de los municipios con alta influencia: caracterizar sus condiciones de rezago y su concentración regional, sin tratarlos como observaciones que deban excluirse automáticamente.
- ▶ Modelos de variables latentes, a partir de la estructura concentrada en la primera dirección canónica.

El rezago municipal es genuinamente multidimensional, y esa multidimensionalidad se mide **explícitamente** en la covarianza residual que sobrevive al ajuste multivariado ($r > 0.27$ entre residuos de educación y vivienda). Las regresiones univariadas independientes descartan esa estructura por construcción.

El modelo absorbe casi el 77 % de la variabilidad conjunta, con una dirección canónica dominante que concentra el 93.8 % de la asociación, organizada en torno al analfabetismo adulto y predicha principalmente por la población sin escolaridad.

La **asociación global persiste** en el análisis de sensibilidad; el alcance sigue siendo asociativo y territorial.

- ▶ Anderson, T. W. (1984). *An Introduction to Multivariate Statistical Analysis* (2.^a ed.). Wiley.
- ▶ Mardia, K. V., Kent, J. T. & Bibby, J. M. (1979). *Multivariate Analysis*. Academic Press.
- ▶ Johnson, R. A. & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6.^a ed.). Pearson.
- ▶ Rencher, A. C. (2002). *Methods of Multivariate Analysis* (2.^a ed.). Wiley.
- ▶ Seber, G. A. F. (2004). *Multivariate Observations*. Wiley.
- ▶ Mardia, K. V. (1970). Measures of multivariate skewness and kurtosis. *Biometrika*, 57(3), 519–530.
- ▶ Hotelling, H. (1951). A generalized T test and measure of multivariate dispersion. *Proc. 2nd Berkeley Symp.*, 23–41.
- ▶ Pillai, K. C. S. (1955). Some new test criteria in multivariate analysis. *Ann. Math. Stat.*, 26(1), 117–121.
- ▶ Olson, C. L. (1976). On choosing a test statistic in MANOVA. *Psychological Bulletin*, 83(4), 579–586.
- ▶ White, H. (1980). A heteroskedasticity-consistent covariance matrix estimator. *Econometrica*, 48(4), 817–838.
- ▶ Belsley, D. A., Kuh, E. & Welsch, R. E. (1980). *Regression Diagnostics*. Wiley.
- ▶ Bollen, K. A. & Jackman, R. W. (1985). Regression diagnostics: outliers and influential cases. *Sociol. Methods Res.*, 13(4), 510–542.
- ▶ Tabachnick, B. G. & Fidell, L. S. (2019). *Using Multivariate Statistics* (7.^a ed.). Pearson.
- ▶ Robinson, W. S. (1950). Ecological correlations and the behavior of individuals. *Am. Sociol. Review*, 15(3), 351–357.
- ▶ INEGI (2020). *Censo de Población y Vivienda 2020*. México.
- ▶ CONEVAL (2020). *Índice de Rezago Social 2020*. México.



Notebook completo, datos y reproducibilidad

El código fuente, las funciones auxiliares y todos los resultados numéricos del análisis están disponibles públicamente:

<https://github.com/israelcervantes31416/regresion-multivariada-censo2020>

El repositorio contiene:

- ▶ Notebook con 18 celdas ejecutables (Python)
- ▶ Instrucciones para obtener `datos.csv` de INEGI
- ▶ `requirements.txt` con dependencias mínimas
- ▶ Documentación de uso y citación

Toda la estimación se reproduce con semilla fija $SEED = 2026$.